



(12) 发明专利申请

(10) 申请公布号 CN 121658977 A

(43) 申请公布日 2026. 03. 13

(21) 申请号 202511857728.0

G06V 10/36 (2022.01)

(22) 申请日 2025.12.10

G06V 10/60 (2022.01)

(71) 申请人 西北农林科技大学

G06V 10/54 (2022.01)

地址 712100 陕西省咸阳市杨凌示范区郿城路3号

G06V 10/62 (2022.01)

G06Q 50/02 (2024.01)

(72) 发明人 史海静 李傲雪 刘洋洋 吴有福 温仲明

(74) 专利代理机构 西安铭泽知识产权代理事务所(普通合伙) 61223

专利代理师 韩晓娟

(51) Int. Cl.

G06F 18/24 (2023.01)

G06F 18/213 (2023.01)

G06V 20/10 (2022.01)

G06V 10/30 (2022.01)

权利要求书2页 说明书13页 附图11页

(54) 发明名称

一种高原作物识别方法、系统、计算机设备及存储介质

(57) 摘要

本发明提供了一种高原作物识别方法、系统、计算机设备及存储介质,属于遥感数据分析领域,包括获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据,并由光学遥感数据提取植被指数;将每月的植被指数中位数作为像元反射率,当存在像元反射率缺失时,基于相邻月线性插值得到像元反射率,基于像元反射率构建每一个月的合成影像;SG平滑滤波得到时间序列重建的植被指数;从植被指数中提取植被指数统计特征和植被指数纹理特征;分别从地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征,输入预先训练的作物分类模型中,得到高原地区的作物识别结果。该方法避免物候信息的缺失,提高了高原场景下作物识别的准确性。

获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据

根据光学遥感数据计算植被指数;将每一个月的植被指数中的中位数作为该月的像元反射率,当存在像元反射率缺失时,基于相邻月的像元反射率线性插值得到该月的像元反射率,基于像元反射率构建每一个月的合成影像;对每一个月的合成影像进行SG平滑滤波处理,得到时间序列重建的植被指数

从时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征;分别从地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征

将植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入预先训练的作物分类模型中,得到高原地区的作物识别结果

1. 一种高原作物识别方法,其特征在于,包括:

获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据;根据所述光学遥感数据计算植被指数;将每一个月的植被指数中的中位数作为该月的像元反射率,当存在像元反射率缺失时,基于相邻月的像元反射率线性插值得到该月的像元反射率,基于每一个月的所述像元反射率构建每一个月的合成影像;对所述每一个月的合成影像进行SG平滑滤波处理,得到时间序列重建的植被指数;

从所述时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征;分别从所述地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征;

将所述植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入预先训练的作物分类模型中,得到所述高原地区的作物识别结果。

2. 根据权利要求1所述的一种高原作物识别方法,其特征在于,根据所述光学遥感数据计算植被指数之前,还包括:

通过基于bit10和bit11标识的QA60波段和SCL波段对所述光学遥感数据进行气象干扰像元掩膜处理,得到气象干扰掩膜后的光学遥感数据。

3. 根据权利要求1所述的一种高原作物识别方法,其特征在于,所述植被指数包括归一化植被指数、增强型植被指数、陆地表面水指数、归一化差异干旱指数、归一化差异耕作指数和绿色冠层植被指数,从所述时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征包括:

基于作物的关键生育期筛选所述归一化植被指数、增强型植被指数、陆地表面水指数,得到归一化植被指数子集、增强型植被指数子集和陆地表面水指数子集,分别从所述归一化植被指数子集、增强型植被指数子集和陆地表面水指数子集确定关键生育期归一化植被指数均值、关键生育期增强型植被指数均值和关键生育期陆地表面水指数均值;

分别计算归一化植被指数、增强型植被指数、陆地表面水指数、归一化差异干旱指数、归一化差异耕作指数和绿色冠层植被指数的月均值、月中值、标准差和最值,由所述月均值、月中值、标准差和最值,以及关键生育期归一化植被指数均值、关键生育期增强型植被指数均值和关键生育期陆地表面水指数均值构建所述植被指数统计特征。

4. 根据权利要求1所述的一种高原作物识别方法,其特征在于,分别从所述地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征包括:

从所述地形数据提取海拔信息、坡度信息和坡向信息,由所述海拔信息、坡度信息和坡向信息构建所述地形特征;

从所述土壤数据提取表层土壤指定分类和黏土含量占比,由所述表层土壤指定分类和黏土含量占比构建所述土壤特征;

从所述气候特征提取年均气温和年累计降水量,由所述年均气温和年累计降水量构建所述气候特征。

5. 根据权利要求1所述的一种高原作物识别方法,其特征在于,所述预先训练的作物分类模型包括随机森林分类模型,输入预先训练的作物分类模型之前,还包括:

获取训练用区域的地区的光学遥感数据、地形数据、土壤数据和气候数据,并分别提取得到训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征;

将所述训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征

输入基于谷歌地球引擎平台的随机森林分类器中进行模型训练,得到所述随机森林分类模型。

6. 根据权利要求5所述的一种高原作物识别方法,其特征在于,所述预先训练的作物分类模型还包括梯度提升树分类模型,并分别提取得到训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征之后,还包括:

将所述训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入基于谷歌地球引擎平台的梯度提升树分类器中进行模型训练,得到所述梯度提升树分类模型。

7. 根据权利要求1所述的一种高原作物识别方法,其特征在于,所述预先训练的作物分类模型还包括支持向量机分类模型,并分别提取得到训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征之后,还包括:

将所述训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入基于谷歌地球引擎平台的支持向量机分类器中进行模型训练,得到所述支持向量机分类模型。

8. 一种高原作物识别系统,其特征在于,包括:

时序重建模块,用于获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据;根据所述光学遥感数据计算植被指数;将每一个月的植被指数中的中位数作为该月的像元反射率,当存在像元反射率缺失时,基于相邻月的像元反射率线性插值得到该月的像元反射率,基于每一个月的所述像元反射率构建每一个月的合成影像;对所述每一个月的合成影像进行SG平滑滤波处理,得到时间序列重建的植被指数;

特征提取模块,用于从所述时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征;分别从所述地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征;

作物分类模块,用于将所述植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入预先训练的作物分类模型中,得到所述高原地区的作物识别结果。

9. 一种计算机设备,包括存储器、处理器及存储在存储器上的计算机程序,其特征在于,所述处理器执行所述计算机程序以实现权利要求1至7任一项所述一种高原作物识别方法的步骤。

10. 一种计算机可读存储介质,其上存储有计算机程序,其特征在于,该计算机程序被处理器加载时,能够执行权利要求1至7任一项所述一种高原作物识别方法的步骤。

一种高原作物识别方法、系统、计算机设备及存储介质

技术领域

[0001] 本发明属于遥感数据分析领域,具体涉及一种高原作物识别方法、系统、计算机设备及存储介质。

背景技术

[0002] 高原高寒地区因其独特的地理与气候条件,使得大范围的农作物种植信息调查变得尤为迫切且充满挑战。该区域耕地破碎化分布显著,地形起伏与海拔梯度大,导致农业生产规模小而分散。同时,作物生长季内云雪干扰频繁,严重影响了光学遥感数据的质量与连续性。更为复杂的是,受局地微气候和地形影响,作物的物候期在空间上表现出强烈的非平稳性,即同一作物在不同地块的关键生长阶段可能存在显著差异。在此背景下,传统的依赖人力实地调查的方法,不仅需要耗费巨大的人力物力,且时效性差,难以满足对农作物空间分布进行快速、准确获取的战略需求。

[0003] 现有技术往往利用遥感技术进行高原作物的识别,将光谱特征、纹理特征以及植被指数特征应用于作物分类。但是高原地区云雪覆盖频繁,采集的遥感数据噪声严重,作物识别的准确率较低。

发明内容

[0004] 为了解决现有作物识别受高原地区云雪覆盖影响,识别准确率低的问题,本发明提供了一种高原作物识别方法、系统、计算机设备及介质。

[0005] 为了实现上述目的,本发明提供如下技术方案:

一种高原作物识别方法,包括:

获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据;根据光学遥感数据计算植被指数;将每一个月的植被指数中的中位数作为该月的像元反射率,当存在像元反射率缺失时,基于相邻月的像元反射率线性插值得到该月的像元反射率,基于每一个月的像元反射率构建每一个月的合成影像;对每一个月的合成影像进行SG平滑滤波处理,得到时间序列重建的植被指数;

从时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征;分别从地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征;

将植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入预先训练的作物分类模型中,得到高原地区的作物识别结果。

[0006] 本发明还提供一种高原作物识别系统,包括:

时序重建模块,用于获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据;根据光学遥感数据计算植被指数;将每一个月的植被指数中的中位数作为该月的像元反射率,当存在像元反射率缺失时,基于相邻月的像元反射率线性插值得到该月的像元反射率,基于每一个月的像元反射率构建每一个月的合成影像;对每一个月的合成影像进行SG平滑滤波处理,得到时间序列重建的植被指数;

特征提取模块,用于从时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征;分别从地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征;

作物分类模块,用于将植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入预先训练的作物分类模型中,得到高原地区的作物识别结果。

[0007] 本发明还提供一种计算机设备,包括存储器、处理器及存储在存储器上的计算机程序,处理器执行计算机程序以实现一种高原作物识别方法中任一项的步骤。

[0008] 本发明还提供一种计算机可读存储介质,存储介质上存储有计算机程序,该计算机程序被处理器加载时,能够执行一种高原作物识别方法中任一项的步骤。

[0009] 本发明提供的一种高原作物识别方法具有以下有益效果:

由于本发明提供的一种高原作物识别方法通过月度中值合成-邻月插值-SG平滑滤波这一数据处理流程,克服了高原地区云雪干扰带来的数据质量难题。其中,月度中值合成能够抑制瞬时噪声并获取每月最具代表性的地表反射信息,邻月插值确保了作物生长时间序列的连续性,避免了关键物候期信息的缺失,SG滤波能够在平滑噪声的同时,高保真地保留返青、抽穗、成熟等作物生长关键拐点的幅度与相位信息,进而提升了原始遥感数据的信噪比,为后续特征提取和模型分类提供了高质量、高稳健性的输入数据,避免了高原地区云雪覆盖频繁导致作物识别误差大的缺陷。

附图说明

[0010] 为了更清楚地说明本发明实施例及其设计方案,下面将对本实施例所需的附图做简单的介绍。下面描述中的附图仅仅是本发明的部分实施例,对于本领域普通技术人员来说,在不付出创造性劳动的前提下,还可以根据这些附图获得其他的附图。

[0011] 图1为本发明实施例提供的一种高原作物识别方法示意图;

图2为本发明实施例提供的高原作物分类方法流程示例;

图3为本发明实施例提供的高原区域取样示例;

图4为本发明实施例提供的无人机航飞样方示例;

图5为本发明实施例提供的采样点分布示例;

图6为本发明实施例提供的特征重要性排序示例;

图7为本发明实施例提供的特征袋外正确率排序示例;

图8为本发明实施例提供的不同特征组合方案下不同分类器的分类精度及kappa系数示例;

图9为本发明实施例提供的不同特征组合方案下不同分类器的kappa系数示例;

图10为本发明实施例提供的Kappa系数热力图示例;

图11为本发明实施例提供的不同特征组合方案分类精度评价图示例;

图12为本发明实施例提供的RF分类模型的分类结果空间分布示例;

图13为本发明实施例提供的GTB分类模型的分类结果空间分布示例;

图14为本发明实施例提供的SVM分类模型的分类结果空间分布示例。

具体实施方式

[0012] 为了使本领域技术人员更好地理解本发明的技术方案并能予以实施,下面结合附图和具体实施例对本发明进行详细说明。以下实施例仅用于更加清楚地说明本发明的技术方案,而不能以此来限制本发明的保护范围。

[0013] 实施例1

本申请提供了一种高原作物识别方法,具体如图1所示,包括以下步骤:

步骤11、获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据。

[0014] 步骤12、通过基于bit10和bit11标识的QA60波段和SCL波段对光学遥感数据进行气象干扰像元掩膜处理,得到气象干扰掩膜后的光学遥感数据。

[0015] 步骤13、根据光学遥感数据计算植被指数;将每一个月的植被指数中的中位数作为该月的像元反射率,当存在像元反射率缺失时,基于相邻月的像元反射率线性插值得到该月的像元反射率,基于像元反射率构建每一个月的合成影像;对每个月的合成影像进行SG平滑滤波处理,得到时间序列重建的植被指数。

[0016] 具体的,如图2所示,首先采集待识别作物的高原地区的地表反射率的光学遥感影像,例如获取2019年的全球耕地掩膜数据加载需要研究区域的矢量数据“.shp”,并添加年积日 (Day of year, DOY)、年 (YEAR) 时间信息,同步采集待识别作物的高原地区的地形数据、土壤数据和气候数据。

[0017] 然后,通过GEE调用Sentinel-2 L2A自带的QA60与SCL质量层,利用比特10/11及场景分类标识,对光学遥感影像逐像元剔除云、卷云、云阴影、雪和饱和像元,得到气象干扰掩膜后的光学遥感数据。其中,为了节省存储空间、提高读写效率并避免使用浮点数计算带来的潜在问题,如底表反射率等反射率数据被放大了10000倍,然后以16位无符号整数的形式存储,在后续读取像素值时,通过根据放大系数对应的缩放因子,例如0.0001逆运算进行标准化处理。

[0018] 之后,将气象干扰掩膜后的光学遥感数据初步计算得到植被指数。之后,将这些植被指数按照月份分类,并将每个月份的中位数作为该月的像元反射率,生成每个月的月度合成影像。其中,存在部分月份受气候影响存在数据缺失时,基于相邻月的数据线性插值进行数值估计与填充。之后,用Savitzky-Golay (SG) 平滑滤波算法对每个月的月度合成影像进行时间序列优化及进一步线性差值填充数据,得到时间序列重建的植被指数。

[0019] 举例来说,以月为单位对 NDVI、EVI、LSWI、NDSVI、NDTI、GCVI 六类植被与干湿度指数计算中位值 (median),生成全年 12 期的初始合成序列,并且针对高原地区常见的数据缺失与季节性云量干扰问题,在返青、拔节、灌浆期等作物关键生长期对缺测月份采用邻近月份的线性插值进行填补,从而构建时间上连续的指数序列。在此基础上,引入Savitzky-Golay (SG) 平滑滤波算法对各指数序列进行曲线重建。具体采用 7 点窗口、2 阶多项式拟合,并在序列边界引入夹紧约束以稳定首尾趋势,从而在有效抑制云雾残留与观测误差影响的同时,保留植被指数的关键物候起伏特征。重建后的指数曲线不仅显著改善了原始时序中的不规则跳变问题,也为后续物候窗口提取、纹理分析与分类建模提供了更具生态意义的时间维度基础。

[0020] 具体的,当计算得到中位数之后,在时间序列中存在缺测月份或空洞时,利用相邻

两个月的观测值 (t_0, y_0) 与 (t_1, y_1) 通过一阶线性模型估计该月的值,如公式(1)所示:

$$\hat{y}_b(t) = y_b(t_0) + \frac{y_b(t_1) - y_b(t_0)}{t_1 - t_0} \cdot (t - t_0) \quad (1)$$

其中, $\hat{y}_b(t)$ 为DOY = t时的估计值, $y_b(t_0)$ 为前一个月对应的观测值, $y_b(t_1)$ 为后一个月对应的观测值,从而既能补全缺测影像,也能保证序列连续性,在短期内假设作物生长趋势近似线性。为后续平滑、谐波回归和物候特征提取提供规则采样。之后,通过S-G平滑滤波在滑动窗口内利用最小二乘法对数据进行低阶多项式拟合,并用拟合曲线的中心点值替代原始值,实现局部平滑,在去除噪声的同时最大程度保留信号的趋势、峰值和波形特征,如公式(2)所示:

$$[0021] \quad \hat{y}_i = \sum_{j=-k}^k c_j \cdot y_{i+j} \quad (2)$$

其中, $\hat{y}_i$ 为第i个平滑后的值, y_{i+j} 为滑动窗口的原始值, c_j 为通过最小二乘法确定的滤波系数。在本实施例中,S-G平滑滤波通过设置7点2阶的固定加权系数,对每个植被指数时序影像执行滑动加权平均,实现去噪与趋势保留。平滑过程在每个时间点上提取其邻近窗口内的影像值,按系数进行加权求和,边界处采用“夹紧”策略避免索引越界,从而确保输出序列与原始影像时间轴对齐。最终生成的每期影像同时包含原始与平滑波段。

[0022] 步骤14、从时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征;分别从地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征。

[0023] 其中,步骤14包括:

步骤141、基于作物的关键生育期筛选归一化植被指数、增强型植被指数、陆地表面水指数,得到归一化植被指数子集、增强型植被指数子集和陆地表面水指数子集,分别从归一化植被指数子集、增强型植被指数子集和陆地表面水指数子集确定关键生育期归一化植被指数均值、关键生育期增强型植被指数均值和关键生育期陆地表面水指数均值。

[0024] 步骤142、分别计算归一化植被指数、增强型植被指数、陆地表面水指数、归一化差异干旱指数、归一化差异耕作指数和绿色冠层植被指数的月均值、月中值、标准差和最值,由月均值、月中值、标准差和最值,以及关键生育期归一化植被指数均值、关键生育期增强型植被指数均值和关键生育期陆地表面水指数均值构建植被指数统计特征。

[0025] 具体的,当完成时序重建后,本发明采用多种植被指数组合构建多维特征空间,确保分类模型能够同时利用作物的生长状态、水分状况以及成熟、背景特征等多方面信息进行作物分类,确保能够捕捉不同作物类型在其完整物候期内光谱动态变化,进而保障了作物的高精度分类。其中,植被指数包括归一化植被指数(NDVI)、增强型植被指数(EVI)、陆地表面水指数(LSWI)、归一化差异干旱指数(NDSVI)、归一化差异耕作指数(NDTI)和绿色冠层植被指数(GCVI)

[0026] 之后,按关键生育期划分4-5月、6-7月和8-9月三个时段,分别合成各时段内NDVI、

EVI与LSWI的平均值,以凸显不同作物在不同物候阶段的差异。同时,通过对全年影像按月统计中值、均值、标准差、最大值和最小值,构建了丰富的植被指数时序统计特征。为增强特征稳健性,还引入基于中值平滑的GLCM纹理特征,以及通过谐波回归拟合得到的NDVI、EVI和LSWI的季节性变化参数,有效表达了植被生长的周期性规律。

[0027] 举例来说,首先基于 Sentinel - 2 L2A影像构建 NDVI、EVI、LSWI、NDSVI、NDTI、GCVI 等常见植被指数,并于多个时间尺度下提取其变化特征。在统计特征层面,按月计算各指数的中值、均值、最大值、最小值以及标准差,共计构建 15 个波段;在平滑特征方面,采用全年中值抑制短时噪声。物候特征则依据作物4 - 5月、6 - 7月、8 - 9月的作物典型生长阶段提取均值,以反映不同作物的物候节律差异。此外,通过 NDVI/EVI/LSWI 年内时间序列开展谐波回归,提取其周期性波动的振幅与相位,增强对作物时间动态的辨识能力。最终得到的植被指数统计特征如表1所示:

[0028] 表1 植被指数统计特征示例表

特征分类	特征类型	描述	来源或方法
植被指数	NDVI	归一化植被指数(红光与近红外)	Sentinel-2 B8 与 B4 波段
	EVI	增强植被指数(考虑蓝光抑制大气影响)	B8, B4, B2 波段计算
	LSWI	土地表面水体指数	B8 与 B11 波段差值
	NDSVI	近红外与红光的变体指数	B11 与 B4 波段差值
	NDTI	土壤调节指数(SWIR2/SWIR1)	B12 与 B11 波段差值
	GCVI	绿色植被覆盖指数	B8 与 B3 波段比值
统计特征	NDVI_mean	NDVI 每月均值	按月 NDVI 影像求均值
	EVI_mean	EVI 每月均值	按月 EVI 影像求均值
	LSWI_mean	LSWI 每月均值	按月 LSWI 影像求均值
	NDVI_std	NDVI 每月标准差	按月 NDVI 图像集合求 stdDev
	EVI_std	EVI 每月标准差	EVI 同理
	LSWI_std	LSWI 每月标准差	LSWI 同理
	NDVI_max	NDVI 每月最大值	按月 NDVI 图像集合求最大值
	EVI_max	EVI 每月最大值	EVI 同理
	LSWI_max	LSWI 每月最大值	LSWI 同理
	NDVI_min	NDVI 每月最小值	按月 NDVI 图像集合求最小值
	EVI_min	EVI 每月最小值	EVI 同理
	LSWI_min	LSWI 每月最小值	LSWI 同理
物候特征	NDVI_4_5	NDVI 在4 - 5月的均值(早期物候)	NDVI 在4 - 5月时间窗口求均值
	EVI_4_5	EVI 在4 - 5月的均值	EVI 同理
	LSWI_4_5	LSWI 在4 - 5月的均值	LSWI 同理
	NDVI_6_7	NDVI 在6 - 7月的均值(盛期物候)	NDVI 在6 - 7月时间窗口求均值
	EVI_6_7	EVI 在6 - 7月的均值	EVI 同理
	LSWI_6_7	LSWI 在6 - 7月的均值	LSWI 同理
	NDVI_8_9	NDVI 在8 - 9月的均值(晚期物候)	NDVI 在8 - 9月时间窗口求均值
	EVI_8_9	EVI 在8 - 9月的均值	EVI 同理
	LSWI_8_9	LSWI 在8 - 9月的均值	LSWI 同理
平滑特征	NDVI_smooth	全年 NDVI 中值(平滑)	NDVI 全年中值
	EVI_smooth	全年 EVI 中值(平滑)	EVI 全年中值
	LSWI_smooth	全年 LSWI 中值(平滑)	LSWI 全年中值
谐波特征	NDVI_sin3	NDVI 谐波分量 $\sin(3\pi t)$	谐波回归所得时间分量系数
	NDVI_cos3	$\cos(3\pi t)$	
	NDVI_sin6	$\sin(6\pi t)$	
	NDVI_cos6	$\cos(6\pi t)$	
	EVI_sin3	EVI 谐波分量 $\sin(3\pi t)$	
	EVI_cos3	$\cos(3\pi t)$	
	EVI_sin6	$\sin(6\pi t)$	
	EVI_cos6	$\cos(6\pi t)$	
	LSWI_sin3	LSWI 谐波分量 $\sin(3\pi t)$	
	LSWI_cos3	$\cos(3\pi t)$	
	LSWI_sin6	$\sin(6\pi t)$	
	LSWI_cos6	$\cos(6\pi t)$	

具体的,NDVI 4-5月、6-7月、8-9月等NDVI 物候窗口特征展现出显著的时间差异性,三者空间上互补。4-5月的春季NDVI高值主要集中在灌溉条件较好的沟谷地带,6-7月的夏季NDVI在大部分耕地内达到峰值;而8-9月的秋初NDVI则主要保留在生长期较长或迟

播区域。这种多时相 NDVI特征可有效刻画作物生育节律差异,是区分作物类型的重要判据。NDVI_mean反映耕地整体植被生长水平,与耕地分布和地形梯度一致,空间格局连续性较好,作为基础植被特征参与分类。从 NDVI_mean的空间图像看,河谷/沟谷带与地势相对平缓且灌溉/水热条件较好的区段呈现更高 NDVI,显示出植被生长更旺盛的格局;高程较高与坡陡的区域 NDVI 偏低。这种“沿主要河谷一支沟向外递减”的条带状结构,与研究区的微地形—水热格局一致,提示地形梯度是耕地作物长势空间差异的重要外部控制因子。

[0029] 年内标准差EVI_std表征植被指数的波动程度,高值区域多分布于如复种或灌溉频繁区的生长期强烈波动区域,低值区多为植被生长稳定或裸地区域。EVI相比 NDVI更能抑制背景噪声,因此其变异性特征对判别有特殊价值。

[0030] 年内最大值LSWI_max作为反映植被含水状况与灌溉活动的水分指数,在沟谷水源发育区、低洼地带呈现出显著高值,与 NDVI 表现互补。该指数对水稻等需水较高作物具有良好指示性。整体来看,多时相 NDVI 与水分、变异性指数等多维特征在空间上互为补充,能够有效提升作物类型间的区分度。

[0031] 在基础植被指数的基础上,本发明进一步构建了NDVI_smooth、EVI_smooth、LSWI_smooth等年内平滑指数,以及GLCM等纹理特征与谐波特征const_NDVI等时间结构特征,以提升分类模型对作物时空异质性的感知能力。其中,NDVI_smooth、EVI_smooth 与 LSWI_smooth 分别通过对 NDVI、EVI 和 LSWI 的全年影像进行中值合成处理,能够减少云遮、噪声和极值干扰。空间分布上,这三类平滑指数保持了作物主生长期的空间差异性:NDVI_smooth 在主耕作区呈现明显高值,结构清晰,易于作物边界提取;EVI_smooth 显示出更强的背景抑制能力,高值区集中在农田密集分布区;LSWI_smooth 空间变化丰富,在灌溉、湿润区域具有较好响应。

[0032] 在植被指数的基础上,本发明还通过灰度共生矩阵 (GLCM) 方法,从平滑后的 NDVI、EVI、LSWI 图像中提取纹理特征,窗口大小设定为 3×3 。分别计算角二阶矩阵下的同质性、对比度、熵等用以描述植被覆盖区域空间结构变化的统计量。上述纹理特征有助于识别在光谱特征相近的情况下空间格局差异明显的作物类型,尤其适用于高原丘陵区地块破碎的情形,可提升分类器对边缘与斑块区域的判别能力。具体的,GLCM表征了 NDVI 空间纹理异质性,能有效识别作物类型之间的斑块差异性与边界结构。高纹理值主要分布在作物交错或分布破碎区,低纹理值则多集中于耕地集中连片区域。该指标在识别油菜等呈斑块状分布的作物中具有显著效果。而const_NDVI描述了 NDVI 时间序列的基底水平(即年内平均偏移量),空间上呈现出与 NDVI_smooth 类似但更为平滑的分布特征。其数值较高区域集中在灌溉条件好、地势平坦的农田密集区,是刻画作物长势差异的重要时间结构特征之一。通过引入上述特征,模型在空间纹理识别与时间结构表达上能力增强,为后续分类模型对光谱相似作物的分类精度提升提供了重要支持。

[0033] 步骤14还包括:

步骤144、从地形数据提取海拔信息、坡度信息和坡向信息,由海拔信息、坡度信息和坡向信息构建地形特征。

[0034] 步骤145、从土壤数据提取表层土壤指定分类和黏土含量占比,由表层土壤指定分类和黏土含量占比构建土壤特征。

[0035] 步骤146、从气候特征提取年均气温和年累计降水量,由年均气温和年累计降水量

构建气候特征。

[0036] 具体的,考虑到地形因子可作为限制作物种植适宜性的环境变量,在一定程度上揭示高原、山地地区作物类型的分布边界,例如,坡度大于一定阈值的区域往往难以进行耕作,易转变为牧草地或裸地,这对于提升模型的空间泛化能力具有重要意义。本发明还可以从地形数据中提取高原区域的高程、坡度和坡向信息,并使地形特征与遥感特征的空间分辨率保持一致。其中,为了提升分类模型对耕地边界的表达能力与作物空间分布差异的解释力,还可以引入SRTM 1 Arc-Second 全球高程数据(USGS/SRTMGL1_003)计算高原区域的坡度(Slope)与海拔(Elevation)两个关键地形变量,并将其作为地形特征,如图4所示。综上,坡度与海拔作为非光谱类特征,与 NDVI/EVI 等光谱特征组合后可显著提升模型对“地貌-作物类型”的联动响应能力。

[0037] 此外,为进一步提高作物分类模型对空间异质性的解释能力,还可以引入多尺度气候与土壤因子变量。具体的,可以利用ERA5 - Land月尺度再分析数据提取高原区域的年均气温与年累计降水量,以 2 m 高度空气温度代表温度,并将单位转换为摄氏度;降水则累计全年总量并换算为毫米。采用 bilinear 重采样方式使气候因子与 Sentinel - 2 空间尺度相匹配,增强其与地面现象的对应关系,从而反映作物种植的热量与水分条件,便于不同作物的生态适宜性建模。而土壤特征或土壤因子源自 OpenLandMap 数据集,提取了表层土壤的 USDA 质地分类和 0 - 10 cm 黏土含量百分比两类指标。质地类型以整数编码表示不同的颗粒组成,而黏土含量反映土壤的保水与养分能力,对作物根系发育及水分调控起着关键作用。土壤属性通常在短期内较为稳定,可作为基础环境变量为作物分类提供补充信息。

[0038] 步骤15、获取训练用区域的地区的光学遥感数据、地形数据、土壤数据和气候数据,并分别提取得到训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征。

[0039] 步骤16、将训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入基于谷歌地球引擎平台的随机森林分类器中进行模型训练,得到随机森林分类模型。

[0040] 步骤17、将训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入基于谷歌地球引擎平台的梯度提升树分类器中进行模型训练,得到梯度提升树分类模型。

[0041] 步骤18、将训练用植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入基于谷歌地球引擎平台的支持向量机分类器中进行模型训练,得到支持向量机分类模型。

[0042] 步骤19、将植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入预先训练的作物分类模型中,得到高原地区的作物识别结果。

[0043] 具体的,为了实现对高原地区的高精度识别,本发明采用在 Google Earth Engine 平台实现模型训练的随机森林(Random Forest, RF)、梯度提升树(Gradient Tree Boosting, GTB)以及支持向量机(Support Vector Machine, SVM)模型进行作物分类预测。为提升模型的空间一致性与实际应用效果,所有模型均以融合的多维特征栅格作为输入,并在耕地掩膜范围内输出分类图。

[0044] 其中,为能够兼顾模型的稳定性与泛化能力,适用于解决遥感数据中常见的问题,随机森林分类模型的设置800棵决策树,每棵决策树的最小叶节点样本数设定为5,样本抽样比例确定为70%,且在每次划分时随机选取10个特征进行分裂操作。模型借助Google Earth Engine平台的smileRandomForest分类器来实现,以样本点的地类编号作为分类属性,自动识别整合影像输入特征波段并进行训练。训练完成之后,对全区的栅格影像进行分类预测。在制图及面积统计过程中,采用耕地掩膜技术,以此确保分类范围限定在耕地区域内,从而避免对训练样本产生引导偏差。

[0045] 并且,考虑到地表覆盖识别具备非线性、多尺度以及特征耦合的属性,GTB能够渐进式地拟合复杂边界,描绘特征的非线性关系,且对异常值具备较强的稳健性,本发明引入梯度提升树(GTB)作为第二类集成学习模型。其输入特征与RF分类一致,利用多源、多时相的时序信息以及环境信息来刻画作物的生长进程。其中,GTB的参数设定遵循“弱学习器 + 小步长”的稳定收敛准则,为确保在拟合能力与避免过拟合之间达成了平衡,适用于遥感场景中常见的问题,树或弱学习器的数量(numberOfTrees)设置为400,收缩率或学习率(shrinkage)设置为0.05,采样率或用于提升模型的泛化性能的子采样比例(samplingRate)设置为0.7,用于约束模型的复杂度的单棵树的叶节点数(maxNodes)设置为64。并且,GTB运用序列式残差逼近方式以提升模型性能,在样本数量适中且标签质量优良的情形下,GTB的判别精准度更高,训练流程于Google Earth Engine(GEE)平台借助smileGradientTreeBoost分类器得以实现,分类完成之后,于耕地掩膜范围内开展制图并统计面积。

[0046] 此外,考虑到支持向量机(Support Vector Machine,SVM)作为一种基于统计学习理论构建的机器学习方法,能够自动探寻对分类具有显著区分效能的支持向量,进而构建分类器,实现类别间间隔的最大化,因而具备良好的泛化能力与较高的分类精度,可针对高维数据处理小样本的分类问题,本发明引入支持向量机进行作物分类。其中,SVM采用径向基核函数(RBF),为了能够构建非线性可分的最优超平面,对边界模糊以及少量异常点具备良好的鲁棒性,旨在平衡间隔最大化与误差容忍度的软间隔惩罚系数或代价参数取值为10,作为径向基核函数的宽度参数,用于控制样本在特征空间中的影响范围的gamma 取值为0.05。该模型同样训练流程于Google Earth Engine(GEE)平台实现并在耕地掩膜范围内输出分类结果以及进行面积统计。

[0047] 实施例2

在实施例1的基础上,如图3所示,本发明还以某高原高寒区域的粮食种植区为例,进一步验证本发明提供的高原作物分类方法的效果。总面积共计约 $1.67 \times 10^4 \text{ km}^2$,该地集中了该高原区域60%以上的耕地,粮食产量占全区的70%左右。主要种植作物有青稞,约占种植面积的47%左右;冬小麦占29%,春小麦占6.7%,豆类占14.4%;经济作物以油菜、甜菜为主,还种植有少量蔬菜。一方面,通过 GEE 平台获取 2021 年典型作物生育期内 Sentinel-2 L2A 地表反射率遥感影像,利用 QA60 与 SCL 比特位信息剔除云、卷云、云阴影、雪及饱和像元。其中,Sentinel-2 数据的空间分辨率为10 m的可见光-红边-近红外/20 m的短波红外,双星重访周期 5 天。并且,还参考Global Cropland 2019、2024年省市县三级行政区划数据及其他数据,遥感数据如表2所示:

[0048] 表2 本实施例遥感数据表

数据名称	数据来源/传感器	时间分辨率	空间分辨率	主要说明
全球耕地分布 2019 (Global Cropland 2019)	马里兰大学 Potapov 团队		30m	全球耕地掩膜, 像元值 1 = 耕地, 0 = 非耕地
研究区矢量边界	国家基础地理信息中心 https://www.ngcc.cn/xwzs/ywgc/202404/20240426_2410.html	-	-	研究区域范围边界
Sentinel-2 MSI (A/B 双星)	欧空局 (ESA) Copernicus 计划 Sentinel-2A/B 双星。 传感器: Sentinel-2 MSI	5d (赤道)、 2-3d (中纬度)	10 m (可见光-红边-近红外)、 20 m (短波红外)	主影像 (反射率、指数、物候、谐波)
云/卷云/云阴影/雪/冰 和像元掩膜	ESA COPERNICUS S2_SR_HARMONIZED 集合传感器: Sentinel-2 MSI	与影像同步	60 m (QA60)、10 m (SCL)	QA60 波段 + SCL Scene Classification
地形 (高程/坡度/坡 向)	NASA / USGS LP DAA https://doi.org/10.5066/F7P7TFTN NASA SRTM C-band InSAR (SNR-C 雷达)	-	30 m	
气候 (年均温、年降 水)	ERA5-Land 再分析 (哥白尼) ECMWF/ERA5_LAND/MONTHLY_AGGR	逐月	0.1° (≈ 9 km)	
土壤质地分类	OpenLandMap	-	250 m	
土壤粘土含量	OpenLandMap	-	250 m	

此外,本实施例还根据该区域的耕地分布进行实地采样与无人机调查,如图4所示。共得到342个样点数据用于进一步验证,其中青稞219组数据、小麦79组数据、油菜44组数据,如图5所示。

[0049] 该区域坡度(Slope)值范围在 $0-60^{\circ}$ 之间,呈现典型的“山地-河谷”交错格局:高坡度区域主要分布在研究区四周与河谷切割强烈区域,而中低坡度区则集中在河谷平原及沟谷地带,是耕地主要分布区域;海拔(Elevation)值范围为 3000-6000m,呈现出明显的南北方向的高差变化:南部与北部边缘地区地势较高,中部河谷带相对较低。该特征可辅助识别低海拔区优先种植的作物类型,如油菜、小麦等。该区域年降水量(P_{sum} , mm)呈现由北向南递增的空间格局,北部高原区年降水不足 400mm,南部沟谷区域可达 1000mm 以上,形成了明显的水热梯度。这一格局与作物分布具有良好的一致性,有助于区分需水量差异较大的作物种类,如油菜和青稞;年均温($T2m_mean$, $^{\circ}C$)整体变化较平缓,主要控制于地形因子(如高程)所决定的垂直热量带,北部地势较高地区气温偏低,南部河谷地带气温较高。该区域土壤粘粒含量整体在15-35%之间,局部沟谷与山麓交汇处存在 $>40\%$ 的高值区。基于上述数据,确定该区域的植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征。

[0050] 之后,基于上述特征验证GTB、RF和SVM三类模型的性能。举例来说,训练样本进行抖动增强和类别均衡处理,提升模型泛化能力与minority类的分类效果。最终利用构建的特征集开展监督分类,实现该区域内主要作物类型的精确识别;并借助独立的验证样本集进行精度评价,输出混淆矩阵、总体分类精度及Kappa系数;对比分类模型的分类效果,为农业遥感分类提供了一套稳健且高效的解决方案。

[0051] 其中,为增强样本的空间分布多样性并缓解过拟合问题,首先对原始样本点引入坐标扰动。具体做法是为每个样本生成两组独立的随机数,分别作用于经度与纬度方向,扰动幅度约为 0.00025° ,相当于地面距离约25-30米,从而生成增强样本集合。随后将增强样本与原始样本合并,并按 8:2 比例随机划分为训练集与测试集。训练样本的特征提取基于未加掩膜的多源影像或整合后的特征影像,并设置采样分辨率为30米。为确保每个样本包含完整的输入特征,进一步剔除所有存在缺失波段值的像元。在类别分布存在不均衡的情况下,采用最小类下采样策略实现类别均衡。即首先统计每一类样本数量,取其中最小值作为采样上限,再对每类样本执行等量下采样,构建平衡训练集。分类完成后,在测试集上进行精度验证,计算混淆矩阵、总体精度和 Kappa 系数等指标。最终,将分类结果限定于耕地范围内,统计各类别对应的面积分布,用于成果图制作与面积指标分析。三种模型分类结果

如表3所示:

[0052] 表3 精度验证结果表

分类算法	总体最优精度Overallaccuracy/%	最优kappa系数Kappacoefficient	总体平均精度Overallaccuracy/%	平均kappa系数Kappacoefficient
随机森林	85	0.64	66.42	0.40
支持向量机	83	0.55	72.33	0.46
梯度提升树	78	0.55	64.36	0.39

由表3可知,RF 模型在验证样本上总体精度为 84.77%,Kappa 系数为 0.6434,在三种模型中表现最优,说明分类结果与实际作物类型存在较强一致性,且高于常规遥感作物分类精度门槛 ($OA > 0.80$, $Kappa > 0.60$),具备较高的可靠性与推广价值。由于Kappa值在 0.61-0.80范围内属于“良好一致性”,说明模型预测结果与真实标签具有较高的一致性和可靠性。GTB 模型的整体分类精度为 78.47%,Kappa 系数为0.5545,表明模型对各类地物具有中等偏上的判别能力,在一定程度上克服了光谱混叠和地形干扰的影响。SVM模型的总体精度达到 0.8289,Kappa 系数为 0.5485。综上所述,随机森林和支持向量机分类的结果具有一定的准确性,其中随机森林模型分类的效果更好,还可以利用随机森林算法计算每一种特征波段的重要性及添加此特征波段后的袋外正确率,分别如图6和图7所示,特征波段的重要性为植被指数统计特征大于气候特征植被大于指数纹理特征大于土壤特征大于地形特征大于气候特征。

[0053] 之后,将三类模型分别对植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征中多个特征组合进行验证,结果如表4所示:

表4 多特征组合比对表

方法	特征组合	算法	总体精度Overallaccuracy/%	kappa系数Kappacoefficient
方案1	植被指数特征	RF	58.56	0.2879
		GTB	60.36	0.3524
		SVM	55.86	0.2918
方案2	植被指数特征+物候特征	RF	62.16	0.3465
		GTB	63.06	0.3586
		SVM	49.55	0.2116
方案3	植被指数特征+地形特征	RF	62.16	0.3435
		GTB	59.46	0.2863
		SVM	81.98	0.5752
方案4	植被指数特征+气候特征	RF	63.96	0.356
		GTB	62.16	0.3736
		SVM	72.07	0.5313
方案5	植被指数特征+纹理特征	RF	62.16	0.3716
		GTB	57.66	0.3688
		SVM	82.88	0.5484
方案6	植被指数特征+物候特征+地形特征+气候特征+纹理特征	RF	71.17	0.4752
		GTB	69.37	0.4575
		SVM	81.08	0.4885
方案7	植被指数特征+物候特征+地形特征+气候特征+纹理特征+土壤特征	RF	84.77	0.6434
		GTB	78.47	0.5545
		SVM	82.89	0.5485

其中,三种模型的整体分类精度和kappa系数分别如图8和图9所示,Kappa系数热力图如图10所示,不同特征组合方案分类精度评价图如图11所示。而三种模型在该区域的分类结果空间分布分别如图12、图13和图14所示。

[0054] 其中,RF分类模型的分类结果空间分布如图12所示,分类对象包括青稞、小麦和油菜三种主要农作物以 DEM 起伏图为背景,以增强地形信息识别与分布格局分析的直观性。研究区面积约为 $1.67 \times 10^4 \text{ km}^2$ 。从空间分布格局上分析:青稞主要分布于区域中东部低海拔河谷及坡度较缓的冲积扇地带,呈现出片状集中、连片规模大的特征。其分布符合当地青稞以灌溉条件良好的集中区为主的耕作模式。小麦零星分布于中部与北部较高台地之

间,呈现离散型的斑块格局,与高原季节性灌溉条件限制小麦大规模种植的实际一致。油菜则主要分布在交通走廊及局部冲积扇区,表现为线性或点状斑块状格局,显示出该作物对灌溉、热量资源更高的依赖性。总体上,作物分布图与地形起伏关系密切,反映出不同作物在水热条件、地形区位、土地利用方式等方面的差异性响应。RF 分类器对各类作物的判别能力较强,能有效整合多时相植被指数、纹理特征与地形参数,呈现出较高的分类精度与地学解释能力。

[0055] GTB分类模型的分类结果空间分布如图13所示,青稞广泛分布于中部河谷及沿山麓区域,呈线性带状结构,与河谷冲积平原高度吻合,体现出GTB对河谷耕地的良好识别性能;小麦主要集中在地形开阔、坡度缓和的山间盆地,呈现出连片块状分布特征;而油菜分布相对零散,多位于海拔较低、坡向适宜的区域,反映其种植环境的局部化特点。背景叠加的 DEM 信息进一步表明,GTB 分类结果与地形变化具有良好一致性,如高海拔、陡坡等等非耕作类区域基本被归入灰色的“其他”类,说明模型在多特征条件下具备一定的地形适应能力。综上所述,GTB 分类器在本区域表现出较强的泛化能力和对主要作物类型的识别精度,虽略低于随机森林(RF)模型的精度水平,但在地形复杂性更高的区域仍具有良好应用潜力,尤其适用于植被类型与环境因子交互影响显著的高原农区。

[0056] SVM分类模型的分类结果空间分布如图14所示,与 GTB 模型相比,SVM 输出结果呈现出更清晰的空间格局和更强的边界识别能力:青稞为 SVM 模型主要识别出的作物类型,主要分布于南部和中部的河谷地带,且呈带状连续分布,反映出该模型在复杂地形条件下仍能维持较好的边界识别精度。小麦与油菜分类结果极少或缺失,从图上看小麦和油菜几乎未被识别,可能由于 SVM 模型在当前样本构建或特征空间中,将三类作物合并误判为青稞,或受到训练样本数量不均衡影响导致模型分类偏向青稞等主类发生类别塌缩现象。灰色的其他类型地物主要集中于高山及非耕地区域,边界清晰,表明 SVM 模型在主类与非耕类地物间区分能力较强。

[0057] 综上,面对高原地区冬季云雪覆盖面积高达 70%以上,传统单景影像分类极易产生“同谱异物”的问题,本发明提供的高原作物分类方法运用“月内中值-邻月插值-SG平滑”三步法,将缺测率降低,同时保留了作物返青、抽穗、成熟三个关键拐点的幅度与相位信息,SG 滤波既能有效抑制脉冲噪声,又可避免 Whittaker 平滑中常见的高频信号过度衰减问题,使 NDVI 峰谷差异保留率大于 90%,保障了高原作物识别稳健性。并且,本发明提供的一种高原作物识别方法以高质量的时序重建为基础,构建一个涵盖光谱、时序、纹理、地形、气候、土壤的多维特征空间,引入气候、土壤、纹理等非遥感传统特征,提升特征维度与区分度,进一步提高了作物分类的准确性。

[0058] 具体的,本发明提供的高原作物分类方法利用GEE平台提供的RF、SVM和GTB 3种机器学习算法及图像云掩膜等多种遥感影像处理方法,调用Sentinel-2遥感影像,对高原地区的耕地研究区实现了主要粮油作物的提取。GEE平台存储大量遥感影像,如Modis、Landsat和 Sentinel等。并且具有强大的云计算服务做支撑,降低了遥感数据获取成本,可以满足不同尺度的研究。借助GEE平台,能够实现对遥感数据的实时调用和处理。同时,GEE平台丰富的数据集以及强大的计算能力,为多源数据融合和多维度特征提取提供了有力支持,进一步提高了作物识别的精度和可靠性。传统的农作物信息调查主要采用大规模实地考察与样本测算的方法,虽具备局部精度较高的特点,但在数据采集过程中需耗费大量的

人力与物力,时效性欠佳,且难以获取农作物种类精准的位置及面积信息。采用遥感云计算技术,选择分辨率高的 Sentinel-2 影像进行西藏农区主要粮油作物识别,可以有效提升计算效率,并降低由粗分辨率以及像元分辨困难造成的提取精度偏差。因此在未来的研究中,GEE 平台仍然会是主流。此外,随着遥感技术的不断发展,更高分辨率的影像数据将不断涌现,结合GEE平台的云计算能力,将能够实现对农作物更精细、更准确的识别和监测。因此,基于GEE平台的遥感云计算技术,在农业遥感领域具有广阔的应用前景。

[0059] 在粮油作物分类识别中,RF算法分类的结果明显优于SVM算法分类的结果。SVM算法通过寻找最优超平面作为决策边界进行分类,决策边界泛化能力较差。青稞、小麦与油菜的植被指数特征和物候相近,样本分布靠近决策边界两侧,导致青稞、小麦与油菜容易混淆。随机森林(RF)算法基于集成学习理念,通过构建多个决策树并整合其预测结果以实现分类。决策树利用多个随机变量对样本进行多次划分,同时随机选取样本与特征变量,具备更强的鲁棒性与泛化能力。在处理具有相近植被指数特征和物候的作物分类时,RF算法能够更好地捕捉数据中的复杂模式和关系,从而更准确地区分青稞、小麦与油菜。此外,RF算法对样本中的噪声和异常值具有更好的容忍度,进一步提高了分类的准确性。因此,在实际应用中,RF算法更适合用于高原高寒区域主要粮油作物的分类识别。

[0060] 在特征集构建及波段优化中,考虑了物候特征、地形特征和纹理特征的组合明显具有更佳分类效果。这种多特征组合的方式充分利用了不同类型特征之间的互补性,物候特征能够反映作物在不同生长阶段的特性,地形特征可以体现作物生长的地理环境差异,而纹理特征则能展现作物表面的细微结构信息。三者相结合,为分类模型提供了更为丰富和全面的信息,使得模型能够更精准地捕捉不同作物之间的细微差别,进而有效提升了分类的准确性。高寒高海拔的生态环境具有独特性,植被生长受气候与地形因素的影响显著,物候特征、地形条件以及气候状况在粮油作物分类工作中发挥着至关重要的作用。在实际应用中,这种基于多特征组合的波段优化方法具有较高的实用价值,能够为高原高寒农区主要粮油作物的精准识别提供可靠的技术支持。

[0061] 实施例3

本申请还提供一种高原作物识别系统,包括:

时序重建模块,用于获取高原地区的光学遥感数据、地形数据、土壤数据和气候数据;根据光学遥感数据计算植被指数;将每一个月的植被指数中的中位数作为该月的像元反射率,当存在像元反射率缺失时,基于相邻月的像元反射率线性插值得到该月的像元反射率,基于像元反射率构建每一个月的合成影像;对每个月的合成影像进行SG平滑滤波处理,得到时间序列重建的植被指数;

特征提取模块,用于从时间序列重建的植被指数中提取植被指数统计特征和植被指数纹理特征;分别从地形数据、土壤数据和气候数据中提取地形特征、土壤特征和气候特征;

作物分类模块,用于将植被指数统计特征、植被指数纹理特征、地形特征、气候特征和土壤特征输入预先训练的作物分类模型中,得到高原地区的作物识别结果。

[0062] 本发明还提供一种计算机设备,包括存储器、处理器及存储在存储器上的计算机程序,处理器执行计算机程序以实现一种高原作物识别方法实施例中的步骤。具体实现方法可参见方法实施例,这里不再赘述。

[0063] 进一步地,本发明还提供一种包含指令的非临时性计算机可读存储介质,存储介质上存储有计算机程序。例如包含指令的存储器,上述指令可由计算机设备的处理器执行以完成上述方法。例如,非临时性计算机可读存储介质可以是ROM、随机存取存储器(RAM)、CD-ROM、磁带、软盘和光数据存储设备等。该计算机程序被处理器执行时,能够实现一种高原作物识别方法实施例中的步骤。具体实现方法可参见方法实施例,这里不再赘述。

[0064] 本领域内的技术人员应明白,本发明的实施例可提供方法、系统或计算机程序产品。因此,本发明可采用完全硬件实施例、完全软件实施例或结合软件和硬件方面的实施例的形式。而且,本发明可采用在一个或多个其中包含有计算机可用程序代码的计算机可用存储介质(包括但不限于磁盘存储器、CD-ROM、光学存储器等)上实施的计算机程序产品的形式。

[0065] 本发明是参照根据本发明实施例的方法、装置(系统)和计算机程序产品的流程图和/或方框图来描述的。应理解可由计算机程序指令实现流程图和/或方框图中的每一流程和/或方框,以及流程图和/或方框图中的流程和/或方框的结合。可提供这些计算机程序指令到通用计算机、专用计算机、嵌入式处理机或其他可编程数据处理设备的处理器以产生一个机器,使得通过计算机或其他可编程数据处理设备的处理器执行的指令产生用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的装置。

[0066] 这些计算机程序指令也可存储在能引导计算机或其他可编程数据处理设备以特定方式工作的计算机可读存储器中,使得存储在该计算机可读存储器中的指令产生包括指令装置的制造品,该指令装置实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能。

[0067] 这些计算机程序指令也可装载到计算机或其他可编程数据处理设备上,使得在计算机或其他可编程设备上执行一系列操作步骤以产生计算机实现的处理,从而在计算机或其他可编程设备上执行的指令提供用于实现在流程图一个流程或多个流程和/或方框图一个方框或多个方框中指定的功能的步骤。

[0068] 应当指出,以上所述具体实施方式可以使本领域的技术人员更全面地理解本发明创造,但不以任何方式限制本发明创造。因此,尽管本说明书和实施例对本发明创造已进行了详细的说明,但是,本领域技术人员应当理解,仍然可以对本发明创造进行修改或者等同替换;而一切不脱离本发明创造的精神和范围的技术方案及改进,其均涵盖在本发明创造专利的保护范围当中。不应将权利要求中的任何附图标记视为限制所涉及的权利要求。任何熟悉本领域的技术人员在本发明披露的技术范围内,可显而易见地得到的技术方案的简单变化或等效替换,均属于本发明的保护范围。




图1




图2




图3



图4




图5




图6




图7




图8




图9




图10




图11




图12




图13




图14