



(12) 发明专利申请

(10) 申请公布号 CN 120259362 A

(43) 申请公布日 2025. 07. 04

(21) 申请号 202510297451.4

(22) 申请日 2025.03.13

(71) 申请人 西北农林科技大学

地址 712100 陕西省西安市杨凌示范区邠城路3号

(72) 发明人 张宏鸣 孙扬 韩亚敏 咎林森
王博文 张涛平 李安宁 黄铝文
蒲攀 卓涛 吴丹阳 孙朋朋

(74) 专利代理机构 西安恒泰知识产权代理事务
所 61216

专利代理师 王孝明

(51) Int. Cl.

G06T 7/246 (2017.01)

G06T 7/277 (2017.01)

G06V 40/10 (2022.01)

G06V 10/25 (2022.01)

G06V 10/764 (2022.01)

G06V 10/766 (2022.01)

G06V 10/80 (2022.01)

G06V 10/82 (2022.01)

G06N 3/0455 (2023.01)

G06N 3/0464 (2023.01)

G06N 3/084 (2023.01)

G06N 3/096 (2023.01)


权利要求书3页 说明书20页 附图13页

(54) 发明名称

一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法

(57) 摘要

本发明提供了一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,包括:步骤S1,构建肉牛检测与多目标跟踪数据集;步骤S2,实现高精度上下文感知目标检测教师网络HP-CAOD-TN;步骤S3,训练高精度上下文感知目标检测教师网络HP-CAOD-TN;步骤S4,实现高效上下文感知目标检测学生网络EC-CAOD-SN;步骤S5,模型蒸馏;步骤S6,实现伪深度增强卡尔曼滤波器P-DEKF;步骤S7,基于S5得到的目标双检测网络,使用步骤S6中伪深度增强卡尔曼滤波器P-DEKF模拟目标的状态进行伪深度运动模型驱动,并使用匈牙利算法进行逐帧数据关联来共同实现多目标跟踪。本发明通过引入高精度上下文感知目标检测教师网络HP-CAOD-TN和高效上下文感知目标检测学生网络EC-CAOD-SN,本发明不仅在多目标跟踪中实现了高精度的目标检测,还兼顾了低计算负担。



1. 一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,该方法包括以下步骤:

步骤S1,构建肉牛检测与多目标跟踪数据集;

其特征在于:

步骤S2,实现高精度上下文感知目标检测教师网络HP-CAOD-TN;

步骤S3,训练高精度上下文感知目标检测教师网络HP-CAOD-TN;

基于步骤S1中得到的肉牛检测与多目标跟踪数据集,对步骤S2中得到的高精度上下文感知目标检测教师网络HP-CAOD-TN进行训练;

步骤S4,实现高效上下文感知目标检测学生网络EC-CAOD-SN;

在经过步骤S3训练后的所述的高精度上下文感知目标检测教师网络HP-CAOD-TN中,将上下文感知注意力增强特征融合模块CAAFM中的上下文感知边界融合金字塔模块CABFP替换为学生-上下文感知边界融合金字塔S-CABFP模块,形成学生-上下文感知注意力增强特征融合模块S-CAAFM,从而实现高效上下文感知目标检测学生网络EC-CAOD-SN;

步骤S5,模型蒸馏:

通过计算步骤S4得到的高效上下文感知目标检测学生网络EC-CAOD-SN的学生特征图和步骤S3得到的高精度上下文感知目标检测教师网络HP-CAOD-TN的教师特征图之间的相似度来实现模型蒸馏,最终得到目标双检测网络;

步骤S6,实现伪深度增强卡尔曼滤波器P-DEKF;

将伪深度信息集成到卡尔曼滤波器的状态向量中,将状态向量的维度由8维(x,y,w,h,vx,vy,vw,vh)扩展为10维(x,y,w,h,d,vx,vy,vw,vh,vd);

其中:

x,y表示目标边界框的中心位置坐标;

w,h表示目标边界框的宽度和高度;

d表示伪深度值,即表示目标距离摄像头的远近;

vx,vy表示位置在x和y方向的速度;

vw,vh表示宽度和高度的变化速度;

vd表示伪深度的变化速度;

步骤S7,双检测与伪深度运动模型驱动的肉牛多目标跟踪方法:

基于S5得到的目标双检测网络,使用步骤S6中伪深度增强卡尔曼滤波器P-DEKF模拟目标的状态进行伪深度运动模型驱动,并使用匈牙利算法进行逐帧数据关联来共同实现多目标跟踪。

2. 如权利要求1中所述的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,其特征在于,步骤S2中,所述的高精度上下文感知目标检测教师网络HP-CAOD-TN的关键组件包括:并行上下文感知特征网络PCAFNet、上下文感知注意力增强特征融合模块CAAFM、IoU感知查询选择机制和带有辅助预测头的解码器;

所述的并行上下文感知特征网络PCAFNet由基本卷积模块和PCAF模块组成;

所述的上下文感知注意力增强特征融合模块CAAFM结合了基于注意力机制的尺度内特征交互AIFI模块和上下文感知边界融合金字塔模块CABFP;

所述的上下文感知边界融合金字塔CABFP包括双池通道注意力模块DPCA、三重注意力融合模块TAFM、双重门控机制来控制特征融合模块DGAFM以及频谱增强融合模块SEFM。

3. 如权利要求1中所述的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,其特征在于,步骤S2中,所述的高精度上下文感知目标检测教师网络HP-CAOD-TN的构建方法为:

步骤S201,构建并行上下文感知特征网络PCAFNet;

将输入的图像数据送入并行上下文感知特征网络PCAFNet中,生成{P2、P3、P4、P5}四个层次的特征图;

步骤S202,构建上下文感知注意力增强特征融合模块CAAFM;

将步骤S201中得到的P5特征图输入到注意力机制的尺度内特征交互模块AIFI的内部交互,输出交互后的F5特征图;

将步骤S201中得到的P2特征图、P3特征图、P4特征图和F5特征图输入到上下文感知边界融合金字塔CABFP,对P2特征图、P3特征图、P4特征图和F5特征图进行跨尺度的特征融合拼接,输出Memory特征图;

步骤S203,构建IoU感知查询选择机制;

计算步骤S202中得到的Memory特征图中每个特征对应的预测边界框与真实边界框的回归与分类损失,并且在分类损失中加入IOU,保证网络输出的位置置信度与类别置信度的一致性,根据损失选择其中的Top-K个特征;

步骤S204,构建带有辅助预测头的解码器:

Decoder接收步骤S203中筛选出的Top-K个特征,进行初始目标查询和混合编码器输出的Memory特征序列,通过多层自注意力和交叉注意力迭代优化目标查询,最终输出检测框的类别和坐标;Head将Decoder输出的检测框的类别和坐标映射到检测框上。

4. 如权利要求1中所述的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,其特征在于,步骤S3中,训练采用的损失函数L包括目标边界框回归损失 L_{box} 和分类损失 L_{cls} 两部分,即 $L=L_{\text{box}}+L_{\text{cls}}$;反向传播损失函数L,重复迭代直至迭代次数达到预设初始值时完成训练。

5. 如权利要求1中所述的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,其特征在于,步骤S5中,所述的模型蒸馏的具体过程为:

步骤S501,特征图对齐操作;

步骤S502,标准化特征图;

步骤S503,计算特征图的相似度;

步骤S504:标准化相关性矩阵;

步骤S505,计算损失;

步骤S506,加权损失;

步骤S507,反向传播与优化。

6. 如权利要求1中所述的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,其特征在于,步骤S6中,所述的扩展的方法包括以下步骤:

步骤S60,定义状态向量;

步骤S602,建立运动模型;

步骤S603,建立观测模型;

步骤S604,伪深度增强卡尔曼滤波器P-DEKF初始化;

步骤S605,预测;

步骤S606,更新;
步骤S607,计算门控距离;
步骤S608,计算伪深度。

7.如权利要求1中所述的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,其特征在于,步骤S1的具体过程为:收集来自真实监控视角的五种不同养殖场景的视频,使用DarkLabel1工具对视频进行标注,获取标准数据格式的标注数据,将标注数据转换为肉牛检测与多目标跟踪数据集。

8.如权利要求1中所述的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,其特征在于,该方法还包括步骤S8,后处理:

采用线性插值方法,在每个轨迹中缺失的检测位置填充缺少的检测框。

一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法

技术领域

[0001] 本发明属于视频图像理解技术领域,涉及肉牛多目标跟踪,具体涉及一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法。

背景技术

[0002] 随着肉牛产业的发展和养殖规模的扩大,耗时耗力且高人工成本的传统的人工观察模式已经难以满足规模化肉牛养殖的需要,当下急需解决的是如何通过科学的方式对肉牛养殖过程进行监测,及时发现并处理养殖中的异常情况,提高动物生产力,健康和福利。基于多目标跟踪方法对养殖场监控设备收集到的视频进行分析,实现肉牛个体目标跟踪,为行为识别、体征监测和肉牛个体建立联系提供了支撑。

[0003] 现有技术中针对多目标跟踪技术在畜牧养殖领域的应用进行了多种尝试,大体上可分为以匈牙利(KM匹配)的后端追踪优化算法、基于单目标跟踪器的多目标追踪算法和基于端到端跟踪方法。以匈牙利(KM匹配)的后端追踪优化算法。代表性算法有SORT(Simple Online and Realtime Tracking),DeepSORT(Simple Online and Realtime Tracking with a Deep Association Metric)。这类算法能达到实时跟踪的要求,但是其跟踪效果很大程度上依赖于目标检测器的精确、特征区分程度。基于单目标跟踪器的多目标追踪算法。这类方法中的经典算法是核相关滤波算法(KCF)。这种算法为每一个目标分配一个单目标跟踪器,追踪效果很好,但是在目标众多的情况下十分耗费计算资源,对内存和CPU要求较高。基于端到端的多目标跟踪算法。这类算法将检测和跟踪过程整合在一个统一的框架中,通过端到端的训练优化整个跟踪过程,计算效率较高。但端到端模型的训练过程复杂,需要大量的数据和计算资源。并且由于检测和跟踪过程高度耦合,模型在不同场景中的适应性较差。

发明内容

[0004] 针对现有技术存在的不足,本发明的目的在于,提供一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,解决现有技术中的多目标跟踪方法难以兼顾检测的精度和计算负担的技术问题。

[0005] 为了解决上述技术问题,本发明采用如下技术方案予以实现:

[0006] 一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,该方法包括以下步骤:

[0007] 步骤S1,构建肉牛检测与多目标跟踪数据集。

[0008] 步骤S2,实现高精度上下文感知目标检测教师网络HP-CAOD-TN;

[0009] 步骤S3,训练高精度上下文感知目标检测教师网络HP-CAOD-TN;

[0010] 基于步骤S1中得到的肉牛检测与多目标跟踪数据集,对步骤S2中得到的高精度上下文感知目标检测教师网络HP-CAOD-TN进行训练。

[0011] 步骤S4,实现高效上下文感知目标检测学生网络EC-CAOD-SN;

[0012] 在经过步骤S3训练后的所述的高精度上下文感知目标检测教师网络HP-CAOD-TN中,将上下文感知注意力增强特征融合模块CAAFM中的上下文感知边界融合金字塔模块CABFP替换为学生-上下文感知边界融合金字塔S-CABFP (Student-Context-Aware Boundary Fusion Pyramid) 模块,形成学生-上下文感知注意力增强特征融合模块S-CAAFM (Student-Context-Aware Attention-Enhanced Feature Fusion Module),从而实现高效上下文感知目标检测学生网络EC-CAOD-SN。

[0013] 步骤S5,模型蒸馏:

[0014] 通过计算步骤S4得到的高效上下文感知目标检测学生网络EC-CAOD-SN的学生特征图和步骤S3得到的高精度上下文感知目标检测教师网络HP-CAOD-TN的教师特征图之间的相似度来实现模型蒸馏,最终得到目标双检测网络。

[0015] 步骤S6,实现伪深度增强卡尔曼滤波器P-DEKF:

[0016] 将伪深度信息集成到卡尔曼滤波器的状态向量中,将状态向量的维度由8维($x, y, w, h, v_x, v_y, v_w, v_h$)扩展为10维($x, y, w, h, d, v_x, v_y, v_w, v_h, v_d$)。

[0017] 其中:

[0018] x, y 表示目标边界框的中心位置坐标;

[0019] w, h 表示目标边界框的宽度和高度;

[0020] d 表示伪深度值,即表示目标距离摄像头的远近;

[0021] v_x, v_y 表示位置在 x 和 y 方向的速度;

[0022] v_w, v_h 表示宽度和高度的变化速度;

[0023] v_d 表示伪深度的变化速度。

[0024] 步骤S7,双检测与伪深度运动模型驱动的肉牛多目标跟踪方法:

[0025] 基于S5得到的目标双检测网络,使用步骤S6中伪深度增强卡尔曼滤波器P-DEKF模拟目标的状态进行伪深度运动模型驱动,并使用匈牙利算法进行逐帧数据关联来共同实现多目标跟踪。

[0026] 步骤S8,后处理:

[0027] 采用线性插值方法,在每个轨迹中缺失的检测位置填充缺少的检测框。

[0028] 本发明与现有技术相比,具有如下技术效果:

[0029] (I) 本发明专门为肉牛多目标跟踪任务设计。通过引入高精度上下文感知目标检测教师网络HP-CAOD-TN和高效上下文感知目标检测学生网络EC-CAOD-SN,本发明不仅在多目标跟踪中实现了高精度的目标检测,还兼顾了低计算负担。两者的结合使得系统能够灵活高效地适应多种养殖场景的复杂任务需求。

[0030] (II) 本发明通过将伪深度信息纳入卡尔曼滤波器的状态空间,使得滤波器能够在平面检测基础上间接感知目标的深度变化。无需依赖真实的深度传感器或精确的深度测量,系统能够通过目标在图像中的位置和尺寸推断其远近关系。伪深度增强卡尔曼滤波器P-DEKF显著提高了目标在密集遮挡和复杂背景下的跟踪稳定性与连续性,弥补了传统二维跟踪方法在深度判断上的不足。

[0031] (III) 本发明所构建的肉牛多目标跟踪数据集涵盖了多种真实养殖场景,方法针对性地解决了密集遮挡、背景复杂、光照变化等实际问题。基于此,提出的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法能够在各种生产环境中满足肉牛定位与跟踪的需求,为

智能化、自动化的现代畜牧管理提供了技术支持。

[0032] (IV) 本发明的学生模型在继承教师模型关键特征的同时,大幅降低了计算成本。伪深度信息的引入不仅没有显著增加计算复杂度,反而提升了目标跟踪的精度和鲁棒性,从而提供了一个在性能和效率上兼备的解决方案。

[0033] (V) 针对多目标跟踪中的检测缺失问题,本发明采用了线性插值方法,有效填补了轨迹中的缺失检测框,充分利用了轨迹的时空连续性,从而保持了跟踪的完整性。

[0034] (VI) 本发明结合无外观模型AFLink,仅通过时空信息来预测轨迹之间的连通性,进一步增强了方法在遮挡、目标运动不规则等复杂环境下的稳定性与准确性。

附图说明

[0035] 图1是本发明双检测与伪深度运动模型驱动的肉牛多目标跟踪方法的框架图。

[0036] 图2是本发明高精度上下文感知目标检测教师网络HP-CAOD-TN的结构图。

[0037] 图3是本发明并行上下文感知特征网络的结构图。

[0038] 图4是本发明上下文感知注意力增强特征融合模块的结构图。

[0039] 图5是本发明双池通道注意力模块的结构图。

[0040] 图6是本发明三重注意力融合模块的结构图。

[0041] 图7是本发明双重门控机制来控制特征融合模块的结构图。

[0042] 图8是本发明频谱增强融合模块的结构图。

[0043] 图9是本发明OmniKernel模块的结构图。

[0044] 图10是本发明学生-上下文感知注意力增强特征融合模块S-CAAFM模块的结构图。

[0045] 图11是本发明方法和对比方法的结果对比图。

[0046] 以下结合实施例对本发明的具体内容作进一步详细解释说明。

具体实施方式

[0047] 需要说明的是,本发明中的所有的模型、网络、模块和方法,如无特殊说明,全部均采用现有技术中已知的模型、网络、模块和方法。

[0048] 为了满足真实养殖环节中对肉牛目标跟踪的需求,并应对复杂环境下的挑战,如背景复杂、密集遮挡等,本发明首先收集了一个涵盖多种场景的真实肉牛多目标跟踪数据集。基于这一数据集,本发明提出了一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法(Dual Detection and Pseudo-Depth Motion Model Driven Beef Cattle Multi-Object Tracking Method,DDPDM)。该方法特别针对肉牛目标跟踪进行设计,具有以下创新性组成部分:

[0049] 本发明的高精度上下文感知目标检测教师网络HP-CAOD-TN(High-Precision Context-Aware Object Detection Teacher Network,)由多个关键模块组成,专门解决复杂环境中的目标检测问题。首先,提出并设计了并行上下文感知特征模块(Parallelized Context-Aware Feature,PCAF),结合基本卷积层构建了并行上下文感知特征网络(Parallelized Context-Aware Feature Network,PCAFNet),从而提取更丰富的特征信息,增强了对目标的理解。接着,提出了上下文感知注意力增强特征融合模块(Context-Aware Attention-Enhanced Feature Fusion Module,CAAFM),该模块结合了基于注意力

机制的尺度内特征交互模块(Attention-based Intra-scale Feature Interaction, AIFI)和上下文感知边界融合金字塔(Context-Aware Boundary Fusion Pyramid, CABFP),显著提升了对目标边界和细节的捕捉能力。为进一步提升目标检测精度,教师网络还引入了IoU感知查询选择机制和带有辅助预测头的解码器,确保目标检测更加精准高效。

[0050] 为了提升计算效率并减少计算负担,本发明还设计了高效上下文感知目标检测学生网络EC-CAOD-SN(Efficient Context-Aware Object Detection Student Network),该网络结构与教师网络相似,但提出学生-上下文感知边界融合金字塔模块S-CABFP(Student-Context-Aware Boundary Fusion Pyramid)替代CABFP模块,显著减少了计算开销。通过应用模型蒸馏技术,学生网络能够在保持较低计算负担的同时,接近甚至超越教师网络的检测精度,从而实现高效且精确的目标检测。

[0051] 本发明的另一重要组成部分是伪深度增强卡尔曼滤波器P-DEKF(Pseudo-Depth Enhanced Kalman Filter),该方法通过引入伪深度信息并将其作为卡尔曼滤波器状态空间的一部分,显著提高了目标跟踪的稳定性和连续性,且无需依赖真实的深度传感器或精确的深度测量。该创新设计大大增强了多目标跟踪在复杂环境中的鲁棒性,尤其在目标遮挡和密集分布的情况下,能够有效保持目标追踪的准确性和连贯性。

[0052] 综合以上技术,本发明提出了一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,兼顾了精度与效率,提供了一个高效、稳定的实时多目标跟踪解决方案。为解决多目标跟踪中的检测缺失问题(例如某些帧未能检测到目标),本发明采用了线性插值方法,通过填补缺失的检测框,充分利用轨迹的时间和空间连续性。同时,结合无外观模型AFLink,利用时空信息预测轨迹之间的连通性,进一步提升了跟踪的准确性和鲁棒性。

[0053] 以下给出本发明的具体实施例,需要说明的是本发明并不局限于以下具体实施例,凡在本申请技术方案基础上做的等同变换均落入本发明的保护范围。

[0054] 实施例:

[0055] 本实施例给出一种双检测与伪深度运动模型驱动的肉牛多目标跟踪方法,如图1所示,该方法包括以下步骤:

[0056] 步骤S1,构建肉牛检测与多目标跟踪数据集:

[0057] 收集来自真实监控视角的五种不同养殖场景的视频,使用DarkLabel工具对视频进行标注,获取标准数据格式的标注数据,将标注数据转换为肉牛检测与多目标跟踪数据集。

[0058] 本步骤中,这些视频涵盖了各种干扰和挑战,如遮挡、阴影、相似外观等,且更加贴近实际牛场环境。牛群通常是集体饲养的,且往往不会位于图像的中心。

[0059] 本实施例中具体的,收集了来自真实监控视角下的5种不同养殖场景的视频,视频的平均时长为35分钟,采用MP4格式,分辨率为 1920×1080 像素,帧率为24帧/秒。特别地,在肉牛养殖的不同场景中,存在多种干扰因素影响检测性能,包括:由于摄像机安装在棚顶角落,导致视频中肉牛的尺度变化;由于视频采样时间跨度较大,造成的光照强度变化;肉牛之间的相互遮挡;顶棚、围栏等外物引起的遮挡;肉牛奔跑等行为引起的尘土干扰;以及肉牛的外观特征不如行人明显,特别是在肉牛体色与泥土地面颜色相近时,产生的背景干扰。随后,我们使用DarkLabel工具对肉牛视频进行标注,得到标准数据格式,并将标注数据转换为适用于肉牛检测和多目标跟踪的定制数据集,即肉牛检测与多目标跟踪数据集。该数

据集中的肉牛目标检测部分命名为Beef-Cattle,包括11936张训练集图片,1492张验证集图片和1492张测试集图片,训练集、验证集与测试集的比例为8:1:1。用于测试肉牛多目标跟踪的视频共有5个。

[0060] 步骤S2,实现高精度上下文感知目标检测教师网络HP-CAOD-TN:

[0061] 本步骤中具体的,如图2所示,高精度上下文感知目标检测教师网络HP-CAOD-TN (High-Precision Context-Aware Object Detection Teacher Network,HP-CAOD-TN)的关键组件包括:并行上下文感知特征网络PCAFNet (Parallelized Context-Aware Feature Network)、上下文感知注意力增强特征融合模块CAAFM (Context-Aware Attention-Enhanced Feature Fusion Module)、IoU感知查询选择机制和带有辅助预测头的解码器。

[0062] 并行上下文感知特征网络PCAFNet由基本卷积模块和PCAF模块 (Parallelized Context-Aware Feature) 组成。

[0063] 上下文感知注意力增强特征融合模块CAAFM结合了基于注意力机制的尺度内特征交互模块AIFI (Attention-based Intra-scale Feature Interaction) 和上下文感知边界融合金字塔CABFP (Context-Aware Boundary Fusion Pyramid)。

[0064] 上下文感知边界融合金字塔CABFP包括双池通道注意力模块DPCA (Dual-Pooling Channel Attention Module)、三重注意力融合模块TAFM (Tri-Attention Fusion Module)、双重门控机制来控制特征融合模块DGAFM (Dual-Gate Attention Fusion Module) 以及频谱增强融合模块SEFM (Spectrum-Enhanced Fusion Module)。

[0065] 步骤S2中进一步的,高精度上下文感知目标检测教师网络HP-CAOD-TN的构建方法为:

[0066] 步骤S201,构建并行上下文感知特征网络PCAFNet:

[0067] 将输入的图像数据送入并行上下文感知特征网络PCAFNet中,生成 {P2、P3、P4、P5} 四个层次的特征图。

[0068] 本实施例中,具体的并行上下文感知特征网络的结构如图3所示。在此,PCAF模块作为C2f架构的增强变体,旨在通过并行处理和先进的注意力机制优化特征提取性能。该模块在保持紧凑架构的同时,能够高效地处理计算任务。通过在瓶颈层中引入并行化块感知注意力 (Parallelized Patch-Aware Attention,PPA) 机制,PCAF模块显著提升了模型在捕捉复杂特征表示方面的能力,同时避免了计算开销的大幅增加。具体操作如下:

[0069] 模块首先接收一个具有 c_1 个通道的输入特征图。通过使用 1×1 卷积层 cv_1 ,将通道维度从 c_1 扩展到 $2c$,其中 c 是由扩展因子 e 决定的隐藏通道数。接着, cv_1 的输出沿通道维度进行分割,得到两个特征图 y_1 和 y_2 ,每个特征图具有 c 个通道。分支 y_1 直接传递到拼接阶段,不进行额外处理,保留原始特征信息。

[0070] 与传统的C2f模块不同,PCAF集成了 n 个并行的PPA模块,每个PPA模块独立处理 y_2 分支,实现多样化的特征提取。PPA模块通过注意力机制聚焦于特征图的显著区域,从而增强模型在空间维度上的判别能力。随后,将PPA模块的输出与 y_1 分支沿通道维度拼接,得到一个具有 $(2+n)c$ 个通道的组合特征图。

[0071] 最后,使用 1×1 卷积层 cv_2 将拼接后的特征图通道数从 $(2+n)c$ 降维回期望的输出通道数 c_2 。此时,也可以根据需要在该层引入激活函数 (如FReLU),进一步增加非线性,强化特征表示能力。最终,输出为一个具有 c_2 个通道的特征图,其中包含经过PCAF模块处理和聚合

的精炼信息。

[0072] 步骤S202,构建上下文感知注意力增强特征融合模块CAAFM:

[0073] 将步骤S201中得到的P5特征图输入到注意力机制的尺度内特征交互模块AIFI的内部交互,输出交互后的F5特征图。

[0074] 将步骤S201中得到的P2特征图、P3特征图、P4特征图和F5特征图输入到上下文感知边界融合金字塔CABFP,对P2特征图、P3特征图、P4特征图和F5特征图进行跨尺度的特征融合拼接,输出Memory特征图。

[0075] 本实施例中具体的,上下文感知注意力增强特征融合模块CAAFM的结构如图4所示,P5特征图首先输入到注意力机制的尺度内特征交互模块AIFI,经过内部处理后输出交互后的F5特征图。将P2、P3、P4和F5特征图输入到上下文感知边界融合金字塔CABFP中。该金字塔通过DPCA、TAFM、DGAFM和SEFM四个子模块对输入特征图进行跨尺度的特征融合与拼接,最终生成Memory特征图。

[0076] 步骤S202中的构建过程进一步包括以下步骤:

[0077] 步骤S20201,构建双池通道注意力模块DPCA:

[0078] 双池通道注意力模块(DPCA)如图5所示,旨在通过结合自适应平均池化和自适应最大池化操作,动态调整输入特征图中各通道的重要性,从而增强关键特征的表达能力。具体流程如下:

[0079] 首先,输入特征图X具有C个通道。模块通过两个独立的池化操作对输入特征图进行处理:一是自适应平均池化(AdaptiveAvgPool2d(1)),将每个通道的空间维度压缩为单一数值,捕捉全局的上下文信息;二是自适应最大池化(AdaptiveMaxPool2d(1)),同样将每个通道的空间维度压缩为单一数值,但侧重于捕捉特征图中的显著特征。接下来,经过池化操作后的两个特征图分别通过共享的1x1卷积层(conv1),将通道数从C降低到 $\frac{C}{r}$,其中r为通道压缩比。随后,经过ReLU激活函数(ReLU)增加非线性能力,再通过第二个1x1卷积层(conv2)将通道数恢复至原始的C。然后,将通过平均池化路径和最大池化路径处理后的两个特征图相加,得到一个综合的注意力特征图。该综合特征图进一步通过Sigmoid激活函数(Sigmoid),生成介于0和1之间的通道注意力权重。最后,根据模块初始化时的标志位flag决定输出结果。如果flag=True,则将生成的注意力权重与原始输入特征图X逐元素相乘,实现特征的加权重标定,增强重要通道的特征表达;如果flag=False,则仅返回注意力权重,不对输入特征图进行加权处理。通过上述流程,双池通道注意力模块(DPCA)能够有效地识别并强化输入特征图中具有重要性的通道特征,同时抑制不重要的通道特征,从而提升整体模型的表现能力。

[0080] 步骤S20202,构建三重注意力融合模块TAFM:

[0081] 三重注意力融合模块(TAFM)如图6所示,旨在通过整合通道注意力、空间注意力和像素注意力机制,实现对输入特征图的多层次加权融合,从而增强特征表示能力。具体流程如下:

[0082] 首先,模块接收一对输入特征图x和y,它们通常来自不同的网络分支或不同的尺度层次。模块通过将这两个特征图逐元素相加,生成初始融合特征图 $initial = x + y$ 。这一操作有效地整合了来自不同来源的特征信息,为后续的注意力机制提供了融合后的基础特征。接下来,模块分别应用通道注意力和空间注意力机制对初始融合特征图进行处理。具体

来说,通道注意力模块(ChannelAttention_CGA)通过计算每个通道的重要性权重 $cattn$,强调对任务有重要贡献的通道特征;而空间注意力模块(SpatialAttention_CGA)则通过计算每个空间位置的重要性权重 $sattn$,突出特征图中显著的空间区域。这两种注意力权重 $cattn$ 和 $sattn$ 相加,得到综合注意力权重 $pattn1 = sattn + cattn$,进一步融合了通道和空间层面的注意力信息。随后,像素注意力模块(PixelAttention_CGA)利用综合注意力权重 $pattn1$ 对初始融合特征图进行像素级别的注意力计算,生成最终的像素注意力权重 $pattn2 = \sigma(\text{PixelAttention_CGA}(\text{initial}, pattn1))$,其中 σ 表示Sigmoid激活函数,将权重限制在0到1之间,以确保加权融合的平滑性和稳定性。在特征重标定阶段,模块根据像素注意力权重 $pattn2$

[0083] 对输入特征图 x 和 y 进行加权融合,得到融合后的特征图: $result = initial + pattn2 \times x + (1 - pattn2) \times y$ 。这一操作动态调整了不同特征图的贡献程度,既强化了重要特征的表达,又抑制了不重要的特征,从而提升了特征表示的丰富性和模型的判别能力。最后,模块通过一个 1×1 卷积层(Conv2d(1x1))对融合后的特征图进行进一步处理,整合和压缩特征信息,生成最终输出特征图。此卷积操作不仅有助于特征的整合,还能提升特征的表达能力,为后续的网络层提供高质量的特征输入。综上所述,三重注意力融合模块(TAFM)通过集成通道注意力、空间注意力和像素注意力机制,实现了对输入特征图的多层次加权融合,显著提升了特征表达能力和模型性能。

[0084] 步骤S20203,构建双重门控机制来控制特征融合模块DGAFM:

[0085] 双重门控机制来控制特征融合模块(DGAFM)如图7所示,通过双重门控机制,动态控制高层特征(High-level Feature)和低层特征(Low-level Feature)的融合比例,实现更为灵活和精细的特征整合。具体流程如下:

[0086] 首先,模块接收一对输入特征图 $H_feature$ (高层特征)和 $L_feature$ (低层特征),它们通常来自不同的网络分支或不同的尺度层次。为了开始特征融合,模块分别通过全连接层 $fc1$ 和 $fc2$ 对 $L_feature$ 和 $H_feature$ 进行 1×1 卷积处理,将通道数从原始数值降低到一半($input_dim // 2$),实现特征变换和通道压缩。接下来,模块将变换后的 $L_feature$ 和 $H_feature$ 分别通过Sigmoid激活函数,生成门控权重 $g_L_feature$ 和 $g_H_feature$ 。这些门控权重用于动态调整特征的融合比例,确保重要特征得到强化,而不重要的特征被抑制。随后,模块将经过门控权重处理后的 $L_feature$ 和 $H_feature$ 分别通过 1×1 卷积层 d_in1 和 d_in2 ,保持通道数不变。这一步骤进一步提取和变换特征,为后续的融合操作做准备。在特征融合阶段,模块对 $L_feature$ 和 $H_feature$ 进行加权融合,这一操作通过门控权重动态调整高层和低层特征的融合比例,确保重要特征得到强化,同时抑制不重要的特征。为了确保高层特征 $H_feature$ 与低层特征 $L_feature$ 在空间维度上的一致性,模块对 $H_feature$ 进行上采样,使其尺寸与 $L_feature$ 相同。然后,将融合后的 $H_feature$ 和 $L_feature$ 在通道维度上进行拼接,形成一个具有 $input_dim$ 通道数的综合特征图。最后,模块通过一个 3×3 卷积层 $conv$ 对拼接后的特征图进行进一步处理,整合和压缩特征信息,生成最终的输出特征图 out 。这一过程不仅有助于特征的整合,还能提升特征的表达能力,为后续的网络层提供高质量的特征输入。通过上述流程,双重门控注意力融合模块(DGAFM)能够有效地结合高层和低层特征,通过动态调整融合比例,增强关键特征的表达,同时抑制不重要的特征,从而提升整体模型的性能和表达能力。

[0087] 步骤S20204,构建频谱增强融合模块SEFM:

[0088] 频谱增强融合模块 (SEFM) 如图8所示,其核心目标是通过空间卷积、频域变换和自适应增强机制对特征图进行处理,从而提升特征的表达能力。具体流程如下:

[0089] 首先,SEFM模块接收一个形状为 $[\text{batch_size}, \text{dim}, H, W]$ 的输入特征图,并通过一个 1×1 卷积 (Conv1) 进行初步处理。此卷积层的作用是对输入特征进行维度调整,生成一个精简的特征图。经过卷积层处理后,特征图被分为两个分支:

[0090] **Ok_Branch**:该分支表示输入特征图的一部分(根据比例 e 划分的通道),该分支将输入到OmniKernel模块进行进一步处理。

[0091] **Identity**:该分支为输入特征图的剩余部分,保持原始特征不变,用于后续与处理后的特征进行融合。

[0092] OmniKernel模块如图9所示,负责在空间域和频域对特征进行复杂的增强操作。其处理流程如下:

[0093] **初步卷积与激活**:输入特征图首先经过一个 1×1 的卷积 (Conv2d (1×1)),此操作用于调整特征图的维度,确保后续操作能够在统一的尺度上进行。紧接着,卷积输出通过GELU激活函数进行非线性变换,提升特征的表达能力。

[0094] **频域增强 (FCA)**:在频域增强部分,特征图经过自适应池化后,得到通道注意力 (x_{att})。随后,特征图经过傅里叶变换 (FFT),将特征从空间域转换到频域。在频域中,通过元素级乘法将通道注意力与频域特征进行调制,进而提升频域特征的表达能力。经过逆傅里叶变换 (IFFT),将其恢复到空间域,并取绝对值,得到频域增强后的特征图。

[0095] **空间域增强 (SCA)**:空间域增强部分通过自适应池化和卷积操作,进一步增强特征图的空间信息。特别地,在空间域增强后,特征图与频域增强后的特征图进行加权融合,从而使得模型能够同时关注空间信息和频域信息,捕获更细粒度的特征。

[0096] **深度可分离卷积 (DwConv)**:OmniKernel模块还包含多个深度可分离卷积操作 ($\text{dw}_{13}, \text{dw}_{31}, \text{dw}_{33}, \text{dw}_{11}$)。这些卷积操作帮助进一步提取局部空间特征,并通过不同的卷积核尺寸进行多尺度融合,提升空间特征的丰富性。

[0097] **自适应特征重标定 (FGM)**:在完成空间和频域增强之后,特征图还会通过FGM模块 (Frequency and Spatial Modulation) 进行进一步的自适应特征重标定。FGM模块通过频域和空间域的自适应融合,进一步调整增强后的特征图。具体来说,FGM模块使用频域和空间域的增强信息,结合加权系数 (α 和 β),来重标定输出特征,从而确保最终特征的表达能力最大化。

[0098] **激活函数与输出**:处理后的特征图通过ReLU激活函数进行非线性变换,以提升特征的表达能力。最后,通过一个输出卷积层 (Conv2d (1×1)) 生成最终的输出特征图,完成SEFM模块Ok_Branch分支的处理流程。

[0099] 将处理后的Ok_Branch(来自OmniKernel的输出)和原始的Identity分支拼接在一起,合并成一个新的特征图。拼接操作通过`torch.cat()`完成,随后,拼接后的特征图通过另一个 1×1 卷积 (Conv2) 进行进一步处理,生成最终的输出特征图。

[0100] 最终,经过卷积层处理后的特征图作为输出返回。该输出特征图融合了空间、频域信息以及原始特征,具备更强的表达能力。

[0101] SEFM模块通过结合空间卷积和频域变换来提升特征表达能力。其核心步骤包括:

输入特征的初步处理、分支操作、频域和空间域的自适应增强以及特征融合。通过OmniKernel模块,SEFM能够在空间和频域上对特征进行多维度优化,从而增强模型的表达力和鲁棒性。最终,经过卷积处理后的融合特征将作为输出,提供更丰富的特征表示。

[0102] 步骤S203,构建IoU感知查询选择机制:

[0103] 计算步骤S202中得到的Memory特征图中每个特征对应的预测边界框与真实边界框的回归与分类损失,并且在分类损失中加入IOU,保证网络输出的位置置信度与类别置信度的一致性,根据损失选择其中的Top-K个特征。

[0104] 步骤S204,构建带有辅助预测头的解码器:

[0105] Decoder接收步骤S203中筛选出的Top-K个特征,进行初始目标查询和混合编码器输出的Memory特征序列,通过多层自注意力和交叉注意力迭代优化目标查询,最终输出检测框的类别和坐标;Head将Decoder输出的检测框的类别和坐标映射到检测框上。

[0106] 步骤S3,训练高精度上下文感知目标检测教师网络HP-CAOD-TN:

[0107] 基于步骤S1中得到的肉牛检测与多目标跟踪数据集,对步骤S2中得到的高精度上下文感知目标检测教师网络HP-CAOD-TN进行训练,训练采用的损失函数L包括目标边界框回归损失 L_{box} (Bounding Box Regression Loss)和分类损失 L_{cls} (Classification Loss)两部分,即 $L = L_{\text{box}} + L_{\text{cls}}$;反向传播损失函数L,重复迭代直至迭代次数达到预设初始值时完成训练。

[0108] 本步骤中,目标边界框回归损失 L_{box} 定义为generalized IoU (GIoU)和L1损失的加权和,即

$$[0109] \quad L_{\text{box}}(\hat{b}, b) = \lambda L_{\text{GIoU}}(\hat{b}, b) + \lambda_{L_1} \|b - \hat{b}\|_1;$$

[0110] 式中:

[0111] $\hat{b}$ 表示预测边界框;

[0112] b表示真实边界框;

[0113] L_{GIoU} 表示GIoU损失;

[0114] λ 表示权重参数,用于调整 L_{GIoU} 损失在 L_{box} 损失中的比例;

[0115] λ_{L_1} 表示权重参数,用于调整L1损失在 L_{box} 损失中的比例。

[0116] 本步骤中,分类损失 L_{cls} 采用的是可变焦点损失(VFL,varifocal loss),即:

$$[0117] \quad L_{\text{cls}} = \text{VFL}(p, q) = \begin{cases} -q(q \log(p) + (1 - q) \log(1 - p)), & q < 0 \\ -\alpha p^\kappa \log(1 - p), & q = 0 \end{cases};$$

[0118] 式中:

[0119] VFL表示可变焦点损失;

[0120] p表示预测的实例感知分类分数,这是模型预测的每个实例的分类得分;

[0121] q表示目标得分;

[0122] α 和 κ 均表示超参数。

[0123] 步骤S4,实现高效上下文感知目标检测学生网络EC-CAOD-SN:

[0124] 在经过步骤S3训练后的高精度上下文感知目标检测教师网络HP-CAOD-TN中,将上下文感知注意力增强特征融合模块CAAFM中的上下文感知边界融合金字塔模块CABFP替换为学生-上下文感知边界融合金字塔S-CABFP(Student-Context-Aware Boundary Fusion

Pyramid) 模块,形成学生-上下文感知注意力增强特征融合模块S-CAAFM(Student-Context-Aware Attention-Enhanced Feature Fusion Module),从而实现高效上下文感知目标检测学生网络EC-CAOD-SN。

[0125] 本实施例中,学生-上下文感知注意力增强特征融合模块S-CAAFM如图10所示。

[0126] 步骤S5,模型蒸馏:

[0127] 通过计算步骤S4得到的高效上下文感知目标检测学生网络EC-CAOD-SN的学生特征图和步骤S3得到的高精度上下文感知目标检测教师网络HP-CAOD-TN的教师特征图之间的相似度来实现模型蒸馏,最终得到目标双检测网络。

[0128] 步骤S5中,模型蒸馏的具体方法如下:

[0129] 步骤S501,特征图对齐操作:

[0130] 对于学生模型和教师模型生成的特征图,我们首先要进行对齐操作。学生模型和教师模型的特征图可能在通道数、尺寸等方面存在差异,因此我们需要通过卷积层进行对齐,使得它们的特征图在通道数上匹配。

[0131] $\text{aligned_feat}_s = \text{Conv2d}(f_s), \text{aligned_feat}_t = \text{Conv2d}(f_t);$

[0132] 式中:

[0133] f_s 和 f_t 分别表示学生和教师模型的特征图;

[0134] aligned_feat_s 和 aligned_feat_t 分别表示对齐后的学生和教师模型的特征图;

[0135] Conv2d表示一个1x1卷积操作,它将学生和教师的特征图映射到相同的通道数。

[0136] 这样,我们就确保了学生和教师特征图在通道上的一致性。

[0137] 步骤S502,标准化特征图:

[0138] 对对齐后的特征图进行标准化,确保每一通道的特征具有零均值和单位方差。

[0139] $\hat{x} = \frac{x - \mu}{\sigma};$

[0140] 式中:

[0141] x 表示输入的特征图或特征,通常是学生或教师模型的输出;

[0142] μ 表示输入 x 的均值,计算时是按批次(batch)来求的,表示每个通道的平均值。

[0143] σ 表示输入 x 的标准差,表示每个通道的分布范围。

[0144] $\hat{x}$ 经过标准化后的特征,具有零均值和单位标准差。标准化的目的是让特征在训练过程中更稳定,避免数值范围过大或过小导致训练困难。

[0145] 步骤S503,计算特征图的相似度:

[0146] 计算学生和教师模型之间的跨通道相关性,通过计算学生和教师特征图的相关性矩阵来量化它们的相似度。为了得到相似度,我们首先将特征图展平为二维矩阵,然后计算每对通道之间的相关性。

[0147] $f_s \in \mathbb{R}^{bsz \times ch \times (H \times w)}, f_t \in \mathbb{R}^{bsz \times ch \times (H \times w)};$

$$\text{emd}_s = f_s \cdot f_s^T, \text{emd}_t = f_t \cdot f_t^T;$$

[0148] 式中:

[0149] f_s 和 f_t 分别表示学生和教师模型的特征图;

[0150] bsz表示批次大小;

[0151] ch表示通道数;

[0152] H和w分别表示特征图的高度和宽度。

[0153] 通过将每个特征图展平成二维矩阵,我们可以得到形状为 $bsz \times ch \times (H \times w)$ 的特征图。 emd_s 和 emd_t 分别表示学生和教师特征图的相关性矩阵, f_s^T 和 f_t^T 表示学生和教师特征图的转置。

[0154] 步骤S504:标准化相关性矩阵:

[0155] 对计算得到的相关性矩阵进行L2范数标准化,以确保计算出的相似度具有一致的尺度。

$$[0156] \quad emd_s = \frac{emd_s}{\|emd_s\|_2}, \quad emd_t = \frac{emd_t}{\|emd_t\|_2};$$

[0157] 式中:

[0158] $\|\cdot\|_2$ 表示L2范数,用于标准化相关性矩阵,使其具有统一的尺度;

[0159] emd_s 表示学生特征图的相关性矩阵,计算了通道之间的相似度,通过归一化,使得每个矩阵的范数为1,避免数值过大导致训练不稳定。

[0160] emd_t 表示教师特征图的相关性矩阵,归一化操作与学生特征图相同。

[0161] 步骤S505,计算损失:

[0162] 对于每一对学生和教师特征图,计算它们的相关性矩阵之间的差异。

$$[0163] \quad loss = \frac{1}{bsz \times ch \times bsz} \sum_{i,j} (emd_s - emd_t)^2;$$

[0164] 式中:

[0165] emd_s 和 emd_t 表示学生和教师的相关性矩阵;

[0166] i和j表示批次中的索引;

[0167] bsz表示批次大小;

[0168] ch表示通道数;

[0169] loss表示损失,用于度量学生和教师在跨通道相关性上的差异。

[0170] 步骤S506,加权损失:

[0171] 每一层的损失将按重要性进行加权,并进行汇总,得到最终的总损失。

$$[0172] \quad total_loss = \sum_{i=1}^L w_i \cdot loss_i;$$

[0173] 式中:

[0174] L表示特征图层的总数;

[0175] w_i 表示每一层的权重;

[0176] loss表示每一层计算得到的损失。

[0177] total_loss表示损失的加权和,用于表示学生模型与教师模型在特征图上的总体差异。

[0178] 步骤S507,反向传播与优化:

[0179] 在计算出总损失后,使用反向传播算法来优化学生模型的参数,使其在特征空间上尽可能接近教师模型的表现。反向传播过程通过总损失来更新学生模型的参数。

$$[0180] \quad \nabla \theta_s total_loss;$$

[0181] 式中:

[0182] $\nabla \theta_s$ 表示学生模型参数 θ_s 的梯度,通过反向传播来更新参数。

[0183] 步骤S6,实现伪深度增强卡尔曼滤波器P-DEKF:

[0184] 本步骤中,伪深度是一种基于图像中目标的位置和尺寸,间接估算目标深度(即距离摄像头的远近)的方式。假设图像中y坐标越大(即目标越靠近图像底部),伪深度越小,表示目标距离摄像头越远。

[0185] 将伪深度信息集成到卡尔曼滤波器的状态向量中,将状态向量的维度由8维(x,y,w,h,vx,vy,vw,vh)扩展为10维(x,y,w,h,d,vx,vy,vw,vh,vd)。

[0186] 其中:

[0187] x,y表示目标边界框的中心位置坐标;

[0188] w,h表示目标边界框的宽度和高度;

[0189] d表示伪深度值,即表示目标距离摄像头的远近;

[0190] vx,vy表示位置在x和y方向的速度;

[0191] vw,vh表示宽度和高度的变化速度;

[0192] vd表示伪深度的变化速度。

[0193] 步骤S6中,扩展的方法包括以下步骤:

[0194] 步骤S60,定义状态向量:

[0195] 扩展后的状态向量定义为:

$$[0196] \quad \mathbf{x} = \begin{bmatrix} x \\ y \\ w \\ h \\ d \\ v_x \\ v_y \\ v_w \\ v_h \\ v_d \end{bmatrix};$$

[0197] 步骤S602,建立运动模型:

[0198] P-DEKF假设目标的运动遵循恒速模型,即位置和伪深度按照其各自的速度线性变化。状态转移矩阵F定义为:

$$[0199] \quad \mathbf{F} = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & \Delta t & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & \Delta t & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & \Delta t & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix};$$

[0200] 其中:

[0201] Δt 为时间步长。

[0202] 该矩阵确保位置和伪深度随着时间步长线性变化,同时速度保持恒定。

[0203] 步骤S603,建立观测模型:

[0204] 观测向量z包括目标的中心位置、宽度、高度及伪深度:

[0205]
$$z = \begin{bmatrix} x \\ y \\ w \\ h \\ d \end{bmatrix};$$

[0206] 观测矩阵H将状态向量映射到观测空间:

[0207]
$$H = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \end{bmatrix};$$

[0208] 该矩阵表明,观测值直接对应于状态向量中的位置、尺寸和伪深度部分。

[0209] 步骤S604,伪深度增强卡尔曼滤波器P-DEKF初始化:

[0210] 在伪深度增强卡尔曼滤波器P-DEKF的初始化步骤中,基于初始测量值(包括伪深度)设定状态向量和协方差矩阵。初始状态向量 x_0 包含观测到的位置、尺寸和伪深度,速度部分初始化为零:

[0211]
$$x_0 = \begin{bmatrix} x_0 \\ y_0 \\ w_0 \\ h_0 \\ d_0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 0 \end{bmatrix};$$

[0212] 其中:

[0213] x_0, y_0, w_0, h_0, d_0 表示初始观测值,速度部分初始化为零。

[0214] 协方差矩阵 P_0 根据位置、尺寸和伪深度的不确定性设定为对角矩阵:

[0215]
$$P_0 = \text{diag}(\sigma_x^2, \sigma_y^2, \sigma_w^2, \sigma_h^2, \sigma_d^2, \sigma_{v_x}^2, \sigma_{v_y}^2, \sigma_{v_w}^2, \sigma_{v_h}^2, \sigma_{v_d}^2);$$

[0216] 其中:

[0217] σ 表示各状态变量的不确定性。

[0218] 步骤S605,预测:

[0219] 在预测步骤中,基于运动模型预测下一个时间步的状态和协方差:

[0220]
$$x_{k|k-1} = F \cdot x_{k-1|k-1};$$

[0221]
$$P_{k|k-1} = F \cdot P_{k-1|k-1} \cdot F^T + Q;$$

[0222] 其中:

[0223] F表示状态转移矩阵;

[0224] F^T 表示状态转移矩阵的转置;

[0225] Q表示过程噪声协方差矩阵,反映了模型预测的不确定性。

[0226] $x_{k|k-1}$ 表示预测的状态向量,基于前一时刻k-1的状态和运动模型,预测当前时刻k的状态;

[0227] $P_{k|k-1}$ 表示预测的协方差矩阵,基于前一时刻k-1的协方差和运动模型,预测当前时刻k的状态协方差。

[0228] 步骤S606,更新:

[0229] 在更新步骤中,将新的测量值融合到预测的状态中。

[0230] $y_k = z_k - H \cdot x_{k|k-1}$;

[0231] $S_k = H \cdot P_{k|k-1} \cdot H^T + R$;

[0232] $K_k = P_{k|k-1} \cdot H^T \cdot S_k^{-1}$;

[0233] $x_{k|k} = x_{k|k-1} + K_k \cdot y_k$;

[0234] $P_{k|k} = (I - K_k \cdot H) \cdot P_{k|k-1}$;

[0235] 其中:

[0236] y_k 表示创新向量,测量残差,表示观测值与预测观测值之间的差异;

[0237] S_k 表示创新协方差,表示创新向量的不确定性,结合了预测协方差和测量噪声;

[0238] K_k 表示卡尔曼增益,用于平衡预测与测量值的权重,决定如何更新状态向量;

[0239] R 表示测量噪声协方差矩阵,表示测量过程中的噪声,反映了测量值的不确定性;

[0240] $x_{k|k}$ 表示更新后的状态向量,结合预测值和测量值,更新后的当前时刻状态估计;

[0241] $P_{k|k}$ 表示更新后的协方差矩阵,更新后的状态协方差,反映了状态估计的不确定性;

[0242] I 表示单位矩阵,用于确保矩阵运算中的维度一致性;

[0243] 步骤S607,计算门控距离:

[0244] 门控距离用于判断测量值是否与预测值匹配。引入伪深度后,门控距离的计算考虑了额外的深度信息,从而提升匹配的准确性。常用的距离度量包括马氏距离(Mahalanobis Distance)和欧几里得距离(Euclidean Distance):

[0245] $\text{Mahalanobis Distance} = \sqrt{(z - Hx)^T S^{-1} (z - Hx)}$;

$\text{Euclidean Distance} = \sqrt{\sum_{i=1}^n (z_i - H_i x)^2}$;

[0246] 通过设定基于卡方分布的门控阈值,系统可以有效过滤掉不符合预测的测量值,确保跟踪的准确性和鲁棒性。

[0247] 步骤S608,计算伪深度:

[0248] 伪深度的计算基于目标在图像中的位置和尺寸,具体公式如下:

[0249] $\text{lenth} = 2000 - (y_{\text{top-left}} + h)$;

[0250] 其中: $y_{\text{top-left}}$ 表示目标边界框左上角的y坐标; h 表示目标边界框的高度。

[0251] 本实施例中,伪深度增强卡尔曼滤波器P-DEKF通过将伪深度信息集成到状态向量中,显著提升了多目标跟踪系统在复杂养殖环境中的性能。其具体流程包括状态向量的扩展、运动模型和观测模型的建立、状态的初始化、预测与更新步骤的实施以及门控距离与伪深度的计算。伪深度不仅增强了目标的区分能力和预测准确性,还提高了跟踪的稳定性和鲁棒性,且无需依赖额外的深度传感器,使得系统在实际应用中更加高效和实用。通过这一创新方法,养殖场中的肉牛多目标跟踪需求得到了有效满足,提供了一种高效、稳定且精确的实时跟踪解决方案。

[0252] 步骤S7,双检测与伪深度运动模型驱动的肉牛多目标跟踪方法:

[0253] 基于S5得到的目标双检测网络,使用步骤S6中伪深度增强卡尔曼滤波器P-DEKF模拟目标的状态进行伪深度运动模型驱动,并使用匈牙利算法进行逐帧数据关联来共同实现多目标跟踪。

[0254] 步骤S8,后处理:

[0255] 采用线性插值方法,在每个轨迹中缺失的检测位置填充缺少的检测框。

[0256] 本实施例中,在多目标跟踪中,缺失的检测(即某些帧未能检测到目标)会导致跟踪精度下降。为了解决这一问题,采用线性插值方法,在每个轨迹中缺失的检测位置填充缺少的检测框。该操作充分利用了轨迹在时间和空间上的连续性。同时,结合无外观模型AFLink,单纯依靠时空信息来预测两个轨迹之间的连通性,从而进一步提升了跟踪的准确性和鲁棒性。

[0257] 本实施例中,步骤S5中得到的目标双检测网络的评价方法为:给定肉牛图像数据,输入到步骤S5中得到的目标双检测网络中,输出肉牛检测框的类别和坐标。衡量检测准确性评价指标为准确率(Precision)、召回率(Recall)、mAP0.5和mAP0.5:0.95。除了衡量检测准确性,模型的参数量(Params)、计算量(Gflops)、推理时间(Inference Time)以及FPS(Frame Per Second)指标对于衡量模型的总体性能也十分重要。

[0258] 本实施例中,步骤S7中的肉牛多目标跟踪方法的评价为:使用HOTA(Higher Order Tracking Accuracy,高阶跟踪精度)、MOTA(Multiple Object Tracking Accuracy,多目标跟踪精度)、IDF1(ID F1 Score,身份一致性F1分数)和ID Switch(Identity Switch,身份切换次数)进行评价。

[0259] 对比例1:

[0260] 本对比例将提出的双检测网络与20种经典先进的目标检测方法进行比较,具体对比的方法有Faster R-CNN(NeurIPS'2015)、RetinaNet(ICCV'2017)、Cascade R-CNN(CVPR'2018)、Libra R-CNN(CVPR'2019)、ATSS(CVPR'2020)、Double-Head R-CNN(CVPR'2020)、GFL(Advances in Neural Information Processing Systems'2020)、EfficientDet(CVPR'2020)、Dynamic R-CNN(ECCV'2020)、DDOD(ACM MM'2021)、VarifocalNet(CVPR'2021)、TOOD(ICCV'2021)、Deformable DETR(ICLR'2021)、DAB-DETR(ICLR'2022)、DDQ(CVPR'2023)、DINO(ICLR'2023)、H-DINO(CVF'2023)、Align-DETR(arXiv'2023)、DiffusionDet(ArXiv'2023)、CO-DETR(ICCV'2023)。评价指标共有5种,分别为mAP50、mAP50-95、Params、Gflops以及FPS。

[0261] 表1将本发明实施例与其他最先进的对象检测方法进行比较

[0262]

Models	mAP50	mAP 50-95	Params	Gflops	FPS bs=1
--------	-------	--------------	--------	--------	-------------

[0263]

Faster R-CNN	85.9%	52.0%	28.3M	69.8	50.0
RetinaNet	85.5%	47.8%	19.8M	61.4	56.4
Cascade R-CNN	86.2%	56.5%	56.3M	97.9	34.4
Libra R-CNN	83.8%	51.1%	28.3M	69.8	50.0
Double-Head R-CNN	86.6%	52.6%	33.9M	344.0	15.9
Dynamic R-CNN	85.0%	58.9%	28.3M	69.8	49.5
GFL	86.6%	51.1%	19.24M	61.9	50.4
ATSS	85.5%	50.5%	32.1M	80.5	38.2
VarifocalNet	88.7%	59.2%	32.7M	75.5	30.7
TOOD	87.2%	58.2%	32.0M	78.8	28.2
DDOD	88.5%	58.9%	32.2M	71.1	34.2
EfficientDet	86.5%	57.1%	11.9M	11.7	17.0
DiffusionDet	89.7%	58.3%	—	—	29.2
Deformable DETR	86.6%	55.8%	23.5M	59.5	32.6

[0264]

DAB-DETR	83.4%	45.2%	31.0M	24.2	32.6
DDQ	88.6%	57.4%	—	—	16.9
DINO	88.5%	54.3%	32.8M	102	22.8
H-DINO	86.0%	53.4%	32.7M	120	19.2
Align-DETR	85.6%	53.9%	32.8M	102	28.8
CO-DETR	88.6%	59.7%	50.6M	—	9.1
本实施例高精度上下文感知目标检测教师网络	90.0%	62.8%	44.8M	108.1	40.1
本实施例高效上下文感知目标检测学生网络	90.1%	61.5%	36.6M	61.4	56.4

[0265] 实验验证:本对比例结果如表1所示,我们将本发明实施例的双检测网络与20种经典的目标检测方法进行了全面对比,评价指标涵盖了mAP50、mAP50-95、Params、Gflops和FPS。实验结果表明,本实施例的目标检测学生网络和教师网络在多个指标上表现出色,特别是在精度(mAP50)方面,学生网络(90.1%)和教师网络(90.0%)的表现优于所有其他方法,尤其是在与VarifocalNet(88.7%)和DiffusionDet(89.7%)的比较中展现了卓越的性能。在mAP50-95上,教师网络(62.8%)和学生网络(61.5%)也超过了大多数经典方法,如Deformable DETR(55.8%)和Cascade R-CNN(56.5%),显示出在多尺度目标检测中的优势。在模型复杂度方面,虽然本实施例的参数量(教师网络为44.8M,学生网络为36.6M)和计算量(教师网络为108.1Gflops,学生网络为61.4Gflops)相较于轻量级模型如EfficientDet(11.9M)和GFL(19.24M)较高,但依然保持了较为优化的性能平衡。最后,在推理速度(FPS)上,学生网络(56.4FPS)明显优于Double-Head R-CNN(15.9FPS)和H-DINO(19.2FPS),表明其在高效性方面也具有显著优势。总体而言,本实施例在精度、效率和计算复杂度之间取得了良好的平衡,展现了其在目标检测任务中的优异性能。

[0266] 对比例2:

[0267] 本对比例给出一种高精度上下文感知目标检测教师网络,通过逐步添加步骤S201中并行上下文感知特征网络PCAFNet以及步骤S202中上下文感知注意力增强特征融合模块(CAAFm)最终构成实施例。评价指标共有6种,分别为Precision、Recall、mAP50、mAP50-95、Params(M)、Gflops。

[0268] 表2逐步添加模块后的教师网络检测结果

实验	P/%	R/%	mAP50/%	mAP50-95/%	Params	Gflops
基线	86.0	84.1	88.4	59.0	38.6	56.9
[0269] +PCAFNet	86.4	85.2	88.9	59.8	35.0	60.2
+CAAFM 本 实施例方法	89.6	86.7	90.0	62.8	44.8	108.1

[0270] 实验验证:本对比例结果如表2所示,展示了通过逐步添加并行上下文感知特征网络PCAFNet和上下文感知注意力增强特征融合模块CAAFM后的教师网络性能变化。从实验结果可以看出,基线模型在Precision (86.0%) 和Recall (84.1%) 方面表现良好,但添加PCAFNet后,Precision和Recall分别提升至86.4%和85.2%,显示出PCAFNet在增强特征表示方面的有效性。进一步添加CAAFM模块后,Precision和Recall分别达到89.6%和86.7%,分别较基线提升了3.6%和2.6%。在mAP50上,基线模型为88.4%,添加PCAFNet后提升至88.9%,再到本实施例方法时,mAP50达到了90.0%,展示了模型精度的持续提高。在mAP50-95上,基线为59.0%,PCAFNet提升至59.8%,而最终的本实施例方法则达到了62.8%,说明通过逐步添加模块,模型在不同难度样本上的表现都有显著提升。虽然模型的参数量(Params)从基线的38.6M增加至44.8M,但通过引入的PCAFNet和CAAFM模块,Gflops也增加至108.1,显示出在提升性能的同时,计算复杂度也有所增加。总体来看,通过逐步添加PCAFNet和CAAFM模块,本实施例的教师网络在各项指标上都取得了显著提升,特别是在精度和召回率方面,显示出其在目标检测任务中的优越性能。

[0271] 对比例3:

[0272] 本对比例给出一种高效上下文感知目标检测学生网络,通过逐步添加步骤S201中并行上下文感知特征网络PCAFNet、步骤S4中学生-上下文感知注意力增强特征融合模块(S-CAAFM)以及步骤S5模型蒸馏最终构成实施例。评价指标共有6种,分别为Precision、Recall、mAP50、mAP50-95、Params (M)、Gflops (计算量)。

[0273] 表3逐步添加模块后的学生网络检测结果

实验	P /%	R /%	mAP50 /%	mAP 50-95 /%	Params	GFLOPS
基线	86.0	84.1	88.4	59.0	38.6	56.9
+PCAFNet	86.4	85.2	88.9	59.8	35.0	60.2
[0274] +S-CAAFM	87.6	86.2	89.0	60.3	36.6	61.4
[0275] +模型蒸馏本实施例方法	89.1	86.3	90.1	61.5	36.6	61.4

[0276] 实验验证:本对比例结果如表3所示,展示了通过逐步添加并行上下文感知特征网络PCAFNet、学生-上下文感知注意力增强特征融合模块S-CAAFM以及模型蒸馏后的学生网络性能变化。基线模型的Precision为86.0%,Recall为84.1%,mAP50为88.4%,mAP50-95

为59.0%。通过添加PCAFNet,Precision提升至86.4%,Recall提升至85.2%,mAP50提升至88.9%,显示出PCAFNet有效提升了特征表达能力。进一步添加S-CAAFM模块后,Precision和Recall分别达到了87.6%和86.2%,mAP50为89.0%,mAP50-95提升至60.3%。最终,经过模型蒸馏后,本实施例的学生网络达到了89.1%的Precision、86.3%的Recall、90.1%的mAP50和61.5%的mAP50-95,展示了精度和召回率的进一步提升。尽管Params (36.6M) 和Gflops

[0277] (61.4) 与添加S-CAAFM后的网络相同,但整体性能明显提升,证明了模型蒸馏在压缩模型的同时保持了较高的性能。

[0278] 对比例4:

[0279] 本对比例在对比例3高效上下文感知目标检测学生网络基础上,进一步给出在构建本发明实施例高效上下文感知目标检测学生网络过程中逐步添加步骤S6伪深度增强卡尔曼滤波器(P-DEKF),步骤S8肉牛多目标跟踪方法后处理(AFLink与Interpolation),最终构成实施例。评价指标共有4种,分别为HOTA、MOTA、IDF1、ID Switch进行评价。

[0280] 表8双检测与伪深度运动模型驱动的肉牛多目标跟踪方法消融实验

[0281]

实验	HOTA/%	MOTA/%	IDF1/%	IDS
基线	63.679	75.248	75.432	99
+P-DEKF	64.993	75.314	77.256	96
+AFLink	65.015	75.32	77.737	92
+Interpolation本实施例方法	65.588	75.77	77.98	81

[0282] 实验验证:本对比例结果如表8所示,在本对比例中,逐步加入P-DEKF、AFLink和Interpolation模块显著提升了模型的多目标跟踪性能。在基线模型中,HOTA为63.679%,MOTA为75.248%,IDF1为75.432%,ID Switch为99。通过添加P-DEKF后,HOTA略微提升至64.993%,MOTA增至75.314%,IDF1提升至77.256%,ID Switch下降至96,表明P-DEKF有效提高了模型的预测精度与鲁棒性,并减少了ID切换的发生。接着,加入AFLink模块后,HOTA进一步提高至65.015%,MOTA为75.32%,IDF1增至77.737%,ID Switch减少至92,说明AFLink优化了目标之间的关联性,有效提升了跟踪准确度,并减少了ID切换。最终,通过加入Interpolation模块,模型的HOTA达到65.588%,MOTA为75.77%,IDF1提升至77.98%,ID Switch进一步下降至81,表现出显著的稳定性和一致性改进。综上所述,逐步添加P-DEKF、AFLink和Interpolation模块显著提升了多目标跟踪的性能,尤其是在精度、IDF1和ID Switch等指标上,展示了优化模型精度与减少ID切换的有效性。这一系列优化措施表明,通过结合P-DEKF与多目标后处理方法,可以大幅度提升模型在复杂场景中的多目标跟踪能力。

[0283] 对比例5:

[0284] 本对比例将提出的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法与6种先进的多目标跟踪方法进行比较,具体对比的方法有DeepOCSORT、BoTSORT、OCSORT、HybridSORT、ByteTrack以及StrongSORT。评价指标共有4种,分别为HOTA、MOTA、IDF1、ID Switch进行评价。

[0285] 表9双检测与伪深度运动模型驱动的肉牛多目标跟踪方法对比实验

[0286]

实验	HOTA/%	MOTA/%	IDF1/%	IDS
----	--------	--------	--------	-----

本实施例方法	65.588	75.77	77.98	81
DeepOCSORT	58.773	74.849	69.631	216
BoTSORT	61.819	75.505	74.43	162
OCSORT	59.606	75.351	70.52	205
HybridSORT	56.649	74.957	67.188	204
ByteTrack	58.674	73.368	70.87	158
StrongSORT	54.726	56.717	61.954	255

[0287] 实验验证:本对比例结果如表9所示,本实施例方法在HOTA指标上明显领先,表明该方法能够在肉牛群体的运动和遮挡情境下,保持较高的目标匹配精度和运动轨迹一致性。与次优方法BoTSORT (65.588%) 和OCSORT (59.606%) 相比,本方法具有更好的跟踪精度,特别是在复杂背景下。在MOTA指标上,本实施例方法 (75.77%) 的表现与BoTSORT (75.505%) 和OCSORT (75.351%) 相近,略有领先。MOTA综合考虑漏检、误匹配和身份切换等因素,本方法能够有效减少漏检和误匹配,尤其在复杂环境和肉牛群体较为密集的情况下表现优异。IDF1指标反映了目标的身份一致性,本实施例方法 (77.98%) 在此指标上表现最为突出,显示出该方法在处理目标身份一致性方面的优势。相比之下,ByteTrack (70.87%) 和BoTSORT (74.43%) 的IDF1值较低,说明它们在处理肉牛目标身份一致性时面临一定挑战。在IDS指标上,本实施例方法 (81) 的表现显著优于其他方法,IDS越低表明身份切换越少,跟踪更稳定。与次优方法ByteTrack (158) 和BoTSORT (162) 相比,本方法在减少身份切换方面有明显优势,能够有效避免在复杂背景下出现的身份切换问题。

[0288] 对比例6:

[0289] 本对比例将提出的双检测与伪深度运动模型驱动的肉牛多目标跟踪方法与6种先进的多目标跟踪方法在相同肉牛视频帧中进行可视化比较,具体对比的方法有DeepOCSORT、BoTSORT、OCSORT、HybridSORT、ByteTrack以及StrongSORT。

[0290] 实验验证:本对比例可视化如图11所示,在可视化结果中,本实施例方法展现了显著的优势,与其他方法相比,本实施例方法能够在相同条件下提供更加稳定和精准的跟踪结果,表现出更低的误匹配和目标身份切换,特别适用于复杂的肉牛跟踪场景。




图1




图2




图3




图4




图5




图6




图7




图8




图9






图10




本实施例方法




DeepOCSORT




BoTSORT




OCSORT



HybridSORT



ByteTrack



StrongSORT

图11