



(12) 发明专利申请

(10) 申请公布号 CN 120472214 A

(43) 申请公布日 2025. 08. 12

(21) 申请号 202510557005.2

G06V 10/80 (2022.01)

(22) 申请日 2025.04.29

G06V 10/46 (2022.01)

(71) 申请人 西北农林科技大学

地址 712100 陕西省咸阳市杨凌示范区邠城路3号

申请人 塔里木大学

(72) 发明人 王涛 张宏鸣 白铁成 徐超

刘斌 张二磊

(74) 专利代理机构 西安凯多思知识产权代理事

务所(普通合伙) 61290

专利代理师 李涛

(51) Int. Cl.

G06V 10/764 (2022.01)

G06V 20/10 (2022.01)

G06V 10/40 (2022.01)


权利要求书2页 说明书9页 附图2页

(54) 发明名称

一种图像文本融合的多模态双分支孪生网络遥感变化检测方法及系统

(57) 摘要

本发明涉及计算机视觉与人工智能技术领域,具体涉及一种图像文本融合的多模态双分支孪生网络遥感变化检测方法,该方法将文本特征与高层级语义特征图进行交互融合,使文本特征寻找到最相关的视觉线索,将细化后的文本特征经残差连接后更新文本特征;使用更新的文本特征再与高层阶语义特征图进行联合生成更具区分性的高层语义特征图;根据前后时相多层级特征图和更具区分性的高层语义特征图,提取多层级特征之间的差异信息,然后基于U型视觉语言引导的交叉十字型Transformer多模态解码器,获取变化后的图像分割掩码。本发明通过融合遥感图像与关联文本,有效减少单模态数据的误检漏检问题,提高变化区域的识别准确率。



1. 一种图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,包括:
获取遥感类别的文本信息,获取前后时相遥感图像;
根据遥感类别的文本信息与遥感图像,基于CLIP模型获取前后时相遥感影像对应的文本信息;
根据前后时相遥感图像对应的文本信息通过Transformer编码获取对应的文本特征;
根据前后时相遥感图像,使用与文本编码无相关性的图像编码器Swin Transformer提取对应的图像特征;
将文本特征与图像特征进行交互融合,利用Transformer解码器获取带有视觉线索的文本特征;
将带有视觉线索的文本特征经残差连接更新文本特征,获取更新后的文本特征;
根据更新后的文本特征与图像特征组合计算像素-文本得分图;
将像素-文本得分图对高层特征图进行联合修正前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图;
计算前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图的最优距离,并融合绝对差和拼接特征构造变化前后图像特征的差异信息;
根据变化前后图像特征的差异信息,基于U型视觉语言引导的交叉十字形Transformer多模态解码器,获取变化后的图像分割掩码。
2. 根据权利要求1所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,所述CLIP模型预训练方法,使用CLIP模型对从遥感数据集中提取的原始影像切片进行初始推理生成与遥感影像相对应的文本提示和语言先验知识。
3. 根据权利要求1所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,所述视觉特征是将文本特征与图像特征通过多模态Transformer编码器、解码器进行融合。
4. 根据权利要求1所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,提取图像特征时,包括:将遥感图像在Swin Transformer编码器采用全局平均池化模块对高层特征映射进行视觉嵌入,获取图像特征;
其中,所述图像特征包括原始输入图像丰富的语义类别信息以及语言兼容的特征图。
5. 根据权利要求4所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,所述具有区分性的高层语义特征图获取时,包括:
将像素-文本得分图与遥感图像在Swin Transformer编码器的最后一个特征图连接起来,使得在高层语义特征中补充了与文本相关的语义信息,获取更具区分性的高层语义特征图。
6. 根据权利要求1所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,所述变化前后图像特征的差异信息,是按照以下步骤获取:
根据变化前和变化后的遥感图像分别经Transformer编码器分层编码阶段中,获取每层的变化前和变化后图像的特征;
根据每层的变化前和变化后图像的特征获取每层变化前和变化后的特征最优距离;
根据每层的变化前和变化后图像的特征获取每层变化前和变化后的特征初始差;
连接每层变化前和变化后图像的特征,获取完整的双时态特征信息;

融合变化前和变化后图像的最优距离、每层变化前和变化后的特征初始差,和完整的双时态特征信息,基于DFE模块获取变化前后图像特征的差异信息。

7.根据权利要求1所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,根据变化前后获取的多层级特征图和更具区分性的高层语义特征图,利用DFE模块提取多级特征之间的差异信息,基于U型视觉语言引导的交叉十字形Transformer多模态解码器,提取变化后的图像掩码。

8.一种计算机程序产品,包括计算机程序,其特征在于,所述计算机程序被处理器执行时实现权利要求1至7中任一项所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法。

9.一种电子设备,其特征在于,包括:

处理器;以及

存储器,用于存储所述处理器的可执行指令;

其中,所述处理器配置为经由执行所述可执行指令来执行权利要求1至7中任一项所述的图像文本融合的多模态双分支孪生网络遥感变化检测方法。

10.一种图像文本融合的多模态双分支孪生网络遥感变化检测系统,其特征在于,包括:

数据采集模块,用于获取遥感类别的文本信息,获取前后时相遥感图像;根据遥感类别的文本信息与遥感图像通过,基于CLIP模型获取前后时相遥感影像对应的文本信息;

特征提取模块,用于根据前后时相遥感图像对应的文本信息通过Transformer编码获取对应的文本特征;根据前后时相遥感图像,使用与文本编码无相关性的图像编码器Swin Transformer提取对应的图像特征;将文本特征与图像特征进行交互融合,利用Transformer解码器获取带有视觉线索的文本特征;将带有视觉线索的文本特征经残差连接更新文本特征,获取更新后的文本特征;根据更新后的文本特征与图像特征组合计算像素-文本得分图;将像素-文本得分图对高层特征图进行联合修正前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图;

差异模块,用于计算前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图的最优距离,并融合绝对差和拼接特征构造变化前后图像特征的差异信息;

分割掩码模块,用于根据变化前后图像特征的差异信息,基于U型视觉语言引导的交叉十字形Transformer多模态解码器,获取变化后的图像分割掩码。

一种图像文本融合的多模态双分支孪生网络遥感变化检测方法及系统

技术领域

[0001] 本发明涉及计算机视觉与人工智能技术领域,具体涉及一种图像文本融合的多模态双分支孪生网络遥感变化检测方法及系统。

背景技术

[0002] 遥感图像变化检测(Change Detection,CD)旨在通过分析不同时相的遥感影像,识别地表覆盖的变化区域(如建筑扩张、森林砍伐、灾害损毁等),在环境监测、城市规划、灾害评估等领域具有重要应用。然而,由于遥感数据的复杂性(如光照变化、季节差异、传感器噪声等),传统方法在精度和鲁棒性上仍面临挑战。现有技术的主要问题如下:

[0003] ①单模态方法的局限性:大多数现有方法仅依赖光学图像(如Landsat、Sentinel-2),缺乏对辅助信息(如文本元数据、地理标签)的利用,导致对语义模糊变化(如临时阴影vs.真实地物变化)的区分能力不足。例如:基于像素级的差异分析(如CVA算法)或深度学习模型(如U-Net)易受光照和噪声干扰。

[0004] ②多模态融合的不足:少数研究尝试结合多源数据(如光学+SAR图像),但跨模态特征对齐困难,且未充分利用文本信息的语义指导作用。例如:早期融合(直接拼接图像与文本特征)会导致特征空间不一致,影响网络收敛。

[0005] ③Siamese网络的优化瓶颈:传统Siamese网络(如基于ResNet的双分支结构)通常仅处理图像对,未扩展至多模态输入,且分支间交互不足,导致特征表达冗余。

发明内容

[0006] 本发明解决的技术问题是:提供一种多模态融合的双分支Siamese网络,通过图像与文本的协同增强,解决遥感场景中因光照差异、地物复杂性导致的变化检测精度低、鲁棒性差的问题。本发明提出一种图像文本融合的多模态双分支孪生网络遥感变化检测方法及系统。该方法通过融合遥感图像与关联文本,有效减少单模态数据的误检漏检问题,提高变化区域的识别准确率。

[0007] 本发明第一个目的是提供一种图像文本融合的多模态双分支孪生网络遥感变化检测方法,其特征在于,包括:

[0008] 获取遥感类别的文本信息,获取前后时相遥感图像;

[0009] 根据遥感类别的文本信息与遥感图像,基于CLIP模型获取前后时相遥感影像对应的文本信息;

[0010] 根据前后时相遥感图像对应的文本信息通过Transformer编码获取对应的文本特征;

[0011] 根据前后时相遥感图像,使用与文本编码无相关性的图像编码器Swin Transformer提取对应的图像特征;

[0012] 将文本特征与图像特征进行交互融合,利用Transformer解码器获取带有视觉线

索的文本特征;

[0013] 将带有视觉线索的文本特征经残差连接更新文本特征,获取更新后的文本特征;

[0014] 根据更新后的文本特征与图像特征组合计算像素-文本得分图;

[0015] 将像素-文本得分图对高层特征图进行联合修正前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图;

[0016] 计算前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图的最优距离,并融合绝对差和拼接特征构造变化前后图像特征的差异信息;

[0017] 根据变化前后图像特征的差异信息,基于U型视觉语言引导的交叉十字形Transformer多模态解码器,获取变化后的图像分割掩码。

[0018] 优选地,所述CLIP模型预训练方法,使用CLIP模型对从遥感数据集中提取的原始影像切片进行初始推理生成与遥感影像相对应的文本提示和语言先验知识。

[0019] 优选地,所述视觉特征是将文本特征与图像特征通过多模态Transformer编码器、解码器进行融合。

[0020] 优选地,提取图像特征时,包括:将遥感图像在Swin Transformer编码器采用全局平均池化模块对高层特征映射进行视觉嵌入,获取图像特征;

[0021] 其中,所述图像特征包括原始输入图像丰富的语义类别信息以及语言兼容的特征图。

[0022] 优选地,所述具有区分性的高层语义特征图获取时,包括:

[0023] 将像素-文本得分图与遥感图像在Swin Transformer编码器的最后一个特征图连接起来,使得在高层语义特征中补充了与文本相关的语义信息,获取更具区分性的高层语义特征图。

[0024] 优选地,所述变化前后图像特征的差异信息,是按照以下步骤获取:

[0025] 根据变化前和变化后的遥感图像分别经Transformer编码器分层编码阶段中,获取每层的变化前和变化后图像的特征;

[0026] 根据每层的变化前和变化后图像的特征获取每层变化前和变化后的特征最优距离;

[0027] 根据每层的变化前和变化后图像的特征获取每层变化前和变化后的特征初始差;

[0028] 连接每层变化前和变化后图像的特征,获取完整的双时态特征信息;

[0029] 融合变化前和变化后图像的最优距离、每层变化前和变化后的特征初始差,和完整的双时态特征信息,基于DFE模块获取变化前后图像特征的差异信息。

[0030] 优选地,根据变化前后获取的多层级特征图和更具区分性的高层语义特征图,利用DFE模块提取多级特征之间的差异信息,基于U型视觉语言引导的交叉十字形Transformer多模态解码器,提取变化后的图像掩码。

[0031] 本发明第二个目的是提供一种计算机程序产品,包括计算机程序,所述计算机程序被处理器执行时实现图像文本融合的多模态双分支孪生网络遥感变化检测方法。

[0032] 本发明第三个目的是提供一种电子设备,包括:

[0033] 处理器;以及

[0034] 存储器,用于存储所述处理器的可执行指令;

[0035] 其中,所述处理器配置为经由执行所述可执行指令来执行图像文本融合的多模态

双分支孪生网络遥感变化检测方法。

[0036] 本发明第四个目的是提供一种图像文本融合的多模态双分支孪生网络遥感变化检测系统,包括:

[0037] 数据采集模块,用于获取遥感类别的文本信息,获取前后时相遥感图像;根据遥感类别的文本信息与遥感图像通过,基于CLIP模型获取前后时相遥感影像对应的文本信息;

[0038] 特征提取模块,用于根据前后时相遥感图像对应的文本信息通过Transformer编码获取对应的文本特征;根据前后时相遥感图像,使用与文本编码无相关性的图像编码器Swin Transformer提取对应的图像特征;将文本特征与图像特征进行交互融合,利用Transformer解码器获取带有视觉线索的文本特征;将带有视觉线索的文本特征经残差连接更新文本特征,获取更新后的文本特征;根据更新后的文本特征与图像特征组合计算像素-文本得分图;将像素-文本得分图对高层特征图进行联合修正前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图;

[0039] 差异模块,用于计算前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图的最优距离,并融合绝对差和拼接特征构造变化前后图像特征的差异信息;

[0040] 分割掩码模块,用于根据变化前后图像特征的差异信息,基于U型视觉语言引导的交叉十字形Transformer多模态解码器,获取变化后的图像分割掩码。

[0041] 本发明至少具有如下有益效果:

[0042] 本发明提供了一种图像文本融合的多模态双分支孪生网络遥感变化检测方法及系统,本发明通过融合遥感图像与关联文本(如时间、坐标、地物描述),有效减少单模态数据(仅图像)的误检问题(如阴影、光照变化、季节变化干扰),提高变化区域的识别准确率。本发明采用跨模态注意力机制,使网络能自适应调整图像与文本特征的权重,适应不同场景(如城市建筑、农田、森林),降低环境噪声影响。本发明在光照变化、部分遮挡等复杂条件下,仍能保持稳定的检测性能,减少虚警率。

[0043] 本发明不仅适用于光学遥感图像,还可扩展至SAR(合成孔径雷达)图像+文本、多时相遥感数据+气象文本等组合,适用性更广。本发明提供网络结构可适配不同任务,如地物分类、目标检测,只需调整输出层即可复用核心多模态融合模块。本发明可在灾害监测(如洪水、地震)或城市扩张追踪中的应用。

附图说明

[0044] 图1为MDS-Net的总体结构图;

[0045] 图2为用于图像和文本集成的多模态融合Transformer解码器;

[0046] 图3为U形视觉语言引导的Transformer多模式解码器的详细结构。

具体实施方式

[0047] 为了阐述本发明为达成预定发明目的所采取的技术手段及效果,以下结合实施例,进行详细说明。

[0048] 本发明主要针对传统遥感变化检测方法(如纯图像对比、单模态CNN)难以有效融合多模态数据(如光学图像与文本描述),导致对复杂场景(如阴影、季节变化)的误检率高;

现有Siamese网络缺乏对文本信息的建模能力,无法利用辅助文本(如卫星拍摄参数、地理标签)提升变化检测精度;双分支网络结构特征交互不足,导致图像与文本模态的语义对齐不充分,影响二值变化掩模的生成质量。本发明解决的核心问题:提供一种多模态融合的双分支Siamese网络,通过图像与文本的协同增强,解决遥感场景中因光照差异、地物复杂性导致的变化检测精度低、鲁棒性差的问题。

[0049] 本发明的目的是提供一种图像文本融合的多模态双分支孪生网络遥感变化检测方法,本发明提出了MDS-Net模型,参见图1所示,MDS-Net的输入包括两组并行的图像编码器和文本编码器。新的主干生成的特征图与CLIP文本编码器生成的文本特征没有很强的相关性,与原始图像编码器相比(ResNet和ViT)。本发明利用CLIP的无监督预测能力来制定双时态图像的原始文本提示,同时采用分层Swin Transformer来产生多尺度特征。该架构由三个主要模块组成:多模态编码器、差异特征增强模块和U形视觉语言引导的Transformer解码器。

[0050] 本发明提出的MDS-Net的总体结构由几个步骤组成:首先采用CLIP模型生成双时态图像的文本表示,然后使用文本编码器和Transformer解码器对文本特征进行细化,并识别出最相关的视觉线索,最后计算像素-文本得分图来指导学习过程的训练,该方法利用DFE模块计算差分信息,然后利用UVLGT多模态解码器增强视觉信息和文本信息之间的交互。

[0051] 为了实现上述目的,本发明提供一种图像文本融合的多模态双分支孪生网络遥感变化检测方法,包括:

[0052] S1、获取遥感类别的文本信息;获取前后时相遥感图像;

[0053] 根据遥感类别的文本信息与遥感图像,基于CLIP模型获取前后时相遥感影像对应的文本信息;

[0054] 所述CLIP模型预训练方法,使用CLIP模型对从遥感数据集中提取的原始影像切片进行初始推理生成与遥感影像相对应的文本提示和语言先验知识。

[0055] 其中,前后时相遥感图像指的是变化前和变化后的遥感图像;

[0056] 在本实施例中,由于缺乏提供文本提示标签的像素级变化检测数据集,我们根据56种常见的土地覆盖类别为双时图像生成文本提示,利用CLIP的无监督预测能力。CLIP为每个图像预测的类别表现出不同的置信度;在本发明中,利用对应于这些不同置信度的文本信息。较高的置信度表示图像包含相应类别的概率较高。变化目标可以通过双时态文本提示直接识别,这也为遥感提供了必要的先验知识,这些文本先验知识与预先训练的图像特征相结合,被输入到我们的模型中进行训练和微调。

[0057] S2、根据前后时相遥感图像对应的文本信息通过Transformer编码获取对应的文本特征;根据前后时相遥感图像,使用与文本编码无相关性的图像编码器Swin Transformer提取对应的图像特征;

[0058] 在本实施例中,为了获得文本特征,使用具有K个类名的模板"a photo of a [CLS]"来构造文本提示,并利用CLIP来提取文本序列特征 $T \in \mathbb{R}^{N \times 2 \times C}$ 。参见图2所示,采用基于transformer的文本编码器来细化文本特征T。

[0059] 根据遥感图像经特征提取获取图像特征,包括:将遥感图像在SwinTransformer编码器采用全局平均池化模块对高层特征映射进行视觉嵌入,获取图像特征;

[0060] 其中,所述图像特征包括原始输入图像丰富的语义类别信息以及语言兼容的特征

图。

[0061] 在本实施例中,参见图1所示,给定分辨率为 $H \times W \times 3$ 的输入遥感图像,Swin Transformer编码器输出分辨率为 $\frac{H}{2^{i+1}} \times \frac{W}{2^{i+1}} \times C_i$ 的特征映射 X_i ,其中, $i = \{1, 2, 3, 4\}$ 并且 $C_{i+1} > C_i$,随后,将高层语义特征映射与文本序列特征相结合。其中,在Swin Transformer编码器端采用全局平均池化模块对高层特征映射进行视觉嵌入,从而提取图像特征,具体计算方式如下:

$$[0062] \quad X' = \text{Concat}(\text{Mean}(\text{Reshape}(X_4)), X_4) \quad (1)$$

$$[0063] \quad X'' = \text{Reshape}(X'W) \quad (2)$$

$$[0064] \quad \bar{Z} = X''[:, :, 0] \quad (3)$$

$$[0065] \quad Z = \text{Reshape}(X''[:, :, 1:]) \quad (4)$$

[0066] 式中, $X_4 \in \mathbb{R}^{N \times C \times H_4 \times W_4}$ 表示编码阶段Swin Transformer提取的高级特征图,包含高级语义信息, N, C, H_4, W_4 表示 X_4 的四个维度,即批量大小、通道、高度和宽度。 $W \in \mathbb{R}^{C \times C'}$ 矩阵是一个可学习的参数矩阵,而Mean是指全局平均池化。 $\bar{Z} \in \mathbb{R}^{N \times C'}$ 表示全局表示,其中包含了原始输入图像丰富的语义类别信息。 $Z \in \mathbb{R}^{N \times C' \times H_4 \times W_4}$ 是一个语言兼容的特征图,可以与后续的文本序列特征进行整合。

[0067] S3、将文本特征与图像特征进行交互融合,利用Transformer解码器获取带有视觉线索的文本特征;将带有视觉线索的文本特征经残差连接更新文本特征,获取更新后的文本特征;

[0068] 根据更新后的文本特征与图像特征组合计算像素-文本得分图;

[0069] 将像素-文本得分图对高层特征图进行联合修正前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图;

[0070] 也就是分别获取变化前和变化后的遥感图像对应的多层级图像特征和更具区分性的高层语义特征图;

[0071] 其中,所述视觉特征是将文本特征与图像特征通过多模态Transformer编码器、解码器进行融合。

[0072] 所述具区分性的高层语义特征图获取时,包括:

[0073] 将像素-文本得分图与遥感图像在Swin Transformer编码器的最后一个特征图连接起来,使得在高层语义特征中补充了与文本相关的语义信息,获取具区分性的高层语义特征图。

[0074] 需要说明的是,获取更具区分性的高层语义特征图时,采用通过变化前的遥感图像,经步骤1中根据遥感类别的文本信息与变化前的遥感图像通过CLIP模型进行预训练获取变化前的遥感图像对应的文本信息;在经过步骤2到本步骤,获取变化前的遥感图像对应的更具区分性的高层语义特征图;

[0075] 同理,获取变化后的遥感图像对应的更具区分性的高层语义特征图;

[0076] 在本实施例中,将文本特征与图像特征通过多模态融合Transformer解码器的查询:

[0077] $V = \text{TransDecoder}(T, [\bar{Z}, Z])$ (5)

[0078] 使用以下公式计算注意力:

[0079] $\text{Attention}(Q, K, V) = \text{Softmax}(QK^T / \sqrt{d_k})V$ (6)

[0080] 式中,其中Q、K和V分别表示查询、键和值。

[0081] 对于自注意,输入仅由文本特征组成,而对于交叉注意,文本特征充当查询,视觉特征充当键和值。

[0082] 为了使文本特征能够识别最相关的视觉线索,使用残差连接更新文本特征,如下:

[0083] $T = T + \gamma V$ (7)

[0084] 其中, γ 是调节残差的缩放的可学习参数。

[0085] 然后将T与语言兼容的特征图Z组合以计算像素-文本得分图,像素-文本得分图用于指导变化检测模型的学习过程。计算公式如下:

[0086] $S = \tilde{Z} \tilde{T}, S \in R^{N \times 2 \times H_4 \times W_4}$ (8)

[0087] 式中,S表示得分图; $\tilde{Z}$ 和 $\tilde{T}$ 是Z和T沿着通道维度的 L_2 归一化版本;

[0088] $\tilde{T}$ 将被集成到解码器中以在解码阶段补充语义特征,增强整体特征表示;

[0089] 得分图S描述了像素-文本匹配的结果,构成了多模态编码器中最关键的组件之一。将得分图与最后一个特征图连接起来,以显式地包含语言先验,如下所示:

[0090] $X_4 = [X_4, S] \in R^{N \times (C' + 2) \times H_4 \times W_4}$ (9)

[0091] 这在高层语义特征中补充了与文本相关的语义信息,使得高层语义特征图更具区分性。

[0092] S4、计算前后时相遥感图像对应的多层级图像特征以及更具区分性的高层语义特征图的最优距离,并融合绝对差和拼接特征构造变化前后图像特征的差异信息;

[0093] 所述变化前后图像特征的差异信息,是按照以下步骤获取:

[0094] 根据变化前和变化后的遥感图像分别经Transformer编码器分层编码阶段中,获取每层的变化前和变化后图像的特征;

[0095] 根据每层的变化前和变化后图像的特征获取每层变化前和变化后的特征最优距离;

[0096] 根据每层的变化前和变化后图像的特征获取每层变化前和变化后的特征初始差;

[0097] 连接每层变化前和变化后图像的特征,获取完整的双时态特征信息;

[0098] 融合变化前和变化后图像的最优距离、每层变化前和变化后的特征初始差,和完整的双时态特征信息,基于DFE模块获取变化前后图像特征的差异信息。

[0099] 在本实施例中,利用四个差异模块来计算由分层Transformer编码器从成对图像中提取的多级特征之间的差异,旨在学习每个尺度下的最佳距离(Optdist)度量。计算公式如下:

$$D_i^1 = \text{BN}(\text{ReLU}(\text{Conv2D}([X_{i1}, X_{i2}])))) \quad (10)$$

[0100]

$$D_5^1 = \text{Linear}(\text{Cat}(D_1^1, D_2^1, D_3^1, D_4^1)) \quad (11)$$

[0101] 其中 X_{i1} 和 X_{i2} 表示来自变化前和变化后遥感图像在编码阶段中的第 i 层的改变前和改变后图像的特征, $i \in \{1, 2, 3, 4\}$; BN表示BatchNorm, Conv 2D指的是 3×3 深度卷积, Cat表示级联。

[0102] 参见图3所示, 给出了U形视觉语言引导的Transformer多模态解码器的详细结构。获得了 $D_1^1, D_2^1, D_3^1, D_4^1$ 和 D_5^1 , 空间分辨率分别为 $8 \times 8, 16 \times 16, 32 \times 32, 64 \times 64$ 和 128×128 。

[0103] 利用变化前后遥感图像中的特征获得初始差, 其定义如下:

$$D_i^2 = \text{Conv}(|X_{i1} - X_{i2}|) \quad (12)$$

[0104]

[0105] 连接特征图以保留完整的双时态特征信息, 其定义如下:

$$D_i^3 = [X_{i1}, X_{i2}] \quad (13)$$

[0106]

[0107] DFE的计算可以描述如下:

$$D = [\text{CA}(|D_i^1, D_i^2, D_i^3|), D_5^1] \quad (14)$$

[0108]

[0109] 式中, $|\cdot|$ 表示绝对值运算, Conv是卷积块, $[\cdot]$ 表示张量级联, 以及CA是通道注意模块, DFE模块优化了差异特征学习策略, 显著提高了RSCD任务的准确性和鲁棒性。

[0110] S5、根据变化前后图像特征的差异信息, 基于U型视觉语言引导的交叉十字形Transformer多模态解码器, 获取变化后的图像分割掩码。

[0111] 根据变化前后获取的多层级特征图和更具区分性的高层语义特征图, 利用DFE模块提取多级特征之间的差异信息, 基于U型视觉语言引导的交叉十字形Transformer多模态解码器, 根据编码阶段获得的丰富的图像差异信息和文本序列特征, 利用交叉注意机制捕捉图像特征和文本特征之间的相互依赖和匹配程度, 基于十字形交叉Transformer模块逐层多层次特征融合结构将文本语义信息融合到图像特征图中, 使模型可以更好地识别变化区域, 提取变化后的图像掩码。

[0112] 在本实施例中, 采用一种新的解码器, 称为U形视觉语言引导的Transformer多模态解码器, 它增强了视觉和文本信息之间的交互, 建立了全局注意关系。从编码阶段获得的视觉语言特征包含了来自图像和文本的丰富语义信息。通过这些语义信息集成到解码阶段, 该模型可以更有效地识别变化区域, 从而增强模型的特征表示能力。计算步骤如下:

$$T' = \text{Concat}(\tilde{T}^1 \cdot W', \tilde{T}^2 \cdot W') \quad (15)$$

[0113]

[0114] 其中, $\tilde{T}^1, \tilde{T}^2 \in \mathbb{R}^{n \times 2 \times C'}$ 表示在编码阶段期间从双时图像提取的文本序列特征, $W' \in \mathbb{R}^{C' \times d}$ 是线性变换矩阵。可以采用交叉注意机制来捕获视觉和语言之间的交互, 如下所示:

$$Q = W_D \cdot D', K = W_T \cdot T', V = W_V \cdot T' \quad (16)$$

[0115]

$$X = \text{Softmax}(QK^T / \sqrt{d_k})V \quad (17)$$

[0116]

[0117] 其中 $D' \in \mathbb{R}^{n \times l_1 \times d}$ 表示DFE特征图, $T' \in \mathbb{R}^{n \times l_2 \times d}$ 表示视觉语言特征序列 W_D ,

$W_T \in R^{d \times d_K}$, 和 $W_V \in R^{d \times d_V}$ 是三个线性变换矩阵。然后, X 被均匀地划分为不重叠的水平和垂直条纹, 每一个头的宽度为 sw , K 个头平均分为两个平行组, 一组采用水平条形自引, 另一组采用垂直条形自注意, 然后将这两组的输出连接起来, 详细计算见:

$$[0118] \quad \text{head}_k = \begin{cases} \text{H-Attention}_k(X) & k=1, \dots, K/2 \\ \text{V-Attention}_k(X) & k=K/2+1, \dots, K \end{cases} \quad (18)$$

$$[0119] \quad \text{CSWAtt}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_K) W^0 \quad (19)$$

[0120] 其中 H-Attention 为水平条带自关注, V-Attention 为垂直条带自关注, $W^0 \in R^{d \times d}$ 为将自关注结果投影到目标输出维度的投影矩阵, 条带宽度 sw 默认设置为 1、4、4、4 四个阶段, 配备了上述自关注机制, 多模式 Transformer 解码器被正式定义为:

$$[0121] \quad X^1 = \text{MLP}(\text{LN}(\text{CSWAtt}(\text{LN}(X^{1-1})) + X^{1-1})) \quad (20)$$

[0122] 其中, X^1 表示第 1 个 Transformer 解码器的输出。

[0123] 在计算机视觉中, 人们普遍认为高级图像特征有效地捕捉图像的语义信息, 而低级图像特征擅长捕捉更精细的细节。受 U-Net 系列的启发, 我们在 DFE 和 Transformer 解码器路径之间集成了多个跳过连接, 以保留局部细节的传输并增强多尺度表示。此外, 我们利用多级特征融合模块对双时相遥感影像的不同特征进行多模态解码处理, 参见图 3 所示, 计算步骤如下:

$$[0124] \quad F_4 = \text{Conv}(\text{Concat}(\text{TransDecoder}(D_2, \text{text}), D_1)) \quad (21)$$

$$[0125] \quad F_3 = \text{Conv}(\text{Concat}(\text{TransDecoder}(F_4, \text{text}), D_3)) \quad (22)$$

$$[0126] \quad F_2 = \text{Conv}(\text{Concat}(\text{TransDecoder}(F_3, \text{text}), D_4)) \quad (23)$$

$$[0127] \quad F_1 = \text{Conv}(\text{Concat}(\text{TransDecoder}(F_2, \text{text}), D_5)) \quad (24)$$

[0128] 其中 D_1, D_2, D_3, D_4 和 D_5 是 DFE 模块实现的不同特征图, 文本是视觉语言特征序列。

[0129] 本发明提供一种计算机程序产品, 包括计算机程序, 所述计算机程序被处理器执行时实现图像文本融合的多模态双分支孪生网络遥感变化检测方法。

[0130] 本发明提供一种电子设备, 包括:

[0131] 处理器; 以及

[0132] 存储器, 用于存储所述处理器的可执行指令;

[0133] 其中, 所述处理器配置为经由执行所述可执行指令来执行图像文本融合的多模态双分支孪生网络遥感变化检测方法。

[0134] 本发明提供一种图像文本融合的多模态双分支孪生网络遥感变化检测系统, 包括:

[0135] 数据采集模块, 用于获取遥感类别的文本信息; 并分别获取变化前和变化后的遥感图像; 根据遥感类别的文本信息与遥感图像通过 CLIP 模型进行预训练获取遥感图像对应的文本信息;

[0136] 特征提取模块, 用于根据遥感图像对应的文本信息通过编码获取文本特征; 根据遥感图像经特征提取获取图像特征; 将文本特征与图像特征进行交互融合, 获取视觉特征; 将视觉特征经残差连接更新文本特征, 获取更新后的文本特征; 根据更新后的文本特征与图像特征组合计算像素-文本得分图; 将像素-文本得分图对图像特征进行联合修正获取更具区分性的高层语义特征图; 依此分别获取变化前和变化后的遥感图像对应的更具区分性

的高层语义特征图；

[0137] 差异模块,用于将变化前和变化后的遥感图像分别经Transformer编码器分层编码获取图像中提取的多级特征之间的差异信息；

[0138] 分割掩码模块,用于根据变化前对应的更具区分性的高层语义特征图、变化后的遥感图像对应的更具区分性的高层语义特征图,以及图像中提取的多级特征之间的差异信息,基于U型视觉语言引导的Transformer多模态解码器,获取变化后的图像分割掩码。

[0139] 综上,本发明提供的方法使用无相关性的文本和图像编码双分支孪生网络获取前后时相遥感图像对应的多层级特征图;并将文本特征与高层级语义特征图进行交互融合,使文本特征寻找到最相关的视觉线索,将细化后的文本特征经残差连接后更新文本特征;使用更新的文本特征再与高层阶语义特征图进行联合生成更具区分性的高层语义特征图;根据前后时相多层级特征图和更具区分性的高层语义特征图,提取多层级特征之间的差异信息,然后基于U型视觉语言引导的交叉十字型Transformer多模态解码器,获取变化后的图像分割掩码。本发明通过融合遥感图像与关联文本,有效减少单模态数据的误检漏检问题,提高变化区域的识别准确率。

[0140] 以上所述仅为本发明的较佳实施例,并不用以限制本发明,凡在本发明的原则之内,所作的任何修改、等同替换、改进等,均应包含在本发明的保护范围之内。




图1




图2




图3