



## (12) 发明专利申请

(10) 申请公布号 CN 120952123 A

(43) 申请公布日 2025. 11. 14

(21) 申请号 202510882335.9

G06N 3/126 (2023.01)

(22) 申请日 2025.06.27

(71) 申请人 西北农林科技大学

地址 712100 陕西省咸阳市杨凌示范区邵  
城路3号(72) 发明人 吕志明 李骏琳 冯泽宇 张可  
鲁瑶 张宏鸣(74) 专利代理机构 西安长和专利代理有限公司  
61227

专利代理师 黄伟洪

(51) Int. Cl.

G06N 5/022 (2023.01)

G06N 3/006 (2023.01)

G06N 3/0985 (2023.01)

G06N 3/0442 (2023.01)


权利要求书2页 说明书11页 附图6页

## (54) 发明名称

一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法及系统

## (57) 摘要

本发明属于知识图谱补全技术领域,公开了一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法,该方法包括:首先,设计局部语义、交互语义、全局语义增强模块和卷积模块、池化模块分别提取邻接语义、不同关系下的差异化语义以及全局补偿语义特征;接着,通过语义增强模块级联促进语义信息流动与互补,实现多粒度语义特征的深度融合;提出一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法SAGA-KGE;为了增强搜索过程中的种群多样性,提出基于Levenshtein Distance的精英环境选择方法,在保留精英个体的情况下扩大遗传算法的搜索范围;为了降低搜索过程中的计算资源开销,设计“分类+回归”双层代理模型替代昂贵的适应度评估函数,减少计算资源的消耗。



1. 一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法, 其特征在于, 包括下列步骤:

步骤一, 设计特征融合的知识图谱嵌入模型, 所述模型依次包括本地语义增强模块、交互语义增强模块、全局语义增强模块、卷积模块和池化模块, 用于分别提取邻接语义、差异化语义和全局补偿语义并实现多粒度语义特征深度融合;

步骤二, 采用可变长混合编码策略将嵌入模型的级联模块类型序列与对应超参数配置序列编码为种群个体;

步骤三, 利用双层代理辅助模型替代昂贵适应度函数, 所述双层代理辅助模型包括分类模型与回归模型, 根据个体编码快速预测模型在知识补全任务中的hits@10指标作为适应度值;

步骤四, 基于Levenshtein距离的精英环境选择方法结合随机单点交叉算子与随机单点变异算子对种群进行选择、交叉与变异以生成新一代种群, 直至达到预设迭代次数;

步骤五, 从最终种群中选取适应度值排名前二十的嵌入模型个体进行完整训练与测试, 并将测试表现最佳的模型作为优化后的嵌入模型。

2. 根据权利要求1所述方法, 其特征在于, 所述本地语义增强模块首先将实体嵌入向量与关系嵌入向量通过左右拼接与上下拼接两种方式组合形成特征向量, 再通过多通道卷积核提取邻接位置语义交互特征, 以显式捕获实体与关系的共现模式并提升不同粒度语义交互的建模能力。

3. 根据权利要求1所述方法, 其特征在于, 所述交互语义增强模块将关系嵌入向量重塑为卷积核, 与输入的多通道实体向量分别卷积后逐通道相加取平均生成输出特征向量, 以全面捕获同一输入向量在不同关系下的复杂交互语义特征并保证各关系特征的独立提取能力。

4. 根据权利要求1所述方法, 其特征在于, 所述全局语义增强模块首先将关系嵌入向量展平并通过全连接层扩展维度后重塑为卷积核, 与输入实体向量进行卷积操作, 以融合全局语义信息增强低频关系特征稳定性并缓解长尾关系问题。

5. 根据权利要求1所述方法, 其特征在于, 所述卷积模块用于强化模型对复杂关系模式的建模能力, 所述池化模块用于对卷积输出特征进行降维与信息聚合, 通过保留最显著特征抑制冗余信息并提升重要特征关注度。

6. 根据权利要求1所述方法, 其特征在于, 所述Levenshtein距离的精英环境选择方法将种群个体的架构序列视为文本序列, 先保留适应度排名前四分之一的个体, 再对剩余个体两两计算Levenshtein距离并按距离由大到小选择至下一代, 最后通过交叉与变异补充新个体以维持种群规模。

7. 根据权利要求1所述方法, 其特征在于, 所述分类模型采用双向长短期记忆网络结构对架构序列与超参数序列进行嵌入处理并提取时序特征完成粗略分类, 所述回归模型在分类模型输出基础上结合嵌入向量通过多层全连接网络进一步优化适应度预测精度。

8. 一种基于双层代理辅助遗传算法的嵌入模型架构搜索系统, 其特征在于, 包括处理器与存储器, 所述存储器中存储有可执行于所述处理器的指令, 执行后实现权利要求1至权利要求7任一项所述的方法步骤。

9. 一种存储有计算机可读指令的非易失性存储介质, 所述指令经所述计算机执行后实

现权利要求1至权利要求7任一项所述的方法步骤。

10. 根据权利要求8所述系统,其特征在于,所述处理器与存储器还配置有通信接口,用于接收知识图谱数据输入并输出优化后嵌入模型的架构与参数配置。

## 一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法及系统

### 技术领域

[0001] 本发明属于但不限于知识图谱补全技术领域,尤其涉及一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法。

### 背景技术

[0002] 知识图谱作为一种强大的数据表示与推理工具,能够将分散、无序且结构复杂的农业大数据进行组织和管理。然而,知识图谱中实体间关系的缺失导致语义信息丢失。因此,知识图谱补全成为提升知识图谱在下游任务中应用价值的主要挑战。鉴于此,基于卷积神经网络的知识图谱嵌入表示凭借其良好的非线性特征提取与特征空间交互能力,已被广泛应用于图谱补全任务中。然而,该方法仍存在诸多缺点:语义信息提取结构固定、实体与关系语义特征交互不够充分、模型设计与优化在很大程度上依赖专家经验。

[0003] 知识图谱以结构化的方式将知识表示为实体(节点)与关系(边),但在特定领域中,实体间常存在链接缺失的问题,影响推理效果和应用的准确性。为了解决这一问题,知识图谱补全(KnowledgeGraphCompletion,KGC)应运而生,其核心任务是利用已有信息挖掘潜在三元组,预测实体之间的关系,从而提升知识图谱的完整性。在众多补全方法中,知识图谱嵌入(KnowledgeGraphEmbedding,KGE)是当前最主流的技术路线。知识图谱嵌入通过将实体与关系映射到稠密的低维特征空间中,实现对实体语义关系的有效建模,同时显著降低知识图谱的计算复杂度。现有用于知识图谱补全的嵌入模型主要分为三类:基于平移距离的模型、基于语义匹配的模型和基于神经网络的模型。

[0004] (1) 基于平移距离的知识图谱嵌入模型。基于平移距离的模型通过将实体和关系映射到低维向量空间,利用向量之间的几何关系建模实体与关系的交互。这类模型的核心思想是,头实体向量与关系向量的组合应尽可能接近尾实体向量。TransE是这类模型的代表性方法。它假设对于一个正确的三元组  $(h, r, t)$ , 头实体  $h$  与关系  $r$  的向量之和应接近尾实体  $t$ , 即  $h+r=t$ 。该方法计算简单、高效,适用于大规模知识图谱补全任务。然而,它难以处理一对多、多对一和多对多等复杂关系。TransH在TransE的基础上引入了关系特定的超平面,使得相同实体在不同关系下的投影能够有所区分,从而缓解了TransE在建模复杂关系时的局限性。但该方法在计算过程中仍然存在一定的限制,无法完全消除实体间的耦合。TransR进一步改进,每个关系  $r$  具有一个独立的投影矩阵,使得实体能够在不同关系的特定空间中表示,从而更灵活地建模复杂关系。然而,TransR计算量较大,训练复杂度较高。TransD在TransR的基础上引入了关系特定和实体特定的映射矩阵,进一步增强了模型的表达能力,提高了对多关系语义的建模能力。综上所述,基于平移距离的模型计算高效,但其语义特征计算过程仅依赖简单几何关系的线性运算,对实体与关系种类多样,且关系复杂度较高的大规模知识图谱适应性较差,难以捕捉更细粒度的语义信息。

[0005] (2) 基于语义匹配的知识图谱嵌入模型。基于语义匹配的模型通过计算实体和关系的相似度来建模知识图谱。DistMult采用三元组嵌入的点积作为评分函数,并通过最大

化正确三元组的得分来优化模型。其优势在于计算简单、效率高,适用于大规模知识图谱任务。但该方法对称地建模所有关系,因此无法处理方向性关系。Comp1EX针对DistMult无法处理非对称关系的问题,引入了复数嵌入表示,将实体和关系分别映射到实部和虚部,通过计算复数内积来建模关系的方向性cite{trouillon2016complex}。这种方法有效增强了语义表达能力,特别适用于复杂的知识图谱补全任务。然而,复数计算增加了模型的复杂度,并对优化过程提出了更高要求。综上所述,基于语义匹配的模型通过度量实体与关系之间的语义相似性来预测缺失链接,在建模效率和实现复杂度方面具有一定优势。然而,此类模型在处理低频实体及关系时表现有限,且其静态语义表示难以捕捉上下文语义变化,导致对知识图谱中深层次语义信息的建模能力不足,从而影响补全结果的准确性。

[0006] (3) 基于神经网络的知识图谱嵌入模型。近年来,深度神经网络被引入知识图谱嵌入模型,通过深度学习方法提取更复杂的语义信息,完成知识图谱补全任务。ConvE首次在知识图谱补全任务中引入卷积神经网络(ConvolutionalNeuralNetwork,CNN),将头实体和关系拼接后作为输入,通过二维卷积层提取特征,并利用1-N评分函数预测尾实体。该方法通过卷积操作提升了嵌入的表示能力,但拼接操作可能导致信息损失。ConvKB采用不同于ConvE的拼接方式,将(h,r,t)组合成一个三列矩阵,并使用多个卷积核进行特征提取,从而提升模型对复杂关系的建模能力cite{nguyen2017novel}。然而,该方法仍然受到局部感受野的限制,难以全局建模实体之间的长距离关系。ConvR针对ConvE可能造成的信息损失问题,提出了一种自适应卷积机制,即使用关系向量作为卷积核对实体进行特征提取。这种方法增强了关系特定的特征表示能力,提高了模型的泛化能力,但也增加了参数规模和计算复杂度。R-GCN基于图卷积神经网络(GraphConvolutionalNetwork,GCN),通过在知识图谱的图结构上进行多层关系特定的卷积操作,以更好地学习实体的嵌入表示。R-GCN能够充分利用知识图谱的图结构信息,适用于建模多跳推理关系。然而,该方法的计算复杂度较高,在大规模知识图谱上可能存在计算瓶颈。综上所述,基于神经网络的模型能够在统一的嵌入空间中同时表示实体与关系,有效缓解了二者在表示空间上的分离问题。同时,借助卷积、池化等操作,模型能够提取复杂的非线性语义特征。然而,现有方法普遍受限于固定的神经网络结构设计,往往仅关注局部语义信息,缺乏从多角度全面提取和融合语义特征的有效机制。。

[0007] 随着深度学习的不断发展,各种神经网络结构相继诞生,从早期的多层感知机(MultilayerPerceptron,MLP)到VGG16、ResNet和DenseNet,网络层数的加深与结构的优化显著提升了深度学习模型的性能。然而,设计高效的神经网络模型仍然依赖大量专业知识和反复试验,成本极高。基于进化计算的神经网络架构搜索(EvolutionaryNeuralArchitectureSearch,ENAS)是一种利用进化算法自动设计神经网络的技术。ENAS在图像分类、目标检测和语义分割等任务中均取得了优异表现。在ENAS中,基于遗传算法的神经网络架构搜索方法(GeneticAlgorithm-NeuralArchitectureSearch,GA-NAS)应用广泛,其通过改进编码策略、搜索空间、环境选择、交叉与变异算子,能够有效探索不同架构的神经网络并优化其性能。

[0008] 基于遗传算法的神经网络架构搜索方法广泛应用于并行计算、分布式优化、多目标优化以及自适应优化等领域。在该方法中,初始神经网络被视为种群个体,通过遗传操作,如:交叉和变异,不断优化网络结构。EvoCNN通过搜索卷积层、池化层和全连接层的最佳

组合,生成高性能神经网络架构。该模型采用随机变异与单点交叉算子,引导种群向更优方向进化,同时使用精英选择策略保留优秀个体。此外,可以通过引入ResNet和DenseNet块结构,进一步提升搜索效果。在编码方式中,GACNN设计“手风琴”编码方式,将神经网络架构表示为一维数组,并利用多点随机交叉与变异算子进行架构优化,同时用新生成的个体替换表现较差的个体,以稳定种群进化。另一些研究则引入跳跃连接等残差结构,以借助先验知识避免陷入局部最优解,并减少过拟合。此外,为降低计算成本,部分方法采用适应度继承机制,即对于架构相同的个体,直接沿用已有的适应度值而无需重新评估。综上所述,基于遗传算法的神经网络架构搜索方法通过模拟进化过程对网络结构进行优化,具备良好的全局搜索能力和泛化性能,已成为架构自动化设计的重要手段。然而,基于遗传算法的神经网络架构搜索方法在适应度评估阶段仍主要依赖对个体的完整训练,导致计算资源消耗较大,同时,其环境选择策略在种群多样性控制方面存在不足,容易导致算法陷入局部最优,从而限制整体搜索性能的提升。

[0009] 综上所述,现有技术存在的问题及缺陷为:

1、在现有知识图谱嵌入模型中,实体与关系特征空间隔离,静态关系表示难以适应语境变化,低频实体关系训练不佳。

[0010] 2、现有嵌入模型的结构设计与参数优化过度依赖专家经验,导致其优化效率较低。

## 发明内容

[0011] 针对现有技术存在的问题,本发明提供了一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法。

[0012] 本发明是这样实现的,一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法,该方法包括:

S1,针对现有知识图谱嵌入模型语义信息提取结构固定,实体与关系交互不充分等问题,设计了基于特征融合的知识图谱嵌入模型;首先,设计局部语义、交互语义、全局语义增强模块和卷积模块、池化模块分别提取邻接语义、不同关系下的差异化语义以及全局补偿语义特征;接着,通过语义增强模块级联促进语义信息流动与互补,实现多粒度语义特征的深度融合。

[0013] S2,针对传统知识图谱嵌入模型结构设计过度依赖专家经验的问题,提出一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法SAGA-KGE;为了增强搜索过程中的种群多样性,提出基于Levenshtein Distance的精英环境选择方法,在保留精英个体的情况下扩大遗传算法的搜索范围;为了降低搜索过程中的计算资源开销,设计“分类+回归”双层代理模型替代昂贵的适应度评估函数,减少计算资源的消耗。

[0014] 进一步,所述局部语义增强模块通过非线性卷积操作捕捉实体与关系邻接位置的语义交互信息;模块首先将输入向量 $e$ 与关系 $r$ 的二维嵌入向量进行拼接,接着通过多尺度卷积核实现局部区域特征的混合与提取,从而显式捕捉实体与关系的共现模式,提升模型对不同粒度语义交互的建模能力;该模块的具体工作流程如下:LSEB将关系嵌入向量与输入向量通过两种拼接方式进行拼接,使之构成完整的特征向量。拼接方式为:左右拼接与上下拼接,不同的拼接方式会得到不同尺寸的特征向量;之后,通过一个多通道卷积核提取输

入向量与关系的邻接交互位置语义信息,并输出经过卷积操作以后的特征向量,有效捕获两者的耦合关系。

[0015] 进一步,所述交互语义增强模块,实现了对同一输入向量下不同关系的复杂交互语义特征的全面捕获与表达;ISEB通过将关系嵌入向量重塑为卷积核,与输入向量进行卷积,生成对应的特征向量;当输入向量包含多个通道时,关系卷积核会分别与每个通道的向量进行卷积,并通过逐通道相加取平均的操作,形成多通道输出;与ConvR模型的普通自适应卷积不同,ISEB支持多通道输入,能够更全面地捕获输入向量与关系的交互语义特征,提升模型对多样化关系模式中语义差异的感知能力,从而实现更精准的动态语义建模;这种多通道自适应卷积设计有效保证了同一输入向量对不同关系的独立特征提取能力,进一步提升了模型对复杂知识图谱的适应性;

进一步,所述全局语义增强模块,用于提升特征融合知识图谱嵌入模型对高频与低频关系模式的识别能力,降低长尾低频关系对知识图谱嵌入的影响;与ISEB相比,GSEB通过全局线性层在整个数据集层面对不同关系嵌入向量进行全局特征变换,实现对低频关系向量的全局细粒度语义特征的精准提取与综合表征,并将变换后的关系嵌入向量重塑为卷积核;具体而言,GSEB首先将关系嵌入向量展平,并通过全连接层扩展其维度,随后将扩展后的向量重塑为卷积核,与输入向量进行卷积操作;其优势在于:(a)提升关系表示能力。全连接层可学习全局映射,使关系嵌入向量在转化为卷积核时融合更多全局语义,增强表达能力;(b)缓解长尾关系问题。通过参数共享机制,对低频关系起到正则化作用,提升其嵌入稳定性;(c)增强模型泛化性;共享参数促进跨关系特征学习,即使是低频关系也能借助全局信息提升表现;

所述卷积模块可以强化模型对复杂关系模式的建模能力;所述池化模块能够对特征向量进行降维和信息聚合,通过保留最显著的特征值,抑制无关或冗余信息,从而提高模型对重要特征的关注度。

[0016] 进一步,所述基于特征融合的知识图谱嵌入模型是将LSEB、ISEB、GSEB、PB、CB五种不同模块以串联组合方式嵌入神经网络中,构建多级特征融合知识图谱嵌入模型,以提高嵌入模型在知识补全中的表现;模型主要由嵌入层、级联模块序列( $B_1$ 至 $B_n$ )和线性全连接层FC组成;级联模块的最大数量为 $n=7$ 。

[0017] 进一步,该方法使用遗传算法作为架构搜索的基本框架,并将hits@10指标作为适应度值用于评价嵌入模型在知识补全任务中的性能表现,从而将嵌入模型优化问题转化为对评价指标hits@10的最大化问题,得到优化的目标函数如下:

$$\text{Maximize } f(a, p) = \text{hits@10}(a, p),$$

其中  $a$  表示知识图谱嵌入模型的架构,  $p$  表示嵌入模型的超参数配置。同时,目标函数  $f(a, p)$  也作为适应度函数,用于评估嵌入模型个体在种群中的性能优劣。

[0018] 进一步,所述SAGA-KGE通过遗传算法一般流程对嵌入模型的架构组成及超参数配置进行自动优化;首先,根据嵌入模型的编码方式进行初始种群的构建,随机生成100个在架构组成与超参数配置上具有差异的嵌入模型个体。随后,对初始种群中的个体进行适应度评估,计算其在链接预测任务中的hits@10指标;基于评估结果,SAGA-KGE通过环境选择、

交叉及变异操作生成新一代种群,并重复上述评估与进化过程,直至达到预设的最大迭代次数,获得最终一代种群;最后,从最终种群中选取适应度值排名前20的嵌入模型,并使用训练数据对其进行完整的训练,之后通过测试数据进行性能测试,选取测试表现最优者作为SAGA-KGE优化后的嵌入模型;为了降低大规模种群适应度评估带来的计算资源开销,SAGA-KGE引入基于“分类+回归”的代理辅助模型用于替代昂贵的适应度函数,该模型通过将嵌入模型个体的架构序列及超参数序列作为输入,实现嵌入模型编码到其性能的快速映射,从而提升遗传搜索效率并减少计算资源消耗;

所述SAGA-KGE用架构序列与超参数序列表示嵌入模型个体,并据此构建了具有高度灵活性与表达力的搜索空间;该搜索空间不仅包含嵌入模型的模块组合方式,还涵盖各模块的超参数配置;搜索空间涵盖所有可能的模块组合及其超参数配置。

[0019] 进一步,所述SAGA-KGE采用可变长混合编码策略,以提升优化搜索的灵活性;每个嵌入模型的染色体编码由架构序列和超参数序列两部分组成;架构序列以整数表示,用于标识知识图谱嵌入模型的级联模块类型及其组合顺序;1代表LSEB,2代表ISEB,3代表GSEB,4代表CB,5代表PB,6代表全连接层;对于图中架构序列的第一个模块编号为1,其对应的超参数为“16,4,1,1,2”,分别表示输出通道数、卷积核大小、步长、填充大小和拼接位置;其余模块的超参数依次排列,与架构序列严格对齐;

为了适配可变长混合编码策略,SAGA-KGE使用随机单点交叉算子与随机单点变异算子生成新的个体;其中,单点交叉算子通过随机选取两个父代个体,并在较短个体中随机确定一个交叉点,对交叉点之后的架构序列与参数序列进行交换,生成两个子代个体,该方法通过保留关键结构实现对父代优良特性的继承。单点变异算子则随机选择个体架构序列中的一个位置,执行等概率的修改、增加或删除操作;其中,修改操作可改变模块类型或其超参数,增加和删除操作在调整架构序列的同时同步更新超参数序列。例如,插入新模块时将同时添加相应的超参数;变异操作有助于打破当前种群局限,发掘潜在最优解。

[0020] 进一步,所述Levenshtein Distance的精英环境选择方法将编码视为离散的文本序列,通过判断编码的相似性,进行环境选择;定义为将一个字符串转换为另一个字符串所需的最少编辑操作次数,允许的编辑操作包括插入、删除和替换;例如,将字符串“kitten”转换为“sitting”需要进行三次操作:将“k”替换为“s”、将“e”替换为“i”、在末尾插入“g”,因此它们的Levenshtein Distance为3,Levenshtein Distance计算方法见下式:

$$lev_{a,b}(i,j) = \begin{cases} \max(i,j) & \text{if } \min(i,j) = 0 \\ \min \begin{cases} lev_{a,b}(i-1,j)+1 \\ lev_{a,b}(i,j-1)+1 \\ lev_{a,b}(i-1,j-1)+1_{(a_i \neq b_j)} \end{cases} & \text{otherwise} \end{cases}$$

其中, $lev_{a,b}(i,j)$ 表示序列a和b的莱文斯坦距离; $1_{(a_i \neq b_j)}$ 为指示函数,用于判断字符 $a_i$ 和 $b_j$ 是否相等;在SAGA-KGE中,将嵌入模型的架构序列视为文本序列,以此判断序列的多样性;

基于Levenshtein Distance的精英环境选择方法步骤如下:首先,从当前种群中



选择适应度值前四分之一个体,保留至下一代种群;然后,计算父代种群中剩余的四分之三个体的Levenshtein Distance,并按Levenshtein Distance对其排序,两两选择其中距离更大的个体并保留至下一代种群;最后,通过交叉、变异生成全新的个体,加入后代种群,使种群规模达到预设要求;该方法在保证精英个体传承的同时,增强了种群的个体多样性,提升了优化效果。

[0021] 进一步,所述“分类+回归”双层代理模型能够通过个体的编码实现嵌入模型个体到其性能的快速映射;在基于“分类+回归”的双层代理辅助模型中,分类模型基于双向长短期记忆网络架构,能够捕捉嵌入模型架构序列和超参数序列中的时序依赖关系,快速提取高性能嵌入模型个体的特征;回归模型则在分类模型的输出基础上,结合架构序列和超参数序列的嵌入向量,利用多层全连接网络进一步优化适应度值预测;通过将适应度预测任务分解为分类和回归两个相对简单的子任务,该方法有效平衡了预测速度与精度,适用于快速评估嵌入模型性能的场景;具体而言,分类模型首先对架构序列和超参数序列进行嵌入处理,随后通过双向LSTM模块提取时序特征,并经过全连接层完成粗略但高效的分类过程;之后,回归模型利用分类模型的输出结果作为先验信息,在合理的预测范围内,通过多层全连接网络进一步优化适应度值的预测精度。双重代理辅助模型的核心创新在于分类模型通过LSTM结构捕捉块结构组合的合理性,而回归模型在预测过程中利用分类模型的输出范围,有效减少了预测适应度值与真实值之间的偏差,从而显著提升了代理辅助模型的预测精度。

[0022] 结合上述的技术方案和技术问题,本发明所要保护的技术方案所具备的优点及积极效果为:

第一、基于“分类+回归”的双层代理辅助模型拥有较高的适应度预测精度,能够替代昂贵的适应度函数完成适应度评估,为遗传搜索过程中的候选方案筛选提供了有效支持。

[0023] 本发明通过遗传算法一般流程对嵌入模型的架构组成及超参数配置进行自动优化首先,根据嵌入模型的编码方式进行初始种群的构建,随机生成100个在架构组成与超参数配置上具有差异的嵌入模型个体。随后,对初始种群中的个体进行适应度评估,计算其在链接预测任务中的hits@10指标。基于评估结果,SAGA-KGE通过环境选择、交叉及变异操作生成新一代种群,并重复上述评估与进化过程,直至达到预设的最大迭代次数,获得最终一代种群。最后,从最终种群中选取适应度值排名前20的嵌入模型,并使用训练数据对其进行完整的训练,之后通过测试数据进行性能测试,选取测试表现最优者作为SAGA-KGE优化后的嵌入模型。为了降低大规模种群适应度评估带来的计算资源开销,SAGA-KGE引入基于“分类+回归”的代理辅助模型用于替代昂贵的适应度函数,该模型通过将嵌入模型个体的架构序列及超参数序列作为输入,实现嵌入模型编码到其性能的快速映射,从而提升遗传搜索效率并减少计算资源消耗。

## 附图说明

- [0024] 图1是本发明实施例提供的LSEB模块结构;  
图2是本发明实施例提供的ISEB模块结构;  
图3是本发明实施例提供的GSEB的关系卷积核重塑过程;

图4是本发明实施例提供的多级特征融合知识图谱嵌入模型构成；  
图5是本发明实施例提供的SAGA-KGE基本流程；  
图6是本发明实施例提供的可变长混合编码示意图；  
图7是本发明实施例提供的随机单点交叉及随机单点变异算子；  
图8是本发明实施例提供的嵌入模型架构序列间Levenshtein Distance计算；  
图9是本发明实施例提供的基于Levenshtein Distance的精英环境选择；  
图10是本发明实施例提供的“分类+回归”双层代理辅助模型。

## 具体实施方式

[0025] 为了使本发明的目的、技术方案及优点更加清楚明白,以下结合实施例,对本发明进行进一步详细说明。应当理解,此处所描述的具体实施例仅仅用以解释本发明,并不用于限定本发明。

[0026] 本发明提供了一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法。本发明通过以下步骤实现:

步骤1,针对现有知识图谱嵌入模型语义信息提取结构固定,实体与关系交互不充分等问题,设计了基于特征融合的知识图谱嵌入模型。首先,设计局部语义、交互语义和全局语义增强模块分别提取邻接语义、不同关系下的差异化语义以及全局补偿语义特征。接着,通过语义增强模块级联促进语义信息流动与互补,实现多粒度语义特征的深度融合。

[0027] 步骤2,针对传统知识图谱嵌入模型结构设计过度依赖专家经验的问题,提出一种基于双层代理辅助遗传算法的嵌入模型架构搜索方法。为了增强搜索过程中的种群多样性,提出基于Levenshtein Distance的精英环境选择方法,在保留精英个体的情况下扩大遗传算法的搜索范围。为了降低搜索过程中的计算资源开销,设计“分类+回归”双层代理模型替代昂贵的适应度评估函数,减少计算资源的消耗。

[0028] 一、语义增强模块定义

(1) 局部语义增强模块(Local Semantic Enhancement Block, LSEB);

局部语义增强模块通过非线性卷积操作捕捉实体与关系邻接位置的语义交互信息,模块结构如图1所示。模块首先将输入向量 $e$ 与关系 $r$ 的二维嵌入向量进行拼接,接着通过多尺度卷积核实现局部区域特征的混合与提取,从而显式捕捉实体与关系的共现模式,提升模型对不同粒度语义交互的建模能力。该模块的具体工作流程如下:LSEB将关系嵌入向量与输入向量通过两种拼接方式进行拼接,使之构成完整的特征向量。拼接方式为:左右拼接与上下拼接,不同的拼接方式会得到不同尺寸的特征向量。之后,通过一个多通道卷积核提取输入向量与关系的邻接交互位置语义信息,并输出经过卷积操作以后的特征向量,有效捕获两者的耦合关系。

[0029] (2) 交互语义增强模块(Interaction Semantic Enhancement Block, ISEB);

根据自适应卷积机制,设计了交互语义增强模块,实现了对同一输入向量下不同关系的复杂交互语义特征的全面捕获与表达,模块结构如图2所示。ISEB通过将关系嵌入向量重塑为卷积核,与输入向量进行卷积,生成对应的特征向量。当输入向量包含多个通道时,关系卷积核会分别与每个通道的向量进行卷积,并通过逐通道相加取平均的操作,形成多通道输出。与ConvR模型的普通自适应卷积不同,ISEB支持多通道输入,能够更全面地捕

获输入向量与关系的交互语义特征,提升模型对多样化关系模式中语义差异的感知能力,从而实现更精准的动态语义建模。这种多通道自适应卷积设计有效保证了同一输入向量对不同关系的独立特征提取能力,进一步提升了模型对复杂知识图谱的适应性。

[0030] (3) 全局语义增强模块(Global Semantic Enhancement Block, GSEB);

设计全局语义增强模块,用于提升特征融合知识图谱嵌入模型对高频与低频关系模式的识别能力,降低长尾低频关系对知识图谱嵌入的影响。与ISEB相比,GSEB通过全局线性层在整个数据集层面对不同关系嵌入向量进行全局特征变换,实现对低频关系向量的全局细粒度语义特征的精准提取与综合表征,并将变换后的关系嵌入向量重塑为卷积核,重塑过程如图3所示。具体而言,GSEB首先将关系嵌入向量展平,并通过全连接层扩展其维度,随后将扩展后的向量重塑为卷积核,与输入向量进行卷积操作。其优势在于:(a)提升关系表示能力。全连接层可学习全局映射,使关系嵌入向量在转化为卷积核时融合更多全局语义,增强表达能力;(b)缓解长尾关系问题。通过参数共享机制,对低频关系起到正则化作用,提升其嵌入稳定性;(c)增强模型泛化性。共享参数促进跨关系特征学习,即使是低频关系也能借助全局信息提升表现。

[0031] (4) 卷积模块(Convolutional Block, CB)和池化模块(Pooling Block, PB);

“卷积”模块可以强化模型对复杂关系模式的建模能力。“池化”模块能够对特征向量进行降维和信息聚合,通过保留最显著的特征值,抑制无关或冗余信息,从而提高模型对重要特征的关注度。

[0032] 二、多级特征融合知识图谱嵌入模型定义

将上述LSEB、ISEB、GSEB、PB、CB五种不同模块以串联组合方式嵌入神经网络中,构建多级特征融合知识图谱嵌入模型,以提高嵌入模型在知识补全中的表现。多级特征融合知识图谱嵌入模型的结构如图4所示,模型主要由嵌入层、级联模块序列( $B_1$ 至 $B_n$ )和线性全连接层(FC)组成。级联模块的最大数量为 $n=7$ 。

[0033] 三、基于双层代理辅助遗传算法的嵌入模型架构搜索方法的问题定义

针对步骤1中多级特征融合知识图谱嵌入模型的自动优化问题,可转化为对不同模块组合及其超参数配置的优化问题。为此,提出基于双层代理辅助遗传算法的嵌入模型架构搜索方法(Surrogate-assisted Genetic Algorithm for Knowledge Graph Embedding, SAGA-KGE)。该方法使用遗传算法作为架构搜索的基本框架,并将hits@10指标作为适应度值用于评价嵌入模型在知识补全任务中的性能表现,从而将嵌入模型优化问题转化为对评价指标hits@10的最大化问题,得到优化的目标函数如下:

$$\text{Maximize } f(a, p) = \text{hits@10}(a, p),$$

其中  $a$  表示知识图谱嵌入模型的架构,  $p$  表示嵌入模型的超参数配置。同时,目标函数  $f(a, p)$  也作为适应度函数,用于评估嵌入模型个体在种群中的性能优劣。

[0034] 四、SAGA-KGE的基本流程

SAGA-KGE通过遗传算法一般流程对嵌入模型的架构组成及超参数配置进行自动优化,其基本流程如图5所示。首先,根据嵌入模型的编码方式进行初始种群的构建,随机生成100个在架构组成与超参数配置上具有差异的嵌入模型个体。随后,对初始种群中的个体

进行适应度评估,计算其在链接预测任务中的hits@10指标。基于评估结果,SAGA-KGE通过环境选择、交叉及变异操作生成新一代种群,并重复上述评估与进化过程,直至达到预设的最大迭代次数,获得最终一代种群。最后,从最终种群中选取适应度值排名前20的嵌入模型,并使用训练数据对其进行完整的训练,之后通过测试数据进行性能测试,选取测试表现最优者作为SAGA-KGE优化后的嵌入模型。为了降低大规模种群适应度评估带来的计算资源开销,SAGA-KGE引入基于“分类+回归”的代理辅助模型用于替代昂贵的适应度函数,该模型通过将嵌入模型个体的架构序列及超参数序列作为输入,实现嵌入模型编码到其性能的快速映射,从而提升遗传搜索效率并减少计算资源消耗。

#### [0035] 五、SAGA-KGE的搜索空间定义

为了同时对多级特征融合知识图谱嵌入模型的结构组成及超参数配置进行自动优化,SAGA-KGE用架构序列与超参数序列表示嵌入模型个体,并据此构建了具有高度灵活性与表达力的搜索空间。该搜索空间不仅包含嵌入模型的模块组合方式,还涵盖各模块的超参数配置,不同模块的超参数及取值范围如表1所示。搜索空间涵盖所有可能的模块组合及其超参数配置,可表示如下:

表1 各模块可供选择的超参数及取值范围

| 参数类型  | LSEB             | ISEB | GSEB     | CB           | PB  |
|-------|------------------|------|----------|--------------|-----|
| 输出通道  | 16,32,64         | -    | 16,32,64 | 16,32,64,128 | -   |
| 卷积核大小 | 3,4              | 3,4  | 3,4      | 3,4          | 3,4 |
| 步幅    | 1,2              | 1,2  | 1,2      | 1,2          | 1,2 |
| 填充    | 0,1              | 0,1  | 0,1      | 0,1          | 0,1 |
| 偏置    | -                | -    | -        | True,False   | -   |
| 池化核大小 | -                | -    | -        | -            | 1,2 |
| 拼接位置  | 1: 上下拼接, 2: 左右拼接 | -    | -        | -            | -   |

#### [0036] 六、SAGA-KGE的遗传操作算子

##### (1) 可变长混合编码

SAGA-KGE采用可变长混合编码策略,以提升优化搜索的灵活性。每个嵌入模型的染色体(编码)由架构序列和超参数序列两部分组成。架构序列以整数表示,用于标识知识图谱嵌入模型的级联模块类型及其组合顺序。1代表LSEB,2代表ISEB,3代表GSEB,4代表CB,5代表PB,6代表全连接层。多级特征融合知识图谱嵌入模型的架构及超参数编码如图6所示。对于图中架构序列的第一个模块(编号为1),其对应的超参数为“16,4,1,1,2”,分别表示输出通道数、卷积核大小、步长、填充大小和拼接位置。其余模块的超参数依次排列,与架构序列严格对齐,各个超参数含义可参考表1。

##### [0037] (2) 交叉及变异算子

为了适配可变长混合编码策略,SAGA-KGE使用随机单点交叉算子与随机单点变异算子生成新的个体(嵌入模型)。其中,单点交叉算子通过随机选取两个父代个体,并在较短个体中随机确定一个交叉点,对交叉点之后的架构序列与参数序列进行交换,生成两个子代个体,该方法通过保留关键结构实现对父代优良特性的继承。单点变异算子则随机选择个体架构序列中的一个位置,执行等概率的修改、增加或删除操作。其中,修改操作可改变模块类型或其超参数,增加和删除操作在调整架构序列的同时同步更新超参数序列。例如,插入新模块时将同时添加相应的超参数。变异操作有助于打破当前种群局限,发掘潜在最优解。交叉与变异算子如图7所示。

#### [0038] 七、基于Levenshtein Distance的精英环境选择方法

为了增强种群多样性,SAGA-KGE采用基于Levenshtein Distance的精英环境选择方法。该方法将编码视为离散的文本序列,通过判断编码的相似性,进行环境选择。Levenshtein Distance也称为编辑距离,是一种用于衡量两个字符串之间相似度的度量方法。它定义为将一个字符串转换为另一个字符串所需的最少编辑操作次数,允许的编辑操作包括插入、删除和替换。例如,将字符串“kitten”转换为“sitting”需要进行三次操作:将“k”替换为“s”、将“e”替换为“i”、在末尾插入“g”,因此它们的Levenshtein Distance为3。Levenshtein Distance计算方法见下式:

$$lev_{a,b}(i,j) = \begin{cases} \max(i,j) & \text{if } \min(i,j) = 0 \\ \min \begin{cases} lev_{a,b}(i-1,j)+1 \\ lev_{a,b}(i,j-1)+1 \\ lev_{a,b}(i-1,j-1)+1_{(a_i \neq b_j)} \end{cases} & \text{otherwise} \end{cases}$$

其中,  $lev_{a,b}(i,j)$  表示序列a和b的莱文斯坦距离;  $1_{(a_i \neq b_j)}$  为指示函数,用于判断字符  $a_i$  和  $b_j$  是否相等;在SAGA-KGE中,将嵌入模型的架构序列视为文本序列,以此判断序列的多样性;

架构序列间Levenshtein Distance的计算如图8所示。

[0039] 基于Levenshtein Distance的精英环境选择方法步骤如下:首先,从当前种群中选择适应度值前四分之一个体,保留至下一代种群。然后,计算父代种群中剩余的四分之三个体的Levenshtein Distance,并按Levenshtein Distance对其排序,两两选择其中距离更大的个体并保留至下一代种群。最后,通过交叉、变异生成全新的个体,加入后代种群,使种群规模达到预设要求。该方法在保证精英个体传承的同时,增强了种群的个体多样性,提升了优化效果。环境选择流程如图9所示,图中黄色圆点代表通过选择进入下一代的个体,浅蓝色圆点代表父代种群中的个体。

#### [0040] 八、基于“分类+回归”的双层代理辅助模型

在多级特征融合知识图谱嵌入模型的优化搜索过程中,SAGA-KGE采用基于“分类+回归”的双层代理辅助模型,以替代昂贵的适应度函数加速种群适应度评估。该代理辅助模型能够通过个体的编码实现嵌入模型个体到其性能的快速映射。在基于“分类+回归”的双层代理辅助模型中,分类模型基于双向长短期记忆网络(Bidirectional long short-term memory, Bi-LSTM)架构,能够捕捉嵌入模型架构序列和超参数序列中的时序依赖关系,快速提取高性能嵌入模型个体的特征。回归模型则在分类模型的输出基础上,结合架构序列和超参数序列的嵌入向量,利用多层全连接网络进一步优化适应度值预测。通过将适应度预测任务分解为分类和回归两个相对简单的子任务,该方法有效平衡了预测速度与精度,适用于快速评估嵌入模型性能的场景。“分类+回归”双层代理辅助模型的流程如图10所示。具体而言,分类模型首先对架构序列和超参数序列进行嵌入处理,随后通过双向LSTM模块提取时序特征,并经过全连接层完成粗略但高效的分类过程。之后,回归模型利用分类模型的输出结果作为先验信息,在合理的预测范围内,通过多层全连接网络进一步优化适应度值的预测精度。双重代理辅助模型的核心创新在于分类模型通过LSTM结构捕捉块结构组合的合理性,而回归模型在预测过程中利用分类模型的输出范围,有效减少了预测适应度值与

真实值之间的偏差,从而显著提升了代理辅助模型的预测精度。

[0041] 应当注意,本发明的实施方式可以通过硬件、软件或者软件和硬件的结合来实现。硬件部分可以利用专用逻辑来实现;软件部分可以存储在存储器中,由适当的指令执行系统,例如微处理器或者专用设计硬件来执行。本领域的普通技术人员可以理解上述的设备和方法可以使用计算机可执行指令和/或包含在处理器控制代码中来实现,例如在诸如磁盘、CD或DVD-ROM的载体介质、诸如只读存储器(固件)的可编程的存储器或者诸如光学或电子信号载体的数据载体上提供了这样的代码。本发明的设备及其模块可以由诸如超大规模集成电路或门阵列、诸如逻辑芯片、晶体管等的半导体、或者诸如现场可编程门阵列、可编程逻辑设备等的可编程硬件设备的硬件电路实现,也可以用由各种类型的处理器执行的软件实现,也可以由上述硬件电路和软件的结合例如固件来实现。

[0042] 以上所述,仅为本发明的具体实施方式,但本发明的保护范围并不局限于此,任何熟悉本技术领域的技术人员在本发明揭露的技术范围内,凡在本发明的精神和原则之内所作的任何修改、等同替换和改进等,都应涵盖在本发明的保护范围之内。




图 1




图 2






图 3




图 4




图 5

|                |         |            |                    |     |
|----------------|---------|------------|--------------------|-----|
| 1              | 2       | 5          | 4                  | 6   |
| 16, 4, 1, 1, 2 | 2, 1, 1 | 2, 2, 0, 1 | 64, 4, 2, 0, false | 400 |

图 6




图 7




图 8




图 9




图 10