



(12) 发明专利申请

(10) 申请公布号 CN 120219839 A

(43) 申请公布日 2025. 06. 27

(21) 申请号 202510298950.5

G06Q 50/02 (2024. 01)

(22) 申请日 2025. 03. 13

G06N 3/0464 (2023. 01)

G06N 3/0455 (2023. 01)

(71) 申请人 西北农林科技大学

G06N 3/084 (2023. 01)

地址 712100 陕西省咸阳市杨凌示范区邠城路3号

(72) 发明人 黄铝文 张宏鸣 胡晓辉 贾敏
陈可 刘盼 方昶朔 张语涵

(74) 专利代理机构 北京律谱知识产权代理有限公司 11457

专利代理师 黄云铎

(51) Int. Cl.

G06V 10/764 (2022. 01)

G06V 10/766 (2022. 01)

G06V 10/77 (2022. 01)

G06V 10/82 (2022. 01)


权利要求书2页 说明书6页 附图5页

(54) 发明名称

一种基于深度学习的农作物病虫害识别方法

(57) 摘要

本发明涉及一种基于深度学习的农作物病虫害识别方法,包括:步骤S1) 建立农作物病虫害图像数据集,包括对农作物病虫害图像数据的采集与标注;步骤S2) 以YOLOv7-tiny网络模型为基础模型构建改进的YOLOv7-GSNet模型;步骤S3) 使用所述农作物病虫害图像数据集训练所述YOLOv7-GSNet模型;步骤S4) 将农作物图像输入到训练好的所述YOLOv7-GSNet模型,输出关于农作物病虫害的检测结果。



1. 一种基于深度学习的农作物病虫害识别方法,包括:

步骤S1) 建立农作物病虫害图像数据集,包括:对农作物病虫害图像数据的采集与标注;

步骤S2) 以YOLOv7-tiny网络模型为基础模型构建改进的YOLOv7-GSNet模型,其中:将YOLOv7-Tiny网络模型中位于第2-7层的ELAN-T模块和位于第9-14层的ELAN-T模块分别替换成C3模块,在每个C3模块后面插入Swin Transformer模块,在YOLOv7-Tiny网络模型的位于第23-28层的ELAN-T模块后面插入GhostNetV2 Bottleneck模块,将YOLOv7-Tiny网络模型中位于第48层的卷积层替换成RepGhost模块,在构建的所述YOLOv7-GSNet模型中,所述C3模块分别位于第2-7层和第10-15层,插入的2个Swin Transformer模块分别位于第8层和第16层,原来在YOLOv7-Tiny网络模型中位于第23-28层的ELAN-T模块顺延至第25-30层,其后插入的GhostNetV2 Bottleneck模块位于第31层,后面各层位置的索引号顺延,这使得所述RepGhost模块位于第51层,其中位于第30层的卷积层的输出连接所述GhostNetV2 Bottleneck模块的输入,所述GhostNetV2 Bottleneck模块的输出连接位于第40层的卷积层的输入;

步骤S3) 使用所述农作物病虫害图像数据集训练所述YOLOv7-GSNet模型;

步骤S4) 将农作物图像输入到训练好的所述YOLOv7-GSNet模型,输出关于农作物病虫害的检测结果。

2. 根据权利要求1所述的基于深度学习的农作物病虫害识别方法,其中:所述对农作物病虫害图像数据的采集包括:使用公开数据集和实地采集两种途径,

使用公开数据集包括:包含了农作物病虫害的标准化样本并覆盖了不同的场景和多种病虫害类型的对外公开的数据集;

实地采集:通过拍摄装置到农作物种植现场实地拍摄农作物的病虫害图像。

3. 根据权利要求2所述的基于深度学习的农作物病虫害识别方法,其中:对所述农作物病虫害图像数据进行人工标注,标注内容包括:病虫害的种类、位置和边界框。

4. 根据权利要求2所述的基于深度学习的农作物病虫害识别方法,其中:在步骤S1中,还对采集的农作物病虫害图像数据进行数据增强处理,包括以下步骤:

a) 进行几何变换:对采集的所有图像进行随机的角度旋转,旋转角度范围:0至360°,对所有图像进行随机缩放,缩放比例范围:0.8至1.2,以及对所有图像进行随机裁剪,以生成不同视角的局部病虫害区域;

b) 进行光照与颜色变换:随机调整图像的亮度、对比度、饱和度和色调,以便模拟在不同天气条件下采集图像数据的效果;

c) 进行遮挡模拟:在图像的随机位置插入遮挡块,模拟实际场景中的部分病虫害目标被遮挡情况,遮挡块大小为原图面积的5%-15%,并将遮挡区域填充为随机噪声或均值灰度值;

d) 将经过步骤a-c)处理的所有图像输入到StyleGAN模型,生成病虫害图像样本,使用判别网络再对所生成的病虫害图像样本进行处理,通过预设条件过滤掉低质量图像样本,得到最终的农作物病虫害图像数据集。

5. 根据权利要求1所述的基于深度学习的农作物病虫害识别方法,其中:在步骤S3中,按8:2的比例将所述农作物病虫害图像数据集划分出训练数据集与验证数据集,采用AdamW

优化器,初始学习率设定为0.001,使用余弦退火策略动态调整学习率,所述YOLOv7-GSNet模型每次处理16张图像样本,将训练轮次设置为300轮,采用早停机制防止过拟合,当所述YOLOv7-GSNet模型的评估指标达到预期时结束训练。

6.根据权利要求1所述的基于深度学习的农作物病虫害识别方法,其中:使用剪枝技术对构建的所述YOLOv7-GSNet模型进行优化,该优化过程包括:使用权重参数的L1范数评估每个通道的重要性,将重要性排名靠后的占通道总数20%的通道去除掉;调整卷积层的输入和输出的通道数,确保所述YOLOv7-GSNet模型的输入和输出维度一致,最后使用原始训练集进行微调训练,训练轮次为50轮。

7.根据权利要求6所述的基于深度学习的农作物病虫害识别方法,其中:对优化后的所述YOLOv7-GSNet模型进行轻量化处理,包括:

量化配置:选择卷积层和全连接层进行量化,设置量化位宽为INT8;

模拟量化:在前向传播和反向传播中插入量化和反量化操作,模拟量化后的计算;

对量化后的模型进行训练调整:调整学习率为0.0005,使用Adam优化器,训练轮次为100轮;

模型导出:将轻量化后并训练调整完毕的模型导出为ONNX格式。

8.根据权利要求1所述的基于深度学习的农作物病虫害识别方法,其中:在步骤S2中,在构建的所述YOLOv7-GSNet模型中,使用Focal-EIOU损失函数替换原YOLOv7-tiny网络模型中的CIOU损失函数,所述Focal-EIOU损失函数公式如下:

$$L_{EIOU} = L_{IOU} + L_{ais} + L_{asp} = 1 - IOU + \frac{\rho^2(b, b_{gt})}{w_c^2 + h_c^2} + \frac{\rho^2(w, w_{gt})}{w_c^2} + \frac{\rho^2(h, h_{gt})}{h_c^2}$$

其中 L_{IOU} 为IOU损失, L_{ais} 为距离损失, L_{asp} 为方向损失, w_c 表示最小封闭矩形框的宽度, h_c 表示最小封闭矩形框的宽度和高度; b 表示预测框的中心点坐标, b_{gt} 表示真实框的中心点坐标, w_{gt} 表示真实框的宽度, h_{gt} 表示真实框的高度, w 表示预测框的宽度, h 表示预测框的高度; ρ 代表预测框与真实框中心点之间的欧氏距离。

一种基于深度学习的农作物病虫害识别方法

技术领域

[0001] 本发明涉及植物病虫害识别领域,具体涉及一种基于深度学习的农作物病虫害识别方法。

背景技术

[0002] 随着全球人口的持续增长和农业生产需求的不断提高,农业生产面临着诸多挑战。其中,病虫害是影响农作物产量和质量的主要因素之一。病虫害不仅对农作物的生长发育产生严重影响,而且还可能导致大规模的农田损失,甚至威胁到粮食安全。因此,及时、准确地识别和防治病虫害成为现代农业生产中的一项重要任务。

[0003] 传统的农作物病虫害防治方法主要依赖于人工巡查和化学药剂的使用。虽然这些方法在一定程度上能够控制病虫害的发生,但存在诸多问题。首先,人工巡查依赖于农技人员的经验,且巡查频率和效率有限,容易出现漏检现象,导致病虫害的蔓延;其次,化学药剂的过度使用不仅会增加农业成本,还可能对环境和生态系统造成负面影响,且长期依赖化学防治会导致抗药性病虫害的产生。

[0004] 随着计算机视觉技术、人工智能及深度学习算法的快速发展,基于图像识别的病虫害检测技术逐渐成为一种新的解决方案。这些技术可以通过高清图像获取农作物的生长情况,并通过深度学习模型对图像进行分析,自动识别病虫害的种类和程度,进而为农民提供早期预警和精准防治方案。这种技术不仅大大提高了病虫害的识别效率,降低了人工成本,而且能够减少化学药品的使用,从而实现更为环保和可持续的农业生产。

[0005] 尽管已有一些基于深度学习的病虫害识别系统被提出并应用于农业生产中,但仍然存在一些技术瓶颈。例如,现有的病虫害识别模型在处理复杂环境下的图像时,可能会受到光照、角度、背景噪声等因素的影响,导致识别精度降低。此外,现有的系统大多依赖于高质量的标注数据集,且模型训练过程通常需要大量的计算资源和时间,限制了其在实际生产中的广泛应用。

[0006] 因此,如何提高病虫害识别模型的准确性和鲁棒性,尤其是在复杂的农业环境中,同时降低对大规模标注数据集和高性能计算资源的依赖,仍然是当前技术中的一个重要研究方向。

发明内容

[0007] 针对上面提到的技术问题,本发明提供了一种基于深度学习的农作物病虫害识别方法。所述农作物病虫害识别方法包括:

[0008] 步骤S1) 建立农作物病虫害图像数据集,包括:对农作物病虫害图像数据的采集与标注;

[0009] 步骤S2) 以YOLOv7-tiny网络模型为基础模型构建改进的YOLOv7-GSNet模型,其中:将YOLOv7-Tiny网络模型中位于第2-7层的ELAN-T模块和位于第9-14层的ELAN-T模块分别替换成C3模块,在每个C3模块后面插入Swin Transformer模块,在YOLOv7-Tiny网络模型

的位于第23-28层的ELAN-T模块后面插入GhostNetV2 Bottleneck模块,将YOLOv7-Tiny网络模型中位于第48层的卷积层替换成RepGhost模块,在构建的所述YOLOv7-GSNet模型中,所述C3模块分别位于第2-7层和第10-15层,插入的2个Swin Transformer模块分别位于第8层和第16层,原来在YOLOv7-Tiny网络模型中位于第23-28层的ELAN-T模块顺延至第25-30层,其后插入的GhostNetV2 Bottleneck模块位于第31层,后面各层位置的索引号顺延,这使得所述RepGhost模块位于第51层,其中位于第30层的卷积层的输出连接所述GhostNetV2 Bottleneck模块的输入,所述GhostNetV2 Bottleneck模块的输出连接位于第40层的卷积层的输入;

[0010] 步骤S3) 使用所述农作物病虫害图像数据集训练所述YOLOv7-GSNet模型;

[0011] 步骤S4) 将农作物图像输入到训练好的所述YOLOv7-GSNet模型,输出关于农作物病虫害的检测结果。

[0012] 本发明的有益效果在于:

[0013] 本发明提供的一种基于深度学习的农作物病虫害识别方法,基于深度学习的创新性YOLOv7-GSNet模型,实现了自然场景复杂背景下的作物病虫害识别,能准确定位病虫害发生的区域,避免了传统农药使用过程中因过度喷洒或不准确喷洒而导致的农药浪费和环境污染。通过精准识别病虫害区域,有助于农民仅对有问题的区域进行精准防治,达到减少农药使用、降低成本、保护生态环境的目的。不仅提供病虫害识别结果,还能够通过数据分析生成报告,辅助农民进行精准决策。

[0014] 通过数据增强、模型优化及轻量化处理,提升了病虫害检测的精度和实时性,并且可以在微信、支付宝上的小程序平台上部署,同样能够在自然场景复杂背景下进行精准的病虫害检测。

附图说明

[0015] 图1为本发明提供的基于深度学习的农作物病虫害识别方法的流程图;

[0016] 图2为C3模块结构图;

[0017] 图3为RepGhost模块结构图;

[0018] 图4为Swin Transformer模块结构图;

[0019] 图5为GhostNetV2 bottleneck模块结构图;

[0020] 图6为本发明提供的YOLOv7-GSNet模型结构图。

具体实施方式

[0021] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0022] 参考图1,本发明提出了一种基于深度学习的农作物病虫害识别方法,具体包括:

[0023] 步骤S1) 建立农作物病虫害图像数据集,包括:对农作物病虫害图像数据的采集与标注。所述对农作物病虫害图像数据的采集包括:使用公开数据集和实地采集两种途径。

[0024] 公开数据集:本发明使用多个公开数据集,这些公开数据集包含了农作物病虫害

的标准化样本,并覆盖了不同的场景和多种病虫害类型。

[0025] 实地采集:通过照相机、具有拍照功能的智能手机等拍摄装置到农作物种植现场实地拍摄农作物的病虫害图像。采集时,考虑到不同的光照条件、农作物生长阶段及病虫害的多样性,对采集的病虫害图像数据进行人工标注,标注内容包括:病虫害的种类、位置和边界框。

[0026] 另外,公开的数据集中包含的农作物病虫害的标准化样本,有些标准样本带有标注信息,有些标准样本不带有标注信息,因此也需要对其进行人工标注,标注内容也同样包括:病虫害的种类、位置和边界框。

[0027] 为保证数据的高质量,本发明采用LabelImg工具对图像进行标注。

[0028] 进一步的,为了增强数据集的多样性、鲁棒性和泛化能力,本发明还对采集的农作物病虫害图像数据进行数据增强处理,处理方式包括以下步骤:

[0029] 1) 进行几何变换:对采集的所有图像进行随机的角度旋转,旋转角度范围:0至360°,对所有图像进行随机缩放,缩放比例范围:0.8至1.2,以及对所有图像进行随机裁剪,以生成不同视角的局部病虫害区域。

[0030] 2) 进行光照与颜色变换:随机调整图像的亮度(0.5至1.5倍)、对比度(0.8至1.2倍)、饱和度(0.8至1.2倍)和色调(偏移角度:-10°至+10°),由此模拟在不同天气条件下采集图像数据的效果,如阴天、强光等环境。

[0031] 3) 进行遮挡模拟:在图像的随机位置插入遮挡块,模拟实际场景中的部分病虫害目标被遮挡情况,遮挡块大小为原图面积的5%-15%,并将遮挡区域填充为随机噪声或均值灰度值。

[0032] 4) 将经过以上步骤1-3处理的所有图像输入到已知的StyleGAN模型,生成高保真度的病虫害图像样本,确保生成的图像在类别分布上与原始数据一致,并使用判别网络(Discriminator)再对所生成的病虫害图像样本进行处理,通过预设条件过滤掉低质量样本,确保样本数据的质量高可靠性。所述预设条件可以是判别网络的输出置信度低于某个阈值,所述输出置信度表示输入图像为真实图像的概率,如果其低于预设阈值,例如0.6,则认为该输入的图像样本是低质量的,将其去除掉。还可以结合输入图像的清晰度、病虫害特征的完整性等指标来设计过滤条件进行过滤,去除掉低质量的图像样本。

[0033] 通过现有已知的深度网络在深度特征空间中引入对抗性扰动,生成特征增强图像。具体操作如下:

[0034] 首先,通过对抗攻击方法,如FGSM、PGD等在输入图像上生成对抗性样本。其次,将对抗性样本输入到深度网络中,提取其特征表示,然后将这些带有对抗性扰动的特征与原始特征进行混合或替换,从而增强模型对特征扰动的鲁棒性。

[0035] 通过这些数据增强手段,最终生成了一个多样化且富有代表性的病虫害图像数据集。

[0036] S2) 以YOLOv7-tiny网络模型为基础模型构建改进的YOLOv7-GSNet模型。

[0037] 本发明以现有已知的YOLOv7-tiny网络模型为基础模型进行优化改进,建立改进的新YOLOv7-GSNet模型,图6示出了该YOLOv7-GSNet模型的结构。

[0038] 具体而言,改进包括以下几个方面:

[0039] 1) 对YOLOv7-tiny网络模型的骨干网络进行改进:将YOLOv7-Tiny网络模型的骨干

网络中位于第2-7层的ELAN-T模块和位于第9-14层的ELAN-T模块分别替换成C3模块,分别对应图6中的第2-7层的C3模块和第10-15层的C3模块,参见图2所示的C3模块结构图,新加入Swin Transformer模块,即在每个C3模块后面插入Swin Transformer模块,参见图4所示的Swin Transformer模块结构图。在YOLOv7-Tiny网络模型的位于第16-21层的ELAN-T模块和第23-28层的ELAN-T模块保持不变,其在YOLOv7-GSNet网络模型中顺延为第18-23层和第25-30层。如图6所示的YOLOv7-GSNet模型,加入的C3模块通过跨阶段部分连接实现特征融合,增强了小目标检测能力,减少了参数冗余;加入的每个Swin Transformer模块的输入通道与当前层的输出通道数匹配,优化特征的提取能力;保留的ELAN-T模块继续用于特征融合和分类回归任务。所述ELAN-T模块也被称为ELAN-Tiny模块,其为本领域的公开内容,这里不再赘述。所述“跨阶段部分连接”指的是将输入特征图分成两部分,一部分通过Shortcut连接直接跳过某些网络层,另一部分经过处理后再与跳过某些网络层的那部分进行融合。这种结构通过跨越不同阶段的连接,使得低层的特征和高层的特征能够有效融合,从而提高网络的表达能力并减少计算复杂度。在构建的YOLOv7-GSNet网络模型中加入GhostNetV2Bottleneck模块,将其加在原来在YOLOv7-Tiny网络模型中位于第23-28层的ELAN-T模块之后,即将YOLOv7-Tiny网络模型中位于第28层的卷积层的输出(其在YOLOv7-GSNet网络模型中为第30层的卷积层)连接GhostNetV2Bottleneck模块的输入,该GhostNetV2 Bottleneck模块的输出连接到YOLOv7-Tiny网络模型的第37层卷积层(其在YOLOv7-GSNet网络模型中为第40层的卷积层)的输入,图5示出了GhostNetV2 bottleneck模块的结构。此GhostNetV2 Bottleneck模块在图6中用简化形式GhostNet-V2来表示,该GhostNetV2 Bottleneck模块通过轻量化卷积操作和线性变换,提高了特征的表达能力。

[0040] 2) 对YOLOv7-tiny网络模型的颈部网络进行改进:将YOLOv7-Tiny网络模型的颈部网络中位于第48层的卷积层替换成RepGhost模块,其在构建的YOLOv7-GSNet网络模型中位于第51层,以减少计算复杂度,同时提升网络效率,RepGhost模块的结构如图3所示。

[0041] 综上所述,在构建的所述YOLOv7-GSNet模型中,所述C3模块分别位于第2-7层和第10-15层,插入的2个Swin Transformer模块分别位于第8层和第16层,原来在YOLOv7-Tiny网络模型中位于第23-28层的ELAN-T模块顺延至第25-30层,其后插入GhostNetV2 Bottleneck模块,其位于第31层,后面各层位置的索引号顺延,这使得所述RepGhost模块位于第51层,其中位于第30层的卷积层的输出连接所述GhostNetV2 Bottleneck模块的输入,所述GhostNetV2 Bottleneck模块的输出连接位于第40层的卷积层的输入。

[0042] 改进的YOLOv7-GSNet模型采用Focal-EIOU损失函数替代原有的CIOU损失函数,该Focal-EIOU损失函数通过聚焦损失的回归方式,减少预测框与真实框之间的宽高差异,提高了检测框的质量,从而提高检测精度。

[0043] Focal-EIOU损失函数公式如下:

$$[0044] \quad L_{EIOU} = L_{IOU} + L_{ais} + L_{asp} = 1 - IOU + \frac{\rho^2(b, b_{gt})}{w_c^2 + h_c^2} + \frac{\rho^2(w, w_{gt})}{w_c^2} + \frac{\rho^2(h, h_{gt})}{h_c^2}$$

[0045] 其中 L_{IOU} 为IOU损失, L_{ais} 为距离损失, L_{asp} 为方向损失。 w_c 表示最小封闭矩形框的宽度, h_c 表示最小封闭矩形框的宽度和高度; b 表示预测框的中心点坐标, b_{gt} 表示真实框的中心点坐标, w_{gt} 表示真实框的宽度, h_{gt} 表示真实框的高度, w 表示预测框的宽度, h 表示预测框

的高度; p 代表预测框与真实框中心点之间的欧氏距离。IOU (Intersection over Union, 交并比) 是用来衡量两个边界框 (或区域) 重叠程度的指标, IOU 的算法为本领域技术人员所公知的内容, 这里不再赘述。

[0046] S3) 使用所述农作物病虫害图像数据集训练所述YOLOv7-GSNet模型。

[0047] 按8:2的比例将所述农作物病虫害图像数据集划分出训练数据集与验证数据集。训练方法可以使用现有已知的方法。下面简要说明。

[0048] 训练过程采用AdamW优化器, 初始学习率设定为0.001, 使用已知的余弦退火策略动态调整学习率。

[0049] 训练设置如下:

[0050] 批量大小: 16张图像样本, 即模型每次处理16张图像样本。

[0051] 训练轮次: 300轮, 采用早停机制防止过拟合。

[0052] 图像预处理: 所有农作物病虫害图像统一调整为 640×640 像素, 并进行归一化处理。

[0053] 通过评估指标来判断训练的YOLOv7-GSNet模型达到预期结果。具体而言, 使用验证集评估YOLOv7-GSNet模型的性能, 当平均精度均值 (mAP) 大于70%、每秒帧数 (FPS) 达到20以上、参数量 (Model Parameters) 小于10M, 准确率达到约93%或以上、召回率基本与YOLOv7-tiny模型持平或降低时, 训练后的YOLOv7-GSNet模型的性能达到预期结果, 训练结束。

[0054] S4) 将农作物图像输入到训练好的所述YOLOv7-GSNet模型, 输出关于农作物病虫害的检测结果。

[0055] 将实地采集的农作物图像输入到训练好的所述YOLOv7-GSNet模型, 该模型输出关于农作物病虫害的检测结果, 即检测结果包括: 是否有病虫害, 有病虫害的话, 给出具体是哪种病虫害的结论。

[0056] 为了本发明提供的农作物病虫害失败方法能够在微信、支付宝上的小程序平台上部署, 实现在自然场景的复杂背景下进行精准的病虫害检测, 这里还对YOLOv7-GSNet模型进行优化和轻量化处理。

[0057] 具体而言, 首先使用剪枝技术来完成模型优化: 使用权重参数的L1范数评估每个通道的重要性, 将重要性排名靠后的占通道总数20%的通道去除掉; 调整卷积层的输入和输出的通道数, 确保模型的输入和输出维度一致。

[0058] 在使用剪枝技术完成模型优化后, 使用原始训练集进行微调训练, 训练轮次为50轮。

[0059] 接着, 进行量化配置和模拟量化。

[0060] 量化配置: 选择卷积层和全连接层进行量化, 设置量化位宽为INT8。

[0061] 模拟量化: 在前向传播和反向传播中插入量化和反量化操作, 模拟量化后的计算。

[0062] 对量化后的模型进行训练调整: 调整学习率为0.0005, 使用Adam优化器, 训练轮次为100轮, 进而完成进一步的调整和优化量化后的模型, 确保量化过程不会导致性能的显著下降。

[0063] 模型导出: 将轻量化后并训练调整完毕的模型导出为ONNX格式, 适用于移动端部署。

[0064] 通过PyTorch Mobile技术在微信或支付宝小程序平台上部署模型,能够在移动设备上高效执行。

[0065] 以上内容是结合具体实施方式对本发明作进一步详细说明,不能认定本发明具体实施只局限于这些说明,对于本发明所属技术领域的普通技术人员来说,在不脱离本发明的构思的前提下,还可以作出若干简单的推演或替换,都应当视为属于本发明所提交的权利要求书确定的保护范围。




图1




图2




图3




图4




图5




图6