



(12) 发明专利申请

(10) 申请公布号 CN 121459201 A

(43) 申请公布日 2026. 02. 03

(21) 申请号 202511772621.6

G06V 10/82 (2022.01)

(22) 申请日 2025.11.28

G06N 3/0442 (2023.01)

(71) 申请人 西北农林科技大学

G06N 3/0464 (2023.01)

地址 712100 陕西省咸阳市杨陵示范区西
农路22号

G06N 3/09 (2023.01)

(72) 发明人 詹涛 朱源媛 张宏鸣 兰杰
朱铭泽 党乾龙(74) 专利代理机构 陕西禾硕知识产权代理事务
所(普通合伙) 61339

专利代理师 田亚红

(51) Int. Cl.

G06V 20/13 (2022.01)

G06V 10/44 (2022.01)

G06V 10/42 (2022.01)

G06V 10/80 (2022.01)


权利要求书2页 说明书11页 附图1页

(54) 发明名称

一种基于边界引导和动态记忆网络的耕地
语义变化检测方法、系统、介质和电子设备

(57) 摘要

本申请涉及基于边界引导和动态记忆网络的耕地语义变化检测方法、系统、介质和电子设备,属于图像识别技术领域,旨在解决季节差异、光照变化和图像噪声导致的伪变化问题。本发明方法先利用轻量化卷积网络提取双时相遥感图像的局部空间特征,同时获取对应的全局语义特征,随后将两类特征融合,得到能够表征空间细节与全局语义的融合特征。在此基础上提取双时相图像的差异特征,并通过边界增强突出耕地边缘区域的细节变化。随后采用动态记忆网络对差异特征进行更新,使其具备更强表征能力。最终基于更新特征生成耕地语义变化检测结果。本方法能够同时利用低层空间细节与高层语义信息,有效区分真实变化与伪变化,显著提升耕地语义变化检测的精度。



1. 一种基于边界引导和动态记忆网络的耕地语义变化检测方法, 其特征在于, 所述方法包括:

采集耕地的双时相遥感图像 I_1 和 I_2 , 并对图像 I_1 和 I_2 分别进行局部空间特征和全局语义特征提取, 并融合提取的局部空间特征和全局语义特征, 得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} ;

基于融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取, 得到初始差异特征 F^{diff} , 再从 F^{diff} 中提取并处理边界信息, 将处理后的边界信息 E 与 F^{diff} 加权融合, 得到增强后的差异特征 F^{attn} ;

利用动态记忆网络对增强后的差异特征 F^{attn} 进行更新, 得到更新特征 F^{upd} ;

基于更新特征 F^{upd} , 利用分类器得到耕地语义变化检测结果。

2. 根据权利要求1所述的方法, 其特征在于, 得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} 的过程包括:

采用轻量化卷积网络分别提取图像 I_1 和 I_2 的局部空间特征 F_t^{local} , 得到图像 I_1 的局部空间特征 F_1^{local} , 图像 I_2 的局部空间特征 F_2^{local} ;

采用DINOv2-small骨干网络分别提取图像 I_1 和 I_2 的全局语义特征 F_t^{global} , 得到图像 I_1 的全局语义特征 F_1^{global} , 图像 I_2 的全局语义特征 F_2^{global} ;

分别融合图像 I_1 和 I_2 的局部空间特征 F_t^{local} 和全局语义特征 F_t^{global} , 得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} 。

3. 根据权利要求2所述的方法, 其特征在于, 得到增强后的差异特征 F^{attn} 过程包括:

对融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取, 得到初始差异特征 F^{diff} ;

从差异特征 F^{diff} 中提取并处理边界信息, 得到处理后的边界信息 E ;

基于空间注意力与通道注意力机制, 将差异特征 F^{diff} 与处理后的边界信息 E 进行加权融合, 得到增强后的差异特征 F^{attn} 。

4. 根据权利要求3所述的方法, 其特征在于, 得到更新特征 F^{upd} 的过程包括:

构建耕地语义记忆库 M ;

对 F^{attn} 进行操作, 生成查询向量 Q ;

计算查询向量 Q 与记忆库 M 中记忆项 M_j 的相似度, 进而得到更新 Q 时 M_j 对应的权重;

将权重与记忆库 M 中的记忆项 M_j 进行加权求和得到更新项, 再将更新项与增强后的

差异特征 F^{attn} 相加得到更新特征 F^{upd} 。

5. 根据权利要求4所述的方法, 其特征在于, 查询向量 Q 与记忆库 M 中记忆项 M_j 的相似度计算方法为:

$$sim_{b,i,j} = \frac{Q_{b,i} \cdot M_j}{\tau};$$

其中, τ 为温度系数, $Q_{b,i}$ 为具体查询向量, M_j 为记忆项。

6. 一种基于边界引导和动态记忆网络的耕地语义变化检测系统, 所述系统包括:

局部-全局特征提取模块, 用于采集耕地的双时相遥感图像 I_1 和 I_2 , 并对图像 I_1 和 I_2 分别进行局部空间特征和全局语义特征提取, 并融合提取的局部空间特征和全局语义特征, 得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} ;

差异特征提取模块, 基于融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取, 得到初始差异特征 F^{diff} , 再从 F^{diff} 中提取并处理边界信息, 将处理后的边界信息 E 与 F^{diff} 加权融合, 得到增强后的差异特征 F^{attn} ;

更新模块, 利用动态记忆网络对增强后的差异特征 F^{attn} 进行更新, 得到更新特征 F^{upd} ;

输出模块, 基于更新特征 F^{upd} , 利用分类器得到耕地语义变化检测结果;

其中, 该系统基于权利要求1-5中任一项所述的方法实现。

7. 一种存储有计算机指令的非瞬时计算机可读存储介质, 其中, 所述计算机指令用于使所述计算机执行根据权利要求1-5中任一项所述的方法。

8. 一种电子设备, 包括:

至少一个处理器, 以及与所述至少一个处理器通信连接的存储器; 其中, 所述存储器存储有可被所述至少一个处理器执行的指令, 所述指令被所述至少一个处理器执行, 以使所述至少一个处理器能够执行权利要求1-5中任一项所述的方法。

一种基于边界引导和动态记忆网络的耕地语义变化检测方法、系统、介质和电子设备

技术领域

[0001] 本发明属于图像识别技术领域,具体涉及一种基于边界引导和动态记忆网络的耕地语义变化检测方法、系统、介质和电子设备。

背景技术

[0002] 耕地作为人类社会赖以生存和发展的重要自然资源,在粮食安全、经济建设以及生态环境保护等方面发挥着不可替代的作用。耕地利用方式的变化不仅关系到农业生产力的提升,也会对区域生态平衡与社会经济发展产生深远影响。因此,对耕地动态进行持续、精确的监测,对于制定科学合理的土地利用政策、保障耕地资源的可持续利用具有重要意义。

[0003] 随着遥感技术的快速发展,多时相遥感图像的获取能力大幅提升,在空间分辨率和光谱分辨率方面均取得了显著进步。基于遥感图像的变化检测方法逐渐成为土地资源管理、农业调查和生态环境监测等领域的重要工具。其中,变化检测的核心任务是通过分析不同时刻在同一区域获取的遥感图像,以识别地物类型的变化情况。现有的变化检测方法大体可分为两类:一类是二值变化检测方法,旨在识别地物变化与未变化区域,能够满足某些仅需关注变化范围的应用需求;另一类是语义变化检测方法,不仅能够定位变化的发生位置,还能识别具体的地物变化类别,例如由耕地转变为水域、林地转变为建设用地等。这类方法在土地利用精细化管理和资源规划决策中具有更高的应用价值。

[0004] 尽管深度学习方法的引入推动了语义变化检测的发展,但在实际应用中仍存在一些亟待解决的问题。首先,现有模型往往难以同时兼顾低层空间特征与高层语义特征的有效融合,导致对细微的地物变化识别不足。其次,常用的差异特征建模方式,如简单的特征相减或拼接,难以充分表征多时相遥感图像中复杂的时序动态信息。最后,由于遥感图像的获取条件受季节差异、光照条件以及噪声干扰等因素影响,大部分现有方法的检测结果往往会产生伪变化,导致其难以识别地物发生的真实变化。这些问题在耕地动态监测场景中尤为突出,因为耕地变化往往具有细微性和季节性,增加了变化检测的难度。

[0005] 因此,亟需一种能够兼顾局部与全局信息、具备鲁棒差异建模能力并有效抑制伪变化干扰的耕地语义变化检测方法,以提升地物变化的检测精度与可靠性。

发明内容

[0006] 针对上述现有技术难以同时兼顾低层空间细节与高层语义特征,差异建模方式过于简单,以及在面对季节差异、光照变化和图像噪声等因素时容易产生伪变化干扰的问题,本发明提供一种基于边界引导与动态记忆的耕地语义变化检测方法、系统、介质和电子设备,能够有效提升变化检测的精度与鲁棒性。

[0007] 本发明方法思路为:首先,利用轻量化卷积网络提取输入图像的局部空间特征,同时基于DINOv2-small对输入图像进行多层级全局语义特征提取,并通过自注意力机制实现

跨层融合。随后,将局部空间特征和全局语义特征进行融合,从而获得能够兼顾局部空间和全局语义的融合特征;其次,利用双时相图像的融合特征进行差异特征提取和边界增强,生成增强后的差异特征。然后,利用动态记忆网络对该差异特征进行更新,得到更新特征;随后,将更新特征输入分类器中,得到耕地语义变化检测结果。

[0008] 本发明所采用的具体技术方案如下:

[0009] 一种基于边界引导和动态记忆网络的耕地语义变化检测方法,所述方法包括:

[0010] 采集耕地的双时相遥感图像 I_1 和 I_2 ,并对图像 I_1 和 I_2 分别进行局部空间特征和全局语义特征提取,并融合提取的局部空间特征和全局语义特征,得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} ;

[0011] 基于融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取,得到初始差异特征 F^{diff} ,再从 F^{diff} 中提取并处理边界信息,将处理后的边界信息 E 与 F^{diff} 加权融合,得到增强后的差异特征 F^{attn} ;

[0012] 利用动态记忆网络对增强后的差异特征 F^{attn} 进行更新,得到更新特征 F^{upd} ;

[0013] 基于更新特征 F^{upd} ,利用分类器得到耕地语义变化检测结果。

[0014] 优选地,得到与 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} 的过程包括:

[0015] 采用轻量化卷积网络分别提取图像 I_1 和 I_2 的局部空间特征,得到图像 I_1 的局部空间特征 F_1^{local} ,图像 I_2 的局部空间特征 F_2^{local} ;

[0016] 采用DINOv2-small骨干网络分别提取图像 I_1 和 I_2 的全局语义特征 F_i^{global} ,得到图像 I_1 的全局语义特征 F_1^{global} ,图像 I_2 的全局语义特征 F_2^{global} ;

[0017] 分别融合图像 I_1 和 I_2 的局部空间特征和全局语义特征,得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} 。

[0018] 优选地,得到增强后的差异特征 F^{attn} 过程包括:

[0019] 对融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取,得到初始差异特征 F^{diff} ;

[0020] 从初始差异特征 F^{diff} 中提取并处理边界信息,得到处理后的边界信息 E ;

[0021] 基于空间注意力与通道注意力机制,将初始差异特征 F^{diff} 与处理后的边界信息 E 进行加权融合,得到增强后的差异特征 F^{attn} 。

[0022] 优选地,得到更新特征 F^{upd} 的过程包括:

[0023] 构建耕地语义记忆库 M ;

[0024] 对 F^{attn} 进行操作,生成查询向量 Q ;

[0025] 计算查询向量 Q 与记忆库 M 中记忆项 M_j 的相似度,进而得到更新 Q 时 M_j 对

应的权重。

[0026] 将权重与记忆库 M 中的记忆项 M_j 进行加权求和得到更新项,再将更新项与增强后的差异特征 F^{atm} 相加得到更新特征 F^{upd} 。

[0027] 优选地,计算查询向量 Q 与记忆库 M 中记忆项 M_j 的相似度方法为:

$$[0028] \quad sim_{b,i,j} = \frac{Q_{b,i} \cdot M_j}{\tau}$$

[0029] 其中, τ 为温度系数, $Q_{b,i}$ 为具体查询向量, M_j 为记忆项。

[0030] 本发明的第二个目的为,提供一种基于边界引导和动态记忆网络的耕地语义变化检测系统,所述系统包括:

[0031] 局部-全局特征提取模块,用于对图像 I_1 和 I_2 分别进行局部空间特征和全局语义特征提取,并融合提取的局部空间特征和全局语义特征,得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} ;

[0032] 差异特征提取模块,基于融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取,得到初始差异特征 F^{diff} ,再从 F^{diff} 中提取并处理边界信息,将处理后的边界信息 E 与 F^{diff} 加权融合,得到增强后的差异特征 F^{atm} ;

[0033] 更新模块,利用动态记忆网络对增强后的差异特征 F^{atm} 进行更新,得到更新特征 F^{upd} ;

[0034] 输出模块,基于更新特征 F^{upd} ,利用分类器得到耕地语义变化检测结果;

[0035] 其中,该系统基于一种基于边界引导和动态记忆网络的耕地语义变化方法实现。

[0036] 本发明的第三个目的为,提供一种存储有计算机指令的非瞬时计算机可读存储介质,其中,所述计算机指令用于使所述计算机执行一种基于边界引导和动态记忆网络的耕地语义变化方法。

[0037] 本发明的第四个目的为,提供一种电子设备,包括:

[0038] 至少一个处理器,以及与所述至少一个处理器通信连接的存储器;其中,所述存储器存储有可被所述至少一个处理器执行的指令,所述指令被所述至少一个处理器执行,以使所述至少一个处理器能够执行一种基于边界引导和动态记忆网络的耕地语义变化方法。

[0039] 本发明的有益效果是:本发明公开了一种基于边界引导和动态记忆网络的耕地语义变化检测方法、系统、介质和电子设备,与现有技术相比,本发明的改进之处在于:

[0040] (1) 本发明通过轻量化卷积网络与DINOv2-small结合,实现了双时相遥感图像局部空间细节与全局语义信息的互补,使得特征表达更加全面,有效提升了本发明方法在对耕地变化检测时的综合感知能力。

[0041] (2) 本发明引入边界引导机制,并结合差分算子与空间-通道联合注意力,能够突出双时相遥感图像的显著变化区域,抑制无关信息,使得差异建模更加精细,提升了本发明方法对细微耕地变化检测的敏感性。

[0042] (3) 本发明采用动态记忆网络,以类别原型为核心进行特征查询和更新,逐步优化特征分布,从而有效区分双时相遥感图像的真实变化与伪变化,使本发明方法在对耕地语义变化检测时具备更强的鲁棒性,显著增强了本发明方法在复杂环境下的稳定性。

附图说明

[0043] 图1为本发明流程框图;

[0044] 图2为本发明方法结构图。

具体实施方式

[0045] 为了使本领域的普通技术人员能更好的理解本发明的技术方案,下面结合附图和实施例对本发明的技术方案做进一步的描述,以下实施用于说明本发明,但不能用来限制本发明的范围。

[0046] 实施例1:

[0047] 参照附图1-2所示的一种基于边界引导和动态记忆网络的耕地语义变化检测方法,包括:

[0048] S1、采集耕地的双时相遥感图像 I_1 和 I_2 , 并对图像 I_1 和 I_2 分别进行局部空间特征和全局语义特征提取,并融合提取的局部空间特征和全局语义特征,得到与 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} 。

[0049] S101、采用轻量化卷积网络分别提取图像 I_1 和 I_2 的局部空间特征,得到图像 I_1 的局部空间特征 F_1^{local} , 图像 I_2 的局部空间特征 F_2^{local} , 其中, 图像 I_1 和 I_2 为不同时刻获取的耕地遥感图像, 且 $I_1, I_2 \in \mathbb{R}^{H \times W \times 3}$, H 和 W 分别表示图像的高度和宽度。

[0050] 轻量化卷积网络提取图像 I_1 和 I_2 的局部空间特征 F_t^{local} 的表达式为:

$$[0051] \quad F_t^{local} = \sigma(CNN(I_t)), \quad t \in \{1, 2\}, \quad (1)$$

[0052] 其中, $CNN(\cdot)$ 为卷积操作, $\sigma(\cdot)$ 为非线性激活函数。

[0053] 轻量化卷积网络的提取过程为:轻量化卷积网络包括两部分:第一部分为常规的 3×3 卷积,用于提取基础局部特征;第二部分为带有膨胀率的 3×3 膨胀卷积,用于在低计算量下扩大感受野。两部分卷积的输出结果在通道维度上进行拼接后,通过 1×1 卷积实现特征融合和压缩。进一步地,为适应深层网络的特征处理需求,在轻量化卷积网络输出端添加步幅为4的卷积实现下采样操作,该结构在保持轻量化的同时,能够同时获取局部细节与大尺度上下文特征,从而为遥感图像变化检测提供高效的特征。

[0054] S102、采用DINOv2-small骨干网络分别提取图像 I_1 和 I_2 的全局语义特征 F_t^{global} , 得到图像 I_1 的全局语义特征 F_1^{global} , 图像 I_2 的全局语义特征 F_2^{global} 。

[0055] 具体的,利用DINOv2-small骨干网络的多个中间层提取分别提取图像 I_1 和 I_2 的多

层级特征 $\{F_t^1, F_t^2, \dots, F_t^L | t \in \{1, 2\}\}$, 其中, L 为网络层数; 并利用自注意力机制将多层级特征进行合并, 生成图像 I_1 的全局语义特征 F_1^{global} 和图像 I_2 的全局语义特征 F_2^{global} 。

[0056] 提取全局语义特征 F_t^{global} 的表达式为:

$$[0057] \quad F_t^{global} = SelfAttn(Concat\{F_t^1, F_t^2, \dots, F_t^L\}), t \in \{1, 2\} \quad (2)$$

[0058] 其中, $SelfAttn(\cdot)$ 为自注意力机制, $Concat(\cdot)$ 为通道维度拼接操作。

[0059] 本实施例中, 采用 DIN0v2-small 网络作为图像 I_1 和 I_2 特征提取的骨干网络。DIN0v2-small 网络是一种基于自监督学习的视觉 Transformer 模型, 其核心思想是通过自蒸馏机制, 在无标注图像上进行特征对齐训练, 从而获得具有判别性的通用视觉特征。

[0060] 具体地, DIN0v2-small 以 Vision Transformer-small 结构为基础, 包括一个图像分块嵌入层与多个 Transformer 编码器模块。输入图像 I_1 和 I_2 后, 首先图像 I_1 和 I_2 分别被划分为固定大小的图像块 (如 14×14), 并通过线性映射转化为特征向量序列; 随后, 这些特征向量序列依次经过 12 层 Transformer 编码器进行特征提取, 分别得到图像 I_1 和 I_2 的双时相图像的多层级特征。其中, 每一层 Transformer 编码器包含多头自注意力与前馈神经网络结构, 用于捕获全局依赖关系和上下文信息。

[0061] 在本实施例中, 为兼顾多层级特征信息, 选取 12 层 Transformer 编码器中的第 2 层、第 5 层、第 8 层、第 11 层的输出作为具有多尺度特征的多层级特征; 其中, 浅层 (第 2 层、第 5 层) 特征能够保留图像 I_1 和 I_2 更多空间结构和边缘纹理信息, 深层 (第 8 层、第 11 层) 特征能够保留图像 I_1 和 I_2 更强的语义信息。

[0062] 接着分别对双时相图像的多层级特征进行融合, 得到最终的全局语义特征 F_1^{global} 和 F_2^{global} 。具体而言, 以 F_1^{global} 的获取为例, 首先将图像 I_1 来自不同层级的特征通过线性投影统一至相同的特征维度, 以保证多尺度特征在空间与通道维度上的一致性。随后, 将各层级特征展平并序列化后进行级联, 形成包含多尺度信息的特征序列。在此基础上, 引入多头自注意力机制对该特征序列进行全局建模, 通过计算层级间的相关性自适应调整不同尺度特征的权重, 从而实现跨层级的信息交互与特征补充。经注意力增强后的特征序列再经过归一化处理, 并重新映射回原始空间结构; 最终通过在尺度维度上求平均, 得到融合后的特征。该过程能够充分整合图像 I_1 不同层级特征的语义与细节信息, 从而生成更具判别力的多尺度融合特征。

[0063] S103、分别融合图像 I_1 和 I_2 的局部空间特征 F_t^{local} 和全局语义特征 F_t^{global} , 得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} 。

[0064] 具体的, 分别将图像 I_1 的局部空间特征 F_1^{local} 与全局语义特征 F_1^{global} , 和图像 I_2 的局部空间特征 F_2^{local} 与全局语义特征 F_2^{global} 进行尺度对齐与线性变换, 实现图像 I_1 的

F_1^{local} 和 F_1^{global} 的融合, 得到融合特征 F_1^{fus} , 图像 I_2 的 F_2^{local} 和 F_2^{global} 的融合, 得到融合特征 F_2^{fus} ,

[0065] F_t^{local} 和 F_t^{global} 融合表达式为:

[0066] $F_t^{fus} = Fusion(Concat\{W_g Upsample(F_t^{global}), W_l F_t^{local}\}), t \in \{1, 2\}, (3)$

[0067] 其中, $Upsample(\cdot)$ 为上采样操作, W_g 为针对 F_t^{global} 的卷积投影矩阵, W_l 为针对 F_t^{local} 的卷积投影矩阵, $Fusion(\cdot)$ 为融合操作。

[0068] 融合的具体过程为, 首先对特征 F_t^{global} 执行上采样与 1×1 卷积投影, 使其与卷积特征 F_t^{local} 在空间分辨率和通道数上保持一致; 同时, 对卷积特征进行 1×1 卷积投影以完成通道对齐; 然后, 将两类特征在通道维度拼接, 并输入通道注意力单元内, 该单元基于全局平均池化生成注意力权重, 对拼接特征进行加权, 以突出关键信息、抑制冗余信息; 最后, 经过输出卷积单元 (含 1×1 卷积、批归一化与非线性激活函数) 进行特征压缩与增强, 得到同时具备局部空间细节与全局语义信息的融合特征 F_t^{fus} 。

[0069] S2、基于融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取, 得到初始差异特征 F^{diff} , 再从初始差异特征 F^{diff} 中提取并处理边界信息, 将处理后的边界信息 E 与 F^{diff} 加权融合, 得到增强后的差异特征 F^{atm} 。具体过程为:

[0070] S201、对融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取, 得到初始差异特征 F^{diff} ; 具体的过程为:

[0071] 对融合特征 F_1^{fus} 和 F_2^{fus} 执行像素级差分运算, 以凸显两者之间的变化程度; 同时, 将融合特征 F_1^{fus} 和 F_2^{fus} 进行通道维度的拼接, 以保留完整的上下文信息。随后, 将差分结果与拼接特征一同输入卷积单元, 经批归一化和非线性激活函数处理, 生成初始差异特征 F^{diff} 。

[0072] 基于融合特征 F_1^{fus} 和 F_2^{fus} 进行初始差异特征提取, 得到初始差异特征 F^{diff} 的计算表达式为:

[0073] $F^{diff} = \sigma(Conv(Concat(|F_1^{fus} - F_2^{fus}|, F_1^{fus}, F_2^{fus}))) (4)$

[0074] 其中, $|F_1^{fus} - F_2^{fus}|$ 表示像素级差分运算, $Conv(\cdot)$ 表示卷积映射操作, $\sigma(\cdot)$ 为非线性激活函数。

[0075] S202、从初始差异特征 F^{diff} 中提取并处理边界信息, 得到处理后的边界信息 E , 具体过程包括:

[0076] 在得到初始差异特征 F^{diff} 的基础上, 本发明引入边界引导机制, 利用 Sobel 算子从初始差异特征 F^{diff} 中提取边界信息, 再将边界信息经过卷积与归一化运算进行细化处

理,以保证边界检测的准确性和鲁棒性,最终得到边界信息的特征,即处理后的边界信息 E 。

[0077] 得到处理后的边界信息 E 的表达式为:

$$[0078] \quad E = \text{Norm}(\text{Conv}(\text{Sobel}(F^{\text{diff}}))) \quad (5)$$

[0079] 其中, $\text{Norm}(\cdot)$ 表示归一化操作, $\text{Conv}(\cdot)$ 表示卷积操作, $\text{Sobel}(\cdot)$ 为Sobel算子。

[0080] S203、基于空间注意力与通道注意力机制,将初始差异特征 F^{diff} 与处理后的边界信息 E 进行加权融合,得到增强后的差异特征 F^{attn} 。

[0081] 初始差异特征 F^{diff} 与处理后的边界信息 E 加权融合的表达式为:

$$[0082] \quad F^{\text{attn}} = \text{Conv}(\text{Concat}\{\text{CA}(\text{SA}(F^{\text{diff}})), E\}) \quad (6)$$

[0083] 其中, $\text{Conv}(\cdot)$ 表示卷积操作, $\text{Concat}(\cdot)$ 表示通道维度的拼接, $\text{CA}(\cdot)$ 表示通道注意力, $\text{SA}(\cdot)$ 表示空间注意力。

[0084] 在公式 (6) 中,空间注意力通过多头自注意力机制对初始差异特征 F^{diff} 进行建模,从而增强变化区域的空间依赖关系;通道注意力则通过自适应池化与非线性映射学习初始差异特征 F^{diff} 不同通道的重要性分布,实现特征的选择性增强即加权,最后,将加权后的差异特征与处理后的边界信息 E 进行拼接,实现融合,并经由 1×1 卷积和批归一化处理,得到增强后的差异特征 F^{attn} 。

[0085] 通过上述步骤,本实施例能够在有效捕获图像变化区域的同时,利用边界信息抑制噪声干扰,从而突出真实变化区域并提高检测精度。

[0086] S3、利用动态记忆网络对增强后的差异特征 F^{attn} 进行更新,得到更新特征 F^{upd} 。

[0087] 动态记忆网络采用动态记忆优化机制对步骤S2中得到的增强后的差异特征 F^{attn} 进行更新,这是一种基于类别原型的动态记忆优化机制,用于增强本发明方法对耕地伪变化的鲁棒性。

[0088] S301、构建耕地语义记忆库 M ;

[0089] 具体的,耕地语义记忆库 M 多个记忆项 M_j 构成,每个记忆项用于表征不同耕地变化语义特征。

[0090] S302、对 F^{attn} 进行处理,生成查询向量 Q ,该查询向量 Q 中包含多个具体的 $Q_{b,i}$ 。

[0091] 具体的,对 F^{attn} 进行通道归一化,并通过卷积映射生成查询向量 Q ;

[0092] 生成查询向量 Q 的表达式为:

$$[0093] \quad Q = \text{QueryProj}(F^{\text{attn}}_{\text{norm}}), \quad (7)$$

[0094] 其中, $Q \in \mathbb{R}^{B \times hw \times D_k}$, B 为批次大小, $hw = h \times w$ 为 F^{attn} 向量在空间上展平

后的维度, D_k 为查询维度, F_{norm}^{attn} 为 F^{attn} 归一化结果, $QueryProj(\cdot)$ 表示线性投影操作。

[0095] S303、计算查询向量 Q 与记忆库 M 中记忆项 M_j 的相似度, 进而得到更新 Q 时 M_j 对应的权重 $Attn_{b,i,j}$ 。

[0096] 具体的, 对于某一具体查询向量 $Q_{b,i} \in Q$ 和某一类别的记忆项 $M_j \in M$, 两者相似度计算的表达式为:

$$[0097] \quad sim_{b,i,j} = \frac{Q_{b,i} \cdot M_j}{\tau} \quad (8)$$

[0098] 其中, τ 为温度系数, 用来调节特征相似度分布的平滑程度。在本发明的实施例中, τ 设定为 0.1, 该值较小, 可有效增强模型对高相似度样本的敏感性。

[0099] 利用上述查询向量与记忆项相似度得到更新 $Q_{b,i}$ 时 M_j 对应权重 $Attn_{b,i,j}$ 表达式为:

$$[0100] \quad Attn_{b,i,j} = Softmax(sim_{b,i,j}) \quad (9)$$

[0101] 其中, $Softmax(\cdot)$ 是对相似度得分进行归一化处理, 以将各样本间的权重转化为概率分布。通过该操作, 可确保所有权重值均为非负数, 且其总和为 1, 从而实现对 M_j 在更新 $Q_{b,j}$ 时贡献度的相对衡量。

[0102] S304、将权重 $Attn_{b,i,j}$ 与记忆库 M 中记忆项 M_j 进行加权求和得到更新项, 再将更新项与增强后的差异特征 F^{attn} 相加得到更新特征 F^{upd} , 整个过程表达式为:

$$[0103] \quad F^{upd} = F^{attn} + \sum_j Attn_{b,i,j} M_j \quad (10)$$

[0104] 通过上述步骤, 动态记忆网络能够在融合记忆检索结果与差异特征 F^{attn} 后得到更新特征 F^{upd} , 该特征在保留真实变化信息的同时, 有效抑制伪变化干扰, 实现对变化特征的增强和记忆的迭代优化, 从而提升整体变化检测模型的精度与鲁棒性。

[0105] S4、更新特征 F^{upd} 作为分类器的输入, 输出得到耕地语义变化检测结果。

[0106] 分类器可选取常规的分类器, 如, 可采用轻量且稳定的卷积分类器。

[0107] 实施例2:

[0108] 本实施还给出了一种基于边界引导和动态记忆网络的耕地语义变化检测模型, 该模型包括:

[0109] 局部空间特征提取子模块, 用于提取双时相遥感图像 I_1 和 I_2 的局部空间特征, 该过程通过步骤S101实现;

[0110] 全局语义特征提取子模块, 用于提取双时相遥感图像 I_1 和 I_2 的全局语义特征, 该过程通过步骤S102实现;

[0111] 局部与全局特征融合子模块, 用于分别融合图像 I_1 和 I_2 的局部空间特征和全局语

义特征,得到与图像 I_1 和 I_2 对应的融合特征 F_1^{fus} 和 F_2^{fus} ,该过程通过步骤S103实现;

[0112] 差异信息提取与边界增强子模块,基于融合特征 F_1^{fus} 和 F_2^{fus} 进行差异特征提取,得到初始差异特征 F^{diff} ,再从 F^{diff} 中提取并处理边界信息,将处理后的边界信息 E 与 F^{diff} 加权融合,得到增强后的差异特征 F^{atm} ,该过程通过步骤S2实现;

[0113] 动态记忆网络子模块,用于对增强后的差异特征 F^{atm} 进行更新,得到更新特征 F^{upd} ,该过程通过步骤S3实现;

[0114] 分类器子模块,基于更新特征 F^{upd} ,输出得到耕地语义变化检测结果。

[0115] 该模型在使用前还需要对模型进行有监督训练,训练过程中,以标注数据为监督信号,通过优化损失函数不断更新各模块参数。同时,动态记忆网络子模块在模型训练中同步迭代,使类别原型记忆项逐步适配真实数据分布。经过多轮训练后,模型整体能力得到稳定提升,能够更准确地区分真实变化与伪变化,从而实现可靠的耕地变化检测。

[0116] 为了确保动态记忆网络子模块中记忆库 M 中的各类别的记忆项 M_j 能够有效反映各类别特征的分布状态,动态记忆网络子模块的记忆库采用短期记忆(Short Term Memory, STM)与长期记忆(Long Term Memory, LTM)的动态更新机制。其中,STM用于暂存近期样本的特征信息,以快速响应特征分布的变化;LTM用于存储相对稳定的类别特征,以维持模型的整体一致性与代表性。当STM中的记忆项在多次迭代后趋于稳定,系统将该项纳入LTM,实现从短期记忆到长期记忆的迁移与融合。

[0117] 记数据集 $D = \{I_1^i, I_2^i, Y^i | i \in \{1, 2 \dots n\}\}$ 中涉及 C 类耕地变化,对于双时相遥感图像构成的样本对 I_1^i 和 I_2^i ,其对应的像素级耕地语义变化检测标签为 Y^i 。对于每个类别 c , $c \in C$,利用标签 Y^i 选取对应类别的有效像素集合 $S_c = \{x_j | Y_j^i = c\}$,并针对每个短期记忆项 STM_c 按相似度选取前 $k\%$ 的高置信度样本进行更新:

[0118] 进行 STM_c 更新的表达式为:

$$[0119] \quad STM'_c \leftarrow \alpha \cdot STM_c + (1 - \alpha) \cdot Norm\left(\sum_i w_i x_{c,i}^{topk}\right), \quad (11)$$

[0120] 其中, STM'_c 为更新后的记忆项, α 为动量系数, $Norm(\cdot)$ 表示归一化操作, w_i 为基于相似度的加权系数, $\{x_{c,i}^{topk}\}$ 为类别 c 对应的 F^{atm} 中的高置信度样本集合, k 设置为0.01, α 设置为0.8。

[0121] 当类别样本 c 不足时,通过跳跃更新机制延迟记忆项 STM_c 的更新。当记忆项 STM_c 累计更新次数达到阈值时,触发门控机制,将可靠的短期记忆项写入 LTM_c ,同时重置对应 STM_c 为零向量,并重置更新计数为0。

[0122] 通过上述流程,动态记忆网络子模块能够在融合记忆检索结果与差异特征 F^{atm}

后得到增强特征 F^{upd} , 该特征在保留真实变化信息的同时, 有效抑制伪变化干扰, 实现对变化特征的增强和记忆的迭代优化, 从而提升整体变化检测模型的精度与鲁棒性。

[0123] 训练过程中, 动态记忆网络子模块的记忆库表达式为:

$$[0124] \quad M = \lambda \cdot \text{LTM} + (1 - \lambda) \cdot \text{STM}, \quad \lambda \in [0, 1]. (8)$$

[0125] 其中, λ 为权衡系数, 用于控制长期记忆与短期记忆在融合过程中的相对贡献度。 λ 取值为 0.7, 即长期记忆占据较高权重, 从而在保持特征一致性的同时兼顾对新变化信息的敏感性。

[0126] 本模型基于 PyTorch 框架实现, 在模型训练阶段, 采用交叉熵损失函数作为监督信号。该损失函数通过比较模型输出的每个像素预测概率与对应的真实类别标签, 衡量预测分布与真实分布之间的差异。在训练过程中, 模型的可学习参数 (包括卷积核权重、注意力权重等) 通过反向传播算法迭代更新, 不断优化特征提取与分类能力, 从而逐步降低整体预测误差, 提高变化区域检测精度。经在多个遥感图像数据集上训练和评估, 本模型在耕地语义变化检测任务中均表现出优异性能, 能够准确识别耕地的真实变化区域, 且对于干扰因素具有较强鲁棒性。

[0127] 实施例 3:

[0128] 为验证实施例 1 方法的有效性与适用性, 本实施例选取了具有代表性的大规模耕地语义变化检测数据集 JL1 数据集进行实验。其中 JL1 数据集由长光卫星技术股份有限公司基于吉林一号卫星图像构建, 包含约 8000 对高分辨率双时相遥感图像对, 空间分辨率优于 0.75 米, 覆盖多种典型的耕地变化类型, 该数据集规模较大、标注精细, 能够充分支持对模型的训练与评估。该数据集具有较大规模和丰富的耕地变化样本, 能够全面反映实际耕地动态情况。本实施例基于此开展实验, 能够充分验证所提方法的有效性与泛化能力。

[0129] 为全面评估本发明方法的性能, 本实施例采用了四种常用的评价指标: 总体精度 (Overall Accuracy, OA)、平均交并比 (mean Intersection over Union, mIoU)、平均 F1 值 (mean F1 score, mF1) 以及面向语义变化检测的 F1 指标 (F_{scd})。其中, OA 用于衡量整体分类的准确性, 能够反映模型对所有类别的总体判别能力; mIoU 强调预测结果与真实标签之间的空间重叠程度, 是语义分割任务的核心指标; mF1 在各类别上平衡了精度与召回率, 更能体现模型在不同语义变化类别上的综合表现; F_{scd} 则专门针对变化区域的检测效果进行评价, 不受“未变化”类别的影响, 能够更客观地反映模型对真实变化的识别能力。上述指标均表现为“数值越高, 性能越优”的趋势, 四者结合可以对比不同方法的整体精度、空间定位能力以及变化检测的敏感性, 从而全面、客观地验证本发明的有效性与优势。

[0130] 为了进一步验证本发明方法的优势, 我们共选取了 5 个对比算法, 分别为: BiSRNet、SCanNet、CdSC、BT-SCD、EGMS-Net, 通过将上述现有方法与本发明方法应用在 JL1 数据集上, 得到的实验结果如表 1 所示。

[0131] 表 1 本发明方法与现有方法在 JL1 数据集上的实验结果

[0132]

方法	OA (%)	mIoU (%)	mF1 (%)	Fscd (%)
BiSRNet	69.57	31.73	44.69	38.01
SCanNet	68.59	25.39	36.67	34.08

CdSC	75.27	36.59	50.58	51.79
BT-SCD	71.34	30.08	42.34	42.61
EGMS-Net	69.67	34.53	48.53	40.65
本发明方法	76.78	39.83	53.53	55.26

[0133] 从表1可明显看出,在四个评价指标上,本发明方法均优于现有方法,表明本发明方法在捕捉耕地变化信息、抑制伪变化以及提升分类准确性方面均具有显著优势。在JL1数据集上,本发明方法的mF1值达到 53.53%,mIoU达到 39.83%, F_{scd} 为55.26%,OA为76.78%。与现有方法相比,本发明方法在各项指标上均有明显提升,如,相比于EGMS-Net,本发明方法在OA,mIoU,mF1, F_{scd} 四项指标上分别高7.11,5.3,5,14.61个百分点,表明本发明方法在识别耕地实际变化区域方面更加准确可靠。

[0134] 综上所述,本发明方法在JL1数据集上的实验结果表明,其能够有效捕捉耕地语义变化,提升检测精度和鲁棒性,相较现有方法具有显著的性能优势。

[0135] 以上显示和描述了本发明的基本原理、主要特征和本发明的优点。本行业的技术人员应该了解,本发明不受上述实施例的限制,上述实施例和说明书中描述的只是说明本发明的原理,在不脱离本发明精神和范围的前提下,本发明还会有各种变化和改进,这些变化和改进都落入要求保护的本发明范围内。本发明要求保护范围由所附的权利要求书及其等效物界定。




图1




图2