



(12) 发明专利申请

(10) 申请公布号 CN 121236817 A

(43) 申请公布日 2025. 12. 30

(21) 申请号 202511320451.8

G06N 3/0895 (2023.01)

(22) 申请日 2025.09.16

G06V 40/10 (2022.01)

(71) 申请人 西北农林科技大学

G06V 10/80 (2022.01)

地址 712100 陕西省咸阳市杨凌示范区西
农路22号

G06V 20/40 (2022.01)

(72) 发明人 张宏鸣 张宇 韩亚敏 咎林森

李安宁 梅楚刚 王博文 孙扬

秦培杰 薛文嘉 秦一溯 曹诗超

(74) 专利代理机构 西安凯多思知识产权代理事
务所(普通合伙) 61290

专利代理师 张西娟

(51) Int. Cl.

G06V 40/20 (2022.01)

G06V 10/774 (2022.01)

G06V 10/82 (2022.01)


权利要求书2页 说明书13页 附图6页

(54) 发明名称

一种多模态数据融合模型驱动的肉牛行为
识别方法

(57) 摘要

本公开是一种多模态数据融合模型驱动的肉牛行为识别方法,该方法包括构建肉牛行为识别视频数据集和九轴加速度文本数据集;构建对比学习行为识别网络并进行数据处理得到融合特征;网络训练;构建时序动态金字塔对比学习行为识别网络,并进行数据处理得到时序动态多模态融合特征;利用双识别网络进行肉牛行为识别。本实施例通过引入对比学习行为识别网络和时序动态金字塔对比学习行为识别网络,不仅在真实养殖环境中实现了高精度的行为识别,还兼顾了低计算负担,两者的结合使得系统能够灵活高效地适应多种养殖场景的复杂任务需求;本发明兼顾了精度与效率,提升了识别的准确性和鲁棒性,提供了一个高效、稳定的行为识别解决方案。



1. 一种多模态数据融合模型驱动的肉牛行为识别方法,其特征在于,包括:

S1,构建肉牛行为识别视频数据集和九轴加速度文本数据集;

S2,构建对比学习行为识别网络,并利用所述对比学习行为识别网络对视频数据和加速度文本数据进行处理得到视频特征和加速度特征,将视频特征和加速度特征进行拼接以及融合,得到融合特征;

S3,对所述对比学习行为识别网络进行训练;

S4,构建时序动态金字塔对比学习行为识别网络,并利用其对视频数据集的帧特征进行动态关键帧提取、时序注意力增强处理和多尺度融合,得到时序动态金字塔视频特征;将加速度文本数据映射之后进行位置编码和特征提取,得到加速度特征;将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征;

S5,将肉牛行为识别视频数据集和九轴加速度文本数据集输入训练后的所述对比学习行为识别网络和所述时序动态金字塔对比学习行为识别网络,进行肉牛行为识别,输出识别结果。

2. 根据权利要求1所述多模态数据融合模型驱动的肉牛行为识别方法,其特征在于,所述S2包括以下步骤:

S2.1,对视频数据的帧特征进行提取,然后将帧特征投影后进行聚合得到视频特征;

S2.2,将九轴加速度文本数据映射之后进行位置编码,对编码后的加速度文本数据进行特征提取,得到加速度特征;

S2.3,将所述视频特征和所述加速度特征进行拼接以及融合,得到融合特征。

3. 根据权利要求1所述多模态数据融合模型驱动的肉牛行为识别方法,其特征在于,所述S4包括以下步骤:

S4.1,对视频数据集的帧特征进行动态关键帧提取,然后将提取的关键帧特征进行时序注意力增强处理,然后进行多尺度融合,最后进行归一化处理得到时序动态金字塔视频特征;

S4.2,将加速度文本数据映射之后进行位置编码,对编码后的加速度文本数据进行特征提取,得到加速度特征;

S4.3,将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征。

4. 一种多模态数据融合模型驱动的肉牛行为识别系统,其特征在于,包括:

数据集构建模块,用于构建肉牛行为识别视频数据集和九轴加速度文本数据集;

第一网络构建处理模块,用于构建对比学习行为识别网络,并利用所述对比学习行为识别网络对视频数据和加速度文本数据进行处理得到视频特征和加速度特征,将视频特征和加速度特征进行拼接以及融合,得到融合特征;

网络训练模块,用于对所述对比学习行为识别网络进行训练;

第二网络构建处理模块,构建时序动态金字塔对比学习行为识别网络,并利用其对视频数据集的帧特征进行动态关键帧提取、时序注意力增强处理和多尺度融合,得到时序动态金字塔视频特征;将加速度文本数据映射之后进行位置编码和特征提取,得到加速度特征;将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征;

行为识别模块,用于将肉牛行为识别视频数据集和九轴加速度文本数据集输入训练后的所述对比学习行为识别网络和所述时序动态金字塔对比学习行为识别网络,进行肉牛行为识别,输出识别结果。

5. 根据权利要求4所述多模态数据融合模型驱动的肉牛行为识别系统,其特征在于,所述对比学习行为识别网络包括:

视频处理模块,用于对视频数据的帧特征进行提取,然后将帧特征投影后进行聚合得到视频特征;

九轴加速度处理模块,用于将九轴加速度文本数据映射之后进行位置编码,对编码后的加速度文本数据进行特征提取,得到加速度特征;

特征对齐与融合模块,用于将所述视频特征和所述加速度特征进行拼接以及融合,得到融合特征。

6. 根据权利要求5所述多模态数据融合模型驱动的肉牛行为识别系统,其特征在于,所述视频处理模块包括:

帧级特征提取子模块,用于将每一帧视频数据划分为多个图像块,并将其展平为一组向量;

编码器子模块,用于将每个所述向量投影到嵌入空间,并为每个图像块添加分类令牌、空间位置编码和时间位置编码,然后将所述图像块的序列和位置编码相加以进行编码,得到帧级视觉特征序列;

视频级特征聚合子模块,用于将所述帧级视觉特征序列的帧特征进行聚合,提取视频全局信息,将所述视频全局信息进行归一化处理得到视频级特征;

提示学习子模块,用于将所述帧级视觉特征序列添加全局提示令牌和局部提示令牌,并基于分类令牌进行条件化,从输出的图像块的序列中提取分类令牌,使用线性投影层将其进行投影,然后得到每帧的特征表示,将所述帧的特征表示进行平均池化,得到整个视频的聚合特征表示。

7. 根据权利要求4所述多模态数据融合模型驱动的肉牛行为识别系统,其特征在于,所述时序动态金字塔对比学习行为识别网络包括:

时序动态金字塔视频处理模块,用于对视频数据集的帧特征进行动态关键帧提取,然后将提取的关键帧特征进行时序注意力增强处理,然后进行多尺度融合,最后进行归一化处理得到时序动态金字塔视频特征;

加速度处理模块,用于将加速度文本数据映射之后进行位置编码,对编码后的加速度文本数据进行特征提取,得到加速度特征;

多模态融合模块,用于将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征。

8. 根据权利要求7所述多模态数据融合模型驱动的肉牛行为识别系统,其特征在于,所述多模态融合模块包括:

特征拼接子模块,用于将视频特征和加速度特征拼接在一起;

融合层子模块,用于使用线性层将拼接后的特征融合为一个统一的特征表示,并输出为一个归一化的张量。

一种多模态数据融合模型驱动的肉牛行为识别方法

技术领域

[0001] 本发明涉及行为识别技术领域,尤其涉及一种多模态数据融合模型驱动的肉牛行为识别方法。

背景技术

[0002] 肉牛养殖规模不断扩大,并呈现出快速持续发展的态势。据统计,2024年我国牛存栏量达到10047万头,牛出栏量为5099万头,牛肉产量高达779万吨。然而,随着肉牛产业的蓬勃发展和养殖规模的不断扩大,传统的依赖人工观察的养殖模式逐渐暴露出耗时耗力、成本高昂等问题,已难以满足现代规模化肉牛养殖的需求。在此背景下,基于肉牛行为识别方法的多模态融合技术应运而生,通过对养殖场监控设备采集的视频和九轴加速度传感器设备收集的文本数据进行深入分析,能够精准地对肉牛个体进行行为识别,为后续的疾病预警、健康评估、生产性能优化、饲料管理以及肉牛个体信息的关联建立提供了有力的技术支撑。

[0003] 该技术的应用,不仅能够有效提升肉牛养殖的管理效率,降低人工成本,还能为肉牛的健康监测和疾病预防提供数据支持,助力肉牛产业向智能化、现代化方向迈进,为农业高质量发展注入新的活力。

[0004] 几十年间,国内外学者针对行为识别技术在畜牧养殖领域的应用进行了多种尝试,大体上可分为基于传感器数据的行为识别算法和基于视频分析的行为识别方法。(1)基于传感器数据的行为识别算法的代表性算法有传统机器学习方法: CART(Classification and Regression Tree)、SVM(Support Vector Machine)、LDA(Linear Discriminant Analysis)和QDA(Quadratic Discriminant Analysis);深度学习方法: CNN(Convolutional Neural Network)、RNN(Recurrent Neural Network)和LSTM(Long Short-Term Memory)。这类算法可以精确记录肉牛的运动数据,通过深度学习算法(如CNN、LSTM)可以实现高精度的行为识别,但是其识别效果很大程度上依赖于养殖场通信信号和数据预处理的质量。(2)基于视频分析的行为识别方法中的典型算法就是YOLO(You Only Look Once)算法系列(例如YOLOv3)、其改进算法系列(例如FABF-YOLOv8s)和DB-TEAF模型。这类算法可以非接触地实现高精度的行为识别,但是识别效果会受到环境影响,并且成本高,高计算需求。

[0005] 因此,有必要改善上述相关技术方案中存在的一个或者多个问题。

[0006] 需要注意的是,本部分旨在为权利要求书中陈述的本公开的技术方案提供背景或上下文。此处的描述不因为包括在本部分中就承认是现有技术。

发明内容

[0007] 本发明的目的在于提供一种多模态数据融合模型驱动的肉牛行为识别方法,进而至少在一定程度上克服由于相关技术的限制和缺陷而导致的一个或者多个问题。

[0008] 本发明首先提供一种多模态数据融合模型驱动的肉牛行为识别方法,包括:

S1,构建肉牛行为识别视频数据集和九轴加速度文本数据集;

S2,构建对比学习行为识别网络,并利用所述对比学习行为识别网络对视频数据和加速度文本数据进行处理得到视频特征和加速度特征,将视频特征和加速度特征进行拼接以及融合,得到融合特征;

S3,对所述对比学习行为识别网络进行训练;

S4,构建时序动态金字塔对比学习行为识别网络,并利用所述时序动态金字塔对比学习行为识别网络,对视频数据集的帧特征进行动态关键帧提取、时序注意力增强处理和多尺度融合,得到时序动态金字塔视频特征;将加速度文本数据映射之后进行位置编码和特征提取,得到加速度特征;将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征;

S5,将肉牛行为识别视频数据集和九轴加速度文本数据集输入训练后的所述对比学习行为识别网络和所述时序动态金字塔对比学习行为识别网络,进行肉牛行为识别,输出识别结果。

[0009] 本发明首先提供一种多模态数据融合模型驱动的肉牛行为识别系统,包括:

本发明中,数据集构建模块,用于构建肉牛行为识别视频数据集和九轴加速度文本数据集;

第一网络构建处理模块,用于构建对比学习行为识别网络,并利用所述对比学习行为识别网络对视频数据和加速度文本数据进行处理得到视频特征和加速度特征,将视频特征和加速度特征进行拼接以及融合,得到融合特征;

网络训练模块,用于对所述对比学习行为识别网络进行训练;

第二网络构建处理模块,构建时序动态金字塔对比学习行为识别网络,并利用所述时序动态金字塔对比学习行为识别网络,对视频数据集的帧特征进行动态关键帧提取、时序注意力增强处理和多尺度融合,得到时序动态金字塔视频特征;将加速度文本数据映射之后进行位置编码和特征提取,得到加速度特征;将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征;

行为识别模块,用于将肉牛行为识别视频数据集和九轴加速度文本数据集输入训练后的所述对比学习行为识别网络和所述时序动态金字塔对比学习行为识别网络,进行肉牛行为识别,输出识别结果。

[0010] 本发明提供的技术方案可以包括以下有益效果:

本发明中的一种多模态数据融合模型驱动的肉牛行为识别方法及系统,通过引入对比学习行为识别网络和时序动态金字塔对比学习行为识别网络,不仅在真实养殖环境中实现了高精度的行为识别,还兼顾了低计算负担,两者的结合使得系统能够灵活高效地适应多种养殖场景的复杂任务需求;本发明兼顾了精度与效率,提升了识别的准确性和鲁棒性,提供了一个高效、稳定的行为识别解决方案。

附图说明

[0011] 此处的附图被并入说明书中并构成本说明书的一部分,示出了符合本公开的实施例,并与说明书一起用于解释本公开的原理。显而易见地,下面描述中的附图仅仅是本公开的一些实施例,对于本领域普通技术人员来讲,在不付出创造性劳动的前提下,还可以根据

这些附图获得其他的附图。

[0012] 图1示出本公开示例性实施例中多模态数据融合模型驱动的肉牛行为识别方法的流程图；

图2示出本公开示例性实施例中S2的流程图；

图3示出本公开示例性实施例中S4的流程图；

图4示出本公开示例性实施例中多模态数据融合模型驱动的肉牛行为识别系统的框架图；

图5示出本公开示例性实施例中对比学习行为识别网络的结构图；

图6示出本公开示例性实施例中时序动态金字塔对比学习行为识别网络的结构图；

图7示出本公开示例性实施例中时序注意力编码器子模块的结构图；

图8示出本公开示例性实施例中全局特征金字塔网络子模块的结构图；

图9示出本公开示例性实施例中局部动态帧采样子模块的结构图；

图10示出本公开示例性实施例中时序动态金字塔视频处理模块的结构图；

图11示出本公开示例性实施例中九轴加速度数据处理模块的结构图；

图12示出本公开示例性实施例中特征对齐与融合模块的结构图。

具体实施方式

[0013] 现在将参考附图更全面地描述示例实施方式。然而，示例实施方式能够以多种形式实施，且不应被理解为限于在此阐述的范例；相反，提供这些实施方式使得本公开将更加全面和完整，并将示例实施方式的构思全面地传达给本领域的技术人员。所描述的特征、结构或特性可以以任何合适的方式结合在一个或更多实施方式中。

[0014] 此外，附图仅为本公开实施例的示意性图解，并非一定是按比例绘制。图中相同的附图标记表示相同或类似的部分，因而将省略对它们的重复描述。附图中所示的一些方框图是功能实体，不一定必须与物理或逻辑上独立的实体相对应。

[0015] 本示例实施方式中首先提供一种多模态数据融合模型驱动的肉牛行为识别方法，请参考图1，该方法可以包括：S1-S5。具体如下：

S1，构建肉牛行为识别视频数据集和九轴加速度文本数据集；

S2，构建对比学习行为识别网络，并利用所述对比学习行为识别网络对视频数据和加速度文本数据进行处理得到视频特征和加速度特征，将视频特征和加速度特征进行拼接以及融合，得到融合特征；

S3，对所述对比学习行为识别网络进行训练；

S4，构建时序动态金字塔对比学习行为识别网络，并利用其对视频数据集的帧特征进行动态关键帧提取、时序注意力增强处理和多尺度融合，得到时序动态金字塔视频特征；将加速度文本数据映射之后进行位置编码和特征提取，得到加速度特征；将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合，得到时序动态多模态融合特征；

S5，将肉牛行为识别视频数据集和九轴加速度文本数据集输入训练后的所述对比学习行为识别网络和所述时序动态金字塔对比学习行为识别网络，进行肉牛行为识别，输出识别结果。

[0016] 本实施例中,通过引入对比学习行为识别网络和时序动态金字塔对比学习行为识别网络,不仅在真实养殖环境中实现了高精度的行为识别,还兼顾了低计算负担,两者的结合使得系统能够灵活高效地适应多种养殖场景的复杂任务需求;本发明兼顾了精度与效率,提升了识别的准确性和鲁棒性,提供了一个高效、稳定的行为识别解决方案。

[0017] 下面对以上实施例中各个步骤的具体过程进行说明。

[0018] S1是构建肉牛行为识别视频数据集和九轴加速度文本数据集的过程。

[0019] 本申请收集了来自真实监控视角下的真实养殖场景的视频和来自牛项圈上安装的九轴加速度数据,在每个戴项圈的肉牛身上喷上标记。收集的数据经过处理后,视频的平均时长为10秒钟,采用MP4格式,分辨率为 1920×1080 像素,帧率为60帧/秒;九轴加速度数据时长对应视频时长10s,格式为xlsx,频率为60Hz,九轴包括X、Y和Z轴上的加速度、角速度和角度。特别地,在肉牛养殖的真实场景中,存在多种干扰因素影响检测性能,包括:由于摄像机安装在棚顶角落,导致视频中肉牛的尺度变化;由于视频采样时间跨度较大,造成的光照强度变化;肉牛之间的相互遮挡;顶棚、围栏等外物引起的遮挡;肉牛奔跑等行为引起的尘土干扰;以及肉牛的外观特征不如行人明显,特别是在肉牛体色与泥土地面颜色相近时,产生的背景干扰。随后,本申请利用视频对对应的九轴加速度表格进行行为标注,得到标准数据格式,并将标注数据转换为适用于肉牛行为识别的定制数据集。该数据集中的肉牛目标检测部分命名为Beef-Cattle,包括800个训练集(800个视频和对应的800个加速度表格)与200个验证集,训练集与验证集的比例为8:2。

[0020] S2是构建对比学习行为识别网络并利用其进行数据处理的过程。如图5所示,所述对比学习行为识别网络包括:视频处理模块(Video Processing Module,VPM)、九轴加速度处理模块(Acceleration Processing Module,APM)和特征对齐与融合模块(Feature Alignment and Fusion Module,FA-FM)。

[0021] 具体地,请参考图2,所述S2包括步骤S2.1、S2.2和S2.3:

S2.1,对视频数据的帧特征进行提取,然后将帧特征投影后进行聚合得到视频特征。S2.1是构建视频处理模块并进行数据处理的过程。

[0022] 视频处理模块包括:视频编码器子模块(Video Encoder SubModule,VESM)、帧级特征提取子模块(Frame-Level Feature Extraction SubModule,FLFESM)、视频级特征聚合子模块(Video-Level Feature Aggregation SubModule,VLFASM)和提示学习子模块(Prompt Learning SubModule,PLSM)。

[0023] S2.1的整体处理过程包括:将输入的视频数据送入VPM中,首先在VESM中,将视频的每一帧进行分类标记后,分割成若干个块,然后将每个块(patch)投影到嵌入空间,然后进入FLFESM中为每个帧的嵌入序列添加位置信息后进行编码并提取帧级特征,然后与PLSM共同工作,帮助捕捉视频的整体特征、整体分布特征和每帧的局部特征,接着将帧级特征投影到目标维度后进入VLFASM中后聚合得到视频级特征(Video Features,VF)。

[0024] 请参考图10,图10为视频处理模块的结构图。VPM模块旨在通过帧级和视频级优化特征提取性能。该模块在保持紧凑架构的同时,能够高效地处理计算任务。通过在瓶颈层中引入多模态提示学习机制,VPM模块显著增强了模型对视频细节的识别能力,同时使得模型能够在单一训练框架下适应不同的任务场景。具体操作过程如下:

S2.1.1,构建帧级特征提取子模块VPSM。

[0025] 将输入视频 V 的空间尺寸定义为 $H \times W$, 包含 T 个采样帧。每一帧被划分为 M 个大小为 $L \times L$ 的非重叠正方形 patch (图像块), 总 patch 数为 $N = \frac{H \times W}{L^2}$ 。对于每一帧, 所有 patch 被展平为一组向量, 并表示为 $\{x_{t,i} \in \mathbb{R}^{3L^2}\}_{i=1}^M$, 其中 t 是帧编号, i 是 patch 编号。

[0026] S2.1.2, 构建编码器子模块FLFESM和视频级特征聚合子模VLFASM。

[0027] 使用线性投影层 $P_{emb} \in \mathbb{R}^{3L^2 \times D}$ 将每个 patch 向量投影到维度为 D 的嵌入空间, 得到嵌入后的 patch 表示。另外为每一帧的嵌入 patch 序列添加一个额外的分类令牌 $x_{ct} \in \mathbb{R}^D$, 用于提取每帧的特征表示。并且为每个 patch 添加空间位置编码 e_{sc} 和时间位置编码 e_{tc} , 以保留空间和时间信息。将分类令牌、嵌入后的 patch 序列和位置编码相加, 形成输入到视频编码器的最终序列: $g_t^{(0)} = [x_{ct}, P_{emb}^T x_{t,1}, \dots, P_{emb}^T x_{t,N}] + e$ 。接着将得到的序列 $g_t^{(0)}$ 输入到包含层 L_v 的视频编码器中, 每层通过 Transformer 结构处理, 提取帧级别的特征表示。在每一层 l 中, 帧级表示的计算公式为: $g_t^{(l)} = f_{\theta_v}^{(l)}(g_t^{(l-1)})$, $l \in \{1, \dots, L_v\}$ 。

[0028] S2.1.3, 构建提示学习子模块PLSM。

[0029] VPM在视频编码处理过程中, 引入提示学习子模块, 在每一层 l 引入一个摘要提示 (Summary Token), 用于总结所有帧的判别信息, 并将其反馈给每一帧。并且引入 Q_v 个全局提示令牌 (Global Prompt Tokens), 用于学习视频数据的整体分布。在全局的基础上继续引入 T 个局部提示令牌 (Local Prompt Tokens), 基于每帧的分类令牌进行条件化, 用于增强帧之间的判别信息传递。

[0030] 最后, 从最后一层的输出序列 $g_t^{(L_v)}$ 中提取分类令牌 x_{ct} , 并使用线性投影层 $P_{out} \in \mathbb{R}^{D \times D'}$ 将其投影到维度为 D' 的空间, 得到每帧的特征表示:

$$w_t = P_{out}^T g_{t,0}^{(L_v)} \in D'$$

[0031] 其中, w_t 是帧 t 的输出表示, $g_{t,0}^{(L_v)}$ 视频编码器最后一层输出序列中的分类令牌, 然后将得到的所有帧的特征表示 $w_{t=1}^T$ 进行平均池化, 得到整个视频的聚合特征表示: $w = \text{AvgPool}([w_1, \dots, w_T])$ 。

[0032] S2.2, 将九轴加速度文本数据映射之后进行位置编码, 对编码后的加速度文本数据进行特征提取, 得到加速度特征。

[0033] S2.2是构建九轴加速度处理模块并利用其处理数据的过程。九轴加速度处理模块 (APM) 结构图如图11所示, APM包括分词器子模块 (Tokenizer SubModule, TSM)、位置编码子模块 (Positional Encoding SubModule, PESM)、自注意力机制子模块 (Self-Attention SubModule, SASM)、上下文感知子模块 (Context-Aware SubModule, CASM)、编码器子模块 (Encoder Layers SubModule, ELSM) 和层归一化子模块 (Layer Norm SubModule, LNSM)。

[0034] S2.2的整体处理过程包括: 将九轴加速度数据 (Nine Axis Acceleration Data, NAAD) 输入至APM中, 先进入TSM利用一个全连接层将NAAD映射到一个更高维度嵌入空间, 然后进入PESM中, 为序列中每个NAAD提供位置信息, 接着进入ELSM, 在该模块会通过多个

Trasnformer层,进一步提取数据的特征,最后,将提取的特征传送LNSM,输出特征表示(Acceleration Features,AF)。这些模块确保了九轴加速度数据的有效处理,生成的特征表示可以用于行为识别等下游任务等。

[0035] S2.2的具体操作步骤如下:

S2.2.1,构建分词器子模块TSM。

[0036] 将输入的九轴加速度数据 $\mathbf{x}$ 的形状定义为 (B, T, D) , 其中 B 为批量大小, T 为时间步数, D 是九轴加速度数据的维数(三轴加速度、三轴角速度、三轴角度)。然后使用一个全连接层(`nn.Linear`)将输入数据映射到嵌入维度 D , 公式为: $\text{accel_features} = \text{Linear}(\mathbf{x})$, 其中 Linear 是一个线性变换, 具体公式为: $\text{accel_features} = W \cdot \mathbf{x} + \mathbf{b}$, 其中, W 是权重矩阵, $\mathbf{b}$ 是偏置向量。

[0037] S2.2.2, 构建位置编码子模块PESM。

[0038] 该模块是为每个时间步 $t \in T$ 添加位置信息, 帮助模型捕捉时间序列中的位置关系。首先将位置编码矩阵的形状为 pe 的形状定义为 (T, D) , 计算公式为: $pe_{(t, 2i)} = \sin\left(\frac{t}{10000^{2i/D}}\right)$, $pe_{(t, 2i+1)} = \cos\left(\frac{t}{10000^{2i/D}}\right)$, 其中, t 是时间步, i 是维度索引, D 是嵌入维度。然后, 将位置编码添加到分词器的输出中, 即: $\text{accel_features} = \text{accel_features} + pe$ 。

[0039] S2.2.3, 构建编码器层子模块ELSM。

[0040] 首先将输入特征分别通过三个线性变换, 生成查询(Query)、键(Key)和值(Value), 表示为: $Q = \text{Linear}_{\text{query}}(\text{src})$, $K = \text{Linear}_{\text{key}}(\text{src})$, $V = \text{Linear}_{\text{value}}(\text{src})$ 。然后将查询、键和值分别划分为多个头(`nhead`), 每个头独立计算注意力权重, 表示为: $Q_i = \text{split}(Q, \text{num_heads})$, $K_i = \text{split}(K, \text{num_heads})$, $V_i = \text{split}(V, \text{num_heads})$ 。接着计算每个头的注意力权重, 并对值进行加权求和, 计算公式为: $\text{attn_weights}_i = \text{Softmax}\left(\frac{K_i K_i^T}{\sqrt{d_k}}\right)$, $\text{attn_output}_i = \text{attn_weights}_i V_i$, 其中 d_k 是每个头的特征维度。最后, 对自注意力的输出进行非线性变换, 具体公式为: $\text{ffnn_output} = W_2 \cdot \text{ReLU}(W_1 \cdot \text{attn_output} + \mathbf{b}_1) + \mathbf{b}_2$, 其中 W_1, W_2 是权重矩阵, $\mathbf{b}_1, \mathbf{b}_2$ 是偏置向量。

[0041] S2.2.4, 构建层归一化子模块LNSM。

[0042] 首先, 将自注意力的输出和前馈神经网络的输出分别与输入特征相加, 表示为: $\text{accel_features} = \text{LayerNorm}(\text{accel_features}) + \text{attn_output}$, $\text{accel_features} = \text{LayerNorm}(\text{accel_features}) + \text{ffnn_output}$ 。然后对特征进行归一化, 稳定训练过程, 计算公式为: $\text{normalized_features} = \frac{\text{accel_features} - \mu}{\sigma} \cdot \gamma + \beta$, 其中, μ 是均值, σ 是标准差, γ 和 β 是可学习的参数。最后输出被归一化后的特征序列:

$$\text{output} = \frac{\text{accel_features}}{\|\text{accel_features}\|}.$$

[0043] S2.3, 将所述视频特征和所述加速度特征进行拼接以及融合, 得到融合特征。S2.3

是构建特征对齐与融合模块并利用其进行数据处理的过程。特征对齐与融合模块 (FA-FM) 结构图如图12所示, 包含特征对齐子模块 (Feature Alignment SubModule, FASM)、模态内融合子模块 (Intra-Modality Fusion SubModule, I-AMFSM) 和模态间融合子模块 (Inter-Modality Fusion SubModule, I-RMFSM)。S2.3的整体处理过程包括: 将VF和AF输入至FA-FM中, 首先, 在FASM中, 将VF和AF投影到相同的维度。接着在I-AMFSM中, 对每种模态的特征进行内部融合。最后, 在I-RMFSM中, 为每种模态分配权重, 动态进行加权融合。

[0044] S2.3具体包括以下过程:

S2.3.1, 构建特征对齐子模块FASM。

[0045] 将不同模态的视频特征 $video_features$ 和九轴加速度特征 $accel_features$ 通过线性层 L_v 和 L_a 投影到相同的目标维度 D' , 表示为:

$$video_features' = L_v \cdot video_features$$

[0046] $accel_features' = L_a \cdot accel_features$

[0047] S2.3.2, 构建模态内融合子模块I-AMFSM。

[0048] 首先将每种模态的共享特征和特有特征拼接在一起, 然后对于投影后的视频特征 $video_features'$ 和文本特征 $accel_features'$, 我们分别应用自注意力模块 $SelfAttention$ 进行内部融合, 表示为:

$$v_{used} = SelfAttention(video_features')$$

[0049] $a_{used} = SelfAttention(accel_features')$

[0050] S2.3.3, 构建模态间融合子模块I-RMFSM。

[0051] 在此步骤中, 使用一个门控神经网络为每种模态分配权重 α , 然后使用该权重来加权融合视频特征 v_{used} 和九轴加速度特征 a_{used} , 计算公式为:

$$f_{final} = \alpha \cdot v_{used} + (1-\alpha) \cdot a_{used}$$

[0052] S3是训练对比学习行为识别网络的过程。

[0053] 对比学习行为识别网络 (Contrastive Acceleration-Video Action Recognition Network, CA-VRNet) 的损失函数L为余弦相似度损失函数 (Cosine Similarity Loss):

余弦相似度损失函数 (Cosine Similarity Loss) 定义为:

$$L_{cos}(v, a) = \frac{\langle v, a \rangle}{\|v\| \|a\|} \quad (1)$$

式中:

v表示视频表示, a表示加速度表示:

$$v = f_{\theta_v}(v | S(I), G(I), L(I)) \quad (2)$$

$$a = f_{\theta_a}(A) \quad (3)$$

模型从抽取视频 $v \in V$ 和相关加速度 $a \in A$, 分别传递给视频编码器 f_{θ_v} 和加速度编码器 f_{θ_a} , 生成视频和加速度表示。

[0054] S4是构建时序动态金字塔对比学习行为识别网络TDPCLARNet并进行数据处理的

过程。时序动态金字塔对比学习行为识别网络(Temporal Dynamic Pyramid Contrastive Learning Action Recognition Network, TDPCLARNet)如图6所示, TDPCLARNet由多个关键组件组成, 包括时序动态金字塔视频处理模块(Temporal Dynamic Pyramid Video Processing Module, TDPVPM)、九轴加速度数据处理模块(Acceleration Data Processing Module, ADPM)、多模态融合模块(Multi-Modal Fusion Module, M-MFM)。

[0055] TDPCLARNet的具体方法与对比学习行为识别网络基本相同, 区别在于在视频处理模块VPM增加了动态帧采样模块(Dynamic Frame Sampler Module, DFSM)、时序注意力编码器子模块(Temporal Attention Module, TAM)和特征金字塔网络模块(Feature Pyramid Network Module, FPNM)。

[0056] 请参考图3, S4的具体过程如下:

S4.1, 构建时序动态金字塔视频处理模块。

[0057] 时序动态金字塔视频处理模块(TDPVPM)结构图如图10所示, TDPVPM包含局部动态帧采样子模块(Local Dynamic Frame Sampler SubModule, LDFSSM)、图像块嵌入子模块(Image Block Embedding SubModule, IBESM)、类别标记子模块(Category Label SubModule, CLSM)、位置编码子模块(Position Encoding SubModule, PESM)、时间编码子模块(Timing Encoding SubModule, TESM)、时序注意力编码器层子模块(Temporal Attention Encoder Layer SubModule, TAELSM)、全局特征金字塔网络子模块(Global Feature Pyramid Network SubModule, GFPNSM)和层归一化和投影子模块(Layer Normalization and Projection Shadow SubModule, LN-PSSM)。

[0058] 首先, 在处理视频数据之前, 使用DFSSM模块对视频帧进行动态采样, 然后在IBESM中, 将视频帧的每个图像块嵌入到一个更高维度的特征空间中并使用CLSM、PESM和TESM分别对嵌入的图像块序列中, 添加一个类别标记、位置编码和时间编码, 接着使用TAELSM和FPNSM提取特征和进一步融合不同层次的特征, 最后输入LN-PSSM对最终特征进行归一化和投影, 并输出为一个归一化的张量。具体操作如下:

S4.1.1, 构建局部动态帧采样子模块。

[0059] 局部动态帧采样子模块结构图如图9所示。从输入视频逐帧提取图像, 然后输入LDFSSM中, 然后从这些帧中动态采样部分关键帧, 以减少计算量并保留重要信息, 表示为:

$F_{k,1}^n = \lambda_1^T \cdot F_{i,1}^m$, $n \in m$, 其中, k 表示关键帧, i 表示输入帧, λ 表示权重。然后为每个采样后的帧添加局部帧级提示标记, 以增强对每帧局部信息的学习, 计算公式为: $X_{Local} = [X_k; P_{local}]$, 其中, X_{Local} 表示动态采样后的帧嵌入序列, P_{local} 表示局部帧级提示标记。最后动态帧采样结果与局部帧级提示标记融合, 以生成增强的帧级特征, 计算公式为: $F_{fused} = \sum_{k=1}^n \alpha_k F_k \cdot (X_{Local})$, 其中, F_{fused} 表示融合后的特征, F_k 是第 k 个输入特征, α_k 是第 k 个输入特征的权重, 通过训练学习得到。

[0060] S4.1.2, 构建图像块嵌入子模块。

[0061] 将动态获取的帧 F_{fused} 分割为多个小块, 并且将每个块嵌入到高维空间, 计算公式为: $X_{patch} = \{x_{t,i} | t = 1, \dots, T; i = 1, \dots, N\}$, $x_{t,i} = P_{emb}(x_{t,i})$, 其中 X_{patch} 表示为一个帧序列的集合, 包含了视频中所有帧的图像块嵌入; $x_{t,i}$ 表示第 t 帧第 i 个块的嵌入向量;

P_{emb} 表示为线性投影层,将每个块 $x_{t,i}$ 嵌入到维度 D 。

[0062] S4.1.3,构建类别标记子模块。

[0063] CLSM为动态采样的每个帧添加一个分类标记,计算公式为: $X_{ct} = [x_{ct}; X_{patch}]$,其中 x_{ct} 表示为分类标记, X_{ct} 表示为添加分类标记后的嵌入序列。

[0064] S4.1.4,构建位置编码子模块。

[0065] PESM为每个帧添加位置编码,计算公式为: $X_{pos} = X_{ct} + E_{pos}$,其中 E_{pos} 是位置编码矩阵,计算公式为: $E_{pos,2i} = \sin\left(\frac{t}{10000^{2i/d_{model}}}\right)$, $E_{pos,2i+1} = \cos\left(\frac{t}{10000^{2i/d_{model}}}\right)$,其中, pos 是token开始的位置; i 是索引维度; d_{model} 是模型的维度。将位置编码向量添加到输入序列的相应部分,以注入位置信息,从而帮助模型理解块的空间位置。

[0066] S4.1.5,构建时间编码子模块。

[0067] TESM为每个帧添加时间编码,计算公式为: $X_{time} = X_{pos} + E_{time}$,其中 E_{time} 是时间编码矩阵,计算公式为: $E_{time,2i} = \sin\left(\frac{t}{10000^{2i/d_{model}}}\right)$, $E_{time,2i+1} = \cos\left(\frac{t}{10000^{2i/d_{model}}}\right)$,其中, pos 是token开始的位置; i 是索引维度; d_{model} 是模型的维度。将时间编码矩阵添加到视频帧的嵌入表示中,模型能够理解帧的时间顺序,从而提高对时间依赖关系的捕捉能力。

[0068] S4.1.6,构建时序注意力编码器子模块。

[0069] 时序注意力编码器子模块(TAELSM)结构图如图7所示,首先,利用多头自注意力机制将输入视频特征映射为查询(Query)、键(Key)和值(Value)三个向量,通过多个注意力头并行计算,捕捉不同子空间中的信息,计算公式为: $Attention(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$,其中, Q,K,V 表示通过线性变换得到的查询、键和值向量; d_k 是键向量的维度; $softmax$ 函数用于将注意力分数归一化为概率分布。然后通过将多个注意力头的输出拼接并再次投影得到的多头注意力的输出: $Multihead(Q,K,V) = Concat(head_1, \dots, head_h)W^O$,其中每个注意力头 $head_i$ 的计算公式为: $head_i = Attention(QW_i^Q, KW_i^K, VW_i^V)$ 。接着利用一个前馈网络,进一步处理自注意力的输出,本模块中的前馈网络是一个两层的全连接网络,计算公式为: $FFN(x) = max(0, xW_1 + b_1)W_2 + b_2$,其中, W_1, W_2 是权重矩阵; b_1, b_2 是偏置项; $max(0, \cdot)$ 是 ReLU激活函数。最后,为了稳定训练过程,时序注意力编码器使用残差连接和层归一化,表示为: $LayerNorm(x + Sublayer(x))$,其中, $Sublayer(x)$ 可以是多头自注意力或前馈网络的输出。

[0070] S4.1.7,构建全局特征金字塔网络子模块。

[0071] 全局特征金字塔网络子模块(GFPNSM)结构图如图8所示,输入的视频帧特征图 C 经过卷积网络提取后,得到不同层次的特征图 $\{C_1, C_2, C_3, C_4\}$ 。然后,对高层特征进行处理,处理计算公式为: $P_4 = f_4(C_4)$,其中, f_4 是对 C_4 进行 $1 \times 1 Conv$ 的操作。接着进行自顶向下路径的操作: $P_i = f_i(C_i) + R(P_{i+1})$, $i = 4, 3, 2$,其中, f_i 是对 C_i 进行 $1 \times 1 Conv$ 的操作, R 是上采

样操作。接着,进行横向连接操作,具体操作: $\bar{P}_{i-1} = f_i(F_i + F_i^*), i = 2, 3$,随后进行对特征进行融合,通过上采样 R 操作将高层特征 P_i 调整到与低层特征相同的空间大小,并与低层特征相加,计算公式为: $P_{i-1} = \bar{P}_{i-1} + R(P_i)$ 。最后需要对特征进行细化,使用 $3 \times 3 \text{Conv}$ 对特征进行细化,消除上采样带来的混叠效应,计算公式为: $P_{k+1} = \text{Conv}_{3 \times 3}(P_k), k = 3, 4$ 。

[0072] S4.1.8,构建层归一化和投影子模块。

[0073] LN-PSSM用于稳定训练过程,减少内部协变量偏移。首先,它对每个样本的特征进行归一化,使得每个特征的均值为0,标准差为1,计算公式为: $\mu = \frac{1}{H} \sum_{i=1}^H x_i$, $\sigma^2 = \frac{1}{H} \sum_{i=1}^H (x_i - \mu)^2$, $\hat{x}_i = \frac{x_i - \mu}{\sqrt{\sigma^2 + \epsilon}}$, $y_i = \gamma \hat{x}_i + \beta$,其中, x_i 是输入特征的第 i 个维度; H 是特征的维度; μ 是输入特征的均值; σ^2 是输入特征的方差; ϵ 是一个小的常数,用于数值稳定性; γ 和 β 是可学习的参数,用于缩放和偏移归一化后的特征。然后,将归一化后的特征投影到目标维度,通常通过一个线性变换实现,计算公式为: $F_{proj} = W_{proj} F_{norm} + b_{proj}$,其中, F_{norm} 是层归一化后的特征; W_{proj} 是投影矩阵; b_{proj} 是投影偏置; F_{proj} 是投影后的特征。

[0074] S4.2,构建加速度处理模块。加速度处理模块的构建过程与前述步骤S2.2相同,此处不再详细叙述。

[0075] S4.3,构建多模态融合模块。

[0076] M-MFM包含特征拼接子模块(Feature Concatenation SubModule,FCSM)和融合层子模块(Fusion Layer SubModule,FLSM)。首先,将视频特征和加速度特征输入FCSM中,将两个特征拼接在一起,然后输入至FLSM中,使用一个线性层将拼接后的特征融合为一个统一的特征表示,并输出为一个归一化的张量。该步骤与步骤S2.3工作方式相同,在此不做详细阐述。

[0077] S5,将肉牛行为识别视频数据集和九轴加速度文本数据集输入训练后的所述对比学习行为识别网络和所述时序动态金字塔对比学习行为识别网络,进行肉牛行为识别,输出识别结果。行为识别结果可以包括:肉牛的常规行为(例如,采食、休息、站立、行走、奔跑等)、交互行为(例如,打斗、亲昵等)、特殊行为(例如,反刍、饮水等);行为置信度;行为时序信息;异常行为标记;健康与生产指标等。

[0078] 下面通过对照实验对本申请的多模态数据融合模型驱动的肉牛行为识别方法的效果进行进一步说明。

[0079] 对于给定肉牛视频数据和九轴加速度数据,利用本申请构建的对比学习行为识别网络以及时序动态特征金字塔对比学习行为识别网络进行行为识别,输出学习率、损失函数、Top-1命中、Params (M) 和Gflops。衡量识别准确性评价指标为Top-1。

[0080] 对比比例的识别方法包括:Vita-clip(With labels)、Vita-clip(No labels) 和CLA-VRNet。对比结果见表1。

[0081] 表1 对比结果

Module	Top-1 (%)	Params (M)	Gflops
Vita-clip (With labels)	90.22	149.19	38.86
Vita-clip (No labels)	88.23	86.19	35.13
CLA-VRNet	89.13	115.68	35.08
TDPCLARNet	93.75	144.97	17.83

[0082] 实验结果表明,本实施例的对比学习行为识别网络以及时序动态特征金字塔对比学习行为识别网络在Top1上表现出色,可以看出,vita-clip模型在有文本标签的情况下比无文本标签的情况下,Top-1高出0.7%,但是,直接将文本替换为九轴加速度数据的CLA-VRNet却表现最差,Top-1只有89.13%,低于Vita-clip(With labels)的90.22%和Vita-clip(No labels)的88.23%。因此,我们在CLA-VRNet基础上添加了时序注意力模块、全局特征金字塔网络子模块和局部动态帧采样子模块后,Top-1表现最好,为93.75%,分别高于Vita-clip(With labels)、Vita-clip(No labels)和CLA-VRNet模型3.53%、5.52%和4.62%。虽然模型的参数量Params从基线的115.68M增加到144.97M,但是Gflops从基线的35.08降低至17.83,显示出在提升性能的同时,模型的复杂度增加了但是计算需求量却有所降低。总体而言,本实施例在行为识别上取得了良好的效果,展现了其在行为识别任务中的优异性能。

[0083] 下面对一种时序动态金字塔对比行为识别网络,逐步添加本申请中的局部动态帧采样子模块、时序注意力编码器子模块以及全局特征金字塔网络子模块,然后最终得到本申请的双识别网络。评价指标共有3种,分别为Top-1、Params (M)、Gflops。评价结果见表2。

[0084] 表 2 逐步添加模块后的行为识别方法评价结果

Module	Top-1 (%)	Params (M)	Gflops
CLA-VRNet (baseline)	89.13	115.68	35.08
+LDFS	89.44	115.68	17.57
+TA	91.07	144.87	35.37
+GFPN	93.75	144.97	17.83
TDPCLARNet			

[0085] 表2展示了通过逐步添加局部动态帧采样子模块LDFSSM、时序注意力编码器子模块TAELSM和全局特征金字塔网络子模块GFPNSM后的对比识别网络性能变化。从实验结果可以看出,基线模型在Top-1方面表现良好,但添加LDFSSM后,Top-1提升至89.44%,显示出LDFS在帧采样表示方面的有效性。进一步添加TAELSM后,Top-1达到91.07%,较基线提升了0.94%。最后添加GFPNSM后,Top-1达到93.75,较基线提升了4.62%。虽然模型的参数量(Params)从基线的115.68M增加至144.97M,但通过引入的LDFSSM、TASM和GFPNSM,Gflops却降低至17.83,显示出在提升性能的同时,通过特殊的模块构建,可以有效降低计算复杂度,而且具体的Gflops值可以随着LDFSSM的具体采样情况而降低。总体来看,通过逐步添加

LDFSSM、TAELSM和GFPNSM模块,本实施例的对比行为识别网络在Top-1上都取得了显著提升,显示出其在行为识别任务中的优越性能。

[0086] 本公开实施例还提供一种多模态数据融合模型驱动的肉牛行为识别系统,请参考图4,所述系统包括:

数据集构建模块,用于构建肉牛行为识别视频数据集和九轴加速度文本数据集;

第一网络构建处理模块,用于构建对比学习行为识别网络,并利用所述对比学习行为识别网络对视频数据和加速度文本数据进行处理得到视频特征和加速度特征,将视频特征和加速度特征进行拼接以及融合,得到融合特征;

网络训练模块,用于对所述对比学习行为识别网络进行训练;

第二网络构建处理模块,构建时序动态金字塔对比学习行为识别网络,并利用其对视频数据集的帧特征进行动态关键帧提取、时序注意力增强处理和多尺度融合,得到时序动态金字塔视频特征;将加速度文本数据映射之后进行位置编码和特征提取,得到加速度特征;将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征;

行为识别模块,用于将肉牛行为识别视频数据集和九轴加速度文本数据集输入训练后的所述对比学习行为识别网络和所述时序动态金字塔对比学习行为识别网络,进行肉牛行为识别,输出识别结果。

[0087] 本实施例中,所述对比学习行为识别网络包括:

视频处理模块,用于对视频数据的帧特征进行提取,然后将帧特征投影后进行聚合得到视频特征;

九轴加速度处理模块,用于将九轴加速度文本数据映射之后进行位置编码,对编码后的加速度文本数据进行特征提取,得到加速度特征;

特征对齐与融合模块,用于将所述视频特征和所述加速度特征进行拼接以及融合,得到融合特征。

[0088] 本实施例中,所述视频处理模块包括:

帧级特征提取子模块,用于将每一帧视频数据划分为多个图像块,并将其展平为一组向量;

编码器子模块,用于将每个所述向量投影到嵌入空间,并为每个图像块添加分类令牌、空间位置编码和时间位置编码,然后将所述图像块的序列和位置编码相加以进行编码,得到帧级视觉特征序列;

视频级特征聚合子模块,用于将所述帧级视觉特征序列的帧特征进行聚合,提取视频全局信息,将所述视频全局信息进行归一化处理得到视频级特征;

提示学习子模块,用于将所述帧级视觉特征序列添加全局提示令牌和局部提示令牌,并基于分类令牌进行条件化,从输出的图像块的序列中提取分类令牌,使用线性投影层将其进行投影,然后得到每帧的特征表示,将所述帧的特征表示进行平均池化,得到整个视频的聚合特征表示。

[0089] 本实施例中,所述时序动态金字塔对比学习行为识别网络包括:

时序动态金字塔视频处理模块,用于对视频数据集的帧特征进行动态关键帧提取,然后将提取的关键帧特征进行时序注意力增强处理,然后进行多尺度融合,最后进行归

一化处理得到时序动态金字塔视频特征；

加速度处理模块,用于将加速度文本数据映射之后进行位置编码,对编码后的加速度文本数据进行特征提取,得到加速度特征；

多模态融合模块,用于将所述时序动态金字塔视频特征和所述加速度特征进行拼接以及融合,得到时序动态多模态融合特征。

[0090] 本实施例中,所述多模态融合模块包括:

特征拼接子模块,用于将视频特征和加速度特征拼接在一起；

融合层子模块,用于使用线性层将拼接后的特征融合为一个统一的特征表示,并输出为一个归一化的张量。

[0091] 关于上述实施例中的系统,其中各个模块执行操作的具体方式已经在有关该方法的实施例中进行了详细描述,此处将不作详细阐述说明。

[0092] 应当注意,尽管在上文详细描述中提及了用于动作执行的系统的若干模块,但是这种划分并非强制性的。实际上,根据本发明的实施方式,上文描述的两个或更多模块的特征和功能可以在一个模块中具体化。反之,上文描述的一个模块的特征和功能可以进一步划分为多个模块来具体化。作为模块显示的部件可以是或者也可以不是物理单元,即可以位于一个地方,或者也可以分布到多个网络单元上。可以根据实际的需要选择其中的部分或者全部模块来实现本发明方案的目的。本领域普通技术人员在不付出创造性劳动的情况下,即可以理解并实施。

[0093] 上面结合附图对本发明的实施例进行了描述,但是本发明并不局限于上述的具体实施方式,上述的具体实施方式仅仅是示意性的,而不是限制性的,本领域的普通技术人员在本发明的启示下,在不脱离本发明宗旨和权利要求所保护的范围情况下,还可做出很多形式,这些均属于本发明的保护之内。




图1




图2




图3




图4




图5




图6




图7




图8




图9




图10




图11




图12