



(12) 发明专利申请

(10) 申请公布号 CN 120257990 A

(43) 申请公布日 2025. 07. 04

(21) 申请号 202510297279.2

(22) 申请日 2025.03.13

(71) 申请人 西北农林科技大学

地址 712100 陕西省西安市杨凌示范区邠城路3号

(72) 发明人 宋荣杰 吴钊 张宏鸣 牛当当 朱珊珊

(74) 专利代理机构 西安恒泰知识产权代理事务所 61216

专利代理师 王孝明

(51) Int. Cl.

G06F 40/295 (2020.01)

G06F 40/30 (2020.01)

G06F 40/284 (2020.01)

G06F 16/353 (2025.01)

G06F 18/2431 (2023.01)

G06F 18/25 (2023.01)

G06V 30/226 (2022.01)

G06V 10/82 (2022.01)

G06N 3/044 (2023.01)

G06N 3/045 (2023.01)


权利要求书4页 说明书11页 附图2页

(54) 发明名称

动态融合多维语义信息的中文苹果栽培命名实体识别方法

(57) 摘要

本发明提供了一种动态融合多维语义信息的中文苹果栽培命名实体识别方法,包括:步骤一,中文苹果栽培文本数据集构建;步骤二,动态多维语义信息嵌入层构建;步骤三,对步骤二得到的多维语义信息嵌入层中的加权后的多维语义信息嵌入MSIE,使用联合特征编码层RWKV_M进行序列编码,得到序列编码结果。步骤四,对步骤三得到的序列编码结果,使用条件随机场进行解码,得到最优序列作为最后的输出,从而得到苹果栽培命名实体识别任务的最终识别结果。本发明设计了动态多维语义信息嵌入层DMSIEL和RWKV_M特征编码层,有效解决了苹果栽培命名实体识别单一嵌入信息不足及深层语义特征提取不充分的问题。提高了苹果栽培命名实体识别的精度,在苹果栽培领域数据集上取得了最优效果。



1. 一种动态融合多维语义信息的中文苹果栽培命名实体识别方法, 其特征在于, 该方法包括以下步骤:

步骤一, 中文苹果栽培文本数据集构建;

其特征在于:

步骤二, 动态多维语义信息嵌入层构建:

首先, 分别获取动态字词嵌入 B_C 、字形嵌入 V_Z 、偏旁嵌入 V_P 以及词汇嵌入 V_C ; 然后, 通过拼接融合得到多维语义信息嵌入 $B_F = [B_C; V_Z; V_P; V_C]$; 最后, 通过多头注意力机制对多维语义信息嵌入 B_F 进行动态权重计算, 得到加权后的多维语义信息嵌入MSIE, 完成动态多维语义信息嵌入层的构建;

步骤三, 对步骤二得到的动态多维语义信息嵌入层中的加权后的多维语义信息嵌入MSIE, 使用结合RWKV和Mamba选择特性的联合特征编码层RWKV_M进行序列编码, 得到序列编码结果;

步骤四, 对步骤三得到的序列编码结果, 使用条件随机场进行解码, 得到最优序列作为最后的输出, 从而得到苹果栽培命名实体识别任务的最终识别结果。

2. 如权利要求1所述的动态融合多维语义信息的中文苹果栽培命名实体识别方法, 其特征在于, 步骤二的具体过程为:

步骤201, 使用PERT预训练模型获取动态字词嵌入 B_C ;

步骤202, 通过基于ViT的汉字字形语义信息获取方法以获取字形嵌入 V_Z ;

步骤203, 使用结合Word2Vec和Mamba的偏旁嵌入联合表征方法以获取偏旁嵌入 V_P ;

步骤204, 使用结合苹果栽培领域词表构建、Glove以及SoftLexicon的词汇嵌入联合表征方法以获取词汇嵌入 V_C ;

步骤205, 将 B_C 、 V_Z 、 V_P 和 V_C 进行拼接融合, 得到多维语义信息嵌入

$B_F = [B_C; V_Z; V_P; V_C]$;

步骤206, 通过多头注意力机制对多维语义信息嵌入 B_F 进行动态权重计算, 得到加权后的多维语义信息嵌入MSIE。

3. 如权利要求2所述的动态融合多维语义信息的中文苹果栽培命名实体识别方法, 其特征在于, 步骤206的具体过程为:

步骤20601, 对于多维语义信息嵌入 B_F , 通过线性变换分别生成第 i 个注意力头对应的查询矩阵 Q_i^B 、键矩阵 K_i^B 和值矩阵 V_i^B ;

$$Q_i^B = B_F W_i^{Q_B};$$

$$K_i^B = B_F W_i^{K_B};$$

$$V_i^B = B_F W_i^{V_B};$$

$$W_i^{Q_B} \in R^{d_{model} \times d_k};$$

$$W_i^{K_B} \in R^{d_{model} \times d_k};$$

$$W_i^{V_B} \in R^{d_{model} \times d_v};$$

$$d_k = d_v = \frac{d_{model}}{n};$$

式中:

$W_i^{Q_B}$ 表示第i个注意力头的查询矩阵用于线性变化的权重矩阵;

$W_i^{K_B}$ 表示第i个注意力头的键矩阵用于线性变化的权重矩阵;

$W_i^{V_B}$ 表示第i个注意力头的值矩阵用于线性变化的权重矩阵;

i表示注意力头的序列编号, $i=1, \dots, n$;

R表示实数集;

d_{model} 表示原始嵌入维度;

d_k 表示查询矩阵和键矩阵的维度;

d_v 表示值矩阵的维度;

n表示注意力头的数量;

步骤20602,进行多头注意力计算,最终得到加权后的多维语义信息嵌入MSIE的表达式为:

$$MSIE = \text{Concat}(h_1, \dots, h_n) W^0;$$

$$h_i = \text{Att}(Q_i^B, K_i^B, V_i^B);$$

$$W^0 \in R^{nd_v \times d_{model}};$$

式中:

MSIE表示加权后的多维语义信息嵌入;

h_i 表示第i个注意力头;

Concat()表示拼接操作;

W^0 表示输出矩阵用于线性变化的权重矩阵。

4. 如权利要求1所述的动态融合多维语义信息的中文苹果栽培命名实体识别方法,其特征在于,步骤三的具体过程为:

步骤301,将加权后的多维语义信息嵌入MSIE输入RWKV模型,通过RWKV模型的时间混合模块进行计算,将过去时间步的历史信息融入到当前标记,再经过层归一化稳定训练过程;

步骤302,接着送入RWKV模型的通道混合模块,对每个标记的通道进行混合以及引入非线性,使用标记偏移操作将每一个标记的当前输入和上一步的输入一同加入到RWKV模型的时间混合模块与通道混合模块之中;

步骤303,将Mamba串行接在RWKV之后,得到的输出即为序列编码结果。

5.如权利要求4所述的动态融合多维语义信息的中文苹果栽培命名实体识别方法,其特征在于,步骤301中,RWKV模型的时间混合模块计算过程如下:

$$\begin{aligned} r_t &= W_r \cdot (\mu_r \odot m_t + (1 - \mu_r) \odot m_{t-1}); \\ k_t &= W_k \cdot (\mu_k \odot m_t + (1 - \mu_k) \odot m_{t-1}); \\ v_t &= W_v \cdot (\mu_v \odot m_t + (1 - \mu_v) \odot m_{t-1}); \\ \text{wkv}_t &= \frac{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} \odot v_i + e^{u+k_t} \odot v_t}{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} + e^{u+k_t}}; \\ o_t &= W_o \cdot (\sigma(r_t) \odot \text{wkv}_t); \end{aligned}$$

式中:

r_t 表示时间混合模块中当前时间步的接受向量;

k_t 表示时间混合模块中当前时间步的键向量;

v_t 表示时间混合模块中当前时间步的值向量;

μ_r 表示时间混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成接受向量时的权重;

μ_k 表示时间混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成键向量时的权重;

μ_v 表示时间混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成值向量时的权重;

m_t 表示时间混合模块中当前时间步信息;

m_{t-1} 表示时间混合模块中上一时间步信息;

o_t 表示时间混合模块的输出向量;

W_o 表示时间混合模块输出向量的权重矩阵;

σ 表示Sigmoid激活函数;

wkv_t 表示RWKV中在不引入二次复杂度的情况下,代替Transformer中的注意力计算的WKV算子;

k_i 表示第i个时间步的键向量;

w 是一个通道方向的时间衰减向量;

u 是为当前字符设计的向量,为了避免 w 的潜在退化;

W_r 为时间混合模块中输入字符的接受向量 R 的权重矩阵;

W_k 为时间混合模块中输入字符的键向量 K 的权重矩阵;

W_v 为时间混合模块中输入字符的值向量 V 的权重矩阵;

$\odot$ 表示元素乘法。

6.如权利要求5所述的动态融合多维语义信息的中文苹果栽培命名实体识别方法,其特征在于,步骤302中,RWKV模型的通道混合模块的计算过程如下:

$$r'_t = W'_r \cdot (\mu'_r \odot m_t + (1 - \mu'_r) \odot m_{t-1});$$

$$k'_t = W'_k \cdot (\mu'_k \odot m_t + (1 - \mu'_k) \odot m_{t-1});$$

$$o'_t = \sigma(r'_t) \odot (W'_v \cdot \max(k'_t, 0)^2);$$

式中:

r'_t 表示通道混合模块中当前时间步的接受向量;

k'_t 表示通道混合模块中当前时间步的键向量;

W'_r 表示通道混合模块中输入字符的接受向量R的权重矩阵;

W'_k 表示通道混合模块中输入字符的键向量K的权重矩阵;

W'_v 表示通道混合模块中输入字符的值向量V的权重矩阵;

μ'_r 表示通道混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成接受向量时的权重;

μ'_k 表示通道混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成键向量时的权重;

o'_t 表示通道混合模块的输出向量;

$\max(k'_t, 0)^2$ 表示采用ReLU激活函数的平方。

7. 如权利要求1所述的动态融合多维语义信息的中文苹果栽培命名实体识别方法, 其特征在于, 步骤一的具体过程为: 选取苹果栽培专业书籍及CNKI中国知网科技论文, 通过OCR识别获取文本数据, 选择BMES方式标注文本数据, 同时在B、M、E和S的后面跟实体类别。

8. 如权利要求7所述的动态融合多维语义信息的中文苹果栽培命名实体识别方法, 其特征在于, 所述的实体类别包含了苹果品种、苗木管理、园地管理、花果管理、土肥水管理、整形与枝梢管理、病害、虫害、药剂、种植地区、时间、部位、方法以及特征。

动态融合多维语义信息的中文苹果栽培命名实体识别方法

技术领域

[0001] 本发明属于农业技术领域,涉及命名实体识别,具体涉及一种动态融合多维语义信息的中文苹果栽培命名实体识别方法。

背景技术

[0002] 命名实体识别是指识别出文本中具有特定意义的命名实体,并将其分类为预先定义的实体类型,对信息抽取和知识图谱构建等下游任务以及智能问答与推荐等信息化服务具有重要支撑作用。如何准确识别出命名实体是知识获取效率提高的关键。

[0003] 苹果栽培涉及多个生产环节的关键技术,这些技术知识具有非结构化、针对特定领域和碎片化分布等特点,限制了苹果栽培技术知识的高效获取与有效应用。基于知识图谱的苹果栽培问答系统能够利用知识图谱的结构化知识组织优势来提供智能问答服务,从而帮助农户根据自身需求高效准确的获取苹果栽培相关知识。命名实体识别是知识图谱构建的重要基础任务,旨在从非结构化的中文苹果栽培文本中准确识别出苹果栽培相关实体,同时,命名实体识别对苹果栽培信息抽取和问答系统等下游任务均具有重要的作用。

[0004] 苹果栽培命名实体识别面临一词多义、大量专业术语、实体结构复杂以及边界模糊等挑战,仅使用基于字符的嵌入在苹果栽培领域命名实体识别上很难取得较好的识别效果。如何提取不同外部特征的语义信息来丰富字符语义表示并根据不同特征的重要性进行合理的权重分配以提升苹果栽培命名实体识别效果,如何有效挖掘多维语义嵌入的深层语义信息并突出重要信息,均是目前该领域的研究重点。

发明内容

[0005] 针对现有技术存在的不足,本发明的目的在于,提供一种动态融合多维语义信息的中文苹果栽培命名实体识别方法,解决现有技术中苹果栽培命名实体识别的有效特征信息挖掘能力和识别精度有待进一步提升的技术问题。

[0006] 为了解决上述技术问题,本发明采用如下技术方案予以实现:

[0007] 一种动态融合多维语义信息的中文苹果栽培命名实体识别方法,该方法包括以下步骤:

[0008] 步骤一,中文苹果栽培文本数据集构建。

[0009] 步骤二,动态多维语义信息嵌入层构建:

[0010] 首先,分别获取动态字词嵌入 B_c 、字形嵌入 V_z 、偏旁嵌入 V_p 以及词汇嵌入 V_c ;然后,通过拼接融合得到多维语义信息嵌入 $B_f = [B_c; V_z; V_p; V_c]$;最后,通过多头注意力机制对多维语义信息嵌入 B_f 进行动态权重计算,得到加权后的多维语义信息嵌入MSIE,完成动态多维语义信息嵌入层的构建。

[0011] 步骤三,对步骤二得到的动态多维语义信息嵌入层中的加权后的多维语义信息嵌入MSIE,使用结合RWKV和Mamba选择特性的联合特征编码层RWKV_M进行序列编码,得到序列编码结果。

[0012] 步骤四,对步骤三得到的序列编码结果,使用条件随机场进行解码,得到最优序列作为最后的输出,从而得到苹果栽培命名实体识别任务的最终识别结果。

[0013] 本发明与现有技术相比,具有如下技术效果:

[0014] (I) 本发明设计了动态多维语义信息嵌入层DMSIEL和RWKV_M特征编码层,有效解决了苹果栽培命名实体识别单一嵌入信息不足及深层语义特征提取不充分的问题。提高了苹果栽培命名实体识别的精度,在苹果栽培领域数据集上取得了最优效果。

[0015] (II) 本发明通过设计融合字符、字形、偏旁和词汇信息并结合多头注意力机制计算特征权重的动态多维语义信息嵌入层DMSIEL,从多个维度增强字符的语义表示。

[0016] (III) 本发明通过设计基于ViT提取汉字图像信息并转化为汉字字形嵌入的方法,将汉字视觉形态特征所包含的丰富语义信息融合进嵌入表示。

[0017] (IV) 本发明通过设计先依据汉字拆字字典拆解汉字,再由Word2Vec训练偏旁嵌入并结合Mamba提取汉字偏旁有效信息进行汉字偏旁嵌入联合表征,将汉字偏旁所包含的有效语义信息融合进嵌入表示。

[0018] (V) 本发明设计先构建苹果栽培分词词表,再通过Glove训练词汇向量并结合SoftLexicon的词汇嵌入联合表征方法进行词汇嵌入获取,有效缓解边界信息不足的问题。

[0019] (VI) 本发明通过多头注意力机制对构建的多维语义信息嵌入进行动态特征权重计算,将对苹果栽培命名实体识别更有效的特征赋予更高的权重,促进多维特征的有效利用,从而提升苹果栽培实体识别精度。

[0020] (VII) 本发明通过设计RWKV_M特征编码层,通过RWKV进行序列编码,增强不同特征之间的信息交互,并结合Mamba突出经过RWKV编码后的有效关键特征,从而提升苹果栽培实体识别精度。

[0021] (VIII) 与现有方法相比,本发明不仅能够提升苹果栽培领域的命名实体识别精度,同时具有一定的泛化性,可以迁移应用至其他农业领域。同时也对知识图谱构建以及问答系统等下游任务具有重要支撑作用。

附图说明

[0022] 图1是中文苹果栽培数据集的标注示例。

[0023] 图2是本发明的模型结构示意图。

[0024] 以下结合实施例对本发明的具体内容作进一步详细解释说明。

具体实施方式

[0025] 需要说明的是,本发明中的所有的模型、模块和方法,如无特殊说明,全部均采用现有技术中已知的模型、模块和方法。

[0026] 中文苹果栽培命名实体识别中,实体复杂度较高,类别较多,单一的字符嵌入难以从多个维度表征语义信息,并且不同维度的嵌入表示对苹果栽培命名实体识别的重要性不同。多维嵌入蕴含丰富的语义信息,需要特征编码层有较强的特征提取能力,以挖掘深层语义信息,并突出对苹果栽培命名实体识别更为有效的语义特征。

[0027] 基于此现状,本发明通过设计融合字符、字形、偏旁和词汇信息并结合多头注意力机制计算特征权重的动态多维语义信息嵌入层DMSIEL从多个维度表征字符嵌入,并且动态

的对有效特征赋予更高权重。设计RWKV_M特征编码层结合RWKV和Mamba对获取到的包含多维语义信息的字符嵌入进行序列编码,突出关键深层语义特征,从而进一步提升命名实体识别效果。

[0028] OCR,即Optical Character Recognition,指光学字符识别。

[0029] MSIE,即Multi-dimensional Semantic Information Embedding,指加权后的多维语义信息嵌入。

[0030] DMSIEL,即Dynamic Multi-dimensional Semantic Information Embedding Layer,指动态多维语义信息嵌入层。

[0031] ViT,即Vision Transformer,指视觉形式的Transformer。

[0032] Mamba,指引入选择机制的结构化状态空间模型。

[0033] SoftLexicon,指通过BMES四个词集获取词汇嵌入的方法。

[0034] RWKV_M,即结合RWKV和Mamba的联合特征编码层。

[0035] RWKV,即Receptance Weighted Key Value,指接受加权键值模型。

[0036] PERT,即Pre-Training BERT With Permuted Language Model,指使用置换语言模型预训练BERT。

[0037] BERT,即Bidirectional Encoder Representations from Transformers,指基于转换器的双向编码器表征模型。

[0038] TENER即Transformer Encoder for Named Entity Recognition,指适配Transformer编码器的命名实体识别模型。

[0039] 以下给出本发明的具体实施例,需要说明的是本发明并不局限于以下具体实施例,凡在本申请技术方案基础上做的等同变换均落入本发明的保护范围。

[0040] 实施例:

[0041] 本实施例给出一种动态融合多维语义信息的中文苹果栽培命名实体识别方法,该方法包括以下步骤:

[0042] 步骤一,中文苹果栽培文本数据集构建:

[0043] 选取苹果栽培专业书籍及CNKI中国知网科技论文,通过OCR识别获取文本数据,选择BMES方式标注文本数据,同时在B、M、E和S的后面跟实体类别。

[0044] 本实施例中,所述的BMES(Begin,Middle,End,Single)方式,其中“B”表示实体的开始字符,“M”表示实体的中间字符,“E”表示实体的结束字符,“S”表示由单个字符构成的实体。

[0045] 本实施例中,所述的实体类别包含了苹果品种、苗木管理、园地管理、花果管理、土肥水管理、整形与枝梢管理、病害、虫害、药剂、种植地区、时间、部位、方法以及特征。

[0046] 本实施例中,中文苹果栽培数据集的标注示例如图1所示。

[0047] 步骤二,动态多维语义信息嵌入层构建:

[0048] 首先,分别获取动态字词嵌入 B_C 、字形嵌入 V_Z 、偏旁嵌入 V_P 以及词汇嵌入 V_C ;然后,通过拼接得到多维语义信息嵌入 $B_F = [B_C; V_Z; V_P; V_C]$;最后,通过多头注意力机制对多维语义信息嵌入 B_F 进行动态权重计算,赋予重要特征以更高权重,得到加权后的多维语义信息嵌入MSIE,完成动态多维语义信息嵌入层(DMSIEL)的构建。

[0049] 如图2所示,步骤二的具体过程为:

[0050] 步骤201,使用PERT预训练模型获取动态字词嵌入 B_c 。

[0051] 步骤S201中,PERT的预训练任务为,使用全词掩码和N-gram掩码选择候选文本,置换文本位置并预测。通过由标记嵌入、分段嵌入和位置嵌入组成的嵌入层和连续的Transformer层将输入的苹果栽培文本转换为向量表示。

[0052] 在本实施例中,对于中文苹果栽培文本而言,使用PERT获取字符嵌入,一方面可以引入词级别的语义信息,另一方面,使用置换文本位置并预测的预训练任务,能够更好关注苹果栽培文本中心语义,增强字符嵌入对中文苹果栽培字符语义的表示能力,相较于一般方法常用的静态字符嵌入,本发明使用的字符嵌入获取方法具有动态字词表示以及聚焦文本中心语义的优点。

[0053] 步骤202,通过基于ViT的汉字字形语义信息获取方法以获取字形嵌入 V_z 。

[0054] 步骤202中,在获取字符嵌入之后,选取汉字的常用字体宋体作为后续提取字形信息的汉字字体,基于STSONG.TTF字体文件,编写切分单个汉字图像的代码,从而制作每个汉字对应的 224×224 大小的字形图像。使用ViT-Base作为汉字特征的提取网络,提取汉字图像特征的过程为,读取尺寸为 224×224 的汉字图像数据,进行标准化和归一化,输入预训练的ViT模型对字形特征进行提取,将提取到的字形特征通过线性层转换为50维的向量表示 V_z 。

[0055] 在本实施例中,对于中文苹果栽培文本而言,通过汉字图像建模汉字的字形特征,能够提取出汉字字形所蕴含的丰富语义信息,进而与字符嵌入进行融合,能够有效提升苹果栽培实体识别精度。一般的方法在字形图像编码时,多为直接将图像编码转换为一维或简单的CNN字形编码提取,本发明引入预训练的ViT用以提取汉字图像的方法,相较于传统方法有两个方面的优势,一方面是ViT的编码结构可以关注到字形信息的全局语义,提取汉字图像深层特征,另一方面,预训练模型的权重是由大规模图像训练得到,因此将预训练的ViT用字形图像提取,能够将预训练模型对深层特征的优越提取能力迁移至汉字图像编码任务之中,从而使苹果栽培命名实体识别可以对汉字图像关键信息进行有效利用,提升苹果栽培命名实体识别效果。

[0056] 步骤203,使用结合Word2Vec和Mamba的偏旁嵌入联合表征方法以获取偏旁嵌入 V_p 。

[0057] 步骤203中,将收集的苹果栽培数据集中的每个汉字字符,依据汉语拆字字典将该汉字字符拆分为对应的多个偏旁,得到包含数据集中原始汉字字符所对应的该字符的所有偏旁的数据文件,通过结合Word2Vec嵌入表示和Mamba特征选择的偏旁嵌入联合表征方法进行偏旁嵌入表征。

[0058] 首先,通过Word2Vec训练得到每个偏旁的50维向量表示。

[0059] 其次,将每个字符所对应的多个偏旁通过Mamba对偏旁特征进行初步提取,利用Mamba选择性保留信息的特性,保留蕴含较多语义信息的偏旁,忽略蕴含较少语义信息的偏旁,最终得到经过联合表征的50维偏旁嵌入表示 V_p 。其中Mamba通过定义与输入相关的系数矩阵B和C以及参数 Δ 引入选择机制提取有效偏旁的计算过程为:

[0060] $h'(t) = Ah(t) + Bx(t)$

[0061] $y(t) = Ch(t)$

[0062] 式中:

[0063] A、B和C均表示系数矩阵, $A \in \mathbb{R}^{N \times N}$, $b \in \mathbb{R}^{N \times 1}$, $C \in \mathbb{R}^{1 \times N}$;

[0064] R表示实数集;

[0065] N表示向量的维度;

[0066] t表示当前时间步;

[0067] $h'(t)$ 表示隐含的潜在状态的导数;

[0068] $h(t)$ 表示隐含的潜在状态;

[0069] $x(t)$ 表示输入一维序列;

[0070] $y(t)$ 表示输出一维序列。

[0071] 系数矩阵A,B可以通过零阶保持 (Zero-Order Hold, ZOH) 和 Δ 间隔的时间采样离散化为 $\bar{A}$, $\bar{B}$, 具体的离散化规则如下:

$$\bar{A} = \exp(\Delta A);$$

[0072]

$$\bar{B} = (\Delta A)^{-1}(\exp(\Delta A) - I) \cdot \Delta B;$$

[0073] 离散化的结构化状态空间模型线性递归形式可以表示为:

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t;$$

[0075] $y_t = Ch_t$;

[0076] 式中:

[0077] h_t 表示当前时间步t的潜在状态;

[0078] h_{t-1} 表示上一时间步t-1的潜在状态;

[0079] x_t 表示当前时间步t的输入序列;

[0080] y_t 表示当前时间步t的输出序列;

[0081] 全局卷积形式可以表示为:

$$\bar{K} = (C\bar{B}, C\bar{A}\bar{B}, \dots, C\bar{A}^k\bar{B}, \dots);$$

[0082]

$$y = x * \bar{K};$$

[0083] 式中:

[0084] y表示输出序列;

[0085] x表示输入序列;

[0086] $\bar{K}$ 表示结构化状态空间模型卷积核;

[0087] k表示时间步数。

[0088] 在本实施例中, 苹果栽培文本的病害实体类别中的“苹果霉心病”、“苹果白粉病”等实体中“病”字的偏旁“疒”, 具有符合“病害”这一实体类别的文本特征, 因此含有偏旁“疒”字符的命名实体, 会有更大的可能分类至“病害”实体。通过偏旁嵌入联合表征方法进行偏旁嵌入表征, 能有效表征苹果栽培文本的偏旁语义, 其中, Word2Vec训练偏旁的向量表示, 不仅能学习到偏旁的基本表征, 同时也能捕捉到偏旁之间的关联性信息。利用Mamba选择性保留信息的特性, 则会保留包含苹果栽培文本汉字的语义信息较多的偏旁, 过滤掉包含苹果栽培文本汉字的语义信息较少的偏旁。两者联合使用, 则可以从蕴含关联信息的偏

旁基础表征与突出更重要的偏旁特征两个方面,来提升苹果栽培命名实体识别对偏旁语义信息的利用。

[0089] 步骤204,使用结合苹果栽培领域词表构建、Glove以及SoftLexicon的词汇嵌入联合表征方法以获取词汇嵌入 V_c 。

[0090] 步骤204中,通过结合苹果栽培领域词表构建、Glove以及SoftLexicon的词汇嵌入联合表征方法进行词汇表征,首先构建适用于苹果栽培领域的词表,使用自己构建的苹果栽培词表通过jieba分词对苹果栽培数据集进行分词。然后将分词后的数据通过Glove训练获得50维的苹果栽培词汇嵌入。最后用词集分类的方法获取最终的词汇嵌入 V_c 。

[0091] 在本实施例中,通过词汇嵌入联合表征方法可以从苹果栽培领域专有名词信息、不同词汇之间具有关联性的全局语义信息和词汇内部字符组成结构信息三个方面共同表征词汇嵌入。相较于一般的词汇嵌入方法,自建苹果栽培词表更能适应苹果栽培领域,词间关系与词内结构信息并存使得语义信息更为丰富。其中,通过构建苹果栽培领域词表并由Glove训练得到的词嵌入,通过词汇共现矩阵,能够捕捉苹果栽培词汇之间的语义关系,提取到全局范围内的苹果栽培词汇上下文信息,词集分类的词汇匹配方法则更为聚焦于字符与词汇之间的结构组织关系。

[0092] 将每个字符所匹配到的词汇分类至BMES四个词集,当输入序列为 $s = \{c_1, c_2, \dots, c_n\}$,对于每个字符 c_i ,当字符位于所匹配到的词汇的开头位置时分类至 $B(c_i)$ 词集,当字符位于词汇的中间位置时会分类至 $M(c_i)$ 词集,当字符位于词汇的末尾位置时会分类至 $E(c_i)$ 词集,当词汇只有单独一个字符时则会分类至 $S(c_i)$ 词集,如果词集为空时,则会在词集中加入“None”。

[0093] 在本实施例中,以“苹果栽培”作为输入举例,对于“果”字,在词典中匹配到“苹果”和“苹果栽培”这两个词,所以“果”字对应的词集表示为 $B = \{\text{“None”}\}$, $M = \{\text{“苹果栽培”}\}$, $E = \{\text{“苹果”}\}$, $S = \{\text{“None”}\}$,对于“栽”字,在词典中匹配到“栽”、“栽培”和“苹果栽培”三个词,所以“栽”字对应的词集表示为, $B = \{\text{“栽培”}\}$, $M = \{\text{“苹果栽培”}\}$, $E = \{\text{“None”}\}$, $S = \{\text{“栽”}\}$ 。

[0094] 在获取到每个字符的“BMES”词集后,每个词集需要压缩为一个固定维度的向量,本发明使用静态的以每个词汇的频率作为其权重的加权方法。

[0095] 最后将四个词集拼接成一个固定维度的嵌入表示 V_c 。

[0096] 步骤205,将 B_c 、 V_z 、 V_p 和 V_c 通过拼接融合,得到多维语义信息嵌入 $B_F = [B_c; V_z; V_p; V_c]$ 。

[0097] 步骤206,通过多头注意力机制对多维语义信息嵌入 B_F 进行动态权重计算,得到加权后的多维语义信息嵌入MSIE。

[0098] 步骤206的具体过程为:

[0099] 步骤20601,对于多维语义信息嵌入 B_F ,通过线性变换分别生成第 i 个注意力头对应的查询矩阵 Q_i^B 、键矩阵 K_i^B 和值矩阵 V_i^B 。

$$Q_i^B = B_F W_i^{Q_B};$$

$$K_i^B = B_F W_i^{K_B};$$

$$V_i^B = B_F W_i^{V_B};$$

$$[0100] \quad W_i^{Q_B} \in R^{d_{model} \times d_k};$$

$$W_i^{K_B} \in R^{d_{model} \times d_k};$$

$$W_i^{V_B} \in R^{d_{model} \times d_v};$$

$$d_k = d_v = \frac{d_{model}}{n};$$

[0101] 式中:

[0102] $W_i^{Q_B}$ 表示第i个注意力头的查询矩阵用于线性变化的权重矩阵;

[0103] $W_i^{K_B}$ 表示第i个注意力头的键矩阵用于线性变化的权重矩阵;

[0104] $W_i^{V_B}$ 表示第i个注意力头的值矩阵用于线性变化的权重矩阵;

[0105] i表示注意力头的序列编号, $i=1, \dots, n$;

[0106] n表示注意力头的数量;

[0107] R表示实数集;

[0108] d_{model} 表示原始嵌入维度;

[0109] d_k 表示查询矩阵和键矩阵的维度;

[0110] d_v 表示值矩阵的维度。

[0111] 步骤20602,进行多头注意力计算,最终得到加权后的多维语义信息嵌入MSIE的表达式为:

$$[0112] \quad MSIE = \text{Concat}(h_1, \dots, h_n) W^0;$$

$$h_i = \text{Att}(Q_i^B, K_i^B, V_i^B);$$

[0113]

$$W^0 \in R^{nd_v \times d_{model}};$$

[0114] 式中:

[0115] MSIE表示加权后的多维语义信息嵌入;

[0116] h_i 表示第i个注意力头;

[0117] $\text{Concat}()$ 表示拼接操作;

[0118] W^0 表示输出矩阵用于线性变化的权重矩阵。

[0119] 在本实施例中,本发明设计多维语义信息嵌入动态融合方法,相较于一般命名实体识别方法的单一字符嵌入,本发明引入蕴含丰富汉字语义信息的字符、字形、偏旁和词汇多种特征,分别从动态字词嵌入、汉字字形视觉形状、汉字偏旁结构以及词汇边界多个方面丰富了字符的嵌入表示。同时,结合多头注意力机制可以动态调整字符嵌入、字形嵌入、偏

旁嵌入和词汇嵌入的特征权重,当实体识别任务更依赖某一特征时,这一特征的权重会高于其余特征,从而进一步提升多维语义特征嵌入的表征能力,相较于一般的外部特征融合方法,本发明不仅从字符、字形、偏旁和词汇多个维度引入有效表征,聚焦于中文苹果栽培,同时设计动态的特征融合方法,能够强化突出关键特征。

[0120] 步骤三,对步骤二得到的多维语义信息嵌入层(DMSIEL)中的加权后的多维语义信息嵌入MSIE,使用结合RWKV和Mamba选择特性的联合特征编码层RWKV_M进行序列编码,得到序列编码结果。

[0121] 如图2所示,步骤三的具体过程为:

[0122] 步骤301,将多维语义信息嵌入MSIE输入RWKV模型,通过RWKV模型的时间混合模块进行计算,将过去时间步的历史信息融入到当前标记,再经过层归一化稳定训练过程。

[0123] 步骤302,接着送入RWKV模型的通道混合模块,对每个标记的通道进行混合以及引入非线性,使用标记偏移操作将每一个标记的当前输入和上一步的输入一同加入到RWKV模型的时间混合模块与通道混合模块之中。

[0124] 步骤303,将Mamba串行接在RWKV之后,通过Mamba编码更有助于苹果栽培文本正确分类的关键特征,从而选择性的突出重要特征,得到的输出即为序列编码结果。

[0125] 步骤301中,RWKV模型的时间混合模块计算过程如下:

$$[0126] \quad r_t = W_r \cdot (\mu_r \odot m_t + (1 - \mu_r) \odot m_{t-1});$$

$$[0127] \quad k_t = W_k \cdot (\mu_k \odot m_t + (1 - \mu_k) \odot m_{t-1});$$

$$[0128] \quad v_t = W_v \cdot (\mu_v \odot m_t + (1 - \mu_v) \odot m_{t-1});$$

$$[0129] \quad \text{wkv}_t = \frac{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} \odot v_i + e^{u+k_t} \odot v_t}{\sum_{i=1}^{t-1} e^{-(t-1-i)w+k_i} + e^{u+k_t}};$$

$$[0130] \quad o_t = W_o \cdot (\sigma(r_t) \odot \text{wkv}_t);$$

[0131] 式中:

[0132] r_t 表示时间混合模块中当前时间步的接受向量;

[0133] k_t 表示时间混合模块中当前时间步的键向量;

[0134] v_t 表示时间混合模块中当前时间步的值向量;

[0135] μ_r 表示时间混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成接受向量时的权重;

[0136] μ_k 表示时间混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成键向量时的权重;

[0137] μ_v 表示时间混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成值向量时的权重;

[0138] m_t 表示时间混合模块中当前时间步信息;

[0139] m_{t-1} 表示时间混合模块中上一时间步信息;

[0140] o_t 表示时间混合模块的输出向量;

[0141] W_o 表示时间混合模块输出向量的权重矩阵;

[0142] σ 表示Sigmoid激活函数;

[0143] wkv_t 表示RWKV中在不引入二次复杂度的情况下,代替Transformer中的注意力计算的WKV算子;

[0144] k_i 表示第*i*个时间步的键向量；

[0145] w 是一个通道方向的时间衰减向量,在衰减时是从当前时间向后追溯,越近的标记会衰减的越少；

[0146] u 是为当前字符设计的向量,为了避免 w 的潜在退化；

[0147] W_r 为时间混合模块中输入字符的接受向量 R 的权重矩阵；

[0148] W_k 为时间混合模块中输入字符的键向量 K 的权重矩阵；

[0149] W_v 为时间混合模块中输入字符的值向量 V 的权重矩阵；

[0150] $\odot$ 表示元素乘法。

[0151] 步骤302中,RWKV模型的通道混合模块的计算过程如下：

[0152] $r'_t = W_r' \cdot (\mu'_r \odot m_t + (1 - \mu'_r) \odot m_{t-1})$

[0153] $k'_t = W_k' \cdot (\mu'_k \odot m_t + (1 - \mu'_k) \odot m_{t-1})$

[0154] $o'_t = \sigma(r'_t) \odot (W_v' \cdot \max(k'_t, 0)^2)$

[0155] 式中：

[0156] r'_t 表示通道混合模块中当前时间步的接受向量；

[0157] k'_t 表示通道混合模块中当前时间步的键向量；

[0158] W_r' 表示通道混合模块中输入字符的接受向量 R 的权重矩阵；

[0159] W_k' 表示通道混合模块中输入字符的键向量 K 的权重矩阵；

[0160] W_v' 表示通道混合模块中输入字符的值向量 V 的权重矩阵；

[0161] μ'_r 表示通道混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成接受向量时的权重；

[0162] μ'_k 表示通道混合模块中控制当前时间步信息 m_t 和上一时间步信息 m_{t-1} 生成键向量时的权重；

[0163] o'_t 表示通道混合模块的输出向量；

[0164] $\max(k'_t, 0)^2$ 表示采用ReLU激活函数的平方。

[0165] 在本实施例中,本发明设计的联合特征编码方法可以从多维语义特征提取、上下文语义提取以及关键特征的选择三个方面对多维语义信息进行深度挖掘。其中,RWKV由一个时间混合模块和一个通道混合子模块组成的残差块不断的堆叠构成,这样的循环结构能够有效利用过去的信息。在通道混合模块,通过不同通道之间的信息交互,可以使模型对字符、字形、偏旁和词汇的多维语义信息进行有效捕捉,能够提取出动态多维语义信息嵌入层的有效特征。标记偏移操作是将每一个标记的当前输入和上一步的输入一起加到时间混合模块和通道混合模块之中,随着模块的不断叠加,模型会具有越强的序列建模能力,从而能够有效的提取长距离信息,更好的捕捉到苹果栽培文本所蕴含的上下文语义信息。结合RWKV和Mamab进行联合编码,可以在RWKV编码后结合Mamba的选择性,可以对有效的深层语义特征进行提取,强化突出更有助于苹果栽培实体识别的深层语义特征,从而进一步提升实体识别的精度。

[0166] 步骤四,对步骤三得到的序列编码结果,使用条件随机场(CRF)进行解码,得到最优序列作为最后的输出,从而得到苹果栽培命名实体识别任务的最终识别结果。

[0167] 在本实施例中,苹果栽培命名实体识别任务的输出标签之间具有依赖性,例如：“M-DIS”标签不能跟在“B-TIM”后面,BMES方式标注的命名实体的首字标签应该以“B-”开

头,不能以“M-”开头。特征编码层虽然提取了多特征嵌入层的丰富语义信息,但没有学习到实体标签之间的上述约束关系。使用条件随机场可以有效学习苹果栽培实体识别标签序列之间的约束关系。

[0168] 性能测试:

[0169] 为了验证本发明的有效性,本发明在上述实施例中的步骤一中所提到的自建中文苹果栽培数据集上,本发明的方法与另外四个方法进行了精度对比实验。

[0170] 四个对比模型如下:

[0171] 对比方法一:命名实体识别领域的常用的BiLSTM-CRF(双向长短期记忆网络-条件随机场)模型。

[0172] 对比方法二:采用预训练模型BERT的BERT-CRF(基于转换器的双向编码器表征模型-条件随机场)模型。

[0173] 对比方法三:通过采用相对位置编码改进了Transformer编码层的TENER(适配Transformer编码器的命名实体识别)模型。

[0174] 对比方法四:通过BMES词集分类方法改进了词汇加入方法的SoftLexicon模型。

[0175] 使用命名实体识别任务常用的精确率P(Precision)、召回率R(Recall)和F1值(F1-score)对命名实体识别性能进行评估。

[0176] 评价指标的计算公式如下所示:

$$P = \frac{TP}{TP + FP}$$

[0177]
$$R = \frac{TP}{TP + FN}$$

$$F1 = \frac{2TP}{2TP + FP + FN}$$

[0178] 式中:

[0179] TP表示模型在所有阳性样本中正确识别的阳性样本数量;

[0180] FP是表示模型错误的识别为阳性样本的阴性样本数量;

[0181] FN表示模型错误的将阳性样本识别为阴性样本的数量。

[0182] 表1本发明与四个对比方法的精度表

[0183]

方法	精确率	召回率	F1值
对比方法一	89.90	88.54	89.22
对比方法二	91.01	91.04	91.02
对比方法三	91.40	94.90	93.12
对比方法四	94.09	94.09	94.09
本发明的方法	95.40	96.27	95.83

[0184] 从表1中可以看出,本发明所提出的方法,与对比方法一、对比方法二、对比方法三和对比方法四相比较,在精确率、召回率和F1值这三个评价指标上,均取得最好的识别精度。

[0185] 相较于对比方法一,本发明的方法F1值提升了6.61,说明本发明的方法相较于基线模型,在苹果栽命名实体识别任务上有大幅度的提升。

[0186] 相较于对比方法二,本发明的方法F1值提升了4.81,说明本发明设计的动态多维语义信息嵌入层DMSIEL,能够动态融合字形、偏旁以及词汇特征,相较于仅使用单一字符嵌入,多维语义信息嵌入层具有更丰富的语义信息,从而提升了识别精度。

[0187] 相较于对比方法三,本发明的方法F1值提升了2.71,说明本发明设计的RWKV_M编码层可以对多维语义信息进行有效提取,同时突出关键特征。

[0188] 相较于对比方法四,本发明的方法F1值提升了1.74,说明相较于仅引入词汇特征,本发明将预训练字符嵌入、字形、偏旁以及词汇多个维度信息引入嵌入表示之中,并动态计算权重,从而构建的动态多维语义信息嵌入层DMSIEL,能有效提升苹果栽培命名实体识别的精度。




图1




图2