



(12) 发明专利申请

(10) 申请公布号 CN 121189419 A

(43) 申请公布日 2025. 12. 23

(21) 申请号 202511394670.0

G06F 18/213 (2023.01)

(22) 申请日 2025.09.28

G06F 18/214 (2023.01)

(71) 申请人 西北农林科技大学

G06F 18/2431 (2023.01)

地址 712100 陕西省咸阳市杨陵区李台街
道郃城路3号(72) 发明人 高小转 潘丽鹏 张宏鸣 赵绅凯
牛当当 李扬雪 康兵义(74) 专利代理机构 西安弘理专利代理事务所
(普通合伙) 61214

专利代理师 陶康杰

(51) Int. Cl.

G06N 3/091 (2023.01)

G06F 18/21 (2023.01)

G06F 18/22 (2023.01)

G06F 18/25 (2023.01)


权利要求书2页 说明书11页 附图7页

(54) 发明名称

面向认知不确定性的广义证据主动学习方法

(57) 摘要

本发明公开的面向认知不确定性的广义证据主动学习方法,具体为对标记样本进行初始化,形成标记样本集,基于标记样本集对标注分类模型进行训练,形成初始标注分类模型,评判初始标注分类模型是否达到预期准确率,是则输出最终模型,否则下一步,检查标记成本是否耗尽,是则以当前模型为最终模型,否则下一步,从未标记样本池选取认知不确定性最高的样本并查询其标签;将样本及其标签加入标记样本集并从未标记池移除;重复操作,直至分类模型达到预期准确率或标记成本耗尽。本发明解决了现有技术中无法在同一框架下同时衡量多种不确定因素,导致样本选择过于片面的问题。



1. 面向认知不确定性的广义证据主动学习方法, 其特征在于, 包括以下步骤:

S1, 对标记样本进行初始化, 形成标记样本集L;

S2, 基于标记样本集L对标注分类模型进行训练, 形成初始标注分类模型;

S3, 评判初始标注分类模型是否达到预期准确率, 是则输出最终模型, 否则进行S4;

S4, 检查标记成本是否耗尽, 是则以当前模型为最终模型, 否则进行S5;

S5, 从未标记样本池中选取认知不确定性最高的样本X并查询其标签;

S6, 将样本X及其标签加入标记样本集L并从未标记池移除;

S7, 重复步骤S2~S6, 直至分类模型达到预期准确率或标记成本耗尽。

2. 根据权利要求1所述的面向认知不确定性的广义证据主动学习方法, 其特征在于, 所述步骤S1中初始化为随机初始化, 从每个类别中随机抽取一个样本, 组成初始已标记集合, 作为模型训练的起点。

3. 根据权利要求1所述的面向认知不确定性的广义证据主动学习方法, 其特征在于, 所述步骤S5中从未标记样本池中选取认知不确定性最高的样本X, 包括以下步骤:

S501, 从认知不确定性的角度出发, 对未标记样本的不确定性信息进行建模分类;

S502, 在广义证据理论的框架下, 基于折扣机制, 针对未标记样本的代表性、信息性和多样性, 生成样本对应的空集、单元素焦元和全集的信念质量;

S503, 设计与主动学习迭代轮次相关的 T -norm算子变体, 并在广义证据理论框架下分析信息的非特异性和不一致性, 实现对未标记样本不确定性的综合评估;

S504, 依据最大不确定性原则, 从未标记样本池中选择不确定性综合得分最高的样本作为样本X。

4. 根据权利要求3所述的面向认知不确定性的广义证据主动学习方法, 其特征在于, 所述步骤S501中将不确定性划分为两类, 一类为未标记样本到决策边界的远近程度, 另一类为未标记样本与标记样本的特征相似性;

其中决策边界由当前监督学习模型训练得到。

5. 根据权利要求3所述的面向认知不确定性的广义证据主动学习方法, 其特征在于, 所述步骤S502具体包括:

利用训练模型对未标注样本进行预测, 输出的类别概率作为初始信念质量; 其次, 计算未标记样本与标记样本距离的标准差, 构造折扣因子, 对初始信念质量进行调整, 重新分配单元素焦元的信念质量, 并将减少部分的信念质量分配给全集, 以反映模型对该样本的多样性, 表达式如下式所示:

$$m_{x_i}(\Theta) = 1 - \sum_{n=0}^{N-1} m'_{x_i}(\theta_n);$$

$$m'_{x_i}(\theta_n) = f(x_i) p_n(x_i);$$

$$f(x_i) = 1 - e^{-\alpha d_1(x_i)};$$

式中, $f(x_i)$ 为未标记样本与标记样本距离标准差相关的折扣函数, $p_n(x_i)$ 表示模型输出的类别概率, $m_{x_i}(\Theta)$ 表示分配给全集的信念质量, $d_1(x_i)$ 为未标记样本与标记样本标准差的相关变量;

再依据未标记样本到标记样本距离之和,构造折扣因子,对单元素焦元的信念质量进行再次折扣,生成空集的信念质量,用以刻画未标记样本的代表性;在上述两次折扣后,剩余的单元素焦元的信念质量用以刻画未标记样本的信息性,定义表达式如下式所示:

$$m_{x_i}(\phi) = \sum_{n=0}^{N-1} m'_{x_i}(\theta_n) - \sum_{n=0}^{N-1} m_{x_i}(\theta_n);$$

$$m_{x_i}(\theta_n) = g(x_i) * m'_{x_i}(\theta_n);$$

$$g(x) = e^{-\beta d_o(x_i)};$$

式中, $g(x_i)$ 为未标记样本与标记样本距离之和相关的折扣函数, $m_{x_i}(\phi)$ 和 $m_{x_i}(\theta_n)$ 分别表示分配给空集和单元素焦元的信念质量, $d_o(x_i)$ 为未标记样本与标记样本距离之和的相关变量。

6. 根据权利要求3所述的面向认知不确定性的广义证据主动学习方法,其特征在于,所述步骤503中 T -norm算子变体根据主动学习迭代轮次进行自适应更新,以动态调整广义证据理论框架下信息的非特异性和不一致性在未标记样本不确定性综合评估中的重要性,表达式如下式所示:

$$TU_{x_i} = Div_{x_i}^{1-factor} + Eve_{x_i}^{factor} - Div_{x_i}^{1-factor} * Eve_{x_i}^{factor};$$

式中, Div_{x_i} 表示全集的信念质量; Eve_{x_i} 表示综合考虑了空集、单元素焦元和全集的信念质量; $factor = 1 - \frac{iter}{num_iter}$ 表示与主动学习迭代轮次相关的参数, $iter$ 表示当前的迭代轮次, num_iter 表示主动学习总迭代轮次。

7. 根据权利要求3所述的面向认知不确定性的广义证据主动学习方法,其特征在于,所述步骤S504中根据最大不确定性准则,对所有未标记样本进行不确定测量,并选择不确定性综合得分最高的样本进行标注,表达式如下式所示:

$$x^* = \arg \max TU(x_u^i);$$

式中, x^* 表示所选中的不确定性综合得分最高的样本, x_u^i 表示第*i*个未标记样本。

8. 根据权利要求1所述的面向认知不确定性的广义证据主动学习方法,其特征在于,所述步骤S5中查询样本X的标签具体为将样本X呈现给标注人员或数据库Oracle,由标注人员为对样本X赋予真实标签,以获取样本X的标签信息。

面向认知不确定性的广义证据主动学习方法

技术领域

[0001] 本发明属于机器学习技术领域,具体涉及面向认知不确定性的广义证据主动学习方法。

背景技术

[0002] 主动学习(Active Learning),又称作“查询学习”或“最优实验设计”,是人工智能和机器学习领域的重要研究方向之一。其基本思想是:模型在训练过程中不再被动接受预先标注的数据,而是主动从海量未标注样本中挑选出最具信息价值的样本进行标注和学习。该过程通常采用迭代方式执行,从少量标记样本出发,模型在每一轮训练中根据样本选择策略,评估未标记样本的标注价值,并确定“最值得标注”的样本,将其由人工标注后加入训练集中,进而重新更新模型参数,直至模型满足性能要求或达到标注资源上限。主动学习的核心目标是在有限标注成本下最大化模型性能,因此特别适用于标注代价高、标注资源有限等样本获取困难的场景。目前,主动学习策略已广泛应用于图像分析、语音识别和文本分类等任务,并在多个实际系统中展现出良好的性能表现。

[0003] 为了选出最具“信息价值”的样本,主动学习样本选择方法通常遵循以下三项基本准则:(1)信息性,要求所选样本包含丰富的信息,可通过熵值、置信度、决策边界距离等不确定性指标进行量化衡量;(2)代表性,衡量样本在数据分布中的代表程度,通常通过与其他样本的相似性或密度评估得到;(3)多样性,确保选择样本在输入空间中的覆盖范围,避免样本集中于某一局部区域,防止信息冗余。理想的主动学习策略应同时满足上述三项原则,从而在少量标注样本下,实现学习效果的高度提升。

[0004] 然而,现有的主动学习方法在对样本进行不确定建模时,多侧重于信息性的度量,对不确定性的类型及来源缺乏深入探究。为实现对不确定信息的精确度量和有效利用,有必要从不确定性的来源,对样本不确定性进行分析。一般而言,不确定性可划分为认知不确定性和随机不确定性两种。前者主要源于模型结构或参数的不完备认知,通常可以通过引入更多的数据或构建更优的模型加以缓解;而后者则源于数据生成过程中的固有随机性,通常被认为是无法消除的噪声因素。

[0005] 现有技术在面向不确定信息时常使用的方式包括:不确定性采样、误差减小、方差减小、损失增加最小化、模型变化最大化、自适应方法等查询策略;现有的几种样本查询策略,尽管为样本选择提供了可行的解决方案,但仍存在以下局限:首先,大多数方法只关注具有最大不确定性或多样性的样本,并未将两种不确定因素放到同一框架下进行衡量;其次,众多样本选择策略只关注未标记样本到决策边界的远近程度,忽略了未标记样本与标记样本的特征相似度。此外,即使有从基于证据的角度来构建样本查询策略,也只是重新搜索支持正类和负类样本的证据,通过证据不足和证据冲突对随机不确定性和认知不确定性进行建模。这些局限性直接导致了:样本选择往往片面,无法同时兼顾多种不确定因素,降低了主动学习的整体选样质量;忽视样本间特征相似度,容易造成所选样本信息冗余、代表性不足,增加了标注成本;对证据信息的建模粒度不足,难以在复杂多类任务中准确刻画不

确定性,从而限制了策略在高复杂度场景下的适用性。

发明内容

[0006] 本发明的目的是提供面向认知不确定性的广义证据主动学习方法,解决了现有技术中无法在同一框架下同时衡量多种不确定因素,导致样本选择过于片面的问题。

[0007] 本发明所采用的技术方案是,面向认知不确定性的广义证据主动学习方法,包括以下步骤:

S1,对标记样本进行初始化,形成标记样本集L;

S2,基于标记样本集L对标注分类模型进行训练,形成初始标注分类模型;

S3,评判初始标注分类模型是否达到预期准确率,是则输出最终模型,否则进行S4;

S4,检查标记成本是否耗尽,是则以当前模型为最终模型,否则进行S5;

S5,从未标记样本池中选取认知不确定性最高的样本X并查询其标签;

S6,将样本X及其标签加入标记样本集L并从未标记池移除;

S7,重复步骤S2~S6,直至分类模型达到预期准确率或标记成本耗尽。

[0008] 本发明的特征还在于,

步骤S1中初始化为随机初始化,从每个类别中随机抽取一个样本,组成初始已标记集合,作为模型训练的起点。

[0009] 步骤S5中从未标记样本池中选取认知不确定性最高的样本X,包括以下步骤:

S501,从认知不确定性的角度出发,对未标记样本的不确定性信息进行建模分类;

S502,在广义证据理论的框架下,基于折扣机制,针对未标记样本的代表性、信息性和多样性,生成样本对应的空集、单元素焦元和全集的信念质量;

S503,设计与主动学习迭代轮次相关的 T -norm算子变体,并在广义证据理论框架下分析信息的非特异性和不一致性,实现对未标记样本不确定性的综合评估;

S504,依据最大不确定性原则,从未标记样本池中选择不确定性综合得分最高的样本作为样本X。

[0010] 步骤S501中将不确定性划分为两类,一类为未标记样本到决策边界的远近程度,另一类为未标记样本与标记样本的特征相似性;

其中决策边界由当前监督学习模型训练得到。

[0011] 步骤S502具体包括:

利用训练模型对未标注样本进行预测,输出的类别概率作为初始信念质量;其次,计算未标记样本与标记样本距离的标准差,构造折扣因子,对初始信念质量进行调整,重新分配单元素焦元的信念质量,并将减少部分的信念质量分配给全集,以反映模型对该样本的多样性,表达式如下式所示:

$$m_{x_i}(\Theta) = 1 - \sum_{n=0}^{N-1} m'_{x_i}(\theta_n);$$

$$m'_{x_i}(\theta_n) = f(x_i) p_n(x_i);$$

$$f(x_i) = 1 - e^{-\alpha d_i(x_i)};$$

式中, $f(x_i)$ 为未标记样本与标记样本距离标准差相关的折扣函数, $p_n(x_i)$ 表示模型输出的类别概率, $m_{x_i}(\Theta)$ 表示分配给全集的信念质量, $d_l(x_i)$ 为未标记样本与标记样本标准差的相关变量;

再依据未标记样本到标记样本距离之和, 构造折扣因子, 对单元素焦元的信念质量进行再次折扣, 生成空集的信念质量, 用以刻画未标记样本的代表性; 在上述两次折扣后, 剩余的单元素焦元的信念质量用以刻画未标记样本的信息性, 定义表达式如下式所示:

$$\begin{aligned} m_{x_i}(\phi) &= \sum_{n=0}^{N-1} m'_{x_i}(\theta_n) - \sum_{n=0}^{N-1} m_{x_i}(\theta_n); \\ m_{x_i}(\theta_n) &= g(x_i) * m'_{x_i}(\theta_n); \\ g(x) &= e^{-\beta d_o(x_i)}; \end{aligned}$$

式中, $g(x_i)$ 为未标记样本与标记样本距离之和相关的折扣函数, $m_{x_i}(\phi)$ 和 $m_{x_i}(\theta_n)$ 分别表示分配给空集和单元素焦元的信念质量, $d_o(x_i)$ 为未标记样本与标记样本距离之和的相关变量。

[0012] 步骤503中 T -norm 算子变体根据主动学习迭代轮次进行自适应更新, 以动态调整广义证据理论框架下信息的非特异性和不一致性在未标记样本不确定性综合评估中的重要性, 表达式如下式所示:

$$TU_{x_i} = Div_{x_i}^{1-factor} + Eve_{x_i}^{factor} - Div_{x_i}^{1-factor} * Eve_{x_i}^{factor};$$

式中, Div_{x_i} 表示全集的信念质量; Eve_{x_i} 表示综合考虑了空集、单元素焦元和全集的信念质量; $factor = 1 - \frac{iter}{num_iter}$ 表示与主动学习迭代轮次相关的参数, $iter$ 表示当前的迭代轮次, num_iter 表示主动学习总迭代轮次。

[0013] 步骤S504中根据最大不确定性准则, 对所有未标记样本进行不确定测量, 并选择不确定性综合得分最高的样本进行标注, 表达式如下式所示:

$$x^* = \arg \max TU(x_u^i);$$

式中, x^* 表示所选中的不确定性综合得分最高的样本, x_u^i 表示第 i 个未标记样本。

[0014] 步骤S5中查询样本 X 的标签具体为将样本 X 呈现给标注人员或数据库 Oracle, 由标注人员为对样本 X 赋予真实标签, 以获取样本 X 的标签信息。

[0015] 本发明的有益效果是:

(1) 本发明通过在不确定性建模过程中, 通过计算未标记样本到已标记样本距离的标准差, 刻画其到分类超平面的远近程度; 同时, 通过计算未标记样本到已标记样本距离之和, 衡量其与已标记样本的特征相似度, 从而在兼顾信息性的同时有效减少所选样本的冗余性, 提高样本集对整体数据分布的覆盖度, 避免了传统样本选择策略仅关注单一不确定性因素所导致的样本选择偏差。

[0016] (2) 本发明在广义信念质量生成过程中, 基于广义证据理论并引入折扣机制, 利用模型输出概率结合未标记样本与已标记样本距离的标准差, 通过折扣因子重新分配信念质量以生成单元素焦元信念, 并将剩余信念分配至全集; 进一步利用未标记样本到已标记样

本距离之和对单元素焦元信念进行二次折扣,将剩余信念分配给空集,其中空集信念反映了未标记样本与标记样本的相对远近程度,而全集信念对应其到分类超平面的距离。通过该方式,实现了分别针对未标记样本的代表性、信息性与多样性生成空集、单元素焦元和全集的信念质量,充分契合主动学习样本选择遵循的三项基本准则,有效克服了单一指标在样本选择过程中可能带来的片面性问题。

[0017] (3) 本发明在未标记样本不确定性综合评估阶段,所设计的 T -norm算子变体能依据主动学习迭代轮次,自适应地调整广义证据理论框架下信息非特异性与不一致性在综合评估中的权重比例,从而实现针对不同迭代阶段的动态优化。

附图说明

[0018] 图1是本发明面向认知不确定性的广义证据主动学习方法的流程示意图;

图2是本发明中基于广义证据理论的样本选择方法;

图3a是本发明中基于SVM的Sobar-72数据集上主动学习表现的学习曲线示意图;

图3b是本发明中基于SVM的Sobar-72数据集上主动学习表现的分器准确度的分布示意图;

图4a是本发明中基于SVM的Ionosphere数据集上主动学习表现的学习曲线示意图;

图4b是本发明中基于SVM的Ionosphere数据集上主动学习表现的分器准确度的分布示意图;

图5a是本发明中基于SVM的Waveform数据集上的主动学习表现的学习曲线示意图;

图5b是本发明中基于SVM的Waveform数据集上的主动学习表现的分器准确度的分布示意图;

图6a是本发明中基于SVM的Sonar数据集的主动学习表现的学习曲线示意图;

图6b是本发明中基于SVM的Sonar数据集的主动学习表现的分器准确度的分布示意图;

图7a是本发明中基于SVM的Transfusion数据集的主动学习表现的学习曲线示意图;

图7b是本发明中基于SVM的Transfusion数据集的主动学习表现的分器准确度的分布示意图;

图8a是本发明中基于SVM的Spect数据集的主动学习表现的学习曲线示意图;

图8b是本发明中基于SVM的Spect数据集的主动学习表现的分器准确度的分布示意图;

图9a是本发明中基于SVM的Npha-doctor-visits数据集的主动学习表现的学习曲线示意图;

图9b是本发明中基于SVM的Npha-doctor-visits数据集的分器准确度的分布示意图;

图10a是本发明中基于SVM的Pop数据集的主动学习表现的学习曲线示意图;

图10b是本发明中基于SVM的Pop数据集的主动学习表现的分器准确度的分布示意图;

意图;

图11a是本发明中基于SVM的主动学习平均表现的学习曲线示意图;

图11b是本发明中基于SVM的主动学习平均表现的分器准确度的分布示意图。

具体实施方式

[0019] 下面将结合本申请实施例中的附图,对本申请实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本申请一部分实施例,而不是全部的实施例。基于本申请中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本申请保护的范围。

[0020] 本发明从认知不确定性的视角出发,构建了一种更为全面的未标记样本不确定性评估机制。该方法不仅考虑未标记样本到决策边界的远近程度,还引入未标记样本与标记样本的特征相似度。在此基础上,引入广义证据理论作为不确定性建模与融合框架,基于折扣机制构造空集、单元素焦元和全集的信念质量,分别对应于主动学习样本选择方法中的代表性、信息性和多样性这三个基本准则。同时,设计了与主动学习迭代次数相关的 T -norm算子变体,用于融合未标记样本的非特异性信息和不一致性信息,实现对未标记样本不确定性的综合评估。最后,依据最大不确定性准则,选择最具价值的未标记样本经由人工标注后加入训练集,进而能够有效提升模型性能,降低整体标注开销。

[0021] 实施例1

本发明面向认知不确定性的广义证据主动学习方法,如图1和图2所示,包括以下步骤:

S1,对标记样本进行初始化,形成标记样本集 L ;初始化为随机初始化,从每个类别中随机抽取一个样本,组成初始已标记集合,作为模型训练的起点。

[0022] S2,基于标记样本集 L 对标注分类模型进行训练,形成初始标注分类模型;

S3,评判初始标注分类模型是否达到预期准确率,是则输出最终模型,否则进行S4;

S4,检查标记成本是否耗尽,是则以当前模型为最终模型,否则进行S5;

S5,从未标记样本池中选取认知不确定性最高的样本 X 并查询其标签;

S6,将样本 X 及其标签加入标记样本集 L 并从未标记池移除;

S7,重复步骤S2~S6,直至分类模型达到预期准确率或标记成本耗尽。

[0023] 进一步地,所述步骤S5中从未标记样本池中选取认知不确定性最高的样本 X ,包括以下步骤:

S501,从认知不确定性的角度出发,对未标记样本的不确定性信息进行建模分类;

S502,在广义证据理论的框架下,基于折扣机制,针对未标记样本的代表性、信息性和多样性,生成样本对应的空集、单元素焦元和全集的信念质量;

S503,设计与主动学习迭代轮次相关的 T -norm算子变体,并在广义证据理论框架下分析信息的非特异性和不一致性,实现对未标记样本不确定性的综合评估;

S504,依据最大不确定性原则,从未标记样本池中选择不确定性综合得分最高的样本作为样本 X 。

[0024] 实施例2

本实施例在上述实施例1的基础上,本发明步骤S501中将不确定性划分为两类,一类为未标记样本到决策边界的远近程度,另一类为未标记样本与标记样本的特征相似性;其中决策边界由当前监督学习模型训练得到。

[0025] 进一步地,步骤S502具体包括:

利用训练模型对未标注样本进行预测,输出的类别概率作为初始信念质量;其次,计算未标记样本与标记样本距离的标准差,构造折扣因子,对初始信念质量进行调整;计算未标记样本与各类别标记样本的距离如下式(1)、(2)所示:

$$d_m = \|x_i - \bar{x}_n\| \quad (1);$$

$$\bar{x}_n = \frac{\sum_{n=0}^{|x_n|-1} x_n}{|x_n|} \quad (2);$$

式中, $|x_n|$ 表示当前类别n中标记样本个数; x_i 表示第i个未标记样本, $\|\cdot\|$ 表示常用的欧几里得范数 (L_2)。假设有N个类别,则会得到N个距离。

[0026] 重新分配单元元素焦元的信念质量,并将减少部分的信念质量分配给全集,以反映模型对该样本的多样性,具体通过一个单调递增的折扣函数 $f(x)$ 将标准差的值映射到 $[0,1]$ 区间内。将分类器的输出概率乘以 $f(x)$,赋值给 Θ : 当标准差较小,表明未标记样本接近决策边界, Θ 获得较大的信念质量;反之,若标准差较大,则表明未标记样本远离决策边界, Θ 获得较小的信念质量。表达式如下式(3)~(6)所示:

$$m_{x_i}(\Theta) = 1 - \sum_{n=0}^{N-1} m'_{x_i}(\theta_n) \quad (3);$$

$$m'_{x_i}(\theta_n) = f(x_i) p_n(x_i) \quad (4);$$

$$f(x_i) = 1 - e^{-\alpha d_l(x_i)} \quad (5);$$

$$d_l(x_i) = \frac{\sqrt{\frac{1}{N} \sum_{n=0}^{N-1} (d_{ln} - \frac{1}{N} \sum_{n=0}^{N-1} d_{ln})^2}}{NM^2} \quad (6);$$

式中, $f(x_i)$ 为未标记样本与标记样本距离标准差相关的折扣函数, $p_n(x_i)$ 表示模型输出的类别概率, $m_{x_i}(\Theta)$ 表示分配给全集的信念质量, $d_l(x_i)$ 为未标记样本与标记样本标准差的相关变量, N表示类别数量, M表示样本的属性数量; α 是调节参数,其值应满足 $\alpha > 0$, 通常默认设置为1。

[0027] 再依据未标记样本到标记样本距离之和,构造折扣因子,对单元元素焦元的信念质量进行再次折扣,生成空集的信念质量,用以刻画未标记样本的代表性;在上述两次折扣后,剩余的单元元素焦元的信念质量用以刻画未标记样本的信息性;具体对代表性程度进行建模,引入单调递减的折扣函数 $g(x)$ 将距离总和值映射到 $[0,1]$ 区间。将中间变量 m'_{x_i} 乘以 $g(x)$, 并且再次折扣后,赋值给 $\emptyset$: 当距离之和较大,表明未标记样本与标记样本特征相似

性弱, $\emptyset$ 获得较大的信念质量分配; 当距离之和较小, 表明未标记样本与标记样本特征相似性强, $\emptyset$ 获得较小的信念质量分配。从样本选择准则中的信息性考虑, 两次折扣剩余的信念质量, 则用来表示单元素焦元的信念质量。

[0028] 定义表达式如下式 (7)~(10) 所示:

$$m_{x_i}(\phi) = \sum_{n=0}^{N-1} m'_{x_i}(\theta_n) - \sum_{n=0}^{N-1} m_{x_i}(\theta_n) \quad (7);$$

$$m_{x_i}(\theta_n) = g(x_i) * m'_{x_i}(\theta_n) \quad (8);$$

$$g(x) = e^{-\beta d_o(x_i)} \quad (9);$$

$$d_o(x_i) = \frac{\sum_{n=0}^{N-1} x_n}{NM^2} \quad (10);$$

式中, $g(x_i)$ 为未标记样本与标记样本距离之和相关的折扣函数, $m_{x_i}(\emptyset)$ 和 $m_{x_i}(\theta_n)$ 分别表示分配给空集和单元素焦元的信念质量, $d_o(x_i)$ 为未标记样本与标记样本距离之和的相关变量, N 表示类别个数, M 表示样本的属性数量。 β 是调节参数, 其值应满足 $\beta > 0$, 通常设置为 1。

[0029] 实施例3

本实施例在实施例2的基础上, 本发明步骤503中 T -norm 算子变体根据主动学习迭代轮次进行自适应更新, 以动态调整广义证据理论框架下信息的非特异性和不一致性在未标记样本不确定性综合评估中的重要性, 未标记样本不确定性综合得分表达式如下式 (11) 所示:

$$TU_{x_i} = Div_{x_i}^{1-factor} + Eve_{x_i}^{factor} - Div_{x_i}^{1-factor} * Eve_{x_i}^{factor} \quad (11);$$

式中, Div_{x_i} 表示全集的信念质量; Eve_{x_i} 表示综合考虑了空集、单元素焦元和全集的信念质量; $factor = 1 - \frac{iter}{num_iter}$ 表示与主动学习迭代轮次相关的参数, $iter$ 表示当前的迭代轮次, num_iter 表示主动学习总迭代轮次。

[0030] 进一步地, 在广义证据理论框架下, 对包含全集、空集、单元素焦元和全集信念质量的非特异性信息与不一致性信息进行操作, 如下式 (12) 和 (13) 所示:

$$Div_{x_i} = m_{x_i}(\Theta) \quad (12);$$

$$Eve_{x_i} = \frac{\log_2 \left(\sum_{n=0}^{N-1} \left(\frac{m_{x_i}(\theta_n) + m_{x_i}(\phi) + m_{x_i}(\Theta)}{\sum_{n=0}^{N-1} N m_{x_i}(\theta_n) + N * (m_{x_i}(\phi) + m_{x_i}(\Theta))} \right)^q \right)}{(1-q) * \log_2 N} \quad (13)。$$

[0031] 实施例4

本实施例在实施例3的基础上, 本发明步骤S504中根据最大不确定性准则, 对所有未标记样本进行不确定测量, 并选择不确定性综合得分最高的样本进行标注, 表达式如下式 (14) 所示:

$$x^* = \arg \max TU(x_u^i) \quad (14);$$

式中, x^* 表示所选中的不确定性综合得分最高的样本, x_u^i 表示第 i 个未标记样本。

[0032] 实施例5

本实施例在实施例4的基础上, 本发明步骤S5中查询样本X的标签具体为将样本X呈现给标注人员或数据库Oracle, 由标注人员为对样本X赋予真实标签, 以获取样本X的标签信息。

[0033] 实施例6

本实施例面向认知不确定性的广义证据主动学习方法的流程如下:

设有一未标记样本池 U 和一小规模标记样本集 L , 首先训练一个初始分类模型(例如支持向量机), 并获取每个未标记样本的输出概率分布 $p_n(x_i)$, 将该概率作为单元素焦元的初始信念质量。

[0034] 然后, 计算未标记样本与当前标记样本集的平均距离及其标准差, 构建第一个折扣因子, 将信念质量部分折扣给全集, 以表达未标记样本的多样性信息。进一步计算未标记样本与标记样本集的距离之和, 构建第二个折扣因子, 将信念质量再次折扣分配给空集, 用于描述未标记样本的代表性。通过两次折扣剩余的单元素焦元的信念质量用来描述未标记样本的信息性。

[0035] 紧接着, 构造基于迭代次数的 T -norm 算子的变体, 用于操作广义证据理论下未标记样本的不一致性信息与非特异性信息, 形成综合不确定性评价指标 TU 。

[0036] 最终, 选择 TU 值最大的未标记样本进行人工标注并加入标记集, 更新分类器, 进入下一轮迭代。直到模型精度达到要求或者标注成本被耗光。

[0037] 进一步地, 本发明在不同数据集上的实验设置如下:

为评估不同框架下样本选择策略的效果, 本发明所提出的方法从UCI机器学习库 (<http://archive.ics.uci.edu>) 选取了19个公开数据集作为实验对象。其中包含15个二分类任务的数据集(如Sonar、Sobar-72和Spect), 还有4个多分类数据集(如Npha-doctor-visits、Seeds、Ecoli和Waveform)。需要指出的是, 所选用的数据集中近一半属于不平衡数据集(如Pop、Fertility和Transfusion)。

[0038] 表1 19个公开数据集详细信息

名称	类别数	样本数	类别比例	特征数
Sonar	2	208	97/111	60
Sobar-72	2	72	51/21	19
Spect	2	80	40/40	22
Ionosphere	2	351	224/127	32
Pop	2	540	46/494	18
Npha-doctor-visits	3	714	211/131/372	14
Bannote	2	1372	761/611	4
Letter_E_F	2	1543	769/774	16
Letter_D_P	2	1608	805/803	16
Seeds	3	210	70/70/70	7
Fertility	2	100	Dec-88	9
Breast_cancer_data	2	569	212/357	30
Transfusion	2	748	570/178	4
Mesothelioma data set	2	324	228/96	34
Algerian_forest_fires_dataset	2	243	137/106	13
Ecoli	8	336	143/77/2/35/5/20/52/2	7
Cryotherapy	2	90	42/48	6
Letter_I_J	2	1502	755/747	16
Waveform	3	4782	1591/1571/1620	21

[0039] 在实验初始化阶段,为确保训练过程的公平性,首先对每个数据集进行随机打乱,然后从每一类别中各随机抽取一个样本构成初始标记集,作为模型训练的起点。同时,为保证实验结果的稳定性和可信度,每个数据集均独立进行了100次蒙特卡罗模拟实验,并将结果取平均后作为最终的性能评价依据。在每一轮主动学习的迭代中,模型会根据不同框架下的样本选择策略,从未标记样本池中挑选出最具信息价值的一个样本,标注后再加入训练集用于模型更新。主动学习共迭代30轮。

[0040] 在训练过程中,所有未被选中的样本均作为测试集,用于评估每轮模型更新后的泛化能力。为更直观地展示模型性能随着训练样本增加的变化趋势,绘制了学习曲线,并采用学习曲线下的面积(Area Under the Learning Curve, ALC)作为衡量模型学习效率的评价指标。此外,为验证结果的统计显著性,在95%的置信水平下实施了单因素方差分析(ANOVA),以科学地检验不同方法间是否存在显著差异,保证结论的可靠性和推广性。

[0041] 进一步地,本发明在不同数据集上的实验结果和分析如下:

从ALC值和ANOVA分析的角度,对基于SVM的八种样本选择策略在性能上的差异进行了系统比较。图3a、图3b、图4a、图4b、图5a、图5b、图6a、图6b、图7a、图7b、图8a、图8b、图9a、图9b、图10a、图10b展示了各样本选择策略在部分数据集上的分类准确率和100次蒙特卡罗实验中最终准确率的分布情况。图11a和图11b总结了所有19个数据集的平均分类效果。

[0042] 表2 八种基于SVM的主动学习策略在19个数据集上的性能比较

数据集	MaxEntropy	Random	VR	MaxAM	Diversity	USGET	CEU	IEU	P 值
Cryotherapy	22.7726	22.729	22.9141	23.1896	19.8471	23.5502	22.4624	21.022	<0.001
Ecoli	21.3642	22.1556	21.0255	21.3577	20.2292	21.9379	--	--	<0.001
Algerian_forest_fires	25.776	24.8314	25.9773	25.0126	24.352	25.8281	23.3096	23.5035	<0.001
Mesothelioma	23.9907	23.5117	23.1646	23.6798	22.3096	24.2939	24.4904	23.3283	0.5258
Transfusion	20.238	20.5791	17.407	19.8986	18.8701	20.7468	19.122	18.7272	<0.001
Breast_cancer_data	26.2299	25.8681	24.5417	25.1868	24.1643	26.3131	23.9857	25.1418	<0.001
Fertility	21.4468	21.4163	20.4724	20.3451	20.8366	22.3547	16.6709	20.7524	<0.001
Seeds	25.7418	25.2484	25.0488	25.6922	23.6763	26.0842	--	--	<0.001
Letter_D_P	25.9927	25.9802	24.3771	26.478	19.7763	26.4759	23.6297	24.7107	<0.001
Sobar-72	24.2048	23.5713	21.5276	24.8038	20.1589	25.1612	20.485	22.4668	<0.001
Spect	18.3369	18.5953	17.4225	17.8994	16.5551	19.6609	16.9702	18.6277	<0.001
Ionosphere	20.7319	21.6931	19.8857	18.3327	17.7343	22.0699	16.5755	19.0069	<0.001
Pop	23.9612	24.5005	22.4024	23.9113	23.73	25.3815	22.422	23.0475	<0.001
Sonar	19.0563	19.0272	19.1164	18.1569	16.8385	19.2592	17.8684	17.4725	<0.001
Npha-doctor-visits	10.3045	11.0566	9.6499	10.7455	10.9086	11.394	--	--	<0.001
Bannote	26.566	26.3165	21.5153	22.1945	17.8783	26.7577	21.4099	23.7286	<0.001
Letter_E_F	25.7728	25.2648	23.6728	25.9738	20.6125	26.0818	22.9812	23.2545	<0.001
Letter_I_J	23.4122	23.5019	19.8687	23.8401	18.4961	24.0365	18.6746	20.2859	<0.001
Waveform	20.0622	20.0253	19.158	21.2374	18.0683	21.6963	--	--	<0.001
胜出次数 (win)	0	1	1	1	0	15	1	0	--
平均排名 (rank)	3.06	3.28	5.33	3.78	6.78	1.22	6.6	5.47	--

[0043] 从表2可以看出,与其他七种方法相比,本发明所提出的面向认知不确定性的广义证据主动学习方法 (USGET) 在15个数据集中具有更好的ALC性能。对于Algerian_forest_fires_dataset数据集,USGET的性能略低于VR,对于Mesothelioma data set数据集,USGET的性能则略低于CEU。因此,USJET的排名为1.22。对于MaxEntropy,它关注未标记样本到超平面的距离,这使得它在某些数据集上表现良好,如Bannote和Breast_cancer_data集,因此其排名为3.06。对于Random,其在每个数据集上的性能接近USGET,排名为3.28。在证据理论的框架下,MaxAM可以被视为MaxEntropy的变体,因此与MaxEntrophy相比,它在某些数据集上也取得了更好的性能,例如:Transfusion、Letter_D_P (MaxAM在Letter_D_P数据集上面表现是最好的)。对于VR,它在Algerian_forest_fires_dataset数据集上的性能最好,但在大多数数据集上的性能低于MaxEntropy、MaxAM和USGET,排名5.33。对于CEU来说,它在Mesothelioma data set上的性能最好,为24.4904。然而,它在其他数据集上的性能低于MaxEntropy、VR、MaxAM和USGET,排名为6.60。与CEU相比,IEU在任何数据集上都没有达到最佳性能,但它在大多数数据集上的性能优于CEU,因此它的排名高于CEU,为5.57。应该指出的是,USGET对于不平衡的数据集 (如Sobar-72、Pop和Fertility) 具有最佳性能。这表明本发明所提出的面向认知不确定性的广义证据主动学习方法具有优势。

[0044] 此外,从图3a、图3b、图4a、图4b、图5a、图5b、图6a、图6b、图7a、图7b、图8a、图8b、图9a、图9b、图10a、图10b可以看出,对于大多数数据集、大多数样本选择策略来说,分类精度和迭代次数呈正相关。从图11a和图11b可以看出,USGET的优势在迭代开始时并不明显。随着迭代次数的增加,其分类性能的变化率高于其他方法。

[0045] 本说明书中各个实施例采用递进的方式描述,每个实施例重点说明的都是与其他实施例的不同之处,各个实施例之间相同相似部分互相参见即可。

[0046] 对所公开的实施例的上述说明,使本领域专业技术人员能够实现或使用本申请。对这些实施例的多种修改对本领域的专业技术人员来说将是显而易见的,本文中所定义的一般原理可以在不脱离本申请的精神或范围的情况下,在其它实施例中实现。因此,本申请

将不会被限制于本文所示的这些实施例,而是要符合与本文所公开的原理和新颖特点相一致的最宽的范围。




图1




图2




图3a




图3b




图4a




图4b




图5a




图5b




图6a




图6b




图7a




图7b




图8a




图8b




图9a




图9b




图10a




图10b




图11a




图11b