



(12) 发明专利申请

(10) 申请公布号 CN 120180095 A

(43) 申请公布日 2025. 06. 20

(21) 申请号 202510310787.X

G06F 123/02 (2023.01)

(22) 申请日 2025.03.17

(71) 申请人 西北农林科技大学

地址 712100 陕西省咸阳市杨陵区邠城路3号

(72) 发明人 吴凤娇 熊星 蒲树仁 张婷婷
王斌 陈帝伊 李永冲

(74) 专利代理机构 北京博尔赫知识产权代理事务
所(普通合伙) 16045

专利代理师 孙盟盟

(51) Int.Cl.

G06F 18/213 (2023.01)

G06N 3/006 (2023.01)

G06F 18/24 (2023.01)

G01M 13/00 (2019.01)

权利要求书2页 说明书7页 附图10页

(54) 发明名称

一种旋转机械故障特征提取方法及系统

(57) 摘要

本发明公开了一种旋转机械故障特征提取方法及系统,涉及机械设备故障诊断技术领域,包括获取原始时序信号,确定所述原始时序信号的分割子序列个数,而后将原始时序信号根据预设规则转化为不同子序列个数下的粗粒序列;对每个子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各所述玻尔兹曼-香农交互熵的熵值进行平均值计算,将所述平均值作为最终熵值。本发明通过对每一个尺度因子所对应的序列进一步的细化,由只生成一个粗粒序列改进为生成多个粗粒序列,再计算多个序列的MBSIE均值作为最终的熵值,使获得的故障信息更加细致。

获取原始时序信号,确定所述原始时序信号的分割子序列个数,而后将所述原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列;

对每个分割子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各所述玻尔兹曼-香农交互熵的熵值进行平均值计算,将所述平均值作为最终熵值。

1. 一种旋转机械故障特征提取方法,其特征在于,包括:

获取原始时序信号,确定所述原始时序信号的分割子序列个数,而后将所述原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列;

对每个分割子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各所述玻尔兹曼-香农交互熵的熵值进行平均值计算,将所述平均值作为最终熵值。

2. 根据权利要求1所述的一种旋转机械故障特征提取方法,其特征在于,所述将所述原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列具体包括:对于所述原始时序信号所给定的有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$, X 为一个长度为 N 的时序信号,长度大小是从1到 N ,属于 $[a, b]$, $[a, b]$ 表示有界区域,定义粗粒化序列 $\phi_{j,k}^{(\tau)} = \{\phi_{j,1}^{(\tau)}, \phi_{j,2}^{(\tau)}, \dots, \phi_{j,l}^{(\tau)}\}$, 计算方式如下:

$$\phi_{j,k}^{\tau} = \frac{1}{\tau} \sum_{i=(j-1)\tau+k}^{j\tau+k-1} x_i, j=1, 2, \dots, N/\tau;$$

其中, $1 \leq j \leq N/\tau$, $1 \leq k \leq \tau$; τ 表示分割子序列的个数,粗粒化处理将原始时序信号变为不同尺度 τ 下长度为 N/τ 的粗粒序列, k 为熵值个数。

3. 根据权利要求2所述的一种旋转机械故障特征提取方法,其特征在于,所述进行平均值计算具体包括:

$$IMBSIE(X, k, \tau) = \frac{1}{\tau} \sum_{k=1}^{\tau} BSIE(\phi_{j,k}^{(\tau)});$$

其中, $IMBSIE$ 表示有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$ 的平均熵值,

$BSIE(\phi_{j,k}^{(\tau)}) = 1 - \frac{D_{KL}(p \parallel m) + D_{KL}(q \parallel m)}{2}$; a, b 分别表示区域的上下界; p 为直方图概率分布, q 为基于几何分位数的概率分布, $m = (p+q)/2$; $D_{KL}(p \parallel m)$ 和 $D_{KL}(q \parallel m)$ 分别表示两个分布在 p 和 q 之间的标准非对称KL散度。

4. 一种旋转机械故障特征提取系统,应用权利要求1-3任一所述的一种旋转机械故障特征提取方法,其特征在于,包括:

信号转化模块,获取原始时序信号,确定所述原始时序信号的分割子序列个数,而后将所述原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列;

信号计算识别模块,对每个分割子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各所述玻尔兹曼-香农交互熵的熵值进行平均值计算,将所述平均值作为最终熵值。

5. 根据权利要求4所述的一种旋转机械故障特征提取系统,其特征在于,所述信号转化模块具体包括:对于所述原始时序信号所给定的有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$, X 为一个长度为 N 的时序信号,长度大小是从1到 N ,属于 $[a, b]$ 表示有界区域,定义粗粒化序列 $\phi_{j,k}^{(\tau)} = \{\phi_{j,1}^{(\tau)}, \phi_{j,2}^{(\tau)}, \dots, \phi_{j,l}^{(\tau)}\}$, 计算方式如下:

$$\phi_{j,k}^{\tau} = \frac{1}{\tau} \sum_{i=(j-1)\tau+k}^{j\tau+k-1} x_i, j=1, 2, \dots, N/\tau;$$

其中, $1 \leq j \leq N/\tau, 1 \leq k \leq \tau$; τ 表示分割子序列的个数, 粗粒化处理将原始时序信号变为不同尺度 τ 下长度为 N/τ 的粗粒序列, k 为熵值个数。

6. 根据权利要求5所述的一种旋转机械故障特征提取系统, 其特征在于, 所述信号计算识别模块中进行平均值计算具体包括:

$$IMBSIE(X, k, \tau) = \frac{1}{\tau} \sum_{k=1}^{\tau} BSIE(\phi_{j,k}^{(\tau)});$$

其中, $IMBSIE$ 表示有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$ 的平均熵值,

$BSIE(\phi_{j,k}^{(\tau)}) = 1 - \frac{D_{KL}(p \| m) + D_{KL}(q \| m)}{2}$; a, b 分别表示区域的上下界; p 为直方图概率分布, q 为

基于几何分位数的概率分布, $m = (p+q)/2$; $D_{KL}(p \| m)$ 和 $D_{KL}(q \| m)$ 分别表示两个分布在 p 和 q 之间的标准非对称KL散度。

一种旋转机械故障特征提取方法及系统

技术领域

[0001] 本发明涉及机械设备故障诊断技术领域,更具体的说是涉及一种旋转机械故障特征提取方法及系统。

背景技术

[0002] 随着现代工业和科学技术的发展以及自动化程度的进一步提高,机械正朝着大型化、高速化、连续化、集中化、自动化方向发展。旋转机械设备长期处于高速运行状态(一般为每分钟3000转以上甚至高达几万转),由于各种因素的影响,难免会出现一些故障,而且这些故障往往会引起巨大的经济损失甚至灾难性后果,因此对旋转机械设备故障诊断十分重要。

[0003] 振动检测诊断法是当今旋转机械设备故障诊断技术的最常用的诊断方法。振动信号包含了丰富的机械运行状态信息,因而振动检测诊断法可以对机械设备中的大部分故障类型进行准确的诊断。目前在工程应用中采用的振动分析方法主要有时域分析法和频域分析法。时域分析法主要是在信号的时域提取故障的时域特征然后根据时域特征的变化对机械设备进行故障诊断的技术。频域分析法是通过傅里叶变换把振动信号变换到频域进行分析,提取信号频域特征然后根据频域特征的变化对机械设备进行故障诊断的技术。时域分析法简单、快捷,但只能判断机械设备是否有故障以及故障的严重程度,而不能判断故障部位和故障类型。频域分析法不但能判定是否有故障而且能够判定故障部位和类型,所以精细诊断多采用频域分析法。目前影响频域分析法诊断效果的因素主要有两个:一个是由于旋转机械设备转速的非匀速(如列车加速、减速、停车,风力发电机转速随着风速的变化而变化等)导致的振动信号的非平稳性,若对这些非平稳信号直接进行傅里叶分析将产生严重的频率模糊现象,从而影响故障的判断;另一个是由于旋转机械设备运动过程中受环境振动噪声、设备其他部件振动产生的噪声的影响,采集的振动信号除故障本身引起的振动信号外往往包含非故障引起的振动噪声,而这些噪声淹没了故障特征信号尤其是故障早期的特征信号使得故障不能够及时发现和误报警,延误了最佳维修时间甚至造成巨大的经济损失甚至灾难性后果。为了解决第一和第二个问题,现有技术(“基于角域平均的齿轮裂纹故障诊断”,中北大学学报(自然科学版),2007年第28卷第1期)采用了以角位移(旋转角度)为自变量的周期平稳信号,先通过阶次跟踪技术重构角域信号,然后再在角域对信号进行分段,对分段信号进行求平均,从而实现对噪声进行压制的方法。该方法能够压制随机噪声的影响,提高信噪比,突出故障特征。然而,由于该方法采用的是把数据分段然后对不同段数据相加求平均的方法压制噪声,因此破坏了数据的连续性,无法实现状态的连续监测;此外,由于把长数据分成短数据,该方法也降低了后续傅里叶变换频域分辨率。

[0004] 因此,如何准确提取旋转机械设备故障特征是本领域技术人员亟需解决的问题。

发明内容

[0005] 有鉴于此,本发明提供了一种旋转机械故障特征提取方法及系统,通过对每一个

尺度因子所对应的序列进一步的细化,由只生成一个粗粒序列改进为生成多个粗粒序列,再计算多个序列的MBSIE均值作为最终的熵值,使获得的故障信息更加细致。

[0006] 为了实现上述目的,本发明采用如下技术方案:

[0007] 一种旋转机械故障特征提取方法,包括:

[0008] 获取原始时序信号,确定所述原始时序信号的分割子序列个数,而后将所述原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列;

[0009] 对每个分割子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各所述玻尔兹曼-香农交互熵的熵值进行平均值计算,将所述平均值作为最终熵值。

[0010] 优选的,所述将所述原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列具体包括:对于所述原始时序信号所给定的有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$, X 为一个长度为 N 的时序信号,长度大小是从1到 N ,属于 $[a, b]$, $[a, b]$ 表示有界区域,定义粗粒化序列 $\phi_{j,k}^{(\tau)} = \{\phi_{j,1}^{(\tau)}, \phi_{j,2}^{(\tau)}, \dots, \phi_{j,l}^{(\tau)}\}$, 计算方式如下:

$$[0011] \quad \phi_{j,k}^{\tau} = \frac{1}{\tau} \sum_{i=(j-1)\tau+k}^{j\tau+k-1} x_i, j=1, 2, \dots, N/\tau;$$

[0012] 其中, $1 \leq j \leq N/\tau$, $1 \leq k \leq \tau$; τ 表示分割子序列的个数,粗粒化处理将原始时序信号变为不同尺度 τ 下长度为 N/τ 的粗粒序列, k 为熵值个数。

[0013] 优选的,所述进行平均值计算具体包括:

$$[0014] \quad IMBSIE(X, k, \tau) = \frac{1}{\tau} \sum_{k=1}^{\tau} BSIE(\phi_{j,k}^{(\tau)});$$

[0015] 其中, $IMBSIE$ 表示有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$ 的平均熵值,

$$BSIE(\phi_{j,k}^{(\tau)}) = 1 - \frac{D_{KL}(p||m) + D_{KL}(q||m)}{2}; a, b \text{ 分别表示区域的上下界}; p \text{ 为直方图概率分布}, q \text{ 为}$$

基于几何分位数的概率分布, $m = (p+q)/2$; $D_{KL}(p||m)$ 和 $D_{KL}(q||m)$ 分别表示两个分布在 p 和 q 之间的标准非对称KL散度。

[0016] 一种旋转机械故障特征提取系统,包括:

[0017] 信号转化模块,获取原始时序信号,确定所述原始时序信号的分割子序列个数,而后将所述原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列;

[0018] 信号计算识别模块,对每个分割子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各所述玻尔兹曼-香农交互熵的熵值进行平均值计算,将所述平均值作为最终熵值。

[0019] 优选的,所述信号转化模块具体包括:对于所述原始时序信号所给定的有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$, X 为一个长度为 N 的时序信号,长度大小是从1到 N ,属于 $[a, b]$ 表示有界区域,定义粗粒化序列 $\phi_{j,k}^{(\tau)} = \{\phi_{j,1}^{(\tau)}, \phi_{j,2}^{(\tau)}, \dots, \phi_{j,l}^{(\tau)}\}$, 计算方式如下:

$$[0020] \quad \phi_{j,k}^{\tau} = \frac{1}{\tau} \sum_{i=(j-1)\tau+k}^{j\tau+k-1} x_i, j=1, 2, \dots, N/\tau;$$

[0021] 其中, $1 \leq j \leq N/\tau$, $1 \leq k \leq \tau$; τ 表示分割子序列的个数, 粗粒化处理将原始时序信号变为不同尺度 τ 下长度为 N/τ 的粗粒序列, k 为熵值个数。

[0022] 优选的, 所述信号计算识别模块中进行平均值计算具体包括:

$$[0023] \quad IMBSIE(X, k, \tau) = \frac{1}{\tau} \sum_{k=1}^{\tau} BSIE(\phi_{j,k}^{(\tau)});$$

[0024] 其中, $IMBSIE$ 表示有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$ 的平均熵值,

$$BSIE(\phi_{j,k}^{(\tau)}) = 1 - \frac{D_{KL}(p \| m) + D_{KL}(q \| m)}{2};$$

a, b 分别表示区域的上下界; p 为直方图概率分布, q 为

基于几何分位数的概率分布, $m = (p+q)/2$; $D_{KL}(p \| m)$ 和 $D_{KL}(q \| m)$ 分别表示两个分布在 p 和 q 之间的标准非对称 KL 散度。

[0025] 经由上述的技术方案可知, 与现有技术相比, 本发明公开提供了一种旋转机械故障特征提取方法及系统, 通过对每一个尺度因子所对应的序列进一步的细化, 由只生成一个粗粒序列改进为生成多个粗粒序列, 再计算多个序列的 $MBSIE$ 均值作为最终的熵值, 使获得的故障信息更加细致。

附图说明

[0026] 为了更清楚地说明本发明实施例或现有技术中的技术方案, 下面将对实施例或现有技术描述中所需要使用的附图作简单地介绍, 显而易见地, 下面描述中的附图仅仅是本发明的实施例, 对于本领域普通技术人员来讲, 在不付出创造性劳动的前提下, 还可以根据提供的附图获得其他的附图。

[0027] 图1为本发明提供的方法步骤示意图;

[0028] 图2为本发明提供的改进多尺度熵粗粒化示意图;

[0029] 图3(a) 为本发明提供的 $RN-MBSIE$ 分布图;

[0030] 图3(b) 为本发明提供的 $RN-IMBSIE$ 分布图;

[0031] 图3(c) 为本发明提供的 $VN-MBSIE$ 分布图;

[0032] 图3(d) 为本发明提供的 $VN-IMBSIE$ 分布图;

[0033] 图4为本发明提供的不同信噪比噪声信号图;

[0034] 图5(a) 为本发明提供的 $IMBSIE$ 抗噪性图;

[0035] 图5(b) 为本发明提供的 $MBSIE$ 抗噪性图;

[0036] 图6(a) 为本发明提供的 $IMBSIE$ 误差棒图;

[0037] 图6(b) 为本发明提供的 $IMBSIE$ 均值图;

[0038] 图6(c) 为本发明提供的 $MBSIE$ 误差棒图;

[0039] 图6(d) 为本发明提供的 $MBSIE$ 均值图;

[0040] 图7(a) 为本发明提供的正常状态振动信号图;

[0041] 图7(b) 为本发明提供的碰磨状态振动信号图;

[0042] 图7(c) 为本发明提供的不平衡状态振动信号图;

[0043] 图7(d) 为本发明提供的不对中状态振动信号图;

[0044] 图8(a) 为本发明提供的 $IMBSIE$ 分离效果比较图;

- [0045] 图8(b)为本发明提供的MBSIE分离效果比较图；
 [0046] 图8(c)为本发明提供的IMAE分离效果比较图；
 [0047] 图8(d)为本发明提供的MAE分离效果比较图。

具体实施方式

[0048] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施例,都属于本发明保护的范围。

[0049] 本发明实施例公开了一种旋转机械故障特征提取方法,如图1所示,包括:

[0050] 获取原始时序信号,确定原始时序信号的分割子序列个数,而后将原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列;

[0051] 对每个分割子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各玻尔兹曼-香农交互熵的熵值进行平均值计算,将平均值作为最终熵值。

[0052] 在一个具体实施例中,将原始时序信号根据预设规则转化为不同尺度下的粗粒序列具体包括:对于所述原始时序信号所给定的有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$, X 为一个长度为 N 的时序信号,长度大小是从1到 N ,属于 $[a, b]$, $[a, b]$ 表示有界区域,定义粗粒化序列 $\phi_{j,k}^{(\tau)} = \{\phi_{j,1}^{(\tau)}, \phi_{j,2}^{(\tau)}, \dots, \phi_{j,l}^{(\tau)}\}$, 计算方式如下:

$$[0053] \quad \phi_{j,k}^{\tau} = \frac{1}{\tau} \sum_{i=(j-1)\tau+k}^{j\tau+k-1} x_i, j=1, 2, \dots, N/\tau;$$

[0054] 其中, $1 \leq j \leq N/\tau, 1 \leq k \leq \tau$; τ 表示分割子序列的个数,粗粒化处理将原始时序信号变为不同尺度 τ 下长度为 N/τ 的粗粒序列, k 为熵值个数。

[0055] 在一个具体实施例中,计算每个粗粒序列的BSIE,再对 k 个熵值求平均即得到该尺度因子下的IMBSIE,计算方式如下:

$$[0056] \quad IMBSIE(X, k, \tau) = \frac{1}{\tau} \sum_{k=1}^{\tau} BSIE(\phi_{j,k}^{(\tau)});$$

[0057] 其中, IMBSIE表示有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$ 的平均熵值,

$BSIE(\phi_{j,k}^{(\tau)}) = 1 - \frac{D_{KL}(p||m) + D_{KL}(q||m)}{2}$; a, b 分别表示区域的上下界; p 为直方图概率分布, q 为基于几何分位数的概率分布, $m = (p+q)/2$; $D_{KL}(p||m)$ 和 $D_{KL}(q||m)$ 分别表示两个分布在 p 和 q 之间的标准非对称KL散度。为便于理解,如图2给出尺度 $\tau=3$ 时的改进多尺度熵粗粒化示意图。

[0058] 一种旋转机械故障特征提取系统,包括:

[0059] 信号转化模块,获取原始时序信号,确定原始时序信号的分割子序列个数,而后将原始时序信号根据预设规则转化为不同分割子序列个数下的粗粒序列;

[0060] 信号计算识别模块,对每个分割子序列个数下的粗粒序列,计算对应的玻尔兹曼-香农交互熵,将各玻尔兹曼-香农交互熵的熵值进行平均值计算,将平均值作为最终熵值。

[0061] 在一个具体实施例中,信号转化模块具体包括:对于所述原始时序信号所给定的有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$, X 为一个长度为 N 的时序信号,长度大小是从1到 N ,属于 $[a, b]$ 表示有界区域,定义粗粒化序列 $\phi_{j,k}^{(\tau)} = \{\phi_{j,1}^{(\tau)}, \phi_{j,2}^{(\tau)}, \dots, \phi_{j,l}^{(\tau)}\}$, 计算方式如下:

$$[0062] \quad \phi_{j,k}^{(\tau)} = \frac{1}{\tau} \sum_{i=(j-1)\tau+k}^{j\tau+k-1} x_i, j=1, 2, \dots, N/\tau;$$

[0063] 其中, $1 \leq j \leq N/\tau, 1 \leq k \leq \tau$; τ 表示分割子序列的个数,粗粒化处理将原始时序信号变为不同尺度 τ 下长度为 N/τ 的粗粒序列, k 为熵值个数。

[0064] 在一个具体实施例中,信号计算识别模块中进行平均值计算具体包括:

$$[0065] \quad IMBSIE(X, k, \tau) = \frac{1}{\tau} \sum_{k=1}^{\tau} BSIE(\phi_{j,k}^{(\tau)});$$

[0066] 其中, $IMBSIE$ 表示有界区域的时序信号 $X = \{x_i\}_{i=1}^{i=N} \subset [a, b]$ 的平均熵值,

$BSIE(\phi_{j,k}^{(\tau)}) = 1 - \frac{D_{KL}(p \| m) + D_{KL}(q \| m)}{2}$; a, b 分别表示区域的上下界; p 为直方图概率分布, q 为基于几何分位数的概率分布, $m = (p+q)/2$; $D_{KL}(p \| m)$ 和 $D_{KL}(q \| m)$ 分别表示两个分布在 p 和 q 之间的标准非对称KL散度。

[0067] 为验证所提算法的性能,本发明采用不同的噪声类别分别验证 $IMBSIE$ 的时序长度稳定性、抗噪性和信号识别能力。为验证 $IMBSIE$ 的有效性和合理性并防止随机性的影响,分别分析 $\frac{1}{f^2}$ 噪声 Red Noise (RN) 和 f^2 噪声 Violet Noise (VN) 的不同时序长度 ($N=1000, N=2000, N=3000, N=4000$ 及 $N=5000$) 下 $IMBSIE$ 和 $MBSIE$ 多尺度熵的分布情况,如图3(a) - 图3(d)。

[0068] 显然,两种噪声下随着尺度因子的增大, $IMBSIE$ 、 $MBSIE$ 分布差异较大,尤其 $MBSIE$ 呈现较为强烈的波动,而 $IMBSIE$ 整体上更稳定。具体地,以长度 $N=2000$ 的信号为例,在 $\frac{1}{f^2}$ 噪声 RN 下 $IMBSIE$ 和 $MBSIE$ 的最大值和最小值分别为 0.573、0.489 和 0.609、0.515, 分别相差 0.084、0.094, 可见在 RN 下 $IMBSIE$ 的稳定性优于 $MBSIE$ 。在 f^2 噪声 VN 下, $IMBSIE$ 和 $MBSIE$ 的最大值和最小值分别为 0.471、0.322 和 0.505、0.324, 分别相差 0.149、0.181, 可见在 VN 下 $IMBSIE$ 的稳定性优于 $MBSIE$ 。综上, $IMBSIE$ 稳定性高于 $MBSIE$ 。

[0069] 为验证 $IMBSIE$ 抗噪性,本发明分析 $IMBSIE$ 和 $MBSIE$ 对于 RN 和高斯白噪音 (White Gaussian Noise, WGN) 的熵值稳定性。为避免随机性的影响,取时序长度为 2000 的 RN 和 WGN 各 30 组,分别计算其不同尺度因子下的熵值并取其均值, $IMFAE$ 、 $IMAE$ 和 MAE 三种多尺度熵的分布情况,如图4。可见, $IMFAE$ 更加稳定且均值较小,性能依然优于 $IMAE$ 和 MAE 。具体地, $IMFAE$ 、 $IMAE$ 、 MAE 的 RN 和 WGN 最大值分别为 0.125 和 0.033、0.155 和 0.031、0.178 和 0.063, 差值分别为 0.092、0.124、0.115, 可见, $IMFAE$ 对于不同类型的噪音依然具有稳定性,抗噪性能较好。

[0070] 旋转机械故障信号的特征提取易受噪声干扰,这要求作为特征提取工具的 $IMBSIE$ 拥有良好的抗噪性。本小节分析 $IMBSIE$ 和 $MBSIE$ 对于对仿真信号及其加入不同大小信噪比

噪声信号的分布情况,评估和分析其抗噪性,由下式仿旋转机械真低频涡流的含噪信号,信号图如图4。

$$\Phi(t) = 0.39 \sin \pi t + 0.21 \sin 4.2 \pi t + 0.1 \sin 33.4 \pi t + 0.11 \sin 58.4 \pi t + 0.13 \sin 100 \pi t + 0.06 \sin 200 \pi t + \phi(t);$$

[0072] 式中, $\Phi(t)$ 表示含有噪声的旋转机械振动信号; $\phi(t)$ 为不同信噪比干扰信号,本节分别取10、20、30和40dB。

[0073] 不同噪声情况下IMBSIE和MBSIE熵值分布情况见图5(a)-图5(b)。可以看到,IMBSIE的曲线在几种不同大小信噪比情况下均较为平滑且波动很小;MBSIE曲线整体波动剧烈,各种信噪比下均有明显波动,受噪声的影响较大。显然,IMBSIE抗噪性明显优于MBSIE。

[0074] 作为特征提取方法,IMBSIE需要具备良好的对信号特征的识别能力,为对比IMBSIE和MBSIE的识别性能,本发明引入RN和高斯白噪声信号(WGN)对两种特征提取方法进行测试。具体实验结果如图6(a)-图6(d),可见两种熵对RN和WGN特征提取的均值均未发生交叉,证明两种方法均能识别噪声信号。进一步,MBSIE许多尺度下两造噪声信号的误差棒均发生交叉,而IMBSIE任意尺度下的误差棒均为交叉,证明CMAE的识别性能更好,具体标准差和均值如表1。可见,IMBSIE在两种噪声下均值和标准差均小于MBSIE,进一步验证了IMBSIE的稳定性更好。

[0075] 表1不同信号不同类型熵均值和标准差

熵类型	噪声	均值		标准差	
		最大值	最小值	最大值	最小值
IMBSIE	RN	0.55237	0.50313	0.045890	0.034947
	WGN	0.46909	0.32035	0.035558	0.014761
MBSIE	RN	0.55611	0.49562	0.066577	0.043355
	WGN	0.48524	0.31541	0.071860	0.026803

[0077] 本发明通过转子试验台模拟机组正常状态和碰磨、不平衡、不对中三种机组常见故障。其中,机组转速设定是1200r/min,采样频率为2048HZ,对机组四种状态各采集了100组数据,每组数据包含2048个振动信号,如图7(a)-图7(d)所示。

[0078] 为了明确本发明所提方法特征提取的优越性,引入多尺度近似熵(MAE)和改进多尺度近似熵(IMAE)方法与本发明方法进行对比,并借助于TSNE对提取的特征进行可视化分析,具体可视化结果如图8(a)-图8(d)。可以看出,IMBSIE有效提取了不同机组状态的信号特征,使相同状态对应的散点紧密聚集在一起且4种状态互相之间分离效果良好,不同状态的特征无混叠;MBSIE可视化结果能大致分开四种状态且特征点较为紧密但个别故障状态存在堆叠;IMAE虽然不存在混叠现象但是碰磨状态的特征分布较为零散;MAE的碰磨和不平衡两种状态没有分开,存在混叠现象。综上,IMBSIE具有较好的特征提取能力。

[0079] 最后,借助于为进一步对比以上四种特征提取方法的效果,借助于鲸鱼算法优化核极限学习机参数的分类器对上述特征提取结果做分类,结果如下:

[0080] 表2不同方法诊断精度

方法	转子振动实验台状态识别率/%				平均识别率/%
	正常	碰磨	不平衡	不对中	
IMBSIE	100	100	100	100	100
MBSIE	100	100	96.2	94.3	97.5
IMAE	98	100	100	96.2	98.5
MAE	98	100	94.3	92.6	96.0

[0082] 由表2可以看到,在该分类器下,IMBSIE的诊断精度为100%,转子振动实验台四种状态均正确识别,而MBSIE的精度仅为97.5%,不对中和不平衡状态发生误判;IMAE的识别率为98.5%,MAE诊断率仅为96%。可见,IMBSIE的分类效果最好,高于其他三种方法,进一步证明IMFAE特征提取的有效性。

[0083] 本说明书中各个实施例采用递进的方式描述,每个实施例重点说明的都是与其他实施例的不同之处,各个实施例之间相同相似部分互相参见即可。对于实施例公开的装置而言,由于其与实施例公开的方法相对应,所以描述的比较简单,相关之处参见方法部分说明即可。

[0084] 对所公开的实施例的上述说明,使本领域专业技术人员能够实现或使用本发明。对这些实施例的多种修改对本领域的专业技术人员来说将是显而易见的,本文中所定义的一般原理可以在不脱离本发明的精神或范围的情况下,在其它实施例中实现。因此,本发明将不会被限制于本文所示的这些实施例,而是要符合与本文所公开的原理和新颖特点相一致的最宽的范围。




图1




图2




图3(a)




图3(b)




图3(c)




图3 (d)




图4




图5(a)




图5(b)




图6(a)




图6(b)




图6(c)




图6(d)




图7(a)




图7(b)




图7(c)




图7(d)




图8(a)




图8(b)




图8(c)




图8 (d)